SKRIPSI

Judul:

Prediksi dan Analisis Harga Minyak Goreng
di Pasar Tradisional Indonesia Menggunakan Algoritma
Gradient Boosting

Disusun oleh:

CARIN GUNAWAN
NIM. 535220056

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS TARUMANAGARA
2025

LEMBAR PERSETUJUAN MENGIKUTI SIDANG SKRIPSI

Persetujuan

Nama	:	CARIN GUNAWAN
NIM	:	535220056
Program Studi	:	TEKNIK INFORMATIKA
Judul	:	Prediksi dan Analisis Harga Minyak Goreng di Pasar Tradisional Indonesia Menggunakan Algoritma Gradient Boosting

Skripsi ini disetujui untuk diuji

Jakarta, 10-November-2025

Pembimbing:
TENY HANDHAYANI, S.Kom., M.Kom., Ph.D.
NIK/NIP: 10813002

Teny Handhayani
70ff6fd7-d83e-4e1f-aa79-4119beabc33a
FTI Untar
2025.11.11 09:28:27+07'00'

Pembimbing Pendamping:
IRVAN LEWENUSA, S.Kom., M.Kom.
NIK/NIP: 10823004

Lewenusa
Digitally signed by Irvan Lewenusa
Date: 2025-11-11 08:35+07:00

LEMBAR PERNYATAAN

Pernyataan

Nama	:	CARIN GUNAWAN
NIM	:	535220056
Program Studi	:	TEKNIK INFORMATIKA
Judul	:	Prediksi dan Analisis Harga Minyak Goreng di Pasar Tradisional Indonesia Menggunakan Algoritma Gradient Boosting

Dengan ini menyatakan bahwa skripsi ini merupakan hasil kerja saya sendiri di bawah bimbingan Tim Pembimbing dan bukan hasil plagiasi dan/atau kegiatan curang lainnya.

Jika saya melanggar pernyataan ini, maka saya bersedia dikenakan sanksi sesuai aturan yang berlaku di Universitas Tarumanagara.

Demikian pernyataan ini saya buat dengan sebenarnya, untuk dipergunakan sebagaimana mestinya.

Jakarta, 10-November-2025
Yang menyatakan

CARIN GUNAWAN
NIM. 535220056

ABSTRAK

Carin Gunawan, NIM: 535220056. Prediksi dan Analisis Harga Minyak Goreng di Pasar Tradisional di Indonesia. Skripsi, Jakarta: Program Studi Teknik Informatika, Fakultas Teknologi Informasi, Universitas Tarumanagara, Agustus 2025.

Perancangan ini bertujuan untuk memprediksi harga minyak goreng di 100 Kabupaten/Kota di Indonesia dengan menggunakan metode algoritma *Gradient Boosting* menggunakan data PIHPS periode 1 Januari 2020 hingga 1 Juli 2025. Data diproses melalui tahap *preprocessing* deret waktu, termasuk penanganan *missing value* dan rekayasa fitur berupa *lag* serta *rolling*. Model dilatih menggunakan *Time Series Cross-Validation* dan 12 kombinasi parameter untuk memperoleh konfigurasi terbaik pada setiap kota. Hasil evaluasi menunjukkan bahwa *Gradient Boosting* mampu memberikan performa prediktif yang baik, dengan 91 dari 100 kabupaten/kota mencapai nilai $R^2 \geq 0,5$ dan rata-rata R^2 keseluruhan sebesar 0,78. Sepuluh kota dengan performa terbaik memperoleh R^2 sekitar 0,94 dan lebih, menandakan model dapat mengikuti pola pergerakan harga dengan sangat baik. Namun, beberapa kota dengan data tidak stabil atau memiliki rentang kosong yang panjang menunjukkan performa rendah, termasuk beberapa yang menghasilkan R^2 negatif. Secara umum, model menunjukkan kemampuan yang baik dalam prediksi namun kurang responsif terhadap lonjakan harga ekstrem atau volatilitas tinggi dan deret waktu dengan noise tinggi. Implementasi *Gradient Boosting* dalam penelitian ini terbukti efektif sebagai metode prediksi harga minyak goreng dan mampu mengungkap disparitas performa antardaerah berdasarkan kualitas data serta karakteristik pola historis masing-masing kota.

Kata Kunci : *Gradient Boosting*, Prediksi, Komoditas Minyak Goreng, Harga Pangan, *Coefficient of determinant* (R2)

KATA PENGANTAR

Segala puji dan syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas segalanya karunia yang telah diberikan sehingga mampu menyelesaikan Skripsi yang berjudul "Prediksi dan Analisis Harga Minyak Goreng di Pasar Tradisional Indonesia Menggunakan Algoritma *Gradient Boosting*". Tujuan dari dibuatnya penulisan Skripsi untuk memenuhi persyaratan yang wajib ditempuh di Program Studi Teknik Informatika, Universitas Tarumanagara Jakarta untuk mendapatkan gelar sarjana Teknik Informatika.

Dalam Penulisan Proposal skripsi ini, penulis mendapatkan banyak bantuan berupa wawasan pengetahuan, informasi maupun dukungan dari berbagai pihak. Oleh karena itu, penulis ingin mengucapkan terima kasih yang sebesar-besarnya kepada:

1. Ibu Teny Handhyani S.Kom., M.Kom., Ph.D. dan Pak Irvan Lewanusa S.Kom., M.Kom selaku dosen pembimbing skripsi Fakultas Teknologi Informasi Universitas Tarumanagara yang telah banyak membantu memberikan bimbingan dan pengarahan kepada penulis selama pembuatan proposal skripsi.
2. Ibu Ir. Jeanny Pragantha, M.Eng. selaku koordinator skripsi Fakultas Teknologi Informasi Universitas Tarumanagara yang telah membantu penulis dan memberikan masukan terkait format penulisan skripsi.

3. Ibu Viny Christanti Mawardi S.Kom., M.Kom. dan pak Manatap Dolok Lauro S.Kom., M.M.S.I. selaku ketua dan sekretaris program studi Teknik Informatika Universitas Tarumanagara.
4. Seluruh dosen Fakultas Teknologi Informasi Universitas Tarumanagara yang telah memberikan ilmu pengetahuan selama proses perkuliahan penulis
5. Keluarga yang telah memberikan dukungan, doa dan motivasi kepada penulis.
6. Teman-teman terdekat yang selalu memberikan semangat, doa dan dukungan bagi penulis.

Penulis menyadari bahwa dalam penulisan Skripsi ini masih terdapat kekurangan baik dari segi kemampuan penulis, materi laporan maupun teknik penyajiannya. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang konstruktif guna memperbaiki laporan ini agar menjadi lebih baik. Akhir kata, penulis berharap semoga laporan ini dapat bermanfaat bagi orang lain.

Jakarta, 2 September 2025

Carin Gunawan

DAFTAR ISI

HALAMAN JUDUL i
LEMBAR PERSETUJUAN MENGIKUTI SIDANG SKRIPSI ii
LEMBAR PERNYATAAN ii
ABSTRAK iv
KATA PENGANTAR v
DAFTAR ISI vii
DAFTAR TABEL x
DAFTAR GAMBAR xv
DAFTAR LAMPIRAN xxii
BAB I PENDAHULUAN 1
1.1. Latar Belakang 1
1.2. Rumusan Rancangan 5
1.3. Komponen Rancangan 5
1.4. Spesifikasi Rancangan 6
1.5. Kegunaan Perancangan 7
1.6. Rancangan yang Sudah Dibuat 8
BAB II DESKRIPSI KONSEP 12
2.1. Sistem yang Dirancang 12
2.2. Kajian Pustaka 15
2.2.1. Minyak Goreng 15
2.2.2. *Time Series* 16
2.2.3. Prediksi 16
2.2.4. *Machine learning* 17
2.2.5. *Forward fill* dan *Backward fill* 18
2.2.6. *Gradient Boosting* 18
2.2.7. *Hyperparameter* 22
2.2.8. *Mean Absolute Error* (MAE) 24

2.2.9. *Mean Squared Error (MSE)* 25
2.2.10. *Ro ot Mean Squared Error* (RMSE) 26
2.2.11. *Coefficient of Determination* 26
2.2.12. *Python* 27
2.2.13. *Flask* 28
2.2.14. *Usecase Diagram* 29
2.3.15. *Time series crossvalidation* 29
2.3.16. *Feature Engineering* 29
2.3.17. *GridSearchCV* 30
2.3.18. *System Development Life Cycle* (SDLC) 30
2.3.19. *Blackbox Testing* 31
2.3.20. *User Acceptance Testing* (UAT) 32
BAB III RANCANGAN PEMBUATAN 35
3.1. Rancangan Sistem 35
3.1.1. Perencanaan Sistem 36
3.1.2. Analisis Kebutuhan Sistem 37
3.1.3. Desain Rancangan Sistem 38
BAB IV PENGUJIAN 51
4.1. Cara Pengujian 51
4.2. Hasil Pengujian 52
4.2.1. Hasil Pengujian Pelatihan Model 52
4.2.2. Pengujian *Black Box Testing* (Internal) 76
4.2.3. Pengujian *User Acceptance System* oleh Masyarakat Umum 90
BAB V KESIMPULAN DAN SARAN 51
5.1. Kesimpulan 94
5.2. Saran 952

DAFTAR PUSTAKA 96

LAMPIRAN 101
DAFTAR RIWAYAT HIDUP 252

DAFTAR TABEL

Tabel 4.1 Daftar 10 Kota dengan $(R2)$ tertinggi 53

Tabel 4.2 Daftar 15 Kota dengan $(R2)$ terendah 61

Tabel 4.3 Analisa Performa Model Terhadap MAPE .....

Tabel 4.4 Daftar Uji coba eksperimen Kabupaten Klaten 70

Tabel 4.5 Daftar Uji coba eksperimen Kota Kendari 72

Tabel 4.6 Daftar Uji Coba Eksperimen Kota Maluku 73

Tabel 4.7 Daftar Uji Coba Eksperimen Kota Palangkaraya 75

Tabel 4.8 Pembagian Tertil Predicted Harga Minyak Goreng di Indonesia pada Tahun 2025 84

Tabel 4.9 Pembagian Tertil actual di Tahun 2025 86

Tabel L1.1 Harga minyak Kota Banjarmasin 101

Tabel L1.2 Data *Split* (Input - Output) 101

Tabel L1.3 Perhitungan Residual R1 104

Tabel L1.4 Perhitungan F1(x) 104

Tabel L1.5 Perbandingan actual price vs predicted price 105

Tabel L1.6 Evaluasi iterasi 1 107

Tabel L1.7 Residual R2 108

Tabel L1.8 Perhitungan F2(x) 108

Tabel L2.1 Penelitian Terdahulu 110

Tabel L3.1 Simbol *Use Case* Diagram 112

Tabel L4.1 *Usecase Scenario* 114

Tabel L8.1 Rangkaian Waktu Pngerjaan Sistem 128

Tabel L9.1 Parameter Input Eksperimen 129

Tabel L9.2 List *Hyperparameter* yang digunakan 129

Tabel L10.1 Daftar Seluruh Kabupaten/Kota dengan evaluasi model terbaik.. 130

Tabel L11.1 Kota Banyumas 133

Tabel L11.2 Kabupaten Banyuwangi 133
Tabel L11.3 Kabupaten Boyolali 133
Tabel L11.4 Kabupaten Bulukomba 134
Tabel L11.5 Kabupaten Bulungan 134
Tabel L11.6 Kabupaten Bungo 135
Tabel L11.7 Kabupaten Cilacap 135
Tabel L11.8 Kabupaten Cirebon 135
Tabel L11.9 Kabupaten Gorontolo 136
Tabel L11.10 Kabupaten Jayawijaya 136
Tabel L11.11 Kabupaten Jember 136
Tabel L11.12 Kabupaten Karangayar 137
Tabel L11.13 Kabupaten Kudus 137
Tabel L11.14 Kabupaten Lombok Timur 138
Tabel L11.15 Kabupaten Majene 138
Tabel L11.16 Kabupaten Manokwari 138
Tabel L11.17 Kabupaten Merauke 139
Tabel L11.18 Kabupaten Mimika 139
Tabel L11.19 Kabupaten Nabire 139
Tabel L11.20 Kabupaten Polewali Mandar 140
Tabel L11.21 Kabupaten Sintang 140
Tabel L11.22 Kabupaten Sukoharjo 141
Tabel L11.23 Kabupaten Sumba Timur 141
Tabel L11.24 Kabupaten Sumbawa 141
Tabel L11.25 Kabupaten Sumenep 142
Tabel L11.26 Kabupaten Wonogiri 142
Tabel L11.27 Kabupaten Klaten 142
Tabel L11.28 Kabupaten Sragen 143
Tabel L11.29 Kota Balikpapan 143
Tabel L11.30 Kota Banda Aceh 144

Tabel L11.31 Kota Bandar Lampung 144
Tabel L11.32 Kota Banggai 144
Tabel L11.33 Kota Banjarmasin 145
Tabel L11.34 Kabupaten Sukoharjo 145
Tabel L11.35 Kabupaten Sumba Timur 145
Tabel L11.36 Kabupaten Sumbawa 146
Tabel L11.37 Kota Bandung 146
Tabel L11.38 Kota Batam 147
Tabel L11.39 Kota Bau – Bau 147
Tabel L11.40 Kota Bekasi 147
Tabel L11.41 Kota Bengkulu 148
Tabel L11.42 Kota Bima 148
Tabel L11.43 Kota Blitar 148
Tabel L11.44 Kota Bogor 149
Tabel L11.45 Kota Bontang 149
Tabel L11.46 Kota Cilegon 150
Tabel L11.47 Kota Cirebon 150
Tabel L11.48 Kota Denpasar 150
Tabel L11.49 Kota Depok 151
Tabel L11.50 Kota Dumai 151
Tabel L11.51 Kota Gorontolo 151
Tabel L11.52 Kota Gunung Sitoli 152
Tabel L11.53 Kota Jakarta Pusat 152
Tabel L11.54 Kota Jambi 153
Tabel L11.55 Kota Jayapura 153
Tabel L11.56 Kota Kediri 153
Tabel L11.57 Kota Kendari 154
Tabel L11.58 Kota Kupang 154
Tabel L11.59 Kota Lhokseumawe 154

Tabel L11.60 Kota Madiun 155
Tabel L11.61 Kota Makassar 155
Tabel L11.62 Kota Malang 156
Tabel L11.63 Kota Maluku 156
Tabel L11.64 Kota Mamuju 156
Tabel L11.65 Kota Manado 157
Tabel L11.66 Kota Mataram 157
Tabel L11.67 Kota Maumere 157
Tabel L11.68 Kota Medan 158
Tabel L11.69 Kota Metro 158
Tabel L11.70 Kota Meulaboh 159
Tabel L11.71 Kota Padang 159
Tabel L11.72 Kota Padang Sidempuan 159
Tabel L11.73 Kota Palangkaraya 160
Tabel L11.74 Kota Palembang 160
Tabel L11.75 Kota Palu 160
Tabel L11.76 Kota Pangkalpinang 161
Tabel L11.77 Kota Pare – Pare 161
Tabel L11.78 Kota Pekanbaru 162
Tabel L11.79 Kota Pematang Siantar 162
Tabel L11.80 Kota Pontianak 162
Tabel L11.81 Kota Probolinggo 163
Tabel L11.82 Kota Semarang 163
Tabel L11.83 Kota Sampit 163
Tabel L11.84 Kota Serang 164
Tabel L11.85 Kota Sibolga 164
Tabel L11.86 Kota Singkawang 165
Tabel L11.87 Kota Sorong 165
Tabel L11.88 Kota Sukabumi 165

Tabel L11.89 Kota Sumenep 166
Tabel L11.90 Kota Surabaya..... 166
Tabel L11.91 Kota Surakarta (Solo)..... 166
Tabel L11.92 Kota Tanggerang..... 167
Tabel L11.93 Kota Tanjung..... 167
Tabel L11.94 Kota Tanjung Pandan 168
Tabel L11.95 Kota Tanjung Pinang..... 168
Tabel L11.96 Kota Tarakan..... 168
Tabel L11.97 Kotak Tasikmalaya 169
Tabel L11.98 Kota Tembilahan 169
Tabel L11.99 Kota Ternate 169
Tabel L11.100 Kota Tual..... 170
Tabel L11.101 Kota Watampone 170
Tabel L11.102 Kota Yogyakarta 171
Tabel L11.103 Kotamobagu 171
Tabel L13.1 *Black Box Testing* (Internal)..... 207

DAFTAR GAMBAR

Gambar 2.1 Diagram Alur Rancangan yang dibuat 14
Gambar 2.2 Alur Kerja *Gradient Boosting* 21
Gambar 3.1 Input dan Pembacaan Data 40
Gambar 3.2 Proses *insert missing values* 41
Gambar 3.3 Fungsi untuk membentuk fitur tambahan 42
Gambar 3.4 Fitur rolling dan lag 43
Gambar 3.5 *Splitting data* 43
Gambar 3.6 *Timeseries Cross Validation* 43
Gambar 3.7 *List Parameter* 44
Gambar 3.8 Pemanggilan *Library* 44
Gambar 3.9 Mencari model terbaik 45
Gambar 3.10 Isi File Joblib 45
Gambar 3.11 Penyimpanan Joblib 46
Gambar 3.12 Evaluasi Model 47
Gambar 4.1 Perbandingan Grafik Aktual – Prediksi Kota Bogor 55
Gambar 4.2 Perbandingan Grafik Aktual – Prediksi Kota Sumenep 55
Gambar 4.3 Perbandingan Grafik Aktual – Prediksi Kota Metro 56
Gambar 4.4 Perbandingan Grafik Aktual – Prediksi Kota Yogyakarta 57
Gambar 4.5 Perbandingan Grafik Aktual – Prediksi Kota Mobagu 57
Gambar 4.6 Perbandingan Grafik Aktual – Prediksi Kota Depok 58
Gambar 4.7 Perbandingan Grafik Aktual – Prediksi Kota Surabaya 59
Gambar 4.8 Perbandingan Grafik Aktual – Prediksi Kota Bekasi 59
Gambar 4.9 Perbandingan Grafik Aktual – Prediksi Kota Pontianak 60
Gambar 4.10 Perbandingan Grafik Aktual – Prediksi Kota Jakarta Pusat 61
Gambar 4.11 Perbandingan Grafik Aktual – Prediksi Kota Bangggai ..... **Error! Bookmark not defined.**
Gambar 4.12 Perbandingan Grafik Aktual – Prediksi Kota Gorotolo

Gambar 4.13 Perbandingan Grafik Aktual – Prediksi Kota Jayawijaya 63
Gambar 4.14 Perbandingan Grafik Aktual – Prediksi Kota Bandar Lampung.... 63
Gambar 4.15 Perbandingan Grafik Aktual – Prediksi Kota Nabire 64
Gambar 4.16 Perbandingan Grafik Aktual – Prediksi Kota Polewali Mandar.....
Gambar 4.17 Perbandingan Grafik Aktual – Prediksi Kota Balikpapan 65
Gambar 4.18 Perbandingan Grafik Aktual – Prediksi Kota Banda Aceh 66
Gambar 4.19 Perbandingan Grafik Aktual – Prediksi Kota Padang Sidempuan 67
Gambar 4.20 Perbandingan Grafik Aktual – Prediksi Kabupaten Manokwari... 67
Gambar 4.21 Daftar Ekperimen Kabupaten Klaten 71
Gambar 4.22 Daftar Ekperimen Kota Kendari 72
Gambar 4.23 Daftar Ekperimen Kota Maluku..... 74
Gambar 4.24 Daftar Ekperimen Kota Palangkaraya 76
Gambar 4.25 Harga *Actual* semua pulau di tahun 2025.....
Gambar 4.26 Harga *predicted* semua pulau di tahun 2025.....
Gambar 4.27 Perbedaan Harga Per Pulau .....
Gambar 4.28 Harga Actual semua pulau di tahun 2025 (nasional avg) 81
Gambar 4.29 Harga *predicted* semua pulau di tahun 2025 (nasional avg) 81
Gambar 4.30 Perbedaan Harga Nasional..... 82
Gambar L4.1 *Use Case* Diagram *website* yang akan dibuat..... 113
Gambar L5.1 Melihat Prediksi Cepat 118
Gambar L5.2 Peta Harga 119
Gambar L5.3 Tren Harga 120
Gambar L5.4 Prediksi 121
Gambar L5.5 *Upload* Data..... 122
Gambar L5.6 Halaman Tentang 123
Gambar L6.1 Diagram Data Pipeline..... 124
Gambar L7.1 Tampilan Halaman *Homepage* (beranda)..... 125
Gambar L7.2 Tampilan *Homepage* Pilih Dropdown Daerah 125
Gambar L7.3 Tampilan Halaman Tinjauan Tren 126

Gambar L7.4 Tampilan halaman prediksi untuk memilih waktu..... 126
Gambar L7.5 Tampilan halaman evaluasi..... 127
Gambar L7.6 Tampilan halaman Tentang..... 127
Gambar L8.1 Tampilan Halaman *Homepage* (beranda)..... 125
Gambar L8.2 Tampilan *Homepage* Pilih Dropdown Daerah 125
Gambar L8.3 Tampilan Halaman Tinjauan Tren 126
Gambar L8.4 Tampilan halaman prediksi untuk memilih waktu..... 126
Gambar L8.5 Tampilan halaman evaluasi..... 127
Gambar L12.1 Kabupaten Banyumas 172
Gambar L12.2 Kabupaten Banyuwangi 172
Gambar L12.3 Kabupaten Boyolali 173
Gambar L12.4 Kabupaten Bulukomba..... 173
Gambar L12.5 Kabupaten Bulungan..... 173
Gambar L12.6 Kabupaten Bungo..... 174
Gambar L12.7 Kabupaten Cilacap..... 174
Gambar L12.8 Kabupaten Cirebon 174
Gambar L12.9 Kabupaten Gorontolo 175
Gambar L12.10 Kabupaten Jayawijaya..... 175
Gambar L12.11 Kabupaten Jember 175
Gambar L12.12 Kabupaten Karangayar..... 176
Gambar L12.13 Kabupaten Kudus 176
Gambar L12.14 Kabupaten Lombok Timur..... 176
Gambar L12.15 Kabupaten Majene..... 177
Gambar L12.16 Kabupaten Manokwari..... 177
Gambar L12.17 Kabupaten Merauke..... 177
Gambar L12.18 Kabupaten Mimika..... 178
Gambar L12.19 Kabupaten Nabire 178
Gambar L12.20 Kabupaten Polewali Mandar..... 178
Gambar L12.21 Kabupaten Sintang..... 179

Gambar L12.22 Kabupaten Sukoharjo 179
Gambar L12.23 Kabupaten Sumba Timur 179
Gambar L12.24 Kabupaten Sumbawa 180
Gambar L12.25 Kabupaten Sumenep 180
Gambar L12.26 Kabupaten Wonogiri 180
Gambar L12.27 Kabupaten Klaten 181
Gambar L12.28 Kabupaten Kotabaru 181
Gambar L12.29 Kabupaten Sragen 181
Gambar L12.30 Kota Balikpapan 182
Gambar L12.31 Kota Banda Aceh 182
Gambar L12.32 Kota Bandar Lampung 182
Gambar L12.33 Kota Bandung 183
Gambar L12.34 Kota Banggai 183
Gambar L12.35 Kota Banjarmasin 183
Gambar L12.36 Kota Batam 184
Gambar L12.37 Kota Bau – Bau 184
Gambar L12.38 Kota Bekasi 184
Gambar L12.39 Kota Bengkulu 185
Gambar L12.40 Kota Bima 185
Gambar L12.41 Kota Blitar 185
Gambar L12.42 Kota Bogor 186
Gambar L12.43 Kota Bontang 186
Gambar L12.44 Kota Cilegon 186
Gambar L12.45 Kota Cirebon 187
Gambar L12.46 Kota Denpasar 187
Gambar L12.47 Kota Depok 187
Gambar L12.48 Kota Dumai 188
Gambar L12.49 Kota Gorontolo 188
Gambar L12.50 Kota Gunung Sitoli 188

Gambar L12.51 Kota Jakarta Pusat 189
Gambar L12.52 Kota Jambi 189
Gambar L12.53 Kota Jayapura 189
Gambar L12.54 Kota Kediri 190
Gambar L12.55 Kota Kendari 190
Gambar L12.56 Kota Kupang 190
Gambar L12.57 Kota Lhokseumawe 191
Gambar L12.58 Kota Madiun 191
Gambar L12.59 Kota Makassar 191
Gambar L12.60 Kota Malang 192
Gambar L12.61 Kota Maluku 192
Gambar L12.62 Kota Mamuju 192
Gambar L12.63 Kota Manado 193
Gambar L12.64 Kota Mataram 193
Gambar L12.65 Kota Maumere 193
Gambar L12.66 Kota Medan 194
Gambar L12.67 Kota Metro 194
Gambar L12.68 Kota Meulaboh 194
Gambar L12.69 Kota Padang 195
Gambar L12.70 Kota Padang Sidempuan 195
Gambar L12.71 Kota Palangkaraya 195
Gambar L12.72 Kota Palembang 196
Gambar L12.73 Kota Palu 196
Gambar L12.74 Kota Pangkalpinang 196
Gambar L12.75 Kota Pare – Pare 197
Gambar L12.76 Kota Pekanbaru 197
Gambar L12.77 Kota Pematang Siantar 197
Gambar L12.78 Kota Pontianak 198
Gambar L12.79 Kota Probolinggo 198

Gambar L12.80 Kota Samarinda 198
Gambar L12.81 Kota Sampit 199
Gambar L12.82 Kota Semarang 199
Gambar L12.83 Kota Serang 199
Gambar L12.84 Kota Sibolga 200
Gambar L12.85 Kota Singkawang 200
Gambar L12.86 Kota Sorong 200
Gambar L12.87 Kota Sukabumi 201
Gambar L12.88 Kota Sumenep 201
Gambar L12.89 Kota Surabaya 201
Gambar L12.90 Kota Surakarta (Solo) 202
Gambar L12.91 Kota Tanggerang 202
Gambar L12.92 Kota Tanjung 202
Gambar L12.93 Kota Tanjung Pandan 203
Gambar L12.94 Kota Tanjung Pinang 203
Gambar L12.95 Kota Tarakan 203
Gambar L12.96 Kotak Tasikmalaya 204
Gambar L12.97 Kota Tembilahan 204
Gambar L12.98 Kota Ternate 204
Gambar L12.99 Kota Tual 205
Gambar L12.100 Kota Watampone 205
Gambar L12.101 Kota Yogyakarta 205
Gambar L12.102 Kotamobagu 206
Gambar L14.1 *Form Uat Sign-Off* 211
Gambar L14.2 *Form Uat Sign-Off* 216
Gambar L14.3 *Form Uat Sign-Off* 220
Gambar L14.4 *Form Uat Sign-Off* 224
Gambar L14.5 *Form Uat Sign-Off* 228
Gambar L14.6 *Form Uat Sign-Off* 232

Gambar L14.7 *Form Uat Sign-Off* 236
Gambar L14.8 *Form Uat Sign-Off* 240
Gambar L14.9 *Form Uat Sign-Off* 244

DAFTAR LAMPIRAN

Lampiran 1 Perhitungan Model 101

Lampiran 2 Perbandingan Penelitian 110

Lampiran 3 Simbol Use Case Diagram 112

Lampiran 4 Usecase Diagram Dan Tabel Usecase Scenario 113

Lampiran 5 Activity Diagram 118

Lampiran 6 Data Pipeline Diagram 124

Lampiran 7 Antarmuka Rancangan 125

Lampiran 8 Rangkaian Waktu Pengerjaan Sistem 128

Lampiran 9 Tabel Uji Eksperimen Training (Pelatihan Model) 129

Lampiran 10 Tabel Uji Eksperimen Training (Pelatihan Model) 130

Lampiran 11 Tabel Uji Eksperimen Hyperparameter 133

Lampiran 12 Grafik Perbandingan Harga Sebenarnya Dengan Harga Terprediksi 172

Lampiran 13 Tabel *Black Box Testing* (Internal) 207

Lampiran 14 Pengujian (Uat) Dengan Target Masyarakat Umum 211

Lampiran 15 Turnitin 211

Lampiran 16 Github 211

BAB I

PENDAHULUAN

1.1. Latar Belakang

Minyak goreng merupakan kebutuhan pokok yang digunakan oleh berbagai lapisan sosial dan masyarakat di seluruh dunia termasuk di Indonesia [1] serta memegang peranan penting [2] bagi perekonomian di Indonesia. Penggunaan minyak goreng tentunya juga meningkat [3] seiring dengan bertambahnya tahun dan juga populasi penduduk [4]. Pemerintah mengkategorikan minyak goreng sebagai salah satu kebutuhan pokok tertentu dalam pangan yang ketersediaan [5] dan harganya dikontrol oleh pemerintah agar terhindar dari fluktuasi sehingga kekuatan pasar dapat tersebar secara merata.

Permintaan dan ketersediaan minyak goreng terus meningkat dan mengalami lonjakan yang signifikan dalam satu tahun terakhir di tahun 2021 [6]. Kenaikan harga ini berpotensi memengaruhi kondisi perekonomian dan memicu terjadinya inflasi [4]. Inflasi sendiri merupakan kenaikan harga barang, termasuk minyak goreng, dalam periode waktu tertentu. Beberapa faktor yang mempengaruhi peningkatan harga pada minyak goreng adalah proses produksi, dan keterbatasan tenaga kerja. Minyak goreng adalah jenis *volatile food*. *Volatile food* adalah kelompok komoditas pangan yang harganya mudah bergejolak atau fluktuatif.

Permintaan yang tinggi juga menyebabkan fenomena ketimpangan harga minyak goreng antar daerah di Indonesia [7]. Harga minyak goreng tidak merata antara satu kabupaten/kota dan daerah – daerah terpencil cenderung mengalami harga yang jauh lebih tinggi dibanding wilayah perkotaan atau sentra produksi [6]. Misalnya, pada puncak krisis minyak goreng yang terjadi di tahun 2022, harga eceran pada Kabupaten Biak di Papua sempat mencapai Rp30.000 per liter dan jauh melampaui harga di Pulau Jawa. Salah satu faktor yang menyebabkan perbedaan harga minyak goreng di Indonesia adalah faktor struktural dan geografis lokal. Karakteristik ekonomi daerah turut memengaruhi harga minyak goreng setempat.

Studi menunjukkan bahwa pasar minyak goreng di Indonesia belum terintegrasi sempurna, sehingga perubahan harga di satu level (produsen/grosir) tidak selalu langsung tersalur merata ke semua daerah dan perubahan harga yang terjadi sangat berpengaruh dalam produsen minyak goreng untuk mengurangi atau meningkatkan produksi [8]. Akibatnya, volatilitas harga di tingkat eceran berbeda-beda tiap daerah; volatilitas cenderung lebih tinggi di wilayah dengan infrastruktur pasar lemah.

Penelitian ini berkaitan dengan SDG 10 yaitu berkaitan terhadap kesenjangan [9][10], terutama wilayah terpencil yang menghadapi harga jauh lebih mahal dan akses pangan yang terbatas. Perancangan ini akan menghitung disparitas atau perbedaan harga antara 100 kabupaten/kota. Hasil Prediksi, metode evaluasi, dan hasil analisis terhadap penelitian ini akan memberikan alat

ukur terkait akurasi harga minyak di masa yang akan datang.

Untuk itu, diperlukan langkah strategis berbasis data untuk memahami pola pergerakan harga minyak goreng yang cenderung fluktuatif [11]. Beberapa penelitian dan rancangan terdahulu telah mencoba memprediksi harga minyak goreng. Pangalila dkk. menggunakan model ARIMA(1,2,1) untuk data Sulawesi Utara dan memperoleh MSE sebesar 350.248 [12], sedangkan Aghnia dkk. membandingkan ARIMA dan ARIMAX untuk data nasional dan memperoleh MAPE 17,31% [13]. Studi lain oleh Nikken Halim dkk. menganalisis harga minyak goreng di Pasar Pagi Pangkalpinang (Bangka Belitung) menggunakan data sekunder PIHPS periode Januari 2018–Mei 2022. Setelah dilakukan pengecekan kestasioneran (visualisasi, uji ADF, differencing hingga first difference), mereka menerapkan tiga varian Exponential Smoothing (Simple, Holt, dan Brown) dan memilih model terbaik berdasarkan RMSE dan MaxAE. Model Holt dipilih karena memberikan RMSE sebesar 1,18736 dan MaxAE 5.192,28, dengan proyeksi yang menunjukkan tren kenaikan harga hingga Desember 2024[3].

Meskipun penelitian-penelitian tersebut memberikan kontribusi penting, ada beberapa kelemahan yang perlu dicatat. Pertama, model ARIMA dan Exponential Smoothing memiliki asumsi linearitas sehingga kurang mampu menangkap pola non-linear dan interaksi kompleks antar variabel, terutama saat terjadi fluktuasi harga yang tajam (seperti pada puncak krisis 2022). Kedua, model-model tersebut umumnya tidak dirancang untuk menangani multi-entitas secara paralel (misalnya 103 kabupaten/kota), sehingga jika ingin menganalisis seluruh

Indonesia diperlukan pemodelan terpisah per kota yang memakan waktu. Ketiga, sebagian besar penelitian tidak memanfaatkan feature engineering seperti lag harian/mingguan, rolling mean, dan variabel musiman (bulan, hari libur, musim panen) yang dapat membantu model menangkap tren jangka pendek maupun pola musiman yang berulang. Keempat, pipeline komputasi pada penelitian tersebut tidak terintegrasi dan jarang disertai dokumentasi teknis yang memungkinkan proses direplikasi (*reproducibility*), sehingga sulit jika hasilnya ingin diintegrasikan ke dalam sistem analitik berbasis web.

Perancangan ini hadir dengan menutupi batasan – batasan yang ada pada rancangan – rancangan sebelumnya, yaitu suatu rancangan yang dikembangkan dengan memanfaatkan metode *machine learning* seperti *Gradient Boosting* [14]. *Gradient Boosting Classifier* adalah kumpulan algoritma *machine learning* yang menggabungkan banyak model yang lemah (*weak learner*) [15] untuk menghasilkan model prediksi yang kuat serta mampu memberikan gambaran tren sekaligus mengidentifikasi faktor-faktor yang memengaruhinya yang bekerja secara bertahap untuk memperbaiki kesalahan (*errors*) dan efektif menangani data non-linear. Perancangan ini juga dilengkapi pipeline terintegrasi mulai dari *preprocessing data* (*handling missing values, reindexing* akhir pekan), *feature engineering* (*lag, rolling mean, flag musiman*), *time-series cross-validation* untuk pemilihan hyperparameter yang optimal, hingga penyimpanan dan visualisasi hasil dalam bentuk grafik interaktif. Dengan desain ini, sistem dapat digunakan secara konsisten untuk seluruh kabupaten/kota, dapat direplikasi pada dataset baru, dan

siap diintegrasikan dengan antarmuka pengguna berbasis web sehingga mendukung pemantauan harga dan pengambilan keputusan secara data-driven.

1.2. Rumusan Rancangan

Berdasarkan latar belakang diatas, maka dapat diidentifikasi rumusan rancangan yang ada pada sistem ini berikut.

1. Bagaimana membangun model prediksi yang dapat digunakan untuk meramalkan harga minyak goreng di berbagai wilayah Indonesia menggunakan metode *machine learning* (misalnya *Gradient Boosting*)?
2. Bagaimana pola harga minyak goreng di pasar tradisional Indonesia berdasarkan data historis, termasuk perbedaan harga antara Kabupaten/Kota?
3. Bagaimana sebaran ketimpangan dan lonjakan harga minyak goreng antar wilayah dapat diukur dan diinterpretasikan dalam analisis data?

1.3. Komponen Rancangan

Untuk menjaga proyek ini tetap fokus dan dapat dilaksanakan, sistem yang dirancang oleh memiliki batas – batas berikut:

1. Perancangan ini hanya akan menggunakan data dari Pusat Informasi Harga Pangan Strategis Nasional (PIHPS) yang bersumber dari https://www.bi.go.id/hargapangan dan meliputi jenis komoditas yaitu minyak goreng, dan fokus pada 100 Kabupaten/Kota di Pasar Tradisional Indonesia pada rentang waktu 1 Januari 2020 hingga 1 Juli 2025.

2. Perancangan ini akan berfokus pada analisis dan prediksi harga minyak goreng berdasarkan data yang dikumpulkan (variabel waktu dan harga minyak per Kabupaten/Kota dengan memanfaatkan metode *machine learning* yaitu implementasi algoritma *Gradient Boosting*.
3. Hasil keluaran (*output*) dari sistem rancangan ini berupa grafik perbandingan harga sebenarnya dengan harga prediksi, analisis tren, peta perbandingan harga rata – rata minyak, dan evaluasi dari metode *gradient boosting*.

1.4. Spesifikasi Rancangan

Dari komponen rancangan yang dibuat diberikan pula spesifikasi terkait modul – modul komponen untuk memperjelas rancangan sebagai berikut

1. Modul *Home* (Beranda)

   Modul *home* (beranda) adalah halaman pertama yang muncul saat aplikasi diakses, dan berperan sebagai sarana navigasi untuk menuju ke fitur – fitur lain. Modul ini memiliki 2 fitur yaitu *quick prediction* untuk prediksi dengan memilih kota yang ingin diprediksi dan fitur kedua memungkinkan pengguna untuk melakukan *input* dengan memilih pulau, mode, jenis rata - rata dan tahun kemudian akan menampilkan bentuk visualisasi spasial pada peta distribusi harga minyak pada pulau – pulau tersebut.
2. Modul Tinjauan Trend

   Modul tinjauan *trend* adalah halaman yang berfokus pada analisis pergerakan minyak goreng dalam dimensi waktu dengan memungkinkan pengguna untuk

memilih Kabupaten/Kota, tahun, bulan (opsional), minggu (opsional) dan menampilkan grafik tren harga minyak goreng yang menggambarkan naik turunnya harga minyak pada daerah tersebut.

3. Modul Prediksi

   Modul prediksi adalah halaman yang memungkinkan pengguna untuk membandingkan pergerakan harga di masa depan sekaligus membandingkannya dengan harga historis. Pengguna dapat menentukan Kabupaten/Kota, tanggal mulai hingga akhir dengan tampilan kalender kemudian akan menampilkan hasil prediksi dengan tampilan grafik perbandingan harga sebenarnya dengan harga terprediksi, dan hasil evaluasi dari data uji.

4. Modul Upload

   Modul *upload* dirancang agar pengguna dapat mengunggah *file* pada format *excel* yang telah diberikan, dan sistem akan melakukan pembuatan model untuk memberikan *output* hasil prediksi dari data *actual* terakhir.

5. Modul Tentang

   Modul tentang dirancang agar pengguna dapat melihat terkait informasi dari aplikasi yang dibuat, metode yang digunakan serta langkah – langkah umum penggunaan setiap fitur.

1.5. Tujuan dan Kegunaan Perancangan

Perancangan ini diharapkan dapat menjadi alat bantu prediksi harga

minyak goreng yang dapat diakses dan dimanfaatkan secara praktis oleh berbagai pihak, khususnya masyarakat umum seperti konsumen, pedagang, ibu rumah tangga, pembuat kebijakan. Adapun tujuan yang ingin dicapai dalam perancangan ini adalah:

1. Menghasilkan model prediksi untuk 100 Kabupaten/Kota yang dianalisis dengan menggunakan metode *gradient boosting*.
2. Menyajikan analisis terhadap model prediksi baik analisa performa model dan analisa spasial, dan perbandingan harga minyak goreng antar kota di Indonesia.
3. Menghasilkan evaluasi untuk menentukan kinerja model dalam memprediksi harga minyak goreng di 100 Kabupaten/Kota di Indonesia menggunakan metriks evaluasi yang sesuai.

1.6. Rancangan yang Sudah Dibuat

Ada beberapa penelitian dan sistem rancangan relevan yang telah dikembangkan terkait prediksi dan analisis harga minyak, yang menjadi landasan dan pembanding bagi perancangan sistem ini.

1. Penelitian berjudul **"***Forecasting Volatile Fresh Chili Prices in Indonesia Using Support Vector Regression*" yang dilakukan oleh Marchel Yusuf Rumlawang Arpipi,Teny Handhayani, Irvan Lewenusa. Studi ini mengembangkan model prediksi harga cabai merah segar dan cabai rawit di 87 kota di Indonesia dengan menggunakan metode *Support Vector Regression* (SVR). Data harga

yang digunakan merupakan data time series harian selama periode 1 Januari 2018 hingga 31 Desember 2023. Model SVR Linear menunjukkan performa terbaik dengan nilai rata-rata koefisien determinasi (R^2) sebesar 0.94, yang mengindikasikan akurasi prediksi yang tinggi pada komoditas dengan volatilitas harga yang signifikan [13].

2. Penelitian oleh oleh Clara Tanudy, Teny Handhayani, dan Janson Hendryli dengan judul "Prediksi Harga Emas di Indonesia Menggunakan Gated Recurrent Unit (GRU)" memfokuskan pada peramalan harga emas di Indonesia. Studi ini memanfaatkan data historis harga penutupan emas, harga saham PT Aneka Tambang, dan nilai tukar dolar Amerika Serikat sebagai variabel input. Metode deep learning GRU digunakan untuk membangun model prediksi yang mampu menangkap pola non-linear pada data time series. Hasil penelitian menunjukkan bahwa model GRU mampu memberikan prediksi yang sangat akurat dengan nilai R-Squared sebesar 0.97, nilai MAE sebesar 300.17, dan RMSE sebesar 17.33, membuktikan keunggulan metode ini dalam pemodelan harga komoditas [14].
3. Studi Nikken Halim dkk. menganalisis harga minyak goreng di Pasar Pagi Pangkalpinang (Bangka Belitung) berdasarkan data sekunder PIHPS periode Jan 2018–Mei 2022. Setelah mengecek kestasioneran (melalui visualisasi, ADF, dan *differencing*, data menjadi stasioner pada *first difference*), penelitian menerapkan tiga varian *Exponential Smoothing* (*Simple, Holt, Brown*), memilih model terbaik berdasarkan RMSE dan MaxAE. Model Holt dipilih

karena memberikan RMSE 1,18736 dan MaxAE 5.192,28; proyeksi menunjukkan kecenderungan kenaikan hingga Desember 2024, sejalan dengan observasi kenaikan tajam Feb–Apr 2022 [2].

4. Pangalila dkk. memodelkan harga minyak goreng bulanan di Provinsi Sulawesi Utara (sekitar 2018–2022) dengan ARIMA. Identifikasi awal berbasis ACF/PACF setelah *second differencing* menghasilkan kandidat ARIMA(1,2,1), (1,2,0), dan (0,2,1). Model terpilih ARIMA(1,2,1) karena MSE paling kecil (350.248) dan parameter signifikan; uji *Ljung-Box* menunjukkan residual *white noise*, sehingga model laik guna peramalan. Tabel peramalan 18 periode (Jan 2023–Jun 2024) memperlihatkan tren peningkatan bertahap [12].
5. Penelitian yang dilakukan oleh Mochammad Agus dkk. Yaitu dengan judul *Perbandingan Model LSTM dan GRU untuk Memprediksi Harga Minyak Goreng di Indonesia* menggunakan data harga minyak goreng PIHPS selama ±tiga tahun terakhir[16]. Eksperimen menampilkan *hyperparameter tuning* (contoh: LSTM terbaik dengan 128 unit, *dropout* 0,2) dengan *mean Mean* 0.000071, dan MAE *validation* bernilai ±0.04 dan MSE *validation loss* bernilai ±0.002.
6. Penelitian yang dilakukan oleh Carin Gunawan dan Teny Handayani membahas fluktuasi harga minyak goreng di Provinsi Papua. Data yang digunakan berupa deret waktu harian harga minyak goreng curah, minyak goreng kemasan bermerk 1, minyak goreng kemasan bermerk 2, serta harga bahan baku crude palm oil (CPO), yang diperoleh dari Pusat Informasi Harga

Pangan Strategis (PIHPS) untuk periode 3 Januari 2022 hingga 1 Januari 2024. Dua model *deep learning, Long Short-Term Memory* (LSTM**)** dan *Gated Recurrent Unit* (GRU), digunakan untuk membandingkan kemampuan prediksi. Hasil evaluasi dengan metrik MAE, MSE, RMSE, MAPE, dan R^2 menunjukkan bahwa model GRU lebih unggul dibandingkan LSTM, dengan nilai kesalahan prediksi lebih rendah dan R^2 yang lebih tinggi, misalnya pada skenario 80:20 GRU menghasilkan MSE 229.454,2 dan MAE 226,89, lebih baik daripada LSTM dengan MSE 339.310,6 dan MAE 270,69.[17]

Pada rancangan yang dibuat fokus pada harga minyak goreng dengan cakupan ±100 Kabupaten/Kota di Indonesia dengan rentang waktu 1 Jan 2020 – 1 Juli 2025 sehingga mampu mengkaji disparitas spasial – temporal yang lebih luas (berbeda dari studi satu provinsi/kota atau komoditas lain). Pendekatan *Gradient Boosting* digunakan sebagai bentuk penelitian baru yang dapat memberikan keseimbangan akurasi pada data tabular dan interpretabilitas serta visualisasi guna memetakan ketimpangan harga dan titik lonjakan yang terjadi pada hari – hari tertentu akan diimplementasikan dalam penelitian ini. Pengaitan eksplisit terhadap SGDs (kemiskinan dan ketahanan pangan) untuk mengidentifikasi wilayah prioritas dan periode rawan tertentu.

BAB II

DESKRIPSI KONSEP

2.1. Sistem yang Dirancang

Sistem yang dirancang adalah sistem prediksi dan analisis harga minyak goreng di 100 Kabupaten/Kota di seluruh Indonesia dengan pendekatan *Gradient Boosting*. Sistem yang dirancang merupakan sistem prediksi dan analisis harga minyak goreng untuk 100 Kabupaten/Kota di Indonesia menggunakan pendekatan machine learning berbasis *Gradient Boosting Regressor*. Sistem ini dibangun dengan tujuan untuk memberikan gambaran pola pergerakan harga yang akurat serta memproyeksikan harga di masa mendatang. Data historis harga minyak goreng yang bersumber dari PIHPS Bank Indonesia akan diproses melalui pipeline otomatis yang mencakup data preprocessing (mengisi *missing value*, normalisasi tanggal), *feature engineering* (lag harian/mingguan, *rolling mean*, variabel musiman), serta pembagian data menjadi train set dan test set menggunakan metode *time-based split* untuk mencegah data leakage.

Tahap pelatihan model dilakukan dengan menggunakan Gradient Boosting yang dilengkapi proses hyperparameter tuning berbasis *Time Series Cross-Validation*. Pendekatan ini memastikan model yang dihasilkan tidak hanya fit pada data historis tetapi juga memiliki kemampuan generalisasi yang baik. Setelah model dilatih dan memenuhi kriteria akurasi yang ditentukan (misalnya $R^2 \geq 0.5$), model disimpan dalam format .joblib sehingga dapat digunakan kembali tanpa

perlu retraining dari awal. Proses ini memungkinkan pengelolaan model yang terstruktur dan reproducible untuk setiap kabupaten/kota.

Hasil akhir sistem ini tidak hanya berupa model prediksi, tetapi juga dilengkapi komponen evaluasi yang mencatat metrik performa seperti MAE, RMSE, dan R^2 untuk setiap kabupaten/kota. Informasi ini penting sebagai feedback loop untuk memantau kualitas model dan mendeteksi jika terjadi penurunan performa akibat perubahan pola harga di masa depan. Dengan desain pipeline yang modular, sistem memungkinkan pembaruan data dan retraining model secara berkala tanpa mengubah struktur inti.

Implementasi akhir dari sistem ini diwujudkan dalam bentuk website interaktif. Pengguna dapat mengakses halaman prediksi, memilih Kabupaten/Kota yang diinginkan, serta menentukan rentang tanggal mulai dan akhir untuk analisis. Ketika tombol Lihat Prediksi ditekan, sistem akan mengirim permintaan (API call) ke *backend*, memuat model yang relevan, menghasilkan prediksi harga, lalu menampilkan hasilnya dalam bentuk grafik perbandingan antara data aktual dan data prediksi. Tampilan ini dirancang agar intuitif, sehingga pengguna dapat dengan mudah memantau tren harga historis maupun memproyeksikan harga di masa depan tanpa perlu pengetahuan teknis yang mendalam.

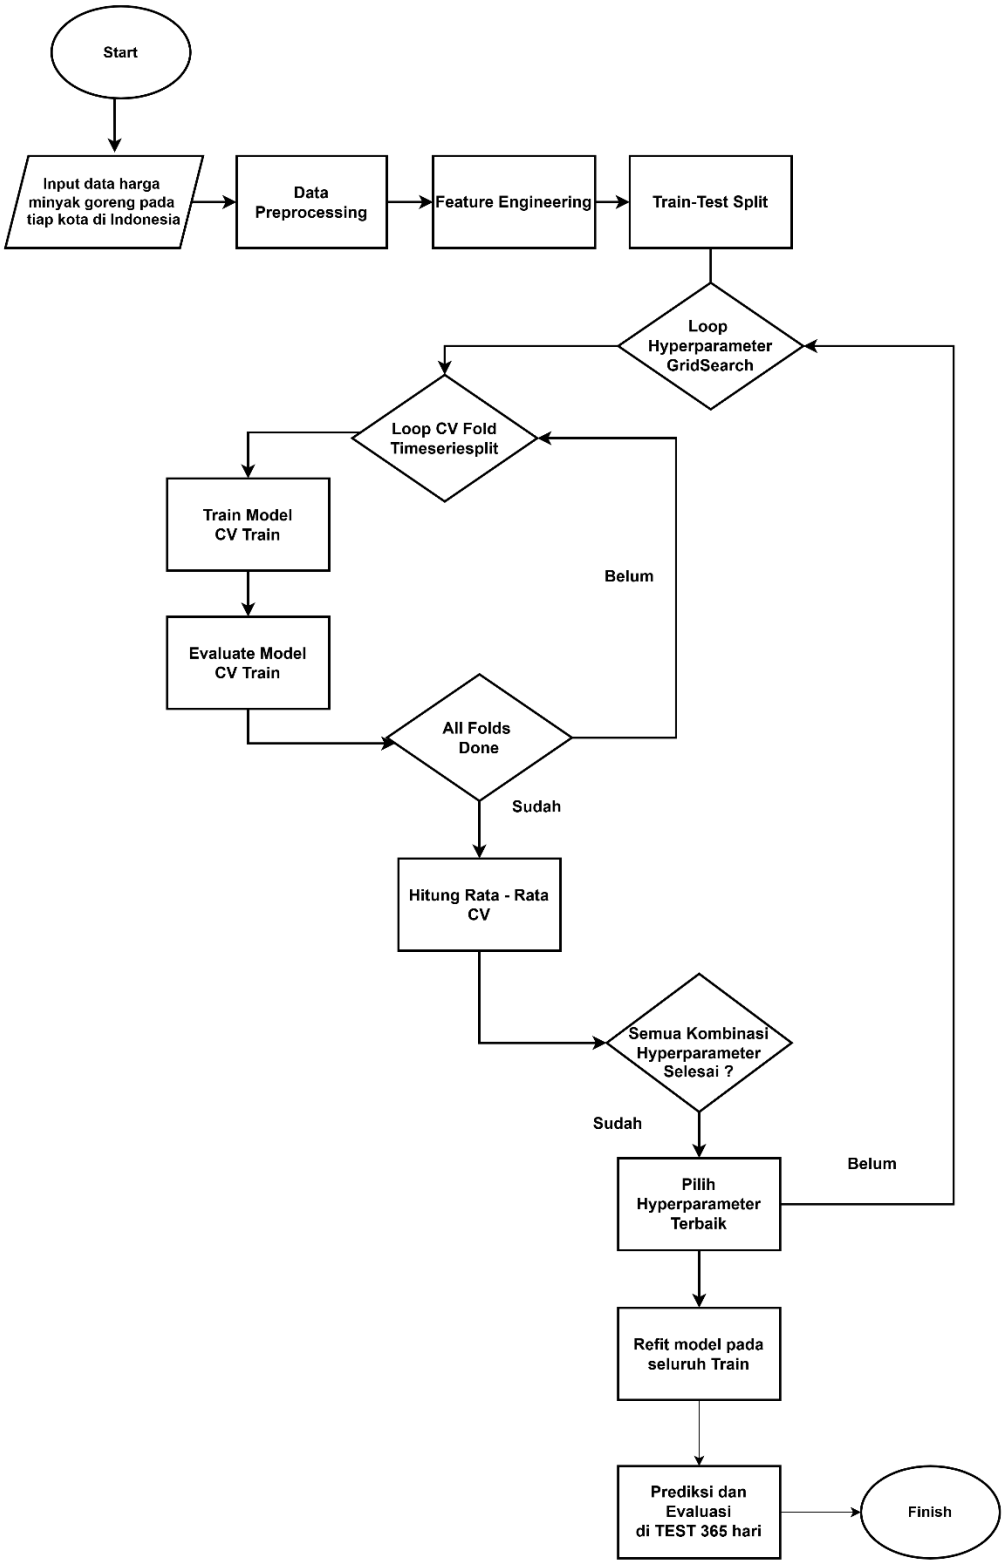

Gambar 2.1 Diagram Alur Rancangan yang dibuat

2.2. Kajian Pustaka

Penelitian ini berfokus untuk memprediksi harga minyak goreng di pasar tradisional Indonesia serta memahami pola tren dan fluktuasi harga, termasuk mengidentifikasi ketimpangan harga antarwilayah. Untuk mencapai tujuan tersebut, digunakan algoritme *machine learning Gradient Boosting* sebagai metode prediksi. Algoritma ini diharapkan mampu mempelajari pola kompleks dalam data historis harga minyak goreng, sehingga dapat menghasilkan prediksi yang akurat sekaligus memberikan wawasan mengenai faktor-faktor yang memengaruhi pergerakan harga.

2.2.1. Minyak Goreng

Minyak goreng merupakan salah satu kebutuhan pokok masyarakat yang berperan penting dalam aktivitas memasak, khususnya untuk menggoreng dan menumis, sekaligus memberikan rasa gurih serta tekstur renyah pada makanan. Di Indonesia, minyak goreng umumnya diproduksi dari bahan nabati seperti kelapa sawit, kedelai, jagung, dan kelapa, dengan kelapa sawit menjadi sumber utama karena ketersediaannya yang melimpah serta biaya produksi yang lebih rendah dibandingkan minyak nabati lainnya. Selain itu, minyak goreng memiliki dimensi ekonomi dan sosial yang signifikan [18], di mana perubahan harga sangat memengaruhi daya beli, terutama pada kelompok berpenghasilan rendah, sehingga sering menjadi perhatian pemerintah dalam menjaga stabilitas pangan .

Relevansinya terhadap penelitian terletak pada sifat minyak goreng yang vital dan dikonsumsi secara luas, dengan harga yang fluktuatif akibat berbagai faktor.

2.2.2. *Time Series*

Data *time series* adalah kumpulan data yang diurutkan berdasarkan waktu, dan saling bergantung antar periode. Data runtun waktu umumnya memperlihatkan kecenderungan jangka panjang (*trend*), pola musiman yang berulang (*seasonality*), serta variasi yang tidak terduga akibat faktor eksternal. Melalui pendekatan ini, informasi dari masa lalu dapat dimanfaatkan untuk menghasilkan prediksi kondisi di masa mendatang. Dalam penelitian yang menjadi acuan, metode *time series* [19] digunakan sebagai dasar pengolahan data dinamis sehingga mampu menggambarkan perilaku variabel yang berubah seiring waktu serta memberikan gambaran yang lebih akurat terhadap kecenderungan di masa depan.

2.2.3. Prediksi

Prediksi merupakan suatu proses memperkirakan kejadian atau nilai pada periode mendatang dengan memanfaatkan data historis yang telah ada [20]. Melalui pola yang terbentuk dalam data masa lalu, prediksi berperan penting dalam membantu pengambilan keputusan, mengurangi ketidakpastian, serta merencanakan langkah strategis di berbagai bidang. Dalam penelitian yang dijadikan acuan, prediksi dilakukan dengan mengolah data runtun waktu menggunakan metode statistik dan algoritma pembelajaran mesin sehingga

model mampu mengenali tren, pola musiman, maupun fluktuasi. Dengan demikian, hasil prediksi diharapkan memberikan gambaran yang lebih akurat mengenai kondisi masa depan serta bermanfaat dalam konteks akademik maupun praktis.

2.2.4. *Machine learning*

Machine learning merupakan salah satu cabang dari kecerdasan buatan yang memungkinkan komputer belajar dari data untuk mengenali pola serta membuat prediksi tanpa harus diprogram dengan aturan yang kaku. *Machine learning* didefinisikan sebagai kemampuan sistem untuk belajar dari data sehingga dapat membangun model analitis secara otomatis dan menyelesaikan suatu tugas tanpa harus diprogram secara eksplisit [21]. Berbeda dengan pendekatan tradisional yang mengandalkan rumus baku, *machine learning* bekerja dengan memanfaatkan algoritma yang secara bertahap menyesuaikan diri berdasarkan informasi yang diberikan. Dengan cara ini, sistem dapat mengolah data dalam jumlah besar, menemukan hubungan yang tidak selalu terlihat secara kasat mata, serta menghasilkan model yang mampu digunakan kembali untuk memprediksi kejadian di masa depan.

Dalam konteks penelitian, *machine learning* menjadi sangat relevan karena data yang dianalisis biasanya memiliki pola yang kompleks dan fluktuatif. Misalnya pada prediksi harga komoditas, harga minyak goreng tidak hanya dipengaruhi oleh tren waktu, tetapi juga oleh berbagai faktor eksternal seperti distribusi, kebijakan, maupun kondisi pasar lokal. Dengan menggunakan *machine learning*, model

mampu menangkap kerumitan pola tersebut sehingga prediksi yang dihasilkan lebih akurat dan adaptif. Hal ini menjadikan *machine learning* sebagai pendekatan modern yang efektif dalam mendukung analisis data ekonomi dan pengambilan keputusan berbasis informasi.

2.2.5. *Forward fill* dan *Backward fill*

Dalam pengolahan data runtun waktu (*time series*) sering terjadi nilai *missing values.* Metode yang digunakan dalam penelitian ini untuk mengatasi hal tersebut adalah dengan metode gabungan *forward fill* dan *backward fill. Forward Fill* (ffill) adalah teknik mengisi nilai kosong dengan nilai terakhir yang sudah ada sebelumnya. Teknik ini efektif digunakan pada data deret waktu di mana nilai antar waktu relatif tidak banyak berubah sehingga data sebelumnya bisa dijadikan perkiraan yang masuk akal. *Backward Fill* (bfill) Adalah teknik mengisi nilai kosong dengan nilai berikutnya yang sudah tersedia. Ketika dua metode tersebut digabungkan, maka tidak ada lagi *missing value* karena semua celah terisi, baik dari arah masa lalu maupun masa depan. [22]

2.2.6. *Gradient Boosting*

Gradient Boosting merupakan salah satu algoritma *ensemble learning* yang banyak digunakan dalam bidang *machine learning* untuk meningkatkan akurasi prediksi [23]. Prinsip dasarnya adalah membangun model secara bertahap melalui pendekatan aditif [24], di mana setiap model baru yang ditambahkan berfungsi untuk memperbaiki kesalahan (*residual error*) dari model sebelumnya. Dengan

kata lain, algoritma ini bekerja dengan menggabungkan sejumlah model lemah (*weak learners*), biasanya berupa pohon keputusan sederhana, menjadi sebuah model kuat (*strong learner*) yang memiliki performa prediktif lebih tinggi.

Gradient Boosting berusaha meminimalkan fungsi kerugian (loss function) secara iteratif. Fungsi *loss* yang diminimalkan dapat dihitung dengan rumus pada persamaan 2.1.

$$F_0 = \arg\min \sum_i (y_i - c)^2 = \bar{y} \qquad (2.1)$$

Keterangan :

F_0 = Model awal (*initial model*)

y_i = Nilai aktual dari variabel target pada data ke-i

c = Konstanta terbaik untuk meminimalkan jumlah kesalahan kuadrat

Argmin = Operator untuk mencari nilai c dengan total kesalahan minimum

$\bar{y}$ = Rata – rata dari semua nilai target y_i

Dalam algoritma *Gradient Boosting*, model dibangun secara bertahap dari iterasi ke iterasi. Pada dasarnya, setiap model baru ditambahkan untuk memperbaiki kesalahan model sebelumnya dengan *learning rate*. *Learning rate* (v) digunakan untuk mengatur kecepatan model dalam belajar dari kesalahan di tiap iterasi agar prediksi lebih stabil dan akurat. Fungsi *Gradient Boosting* yang digunakan terdapat pada persamaan 2.2 :

$$F_m(x) = F_{m-1}(x) + V \cdot h_m(x) \qquad (2.2)$$

Keterangan :

$F_m(x)$ = Model iterasi ke - m

$F_{m-1}(x)$ = Model sebelumnya

$h_m(x)$ = *Weak learner* yang dilatih untuk memprediksi *error* residu

v = *Learning rate*

Secara matematis, *gradient boosting* merupakan penerapan penurunan gradien pada ruang fungsi. Model akhir $F_m(x)$ dibangun sebagai penjumlahan bertingkat dari basis learner $h_m(x)$ dengan bobot tertentu (plus konstanta awal. Pada tiap tahap m, algoritma berusaha menurunkan nilai fungsi *loss* secara maksimal dengan menambahkan fungsi h_m baru. Pendekatan praktisnya adalah dengan memilih h_m yang paling sesuai dengan gradien negatif loss saat ini, kemudian mengalikan hasilnya dengan *learning rate* dan menambahkannya ke model.

Keunggulan *Gradient Boosting* terletak pada kemampuannya menyesuaikan model terhadap pola kompleks pada data serta mengurangi bias dan varians secara bertahap. Proses pembelajaran dilakukan dengan menghitung gradien dari fungsi kerugian (*loss function*) yang digunakan, sehingga setiap model baru dibentuk untuk meminimalkan *error* secara optimal. Oleh karena itu, algoritma ini sangat efektif dalam menangani permasalahan regresi maupun klasifikasi, termasuk untuk memprediksi variabel yang fluktuatif seperti harga komoditas. [25]

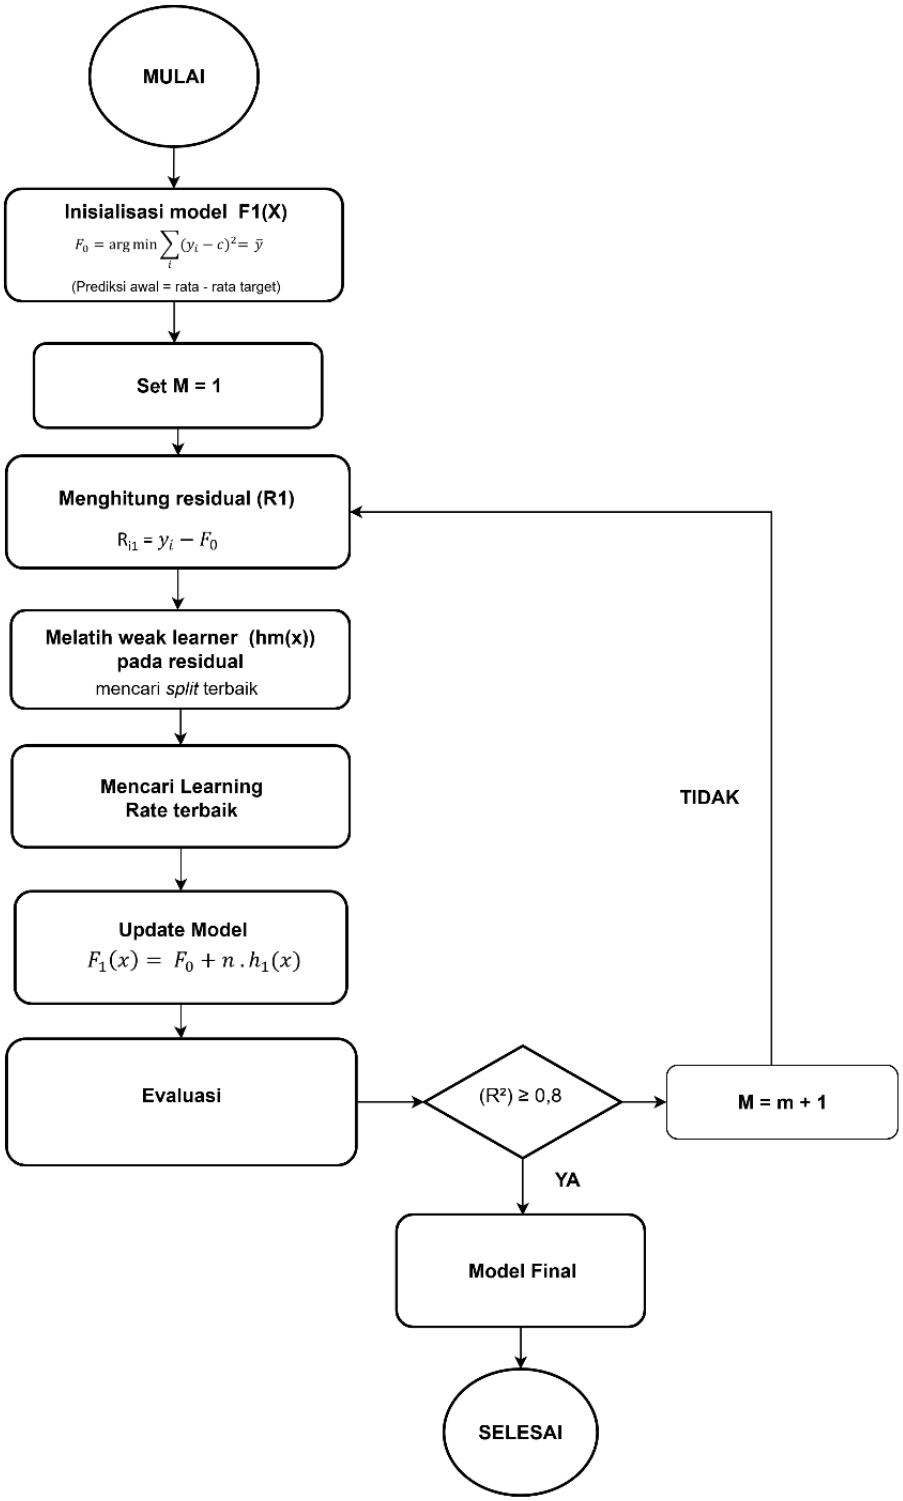

Gambar 2.2 Alur Kerja *Gradient Boosting*
Sumber [25]

Proses *gradient boosting classifier* (GBC) pada **gambar 2.2** dimulai dengan inisialisasi model $F_0(x)$ pada kondisi netral yaitu log-odds awal sama dengan nol. Setelah itu ditentukan jumlah iterasi atau pohon M yang akan dibangun. Pada setiap iterasi M, model menghitung residual, yaitu selisih antara label sebenarnya dengan probabilitas prediksi sebelumnya. Residual ini menggambarkan kesalahan yang masih tersisa dan menjadi target bagi *weak learner* berikutnya [26].

Weak learner yang digunakan adalah pohon keputusan sederhana (*decision tree*), yang dilatih untuk memetakan fitur input terhadap residual. Setiap terminal *node* dari pohon akan menghasilkan sebuah nilai khusus yang digunakan untuk meminimalkan *logistic loss*. Model kemudian diperbaharui dengan menambahkan kontribusi *weak learner* yang diskalakan oleh *learning rate* (η) ke prediksi log-odds [26].

2.2.7. *Hyperparameter*

Hyperparameter merupakan sekumpulan nilai yang tidak dihasilkan dari proses pembelajaran data, tetapi ditetapkan terlebih dahulu sebelum model dilatih. Berbeda dengan parameter model seperti bobot pada regresi [27] atau struktur pohon keputusan yang diperoleh melalui training, hyperparameter berfungsi sebagai pengatur mekanisme kerja model

Penentuan nilai hyperparameter yang sesuai sangat penting karena berpengaruh langsung pada kualitas model. Nilai yang kurang tepat dapat menyebabkan model *underfitting* (gagal menangkap pola penting) atau *overfitting* (terlalu mengikuti data latih sehingga buruk dalam generalisasi). Oleh sebab itu,

peneliti biasanya melakukan pencarian kombinasi hyperparameter terbaik menggunakan metode seperti *grid search* atau *random search*. Dalam penelitian ini, pengaturan hyperparameter pada algoritma *Gradient Boosting* menjadi hal yang krusial agar model mampu memberikan prediksi yang optimal dan tetap mampu beradaptasi terhadap data baru.

Hyperparameter yang dipakai untuk proses *training* dan pembuatan model adalah antara lain :

1. *Learning rate* adalah parameter yang digunakan untuk mengatur skala kontribusi setiap pohon baru terhadap model keseluruhan. Setiap pohon yang akan dibuat akan dikalikan faktor ini sebelum ditambahkan ke model. *Learning rate* yang lebih kecil menyebabkan proses pembelajaran berjalan lebih lambat dan halus: model membutuhkan lebih banyak iterasi/pohon supaya mencapai kapasitas representasi yang sama, namun cenderung mengurangi risiko overfitting dan memperbaiki generalisasi bila dikombinasikan dengan jumlah estimator yang memadai. Sebaliknya, learning rate yang lebih besar membuat model belajar lebih agresif (setiap pohon berdampak besar), yang sering mempercepat penurunan error pada data latih tetapi menaikkan risiko *overfitting* dan membuat proses tuning jadi lebih sensitif. [28].
2. *Max depth,* adalah *hyperparameter* yang membatasi kedalaman (jumlah split beruntun). Dengan *max depth* tinggi, model dapat menurunkan error pada data latih karena menangkap pola kompleks, tetapi ini sering berujung pada

overfitting (menangkap noise atau idiosinkrasi data latih). Dengan *max depth* rendah, tiap pohon menjadi lebih sederhana sehingga model lebih terbatas kemampuannya mengekspresikan interaksi kompleks;

3. Number of Estimators

Estimators menentukan berapa banyak pohon (iterasi boosting) yang akan dibangun. Meningkatkan *estimators* memberikan lebih banyak kesempatan bagi model untuk mengoreksi residual bertahap sehingga biasanya menurunkan error pelatihan sampai titik tertentu; tetapi jika dibiarkan terlalu besar tanpa regularisasi (atau *learning rate* tinggi) dapat menyebabkan *overfitting* dan biaya komputasi yang tinggi. Menurunkan *estimators* (nilai rendah) bisa membuat model berhenti terlalu dini sehingga *underfitting* apabila jumlah pohon tidak cukup untuk menangkap pola. Studi-studi benchmark dan makalah eksplorasi *hyperparameter* menekankan bahwa *estimators* harus ditimbang bersama *learning rate* (contoh: *learning rate* kecil + banyak *estimators* vs *learning rate* besar + sedikit *estimators*) dan bahwa penggunaan *early stopping* pada validasi sering membantu memilih jumlah *estimators* yang pas.

2.2.8. *Mean Absolute Error* (MAE)

Mean Absolute Error (MAE) mengukur rata-rata kesalahan absolut antara nilai aktual dan nilai prediksi. Karena menggunakan nilai absolut, metrik ini bersifat linear dan memberikan gambaran rata-rata deviasi tanpa memperbesar pengaruh kesalahan yang sangat besar. Hal ini membuat MAE lebih mudah ditafsirkan,

terutama ketika model digunakan pada data dengan fluktuasi normal. Perumusan dari *Mean Absolute Error* (MAE) dapat dilihat pada persamaan 2.3. [29]

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_1 - \hat{y}_i| \qquad (2.3)$$

Keterangan :

n = Jumlah total data atau banyaknya observasi

y_i = nilai aktual atau nilai sebenarnya dari data pada observasi ke – i

$\hat{y}_i$ = Nilai prediksi pada observasi ke – i

$|y_1 - \hat{y}_i|$ = Selisih absolut nilai aktual dengan nilai prediksi

$\frac{1}{n}\sum_{i=1}^{n}$ = Rata - rata kesalahan absolut

2.2.9. *Mean Squared Error (MSE)*

Mean Squared Error (MSE) mengukur rata-rata kuadrar kesalahan antara nilai aktual dan nilai prediksi, karena menggunakan nilai absolut, metrik ini bersifat linear dan memberikan gambaran rata-rata deviasi tanpa memperbesar pengaruh kesalahan yang sangat besar. Hal ini membuat MAE lebih mudah ditafsirkan, terutama ketika model digunakan pada data dengan fluktuasi normal. Persamaan (2.4) merupakan perumusan *Mean Squared Error* (MSE) [30]

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_1 - \hat{y}_i)^2 \qquad (2.4)$$

Keterangan

n = Jumlah total data atau banyaknya observasi

y_i = nilai aktual atau nilai sebenarnya dari data pada observasi ke – i

$\hat{y}_i$ = Nilai prediksi pada observasi ke – i

$(y_1 - \hat{y}_i)$ = Selisih (*error*/residual) antara nilai aktual dan prediksi

$(y_1 - \hat{y}_i)^2$ = Kuadrat dari *error*

$\frac{1}{n}\sum_{i=1}^{n}$ = Rata - rata kesalahan absolut

2.2.10. *Root Mean Squared Error* (RMSE)

Root Mean Squared Error (RMSE) merupakan akar kuadrat dari MSE, yang digunakan agar hasil pengukuran kembali pada satuan data aslinya. Meskipun secara konsep hampir sama dengan MSE, RMSE lebih mudah diinterpretasikan dalam konteks nyata karena nilainya sebanding dengan skala variabel yang diprediksi. Nilai RMSE yang rendah menunjukkan bahwa model mampu menghasilkan prediksi yang dekat dengan nilai aktual. Perumusan dari *Root Mean Squared Error* dapat dilihat dari persamaan 2.5. [29]

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}} = \sqrt{\frac{1}{n}\sum_{i-1}^{n}(y_1 - \hat{y}_i)^2} \qquad (2.5)$$

Keterangan

n = Jumlah total data atau banyaknya observasi

y_i = Nilai aktual atau nilai sebenarnya dari data pada observasi ke – i

$\hat{y}_i$ = Nilai prediksi pada observasi ke – i

$(y_1 - \hat{y}_i)$ = Selisih (*error*/residual) antara nilai aktual dan prediksi

$(y_1 - \hat{y}_i)^2$ = Kuadrat dari *error*

$\frac{1}{n}\sum_{i=1}^{n}$ = Rata - rata kesalahan absolut

2.2.11. *Coefficient of Determination*

Coefficient of Determination (R^2) Adalah koefisien determinasi yang digunakan untuk melihat sejauh mana model dapat menjelaskan variasi data. Nilai R^2 berada pada rentang 0 hingga 1, di mana angka yang mendekati 1 menunjukkan bahwa sebagian besar variasi data dapat dijelaskan oleh model. Secara teoritis, R^2 tidak hanya mengukur tingkat akurasi, tetapi juga menilai kesesuaian model dalam

menangkap pola data. Rumus dari *coefficient of determination* (R^2) dapat dilihat pada persamaan 2.6.[5] Adapun tidak ada angka pasti mengenai ukuran minimal bahwa suatu model dikatakan prediktif sebab terdapat beberapa faktor yang mempengaruhi seperti kompleksitas dan kualitas suatu data.

Secara umum, nilai (R^2) antara 0 hingga 0.09 dianggap terlalu rendah untuk sebuah model dalam penelitian sosial. Nilai (R^2) antara 0.10 hingga 0.50 dapat diterima dalam penelitian ilmu sosial hanya jika beberapa atau sebagian besar variabel penjelasnya signifikan secara spesifik. Nilai (R^2) antara 0,51 hingga 0.99 dianggap baik dan dapat diterima dalam penelitian [31]. Rumus dari *coefficient of determination* (R^2) dapat dilihat pada persamaan 2.6.[5]

$$R^2 = 1 - \frac{\sum_{i-1}^{n}(y_1 - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_1 - \hat{y}_i)^2} V \qquad (2.6)$$

Keterangan

y_i = nilai aktual atau nilai sebenarnya dari data pada observasi ke – i

$\hat{y}_i$ = Nilai prediksi pada observasi ke – i

$\sum_{i=1}^{n}(y_1 - \hat{y}_i)^2$ = Jumlah kuadrat *error*

$\sum_{i=1}^{n}(y_1 - \bar{y})^2$ = jumlah kuadrat total

2.2.12. *Python*

Python adalah bahasa pemrograman serbaguna tingkat tinggi yang dirancang sederhana, mudah dipelajari, dan ramah bagi pemula. Bahasa ini pertama kali dikembangkan oleh Guido van Rossum pada akhir 1980-an dan dirilis tahun 1991, serta bersifat *open-source*, lintas *platform*, dan memiliki pustaka

standar yang sangat luas. *Python* mendukung berbagai paradigma pemrograman, baik prosedural maupun berorientasi objek, bersifat dinamis sehingga tidak memerlukan deklarasi tipe data secara eksplisit, serta terinterpretasi sehingga lebih mudah dalam proses debugging. Popularitas *Python* terus meningkat karena sintaksnya yang ringkas, fleksibilitas tinggi, serta dukungan komunitas besar dengan ekosistem pustaka yang kaya untuk berbagai bidang seperti pengembangan web, analisis data, kecerdasan buatan, dan pemrosesan multimedia [22]

2.2.13. *Flask*

Flask adalah sebuah microframework berbasis *Python* yang sering digunakan dalam penelitian maupun pengembangan aplikasi karena sifatnya yang ringan, fleksibel, dan mudah diintegrasikan dengan pustaka lain. Dalam konteks penelitian seperti pada paper di atas, *Flask* biasanya berfungsi sebagai *web framework* untuk membangun antarmuka aplikasi prediksi atau sistem analisis data sehingga model statistik atau *machine learning* yang dikembangkan dapat diakses melalui layanan web. Dengan pendekatan ini, peneliti dapat menghubungkan hasil analisis (misalnya perhitungan reliabilitas, estimasi sampel, atau model prediksi) dengan pengguna akhir melalui API atau dashboard interaktif. Keunggulan *Flask* adalah tidak memerlukan konfigurasi kompleks, mendukung modularisasi, serta dapat diperluas dengan berbagai ekstensi untuk basis data, autentikasi, maupun visualisasi, sehingga sangat sesuai untuk mendukung penelitian akademik maupun implementasi praktis. [32]

2.2.14. *Usecase Diagram*

Use case diagram merupakan salah satu jenis diagram dalam UML yang berfungsi untuk memvisualisasikan hubungan antara pengguna atau sistem eksternal dengan fungsi-fungsi yang disediakan oleh sebuah sistem. Diagram ini menggambarkan layanan utama yang dapat digunakan oleh aktor, sehingga membantu menjelaskan kebutuhan fungsional sistem dari perspektif pengguna. Elemen pentingnya meliputi aktor, use case (fitur atau layanan), batas sistem, serta relasi antar komponen. Dengan demikian, use case diagram memberikan gambaran umum mengenai apa saja yang dapat dilakukan sistem tanpa menjelaskan detail teknis cara kerjanya. Simbol yang digunakan pada *usecase* diagram dapat dilihat pada Lampiran 3.

2.3.15. *Time series crossvalidation*

Time series cross validation merupakan strategi evaluasi dan optimasi model, dengan membagi dataset menjadi beberapa lipatan (*fold*), setiap subset bergantian menjadi data validasi sehingga pemanfaatan data menjadi maksimal. Rata – rata akurasi dari setiap *fold* dianggap representasi akurasi model. Metode ini juga membantu mengurangi risiko *overfitting,* karena model tidak hanya dilatih dan diuji pada subset yang sama [33].

2.3.16. *Feature Engineering*

Feature engineering adalah langkah penting dalam pipeline data *science* yang bertujuan meningkatkan kualitas data masukan agar model dapat belajar

secara optimal. Tahap ini tidak sekadar membersihkan data, tetapi melibatkan pembuatan variabel baru, transformasi numerik/kategorikal, serta pemilihan fitur yang paling informatif. Dengan rekayasa fitur yang tepat, model menjadi lebih sederhana, lebih akurat, dan lebih tahan terhadap *overfitting*. Penelitian ini menekankan bahwa proses tersebut harus dilakukan secara iteratif dengan memanfaatkan wawasan domain dan analisis eksploratif data, karena fitur yang tepat seringkali memiliki dampak lebih besar dibanding sekadar mengganti algoritma mode [34].

2.3.17. *GridSearchCV*

GridSearchCV adalah metode pencarian parameter optimal dengan cara mencoba seluruh kombinasi *hyperparameter* yang telah ditentukan di dalam parameter *grid*. Setiap kombinasi diuji menggunakan *cross-validation* untuk mengukur performanya. Tujuannya adalah menemukan kombinasi parameter yang menghasilkan skor terbaik (misalnya akurasi, R^2, atau metrik lain yang ditentukan)[35].

2.3.18. *System Development Life Cycle* (SDLC)

System Development Life Cycle (SDLC) adalah sebuah metode pengembangan perangkat lunak yang terstruktur, digunakan untuk merancang, mengembangkan, menguji, dan menerapkan sistem sesuai kebutuhan pengguna dalam jangka waktu tertentu. SDLC mencakup beberapa fase utama: analisis kebutuhan, perancangan sistem, implementasi (*coding*), pengujian, hingga

deployment dan pemeliharaan. Pendekatan ini memastikan bahwa setiap tahap pengembangan dilakukan secara sistematis sehingga menghasilkan produk yang berkualitas, memenuhi spesifikasi, serta meminimalkan risiko kesalahan. Model SDLC dapat berbentuk *waterfall*, spiral, iterative, V-model, atau *agile*, yang dipilih sesuai dengan kompleksitas proyek dan kebutuhan pengguna [36].

Waterfall model adalah salah satu SDLC dan juga pendekatan paling klasik dalam rekayasa perangkat lunak yang memandang pengembangan sistem sebagai proses linear dan berurutan. Setiap tahap – mulai dari analisis kebutuhan, desain sistem, implementasi (coding), pengujian, hingga pemeliharaan – harus diselesaikan sepenuhnya sebelum tahap berikutnya dimulai. Pendekatan ini cocok untuk proyek dengan kebutuhan yang sudah jelas, stabil, dan jarang berubah, karena perubahan setelah satu tahap selesai relatif sulit dilakukan. Waterfall menekankan dokumentasi yang lengkap dan perencanaan awal yang mendetail sehingga memudahkan pengendalian proyek, tetapi kelemahannya adalah kurang fleksibel terhadap perubahan kebutuhan selama proyek berlangsung [37].

2.3.19. *Blackbox Testing*

Black-box testing adalah pendekatan pengujian perangkat lunak yang menilai apakah suatu fitur sudah memenuhi kebutuhan dan spesifikasi hanya dari sisi perilaku luarnya—penguji memberi input dan memeriksa output, tanpa mengintip struktur atau kode internal. Kasus uji biasanya diturunkan langsung dari *requirement fungsional*, alur bisnis, dan aturan validasi sehingga fokus pada sistem.

Untuk merancang cakupan yang baik, digunakan teknik seperti *equivalence partitioning, boundary value analysis, decision table,* pengujian berbasis *use case*, dan *state transition*. Kelebihan dari *blackbox testing* adalah sangat representatif dari perspektif pengguna dan efektif untuk memverifikasi skenario *end-to-end*, sedangkan kekurangannya adalah sulit mengukur seberapa banyak kode yang benar-benar teruji [38].

2.3.20. *User Acceptance Testing* (UAT)

User Acceptance Testing (UAT) adalah tahap pengujian terakhir yang dilakukan oleh pengguna bisnis/end-user untuk memastikan sistem sudah memenuhi kebutuhan nyata dan siap digunakan di lingkungan operasional. Berbeda dari pengujian teknis oleh developer atau QA, UAT berfokus pada alur proses end-to-end, aturan bisnis, dan hasil yang "bermakna" bagi pengguna. UAT biasanya dilakukan setelah *system/integration testing*, di lingkungan yang menyerupai produksi dengan data uji yang realistis, dan mengacu pada acceptance criteria yang diturunkan dari requirement atau user stories.

Pelaksanaannya mencakup perencanaan (tujuan, ruang lingkup, peran, *entry/exit criteria,* lingkungan), perancangan skenario uji dari proses bisnis/SOP, serta eksekusi oleh perwakilan pengguna dengan pencatatan hasil expected vs actual, temuan *defect*, dan umpan balik kegunaan. Temuan kritis menjadi dasar perbaikan atau perubahan *scope*, sedangkan hasil yang memuaskan menghasilkan *sign-off* sebagai keputusan go/no-go untuk rilis. Praktiknya bisa berupa pilot/beta di kelompok terbatas atau operational readiness checks; kunci sukses UAT adalah

keterlibatan pengguna sejak awal, kriteria penerimaan yang terukur, dan data uji yang *representative* [38].

2.3.21. *Mean Absolute Percentage Error* (MAPE)

Mean Absolute Percentage Error (MAPE) adalah metriks yang umum digunakan untuk mengukur tingkat kesalahan (*error*) antara nilai aktual dengan nilai prediksi, Secara umum, tidak ada batas absolut yang berlaku untuk semua bidang, tetapi *rule of thumb* yang paling sering dipakai berasal dari Lewis [39]. MAPE < 10 % menunjukkan akurasi yang sangat baik, 10 % hingga 20 % menunjukkan akurasi yang baik, 20 % hingga 50 % menunjukkan prediksi yang cukup atau wajar, sedangkan lebih dari 50 % menunjukkan akurasi yang buruk. Adapun perumusan dari MAPE dapat dilihat pada persamaan (2.3). [40]

$$\text{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_1-\hat{y}_i}{y_1}\right| \times 100\% \qquad (2.3)$$

Keterangan :

n = Jumlah total data atau banyaknya observasi

y_i = nilai aktual atau nilai sebenarnya dari data pada observasi ke – i

$\hat{y}_i$ = Nilai prediksi pada observasi ke – i

$|y_1 - \hat{y}_i|$ = Selisih absolut nilai aktual dengan nilai prediksi

$\frac{1}{n}\sum_{i=1}^{n}$ = Rata - rata kesalahan absolut

2.3.21. Volatilitas

Volatilitas (volatility) adalah ukuran fluktuasi atau variasi harga suatu benda. Secara sederhana, volatilitas menggambarkan seberapa besar dan sering harga aset berubah—semakin tinggi volatilitasnya, semakin tidak stabil (dan berisiko) aset tersebut.

Rumus dasar volatilitas adalah standar deviasi (σ) dari return aset, yang mengukur dispersi return historis. Return dihitung dari perubahan harga untuk menangkap dinamika persentase. Rumus matematisnya adalah:

$$\sigma = \sqrt{\frac{1}{N}\sum_{i=1}^{N} (r_i - \mu)^2}$$

Keterangan :

r_i = Return periode ke-i

μ = Rata-rata return

$\hat{y}_i$ = Nilai prediksi pada observasi ke – i

N = Jumlah observasi

BAB III

RANCANGAN PEMBUATAN

3.1. Rancangan Sistem

Sistem yang dirancang bertujuan untuk menganalisis data numerik historis dan melakukan prediksi harga pada Kabupaten/Kota di Indonsia. Dengan demikian, perancangan ini berfokus pada pengolahan data numerik yang telah terkumpul. Sistem yang dirancang adalah sebuah sistem prediksi dan analisis harga berbasis web dengan menggunakan pengembangan SDLC (*System Development Life Cycle*) dengan pendekatan *waterfall model*.

Waterfall model adalah pengembangan yang dilakukan secara berurutan dan terstruktur, dimulai dari tahap analisis kebutuhan, dilanjutkan dengan perancangan *pipeline* pra-pemrosesan data, pembangunan model awal menggunakan *Gradient Boosting* untuk memvalidasi kelayakan pendekatan, implementasi modul evaluasi, hingga pengembangan antarmuka berbasis web untuk menampilkan hasil prediksi dan analisis. Setiap tahapan harus diselesaikan sebelum melanjutkan ke tahap berikutnya, sehingga alur kerja menjadi jelas dan terdokumentasi dengan baik. Selain itu, model ini mendukung proses pengembangan skala kecil atau individu karena memudahkan perencanaan, pelacakan kemajuan, serta perbaikan di setiap tahap bila ditemukan kesalahan sebelum melanjutkan ke tahap berikutnya [41]. Tabel alur rancangan dengan pendekatan *waterfall* terdapat pada **lampiran 9**.

3.1.1. Perencanaan Sistem

Pada tahap perencanaan sistem, dilakukan penyusunan rancangan awal yang mencakup identifikasi kebutuhan, penentuan lingkup, serta perancangan alur *pipeline* sistem prediksi harga minyak goreng. Tahap ini bertujuan untuk memastikan bahwa proses analisis serta perancangan model (program) dapat berjalan dengan terstruktur dan baik. Fase perencanaan meliputi identifikasi, lingkup dan rencana alur *pipeline system* :

1. Data yang dikumpulkan telah tersedia dalam bentuk *dataset* (*Excel*) yang berisi harga-harga minyak goreng di pasar tradisional dari 100 kabupaten/kota di Indonesia (**gambar 3.2**) yang bersumber dari Pusat Informasi Harga Pangan Strategis Nasional (https://www.bi.go.id/hargapangan).
2. Data yang dikumpulkan untuk dievaluasi berjumlah 2010 baris setiap kota, dengan fitur input
3. Persiapan data meliputi tahap pra-pemrosesan (*data preprocessing*), *feature engineering* (transformasi variabel yang ada), Pembagian data (*data splitting*), *Hyperparameter tuning* dan *training* pada model *Gradient Boosting* dilakukan dengan mencari *hyperparameter* optimal.
4. Hasil Evaluasi model dilakukan dengan menggunakan metriks evaluasi yang dipilih yaitu MSE, RMSE, MAE, MAPE, dan R2.
5. Interpretasi Hasil dilakukan dengan menampilkan hasil prediksi melalui grafik perbandingan harga sebenarnya (*actual price*) dengan harga terprediksi

(*predicted price*) dan analisis – analisis terkait evaluasi, dan pola harga melalui pembuatan *website* berbasis *python – flask*.

3.1.2. Analisis Kebutuhan Sistem

Analisis kebutuhan sistem dilakukan untuk memastikan bahwa spesifikasi perangkat lunak dapat mendukung proses *pipeline data* dan pembuatan *web* hasil prediksi dan analisis harga.

Spesifikasi Perangkat Keras Minimum :

1. CPU : Intel Core i5 Gen-10 / AMD Ryzen 5 (4C/8T)
2. RAM : 8 GB
3. Penyimpanan : SSD 256 GB

Spesifikasi Perangkat lunak :

1. OS : Windows 10/11 64-bit / macOS 12+
2. Python : 3.9 – 3.11
3. Manajemen environment : venv/Conda/pipenv

Analisis kebutuhan sistem dilakukan dengan mempertimbangkan aspek *time complexity* yang dipengaruhi oleh jumlah sampel, fitur serta kombinasi antara *hyperparameter* dan jumlah *fold* pada *time series cross validation*, sehingga perlu strategi pencarian parameter bertahap (*coarce-to-refined search*) agar waktu komputasi tidak berlebihan. Dari sisi *space complexity*, dibutuhkan memori untuk menyimpan DataFrame.

3.1.3. Desain Rancangan Sistem

Desain rancangan sistem menggambarkan rancangan konseptual dan teknik dari sistem prediksi harga minyak goreng yang dikembangkan, mencakup interaksi pengguna, alur pengelohanan data, hingga tampilan antarmuka. Rancangan sistem divisualisasikan melalui berbagai diagram seperti *use case*¸ *activity*, *sequence*, *state* diagram untuk memperlihatkan bagaimana berinteraksi dengan fungsi utama bagaimana proses berjalan secara kronologis, serta bagaimana sistem merespons setiap kondisi. Selain itu, rancangan *pipeline* pengolahan data disusun secara sistematis mulai dari input data mentah, pra-pemrosesan, rekayasa fitur, pemisahan data, validasi silang, tuning hyperparameter, pelatihan model *Gradient Boosting*, hingga tahap evaluasi model. Hasil rancangan ini kemudian diwujudkan dalam rancangan antarmuka aplikasi berbasis web yang terdiri atas empat modul utama, yaitu beranda, tinjauan tren, prediksi, dan evaluasi. Dengan pendekatan ini, sistem tidak hanya memberikan hasil prediksi harga yang akurat, tetapi juga menyediakan antarmuka yang informatif dan mudah dipahami sehingga dapat membantu pengguna dalam mengambil keputusan berbasis data

3.1.3.1. Desain Rancangan Sistem (Diagram)

Rancangan sistem (diagram) yang akan dibuat bertujuan untuk menggambarkan alur kerja sistem prediksi harga minyak goreng agar mempermudah pembaca dalam memahami interaksi antara pengguna.

1. *Use Case Diagram* dan Tabel *usecase scenario*, menggambarkan interaksi

pengguna dengan sistem dan fungsi – fungsi utama yang disediakan.

2. *Activity Diagram*, memvisualisasikan alur proses dari awal sampai akhir termasuk percabangan logika.

Usecase diagram, dan *activity diagram* terdapat pada **LAMPIRAN 4,** dan **5**

3.1.3.2. Rancangan *Pipeline* Pengolahan Data

Data mentah yang dikumpulkan untuk menghasilkan prediksi harga minyak goreng berasal dari Pusat Informasi Harga Pangan Strategis Nasional (https://www.bi.go.id/hargapangan), dengan total 100 variabel Kabupaten/Kota di Indonesia dimana setiap kota memiliki 2010 sampel baris. Harga minyak merupakan harga per satuan Liter.

Data diolah pada suatu rancangan pipeline agar proses analisis bersifat sistematis dan terstruktur. Diagram *Pipeline* (**lampiran 7**) terdiri beberapa tahapan utama :

1. Input Data (*load* data)

   Data dibaca dalam format .csv atau .xlsx. Dataset mentah memuat kolom date (*timeseries*), kabupaten/kota, dan harga. Data tanggal (*date*) dinormalisasi menjadi tipe data *datetime*. Model deret waktu sangat sensitif terhadap urutan sehingga harus berada pada tipe waktu data yang benar. Pembacaan data dilakukan pada **gambar 3.1** dengan menggunakan *library pandas*. Kolom tanggal akan dikonversi tanggal ke format *datetime*, kemudian mengurutkan dari awal sampai akhir.

```
df = pd.read_excel(DATA_PATH, engine="openpyxl")
if df.columns[0].lower() != "date":
    df = df.rename(columns={df.columns[0]: "date"})
df["date"] = pd.to_datetime(df["date"])
df = df.sort_values("date").reset_index(drop=True)
```

Gambar 3.1 Input dan Pembacaan Data

2. Pra-pemrosesan Data (*Preprocessing*)

Data mentah memiliki banyak *missing value* dan memiliki data kosong (*none*) di hari Sabtu dan Minggu sehingga dilakukan metode *backward* dan *forward fill* untuk mengisi data yang hilang agar pola harga pada deret waktu tetap terstruktur. Pada gambar "city_name" merupakan kolom yang berisi harga minyak goreng pada kota tertentu. pd.to_numeric(df_all[city_name], errors="coerce") merupakan *code* yang digunakan untuk mengubah semua nilai dalam kolom kota menjadi tipe data numeric (float), dengan errors="coerce" nilainya diubah menjadi NaN (*missing value*), bukan *error*, kemudian isi nilai kosong dengan .ffill().bfill() (method bawaan dari objek pandas). Pada **gambar 3.**2 merupakan *code* yang digunakan untuk *handling missing values* (contoh *input* dan *output* dapat dilihat pada gambar 3.2.

```python
series_full = (
    pd.Series(pd.to_numeric(df_all[city_name], errors="coerce").values,
              index=pd.DatetimeIndex(df_all["date"]))
    .asfreq("D").ffill().bfill()
)
```

date	Kota Maluku
2020-01-01 00:00:00	14350
2020-01-02 00:00:00	14350
2020-01-03 00:00:00	14350
2020-01-04 00:00:00	14350
2020-01-05 00:00:00	
2020-01-06 00:00:00	
2020-01-07 00:00:00	14350
2020-01-08 00:00:00	14350
2020-01-09 00:00:00	14450

.fill()

date	Kota Maluku
2020-01-01 00:00:00	14350
2020-01-02 00:00:00	14350
2020-01-03 00:00:00	14350
2020-01-04 00:00:00	14350
2020-01-05 00:00:00	14350
2020-01-06 00:00:00	14350
2020-01-07 00:00:00	14350
2020-01-08 00:00:00	14350
2020-01-09 00:00:00	14450

Gambar 3.2 Proses *insert missing values*

3. Rekayasa Fitur (*Feature engineering*)

Pada tahap ini dibuat variabel tambahan untuk memperkaya informasi lain agar hasil prediksi semakin prediktif. Penambahan fitur seperti kolom lag1, lag7 untuk menangkap harga 1 hari dan 7 hari sebelumnya, kemudian kolom *rolling mean* (rata – rata data beberapa hari sebelumnya), dan fitur musiman (menambahkan kolom yang menunjukkan hari libur) untuk memperkuat hasil prediksi dengan menunjukkan lonjakan/penurunan harga agar model tidak kekurangan konteks temporal.

Fungsi make_flags() (**gambar 3.3**) digunakan untuk membentuk *fitur kalender* berdasarkan indeks waktu, seperti bulan (month), hari dalam seminggu (dayofweek), posisi waktu relatif terhadap awal seri (time_index), serta penanda hari-hari khusus seperti akhir tahun (is_end_of_year), awal tahun (is_new_year), dan periode sekitar hari raya Idul Fitri (is_eid_window) dengan jendela waktu ±14 hari sebelum dan 7 hari sesudah tanggal hari raya yang tercantum dalam EID_DATES. Fungsi ini menghasilkan *DataFrame* berisi

variabel-variabel waktu yang nantinya akan digabung ke fitur utama.

Sedangkan fungsi build_features_level_target() (gambar 3.3) digunakan untuk membentuk dataset fitur dan target yang siap dilatih oleh model. Fitur dasar yang selalu dibuat adalah *lag_1* (nilai satu hari sebelumnya), kemudian ditambah *lag tambahan* dan *rolling mean* (rata-rata bergerak) sesuai konfigurasi yang diberikan melalui cfg. Semua fitur waktu dari make_flags() kemudian digabung ke dalam *DataFrame* utama, dan nilai target (y) diambil sebagai kolom terpisah dengan menghapus baris kosong akibat pergeseran waktu (*shift*). Hasil akhirnya adalah pasangan (X, y_target) yang berisi fitur prediktor lengkap beserta nilai target aktual yang akan digunakan untuk pelatihan model.

```
def make_flags(idx) -> pd.DataFrame:
    di = pd.DatetimeIndex(pd.to_datetime(idx, errors="coerce")).tz_localize(None).normalize()
    f = pd.DataFrame(index=di)
    f["month"] = di.month
    f["dayofweek"] = di.dayofweek
    # time index berbasis awal seri
    f["time_index"] = (di - di.min()).days
    f["is_end_of_year"] = ((di.month == 12) & (di.day >= 22)).astype(int)
    f["is_new_year"]  = ((di.month == 1) & (di.day <= 7)).astype(int)

    eid = np.zeros(len(di), dtype=int)
    for d in EID_DATES:
        t = pd.Timestamp(d)
        eid |= ((di >= t - pd.Timedelta(days=14)) & (di <= t + pd.Timedelta(days=7))).astype(int)
    f["is_eid_window"] = eid
    return f
```

Gambar 3.3 Fungsi untuk membentuk fitur tambahan

```python
def build_features_level_target(y: pd.Series, cfg: FeatureCfg):
    y = pd.Series(pd.to_numeric(y, errors="coerce"), index=pd.DatetimeIndex(y.index)).astype(float)
    X = pd.DataFrame(index=y.index)
    X["lag_1"] = y.shift(1)
    for L in (cfg.add_lags or []):
        if L == 1: continue
        X[f"lag_{L}"] = y.shift(L)
    for W in (cfg.rolls or []):
        X[f"rollmean_{W}"] = y.shift(1).rolling(W, min_periods=max(1, W//2)).mean()
    X = X.join(make_flags(X.index))
    df = pd.concat([X, y.rename("y")], axis=1).dropna()
    y_target = df.pop("y")
    return df, y_target
```

Gambar 3.4 Fitur rolling dan lag

4. *Splittiing* Data

Data yang telah dilakukan *preprocessing* akan dibagi menjadi data latih dan data uji dimana data uji diinisialisasi pada suatu konstanta TEST_DAY yang berjumlah 365 hari (20% data uji), presentase *test set* sudah cukup untuk melihat pola musiman jangka pendek – menengah.

```python
X_train, X_test = X_all.iloc[:-TEST_DAYS], X_all.iloc[-TEST_DAYS:]
y_train, y_test = y_all.iloc[:-TEST_DAYS], y_all.iloc[-TEST_DAYS:]
```

Gambar 3.5 *Splitting data*

5. *Time series Cross Validation*

Setelah proses *splitting*, data testing nantinya dibagi menjadi beberapa fold secara bergantian agar setiap *fold* dapat diukur evaluasinya setelah proses *training* selesai. Pada **gambar 3.6** menggunakan 3 *fold*.

```python
max_lookback = int(max([1, *add_lags, *(rolls or [0])]))
try:
    tscv = TimeSeriesSplit(n_splits=N_SPLITS_CV, gap=max_lookback)
    gap_used = max_lookback
except TypeError:
    tscv = TimeSeriesSplit(n_splits=N_SPLITS_CV)
    gap_used = 0
```

Gambar 3.6 *Timeseries Cross Validation*

6. *Hyperparameter tuning*

Pencarian *hyperparameter* terbaik dilakukan dengan berbagai

kombinasi dengan menggunakan *GridSearchCV* dapat dilihat pada **gambar 3.7** yang nantinya akan dikombinasikan dengan *time series cross validation* untuk menghasilkan berbagai macam evaluasi akhir. Hyperparameter yang menjadi fokus eksperimen atau perancangan model prediksi adalah *n_estimators, learning_rate, max_depth,* dan *subsample*. Pemilihan optimal dilakukan dengan memaksimalkan nilai R2 rata – rata pada seluruh *fold*.

```
PARAM_GRID = {
    "learning_rate":      [0.05, 0.03, 0.01],
    "max_depth":          [1, 2, 3],
    "max_iter":           [150, 300, 450],
    "l2_regularization":  [0.0, 1e-3],
    "min_samples_leaf":   [10, 30],
}
```

Gambar 3.7 List Parameter

7. *Training* dan pembuatan model

Semua parameter utama pada model *gradient boosting* yang telah dipilih akan di latih untuk menemukan model final. Adapun parameter dan *hyperparameter* yang diujikan terdiri dari 12 kombinasi fitur *lag* dan *rollling mean* yang berbeda yang dapat dilihat pada **LAMPIRAN 10.**

Pada pembuatan model dilakukan inisialisasi dasar dengan *library* scikit – learn dengan tipe model HistGradientBoostingRegressor (**gambar 3.8**) yang merupakan *Gradient Boosting Machine* (GBM)

```
from sklearn.ensemble import HistGradientBoostingRegressor as HGBR
```

Gambar 3.8 Pemanggilan *library*

Semua model yang telah dicoba dalam banyak kombinasi otomatis akan ditentukan kombinasi terbaik **(gambar 3.9)** hasil dari *cross validation*

berdasarkan skor (R^2). Model terbaik langsung digunakan untuk memprediksi data uji.

```
best_model = gs.best_estimator_
cv_best_r2 = float(gs.best_score_)
```

Gambar 3.9 Mencari model terbaik

```
pack = {
    "model": best_record["model"],
    "feature_cols": best_record["feature_cols"],
    "best_config": {
        "mode": "level",
        "transform": "none",
        "alpha_blend": 1.0,
        "train_until": None,
        "exp_name": best_record["exp_name"],
    },
    "metrics": best_record["metrics"],
}
```

```
{'categorical_features': 'from_dtype',
 'early_stopping': True,
 'interaction_cst': None,
 'learning_rate': 0.05,
 'loss': 'squared_error',
 'max_depth': 3,
 'max_iter': 300,
 'tol': 1e-07,
 'validation_fraction': 0.15,
 'verbose': 0,
 'warm_start': False}
```

Gambar 3.10 Isi File Joblib

Setelah model terbaik ditemukan, model akan disimpan dalam format file .joblib (gambar 3.10). File .joblib berisi objek *python* dalam bentuk file biner (.joblib) yang biasanya dipakai untuk menyimpan model *machine learning* yang sudah dilatih. Isi dari pack berisi objek GradientBoostingRegressor dari library scikit-learn, *features-cols* berisi list nama kolom fitur yang digunakan untuk *training* (dapat dilihat pada tahapan *feature engineering*, *"best_config"* yaitu suatu *dictionary* konfigurasi yang menyimpan metadata dari model. Parameter mode bernilai *"level"* yang

menunjukkan bahwa model memprediksi nilai aktual (level) dari variabel target, bukan perubahan atau selisih antar waktu. Selanjutnya, transform bernilai *"none"* yang berarti tidak dilakukan transformasi apa pun pada data target, seperti log atau normalisasi, sehingga model dilatih langsung pada skala data asli.

Nilai alpha_blend sebesar 1.0 menandakan bahwa prediksi akhir sepenuhnya berasal dari model *Gradient Boosting* tanpa pencampuran dengan metode peramalan lain (blending). Terakhir, exp_name berisi nama eksperimen fitur terbaik, seperti kombinasi lag dan rolling mean (seperti *"lag14_roll30"*), yang menunjukkan konfigurasi input paling optimal berdasarkan hasil evaluasi model. Untuk melihat parameter atau *hyperparameter* dapat di

```
pack_path = best_dir / f"{city_safe}__{best_record['exp_name']}__best_pack.joblib"
joblib.dump(pack, pack_path)
```

Gambar 3.11 Penyimpanan Joblib

8. Evaluasi model

Setiap model akan dilakukan evaluasi untuk melihat performa akurasi dari model dengan metriks evaluasi MSE, RMSE, MAE, MAPE, dan R2 yang dapat dilihat pada gambar 3.12.

```
y_pred = best_model.predict(X_test)
r2_val = float(r2_score(y_test, y_pred))
mae_val = float(mean_absolute_error(y_test, y_pred))
rmse_val = float(rmse(y_test, y_pred))
mse_val = float(mean_squared_error(y_test, y_pred))
mape_val = float(mape_pct(y_test, y_pred))
```

Gambar 3.12 Evaluasi Model

3.1.3.3. Rancangan Antarmuka Sistem

Tampilan antarmuka terdiri dari halaman beranda yang berisi peta interaktif untuk mengukur rata – rata harga setiap provinsi atau setiap pulau serta disertai petunjuk cara penggunaan atau pengenalan aplikasi. Halaman selanjutnya yaitu fitur tinjauan tren harga yang terdiri dari fitur tren harian, mingguan, bulanan, dan tahunan. Halaman selanjutnya adalah fitur prediksi harga, di mana terdapat grafik perbandingan harga sebenarnya dengan harga terprediksi, dan fitur lain adalah halaman evaluasi dari model dari metriks evaluasi yang dipilih.

1. Modul beranda (*home page*)

   Halaman beranda berfungsi sebagai titik awal navigasi sistem yang menyediakan akses ke empat menu utama: Beranda, Tinjauan Tren, Prediksi, dan Evaluasi. Halaman ini memiliki 2 fitur utama yaitu *quick prediction* untuk melihat hasil prediksi kota yang ditampilkan dalam bentuk prediksi hari besok dari data aktual terakhir. Pada halaman beranda juga memungkinkan pengguna untuk memilih parameter analisis melalui dua dropdown selector yaitu pemilihan pulau dan pemilihan tahun data yang ingin dianalisis, serta mode tertil yang dipilih untuk membagi distribusi rata – rata harga. Setelah parameter dipilih, pengguna dapat mengaktifkan sistem dengan menekan

tombol "Tampilkan" untuk memuat dan memproses peta distribusi harga dalam bentuk rata – rata yang disajikan dalam.

Halaman ini juga berfungsi sebagai pusat informasi sistem yang menampilkan ringkasan tentang algoritma yang digunakan (*Gradient Boosting*) dan sumber data (PIHPS). Tampilan antarmuka beranda dapat dilihat pada **LAMPIRAN 7**.

2. Modul tinjauan tren

Halaman ini menyediakan ringkasan perilaku historis harga untuk wilayah dan tahun dimana *user* akan memilih *dropdown* pada Kabupaten/Kota, tahun, dan juga bulan. Jika menekan tombol 'Analisis Data' maka akan menampilkan kanvas grafik deret waktu yang menampilkan harga harian, bulanan, atau tahunan sesuai dengan *input user.*. Di bawah grafik disajikan empat indikator ringkas harga terendah, harga tertinggi, harga rata-rata, dan volatilitas yang dihitung langsung dari subset data yang sedang aktif.

Tinjauan Tren berfungsi sebagai konteks analitik sebelum peramalan: pengguna dapat melihat pola musiman, rentang fluktuasi, serta kejadian ekstrem, sehingga keputusan prediksi pada halaman berikutnya dilakukan dengan pemahaman terhadap dinamika historisnya. Tampilan antaramuka tinjauan *trend* dapat dilihat pada **LAMPIRAN 7.**

3. Modul Prediksi

Halaman prediksi memungkinkan pengguna menghasilkan estimasi harga pada tanggal yang ditentukan. Pada halaman prediksi terdapat 2 mode

prediksi yaitu prediksi untuk menguji data latih sehingga dapat melihat hasil evaluasi yang didapatkan pada setiap model kota, dan juga prediksi yang didasarkan pada harga terakhir sebenarnya dari data PIHPS untuk memprediksikan hari esok atau hari kedepan yang belum diketahui harga mendatang (sehingga belum diketahui secara tepat evaluasi dari harga prediksi).

Antarmuka menyediakan tanggal acuan "hari ini" (yakni observasi paling akhir yang tersedia pada *dataset*) serta pemilih tanggal prediksi. Ketika tanggal prediksi dipilih, sistem menghitung jarak hari (horizon) sebagai selisih kalender antara tanggal prediksi dan tanggal acuan. Jika horizon berada dalam rentang yang diizinkan (misalnya satu dua hari ke depan sesuai rancangan model), layanan prediksi akan mengambil model terlatih untuk kabupaten/kota yang dipilih, membentuk vektor fitur dari observasi terbaru (lag, statistik gulir, dan fitur kalender yang relevan), kemudian melakukan inferensi untuk menghasilkan harga prediksi. Hasil ditampilkan pada panel ringkasan yang memuat nilai prediksi (Rp/l), selisih terhadap harga hari ini (positif berarti kenaikan, negatif penurunan), indikasi tren singkat (naik, turun, atau relatif stabil), serta evaluasi model yang ditampilkan dalam bentuk metriks evaluasi.

Apabila pengguna memilih tanggal di luar jangkauan yang wajar atau sebelum tanggal acuan, sistem menampilkan peringatan dan menonaktifkan tombol prediksi agar tidak terjadi prediksi yang tidak valid. Dengan

pendekatan ini, halaman prediksi menjaga keterlacakan antara keluaran model dan batasan metodologisnya. Tampilan antaramuka prediksi dapat dilihat pada **LAMPIRAN 7.**

4. Modul Upload

Halaman *upload* digunakan *user* untuk mengunggah data dalam format .csv atau .xlsx. *Template* telah disediakan pada *apps* yang telah dibuat agar *user* langsung dapat melakukan *download* pada *template* dan mengisi data sesuai dengan format yang dapat diberikan.

Ketika *user* menekan *button* simpan dan analisis, maka *system* akan melakukan *training* pada *list of hyperparameter* dan parameter yang di *loop* pada program untuk mencari evaluasi paling prediktif di antara semua kombinasi yang ada. Tampilan antarmuka dapat dilihat pada **LAMPIRAN 7.**

5. Modul Tentang

Halaman tentang digunakan sebagai bentuk informasi terkait aplikasi yang akan dibuat. Halaman ini juga berisi mengenai penjelasan singkat terkait metode yang digunakan serta kelebihannya. Langkah – langkah penggunaan setiap fitur juga disajikan secara singkat dan jelas agar *user* dapat menggunakan aplikasi dengan mudah. Tampilan antarmuka dapat dilihat pada **LAMPIRAN 7.**

BAB IV

PENGUJIAN

4.1. Cara Pengujian

Sistem Prediksi Minyak yang telah dirancang akan diuji dengan mengukur keakurasian (evaluasi) dan keseluruhan fitur dan sistem yang dikembangkan. Pengujian dilakukan dengan 3 tahapan,

1. Pengujian sistem terhadap akurasi model *gradient boosting* berdasarkan evaluasi dari data uji selama 1 tahun terakhir (1 Juli 2024 – 1 Juli 2025) dari keseluruhan dataset, dengan mengukur evaluasi model menggunakan metriks evaluasi yang sesuai pada setiap kombinasi *hyperparameter* yang diuji untuk menemukan model terbaik. Pengujian ini juga diserta analisis – analisis yang berkaitan yaitu analisa performa model keseluruhan, analisa performa model terhadap (R^2), analisa performa model terhadap MAPE, Analisa pengaruh *Hyperparameter* dan parameter dalam performa model, dan analisa korelasi
2. Pengujian kedua dilakukan dengan cara melakukan *Black box Testing* terhadap fungsi dan kinerja program (*functional testing*).
3. Pengujian ketiga dilakukan dengan cara *User Acceptance Testing* (UAT) pada 10 *user* (masyarakat umum dan 2 pemilik UMKM).

4.2. Hasil Pengujian

Pengujian dilakukan untuk memastikan bahwa semua fitur dan modul dalam aplikasi yang telah dikembangkan berfungsi dengan baik dan sesuai dengan apa yang diharapkan.

4.2.1. Hasil Pengujian Pelatihan Model

Pengujian dilakukan dengan menggunakan data uji 1 tahun terakhir (Rentang waktu 1 Juli 2024 – 1 Juli 2025) dari total 5 tahun data latih yang digunakan pada 100 kota yang digunakan. Metode evaluasi yang digunakan yaitu metriks R2, MSE, MAE, MAPE, RMSE. Pengujian pelatihan model memiliki parameter input yaitu lag *feature* dan *roll feature*, serta penggunaan *hyperparameter tuning* yang dilakukan dengan 12 kombinasi skenario eksperimen parameter yang berbeda **(LAMPIRAN 9)**. Analisa akan fokus terhadap keseluhan performa model di Kabupaten/Kota yang dianalisa, Performa kota dengan evaluasi terbaik dan terburuk berdasarkan R2 (*coefficient of determinant*)

4.2.1.1. Analisa Performa Model Keseluruhan Kabupaten/Kota

Analisa ini membahas performa keseluruhan model Gradient Boosting yang digunakan dalam memprediksi harga minyak goreng pada 100 kabupaten/kota di Indonesia. Analisis dilakukan untuk mengetahui sejauh mana model mampu memberikan hasil prediksi yang akurat secara umum berdasarkan pengujian metriks evaluasi yang digunakan serta grafik perbandingan harga sebenarnya (actual) dengan harga terprediksi.

Berdasarkan performa Model, terdapat 91 Kabupaten/Kota yang mencapai *Coefficient of Determinant* (R^2) lebih besar sama dengan 0.5, dan terdapat 9 Kabupaten/Kota yang tidak mencapai *Coefficient of Determinant* (R2) 0,5. Berdasarkan rata – rata keseluruhan dari (R^2), terdapat 11 Kabupaten/Kota yang tidak mencapai keseluruhan rata – rata dari (R^2) keseluruhan kota yaitu 0.78203. Tabel disajikan untuk menampilkan keseluruhan performa terbaik setiap kota

4.2.1.2. Analisa Performa Model Terhadap R2 (*Coefficient of Determinant*)

Analisa ini membahas terkait 10 Kabupaten Kota dengan nilai (R^2) tertinggi dan 10 Kabupaten/Kota terendah, serta faktor – faktor yang menjadi pengaruh terkait nilai tersebut. Ada beberapa faktor yang mempengaruhi nilai dari evaluasi, yaitu kelengkapan data, parameter input, dan hyperparameter

Tabel 4.1 Daftar 8 Kota dengan (R^2) tertinggi

Kota	LAGS	ROLLS	Learning_rate	max_depth	max_iter	R2
Kota Bogor	[1, 30]	[30]	0.05	1	300	0.944
Kab. Sumenep	[1]	[7]	0.01	2	450	0.9425
Kota Metro	[1, 7]	[7]	0.05	1	450	0.9424
Kota Yogyakarta	[1]	[7]	0.03	1	450	0.9418
Kotamobagu	[1]	[7]	0.03	1	450	0.9418
Kota Depok	[1, 14]	[]	0.05	2	450	0.9417
Kota Surabaya	[1]	[30]	0.03	1	450	0.9414
Kota Bekasi	[1]	[7]	0.05	3	300	0.9413
Kota Pontianak	[1, 14]	[7]	0.05	3	150	0.9404
Kota Jakarta Pusat	[1, 14]	[]	0.03	3	450	0.9403

Kabupaten/Kota dengan performa nilai (R^2)yang cenderung stabil (tidak terlalu tinggi tapi juga tidak rendah) umumnya memiliki pola data harga yang relatif bergelombang halus atau moderat, bukan berupa garis lurus yang benar-

benar konstan, tetapi juga tidak menunjukkan fluktuasi ekstrem seperti lonjakan tajam atau penurunan drastis dalam waktu singkat. Pola seperti ini menandakan bahwa harga di wilayah tersebut masih mengalami perubahan dari waktu ke waktu, namun dalam batas yang cukup wajar dan teratur — misalnya naik-turun secara bertahap mengikuti tren musiman atau kondisi pasar lokal. Dengan pola seperti ini, model masih dapat mengenali hubungan antar variabel dengan cukup baik, meskipun tidak sempurna, sehingga menghasilkan nilai (R^2)yang menengah dan stabil.

1. Kota Bogor

   Model menggunakan lag hari ke-1 dan ke-30 dan *rolling average* 30 hari. Hal Ini berarti model menangkap tren harian dan musiman bulanan sekaligus. *Learning rate* sebesar 0.05 dengan 300 iterasi menunjukkan *trade-off* di mana laju belajar relatif cepat sehingga hanya perlu 300 pohon untuk konvergen Depth pohon hanya 1 (sangat dangkal), menandakan harga cenderung berubah dalam pola linear sederhana – keputusan ini membantu menghindari overfitting. (R^2) sebesar 0.94 menandakan model ini berhasil menjelaskan 94% variasi harga aktual, sejalan dengan tren kenaikan harga curah yang stabil. Grafik perbandingan harga prediksi dan harga aktual dapat dilihat pada

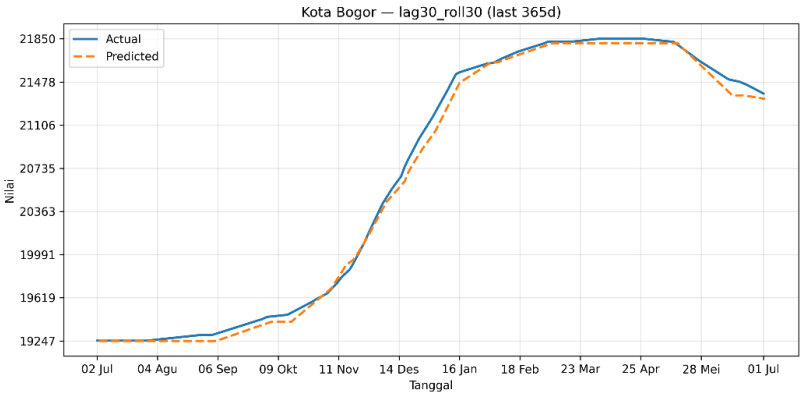

Gambar 4.1 Perbandingan Grafik Aktual – Prediksi Kota Bogor

2. Kabupaten Sumenep

Model memakai lag 1 hari dan rolling 7 hari (mingguan). Learning rate rendah 0.01 dengan iterasi 450 artinya belajar sangat lambat dan butuh banyak pohon untuk konvergensi, sesuai prinsip bahwa *lr* kecil memerlukan iterasi lebih banyak. Kedalaman pohon 2 sedikit lebih besar, menunjukkan kompleksitas pola harga di sini sedikit lebih tinggi. ROLL mingguan menunjukkan harga di Sumenep dipengaruhi fluktuasi seminggu sebelumnya. R2=0.9425 juga sangat tinggi; hal ini wajar karena harga curah secara umum naik, sehingga model lag(1) + roll(7) dapat memprediksi pola naik tersebut.

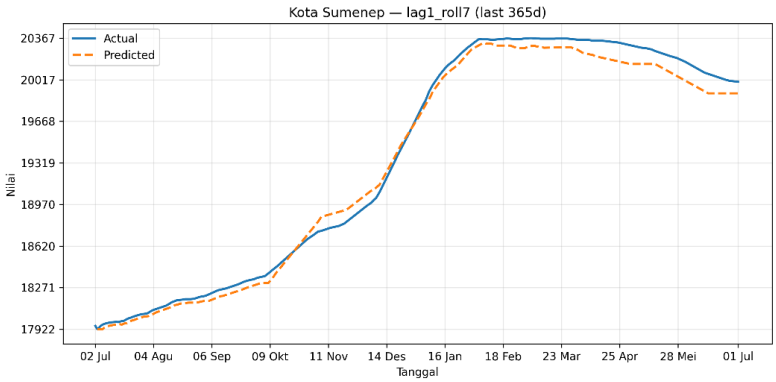

Gambar 4.2 Perbandingan Grafik Aktual – Prediksi Kota Sumenep

3. Kota Metro

Model menggunakan lag 1 dan 7 hari, serta roll 7-hari, dan R^2 mencapai 0.9424. Lag harian dan mingguan serta rata-rata mingguan menangkap tren jangka pendek dan siklus mingguan. *Learning rate* = 0.05, depth=1 (pohon dangkal) menunjukkan model sederhana sudah cukup untuk pola mingguan ini. Kombinasi parameter ini konsisten dengan fluktuasi mingguan di Metro, tercermin dari R^2 yang tinggi.

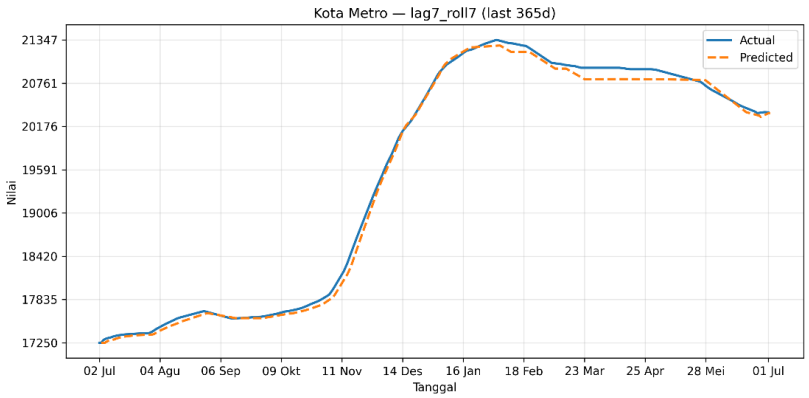

Gambar 4.3 Perbandingan Grafik Aktual – Prediksi Kota Metro

4. Kota Yogyakarta

Model menggunakan lag 1 dan 7 hari, serta roll 7-hari, dan R^2 mencapai 0.9418. Lag harian dan mingguan serta rata-rata mingguan menangkap tren jangka pendek dan siklus mingguan. *Learning rate* = 0.05, depth=1 (pohon dangkal) menunjukkan model sederhana sudah cukup untuk pola mingguan ini. Kombinasi parameter ini konsisten dengan fluktuasi mingguan di Yogyakarta, tercermin dari R^2 yang tinggi.

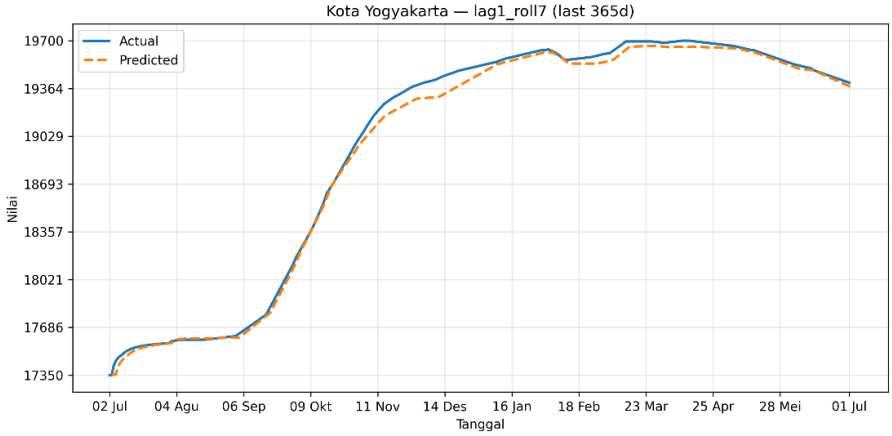

Gambar 4.4 Perbandingan Grafik Aktual – Prediksi Kota Yogyakarta

5. Kotamobagu

Model menggunakan lag 1 dan 7 hari, serta roll 7-hari, dan R^2 mencapai 0.9418. Lag harian dan mingguan serta rata-rata mingguan menangkap tren jangka pendek dan siklus mingguan. *Learning rate* = 0.05, depth=1 (pohon dangkal) menunjukkan model sederhana sudah cukup untuk pola mingguan ini. Kombinasi parameter ini konsisten dengan fluktuasi mingguan di Metro, tercermin dari R^2 yang tinggi.

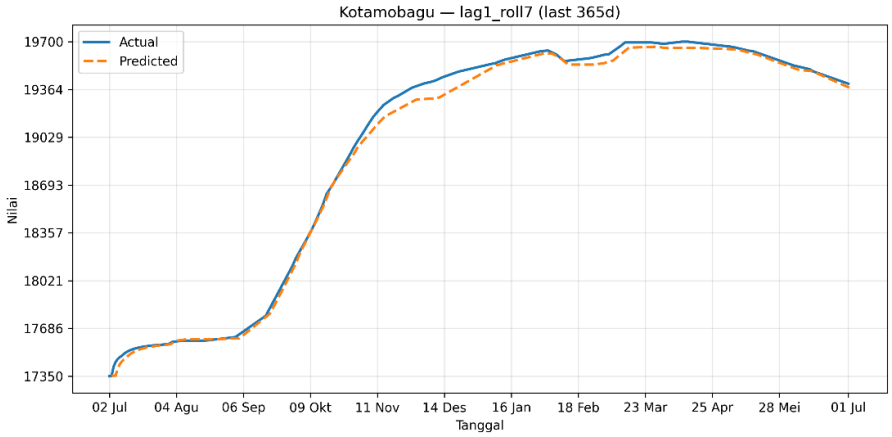

Gambar 4.5 Perbandingan Grafik Aktual – Prediksi Kota Mobagu

6. Kota Depok

Model menggunakan lag 1 dan 14 hari (dua minggu terakhir), tanpa fitur rolling. Learning rate 0.05 dan iterasi 450 menunjukkan porsi pohon masih cukup banyak. Max depth 2 menunjukkan sedikit lebih banyak kompleksitas dibanding kebanyakan kota (depth=1), mungkin karena Depok memerlukan model lebih kompleks untuk mengikuti pola volatilitas lokal. Meski tanpa rolling, (R^2) tetap 0.942, artinya lag 14 hari sudah cukup mewakili pengaruh tren dua mingguan di Depok.

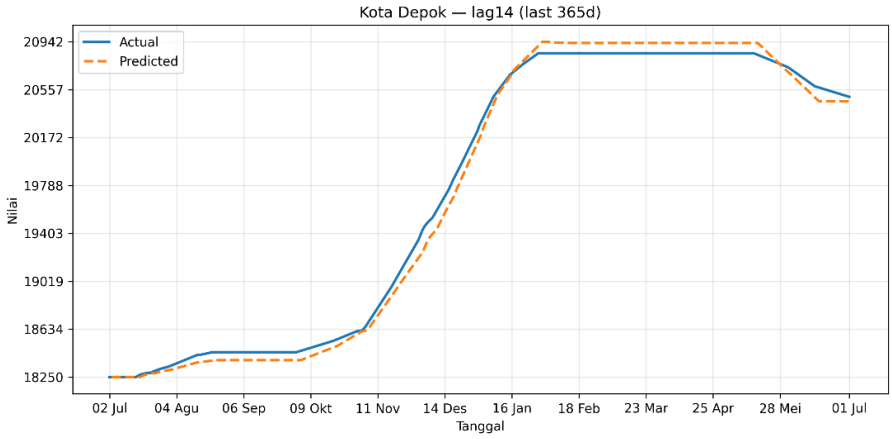

Gambar 4.6 Perbandingan Grafik Aktual – Prediksi Kota Depok

7. Kota Surabaya

Model menggunakan lag 1 hari dan rolling 30 hari (bulanan), *learning rate* 0.03. model fokus pada korelasi dengan harga sehari sebelumnya plus tren bulanan (rolling 30-hari).

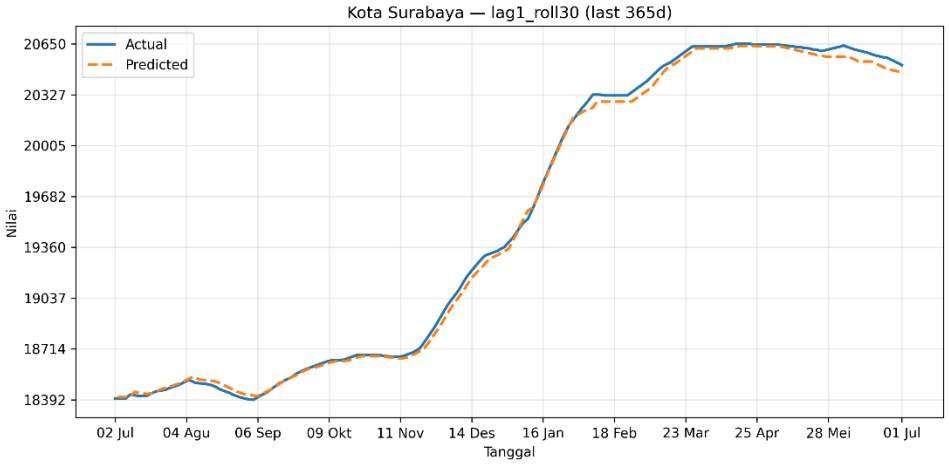

Gambar 4.7 Perbandingan Grafik Aktual – Prediksi Kota Surabaya

8. Kota Bekasi

Fitur lag harian 1 dan tidak ada rolling. Learning rate 0.05, iter 300 (lebih sedikit iter karena LR relatif lebih besar). Max depth 3 (paling tinggi dari daftar) mengindikasikan pola harga lebih kompleks sehingga pohon lebih dalam dipakai agar model dapat menyesuaikan. R2 0.9413 mengindikasikan meski tanpa fitur rolling, depth besar membantu model menangkap fluktuasi harga Bekasi yang mungkin tidak linear.

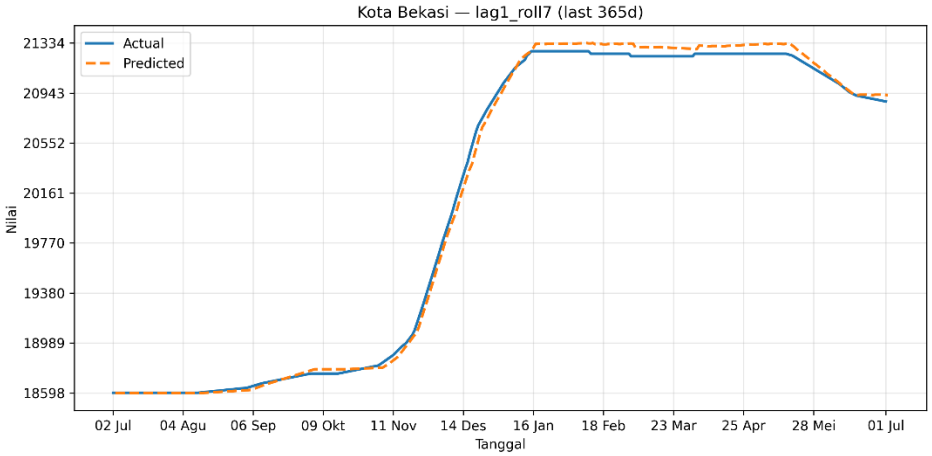

Gambar 4.8 Perbandingan Grafik Aktual – Prediksi Kota Bekasi

9. Kota Pontianak

Model menggunakan Lag 1 dan 14 hari, rolling 7 hari, LR 0.05, depth 3, iter 150 (paling sedikit iter). Kombinasi ini unik: LR relatif tinggi (0.05) tetapi iter hanya 150, mungkin karena *early stopping* atau konvergensi cepat. Max depth 3 menunjukkan model sangat kompleks untuk menyesuaikan pola Pontianak. Roll 7 hari menambah komponen mingguan. R2 ~0.94, menandakan model ini juga cukup menjelaskan tren harga—walaupun iter sedikit, LR besar membantu cepat fit tren naik.

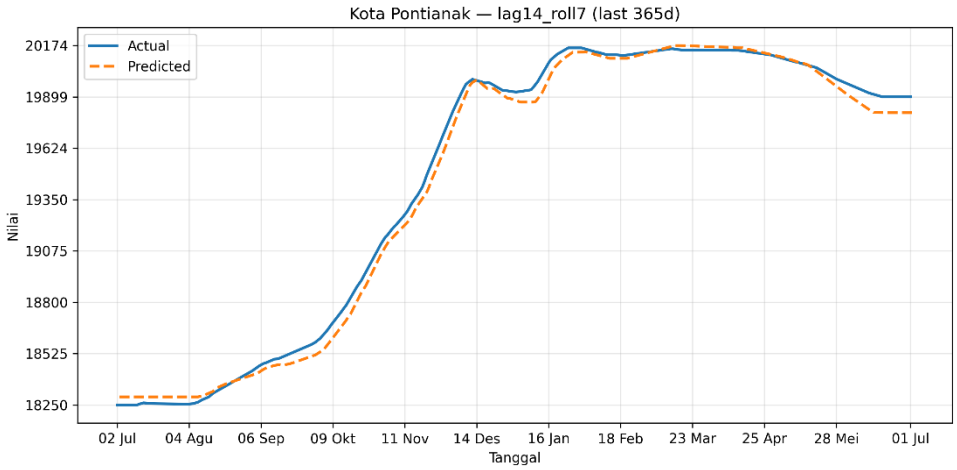

Gambar 4.9 Perbandingan Grafik Aktual – Prediksi Kota Pontianak

10. Kota Jakarta Pusat

Lag 1 dan 14 hari, tanpa rolling, LR 0.03, depth 3, iter 450. Model mirip Pontianak namun tanpa roll. Depth 3 dan banyak iter dibutuhkan karena pola naik turun harga mungkin rumit di kota besar. R2 0.9403 walau sedikit lebih rendah tetap tinggi. Tren dua minggu (lag 14) membantu menangkap siklus per dua minggu, tanpa perlu roll.

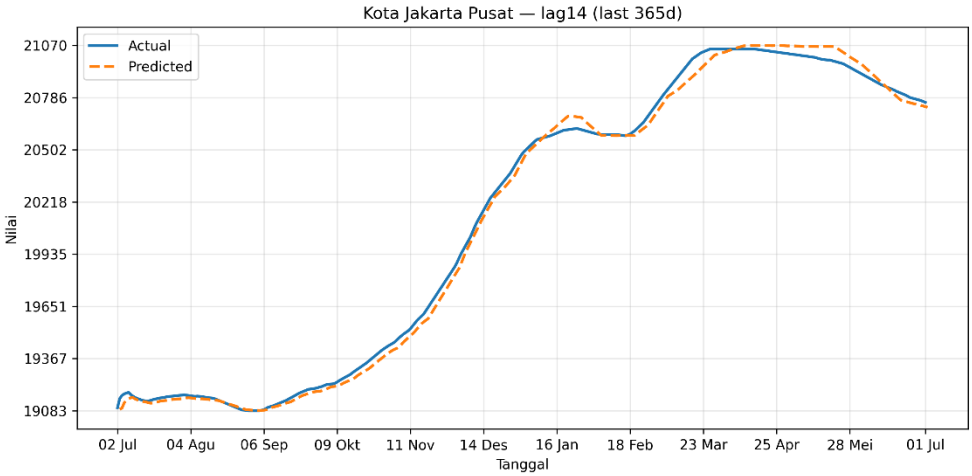

Gambar 4.10 Perbandingan Grafik Aktual – Prediksi Kota Jakarta Pusat

Tabel 4.2 Daftar 8 Kota dengan (R^2) terendah

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	R2
Kota Banggai	[1, 14]	[7]	0.01	2	150	-2.1861
Kab. Jayawijaya	[1]	[]	0.05	1	150	-0.2993
Kota Bandar Lampung	[1, 30]	[30]	0.05	1	300	-0.2004
Kab. Nabire	[1]	[]	0.05	1	150	-0.113
Kota Balikpapan	[1]	[]	0.05	3	150	0
Kota Banda Aceh	[1]	[]	0.05	3	150	0
Kota Padang Sidempuan	[1]	[]	0.01	3	450	0.595
Kab. Manokwari	[1, 7]	[7]	0.05	3	150	0.7173

1. Kota Banggai

Model untuk Kota Banggai menunjukkan performa yang sangat buruk dengan R^2 = -2.1861. Pada kasus data Kota Banggai, cenderung memiliki pola data latih yang kurang variatif sehingga model cenderung kesulitan dalam menangkap pola. Kombinasi lag [1, 14] dan roll [7] seharusnya mampu menangkap pola mingguan dan dua minggu, namun learning rate yang terlalu kecil (0.01) dan jumlah iterasi 150 – 450 juga membuat model tidak belajar optimal (*underfitting*), Meskipun kedalaman pohon ditingkatkan ke 2, hasil

negatif menandakan prediksi model jauh dari aktual. Hal ini terjadi kemungkinan besar karena data yang tidak stabil atau noise tinggi. Kota Banggai juga memiliki data yang tidak lengkap mulai tahun 2020 sampai dengan 14 Desember 2022 sehingga ketika di *handle* dengan *missing value* menghasilkan nilai konstan di harga Rp 16350 sepanjang tahun 2020 – 2022, sehingga proses pelatihan model tidak berlangsung dengan optimal

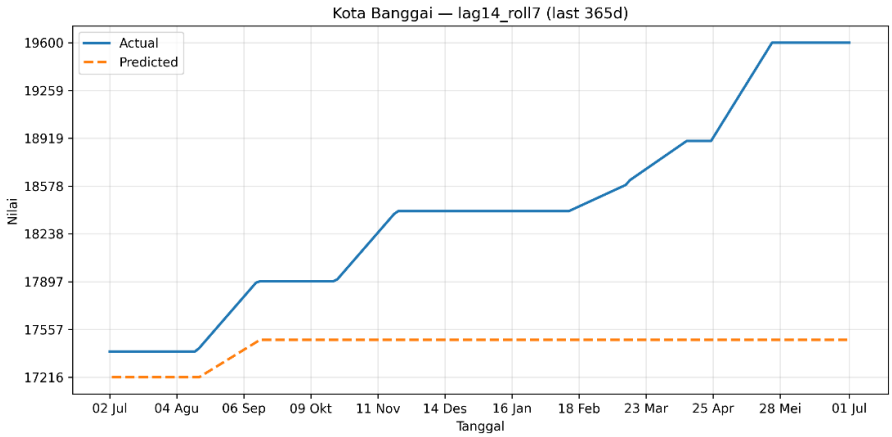

2. Kabupaten Jayawijaya

Model pada Kabupaten Jayawijaya dengan R^2 = -0.2993, model ini menunjukkan bahwa prediksi sangat tidak akurat. Parameter yang digunakan sangat minim, hanya lag ke-1 tanpa rolling atau kedalaman tinggi. Hal ini menandakan bahwa pergerakan harga di daerah ini tidak cukup ditangkap hanya dari harga kemarin. Model ini butuh tambahan fitur atau data preprocessing yang lebih baik. Pada harga sebenarnya dapat dilihat pola harga data latih yang konstan dari tahun 2020 sampai dengan tahun 2024 sehingga model mengalami *underfitting* dan kesulitan dalam menangkap pola harga yang fluktuatif dari bulan Maret Akhir sampai dengan bulan Juli.

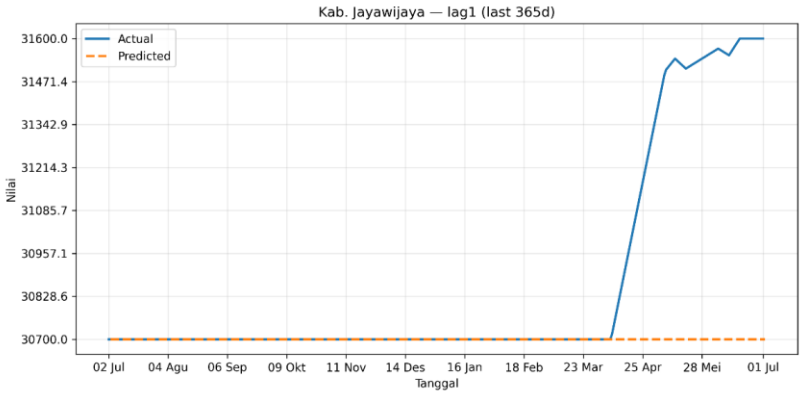

Gambar 4.11 Perbandingan Grafik Aktual – Prediksi Kota Jayawijaya

3. Kota Bandar Lampung

Kota Bandar Lampung Meskipun menggunakan parameter yang lebih kompleks (*lags* [1, 30], *roll* [30], depth 1, iterasi 300), model ini tetap menghasilkan R^2 negatif (-0.2004). Kemungkinan karena data historis sangat fluktuatif atau noise tinggi, sehingga meskipun dengan upaya pelatihan lebih lama, model tidak mampu generalisasi dengan baik.

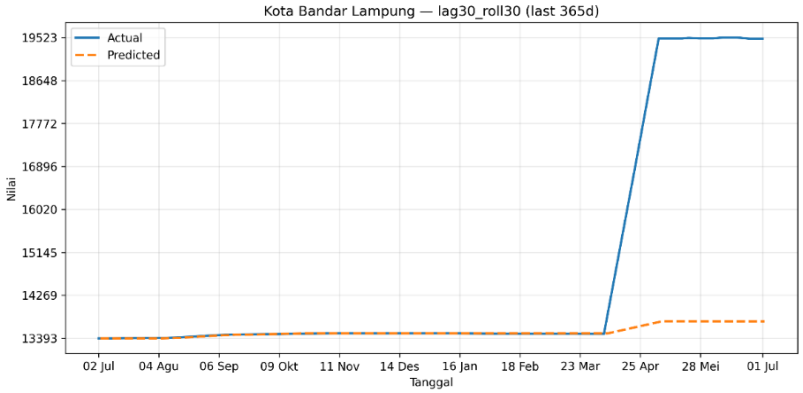

Gambar 4.12 Perbandingan Grafik Aktual – Prediksi Kota Bandar Lampung

4. Kabupaten Nabire

Kabupaten Nabire memiliki R^2 model sebesar -0.113 mengindikasikan performa yang masih di bawah ekspektasi. Faktor terbesar yang

menyebabkan model memiliki evaluasi yang rendah adalah data latih yang kosong dan buruk dimana data hanya memiliki 1 nilai konstan tetapi data uji meningkat di bulan April sampai Juli.Parameter yang digunakan minimal dan iterasi rendah mungkin membuat model terlalu dangkal. Ini menunjukkan bahwa dinamika harga minyak goreng di daerah ini memerlukan kompleksitas lebih tinggi dalam input fitur. Namun, jika dilihat pola harga pada grafik dapat dilihat bahwa di bulan April 2025 sampai Juli terjadi kenaikan dari bulan – bulan sebelumnya yang cenderung stabil.

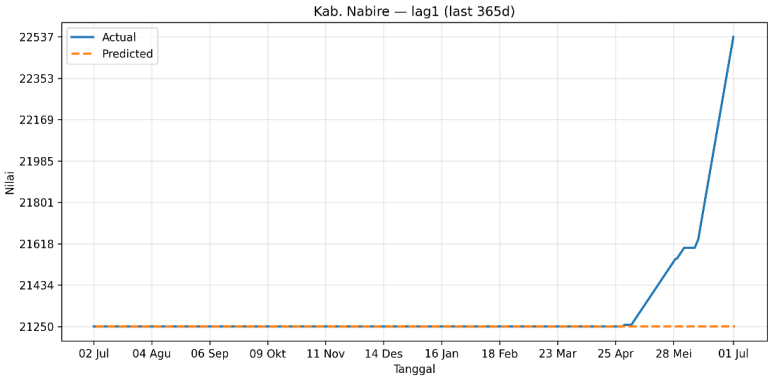

Gambar 4.13 Perbandingan Grafik Aktual – Prediksi Kota Nabire

5. Kota Balikpapan

Dengan konfigurasi yang sama seperti Polewali Mandar, hasil model R^2 = 0. Ini menandakan bahwa model belum mampu belajar dari data yang tersedia (*underfitting*). Hal ini disebabkan oleh variasi harga yang acak atau pola harga tidak mengikuti tren tertentu, terutama pada data latih di kota Balikpapan memiliki harga yang cenderung tidak konstan di tahun 2020 - 2024, namun pada data uji, harga aktual malah mengalami konstan di 1 nilai yaitu di harga Rp 21710, sehingga model mengalami *underfititng*

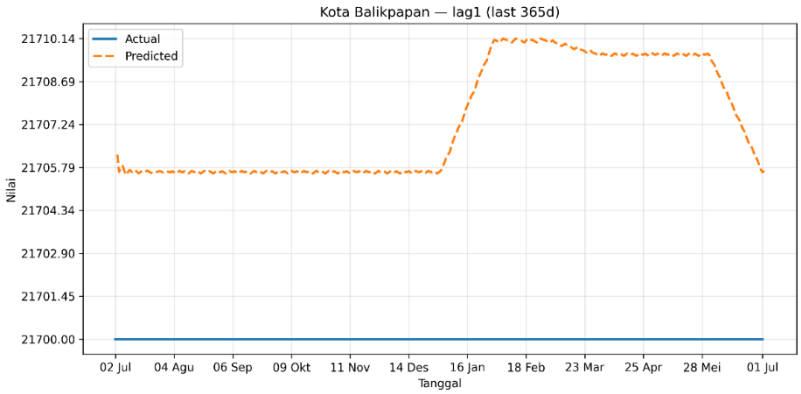

Gambar 4.14 Perbandingan Grafik Aktual – Prediksi Kota Balikpapan

6. Kota Banda Aceh

Kota Banda Aceh memiliki model yang tidak menunjukkan keunggulan (R^2 = 0) meskipun kompleksitasnya cukup tinggi. Hal ini menandakan bahwa data harga minyak goreng di Banda Aceh tidak menunjukkan pola yang dapat ditangkap oleh model berbasis lag harian saja. Pada grafik dapat dilihat bahwa berusaha mempelajari pola dari data sebelumnya (karena ini lag1, berarti model pakai nilai-nilai harga dari hari sebelumnya sebagai prediktor). Namun, karena data aktualnya terlalu datar dan variasinya sangat kecil, model "membaca" adanya sedikit tren naik–turun dari noise atau ketidakseimbangan kecil pada data latih. Akibatnya, hasil prediksinya menunjukkan pola kenaikan bertahap di awal tahun lalu penurunan menjelang akhir, padahal sebenarnya harga riil tetap stabil.

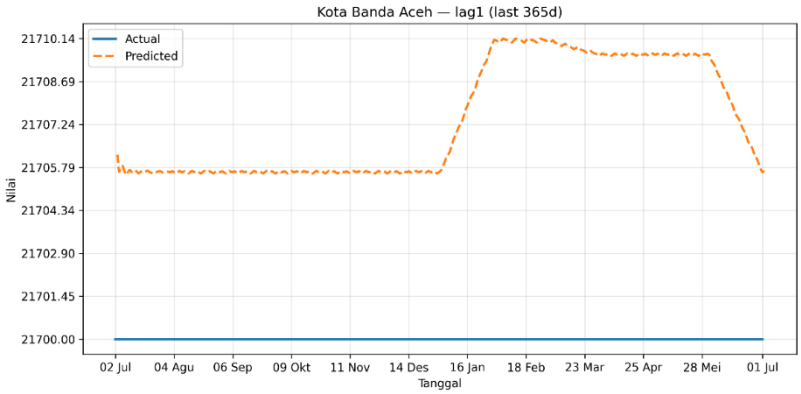

Gambar 4.15 Perbandingan Grafik Aktual – Prediksi Kota Banda Aceh

7. Kota Padang Sidempuan

Kota Padang Sidempuan memiliki model dengan performa yang lebih baik dengan R^2 = 0.595, dibandingkan kota – kota sebelumnya. Parameter sederhana (lag ke-1, no rolling) dengan learning rate 0.01 dan iterasi 450, serta depth 3, memungkinkan model belajar dengan baik. Kemungkinan data historis cukup stabil dan mengikuti pola tertentu. Pada grafik menunjukkan harga aktual mengalami kenaikan bertahap yang cukup jelas, terutama dari Juli hingga Januari, kemudian stabil di level tinggi hingga akhir periode. Model prediksi (garis oranye) berhasil mengikuti pola kenaikan tersebut dengan cukup baik, meskipun cenderung sedikit lebih cepat naik dan berhenti di level yang lebih tinggi dibanding data aktual. Hal ini menandakan bahwa model mampu menangkap arah tren naik secara umum, tetapi masih memiliki sedikit overestimation di akhir periode.

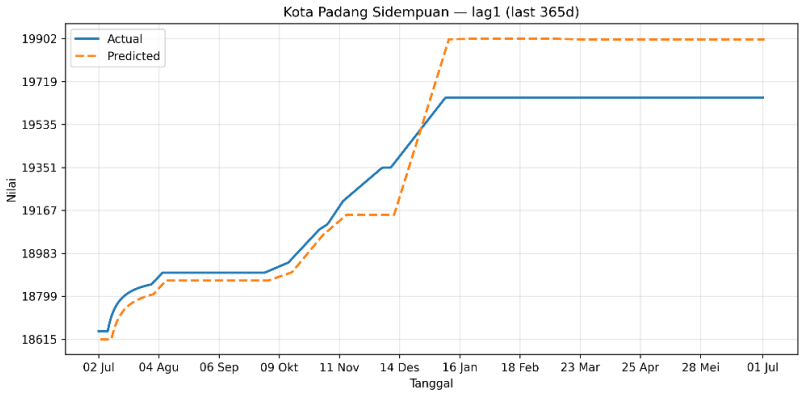

Gambar 4.16 Perbandingan Grafik Aktual – Prediksi Kota Padang Sidempuan

8. Kabupaten Manokwari

Kabupaten Manokwari Model mencatat R^2 = 0.7173 yang tergolong baik. Kombinasi lag harian dan mingguan, serta rolling mingguan, membantu menangkap pola jangka pendek dan fluktuasi. Depth 3 memberikan kompleksitas yang cukup, dan iterasi 150 cukup untuk menyatu dengan data aktual.

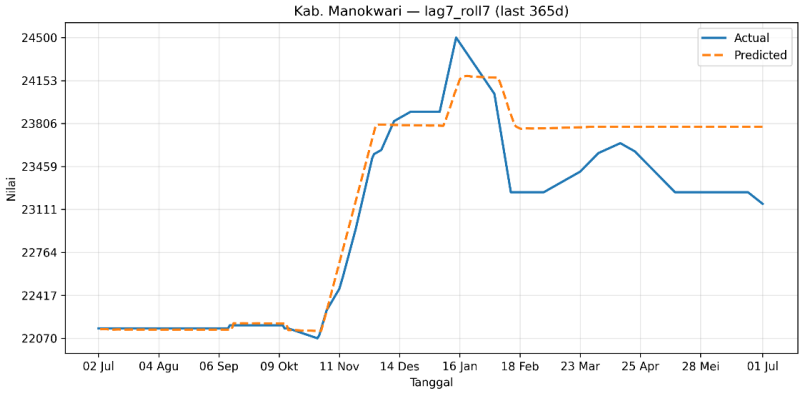

Gambar 4.17 Perbandingan Grafik Aktual – Prediksi Kabupaten Manokwari

Tabel disajikan untuk menampilkan keseluruhan performa terbaik setiap kota

4.2.1.3. Analisa Performa Model Terhadap MAPE

Analisa ini membahas terkait 5 Kabupaten Kota dengan nilai MAPE tertinggi dan terendah, serta faktor – faktor yang menjadi pengaruh terkait nilai tersebut. Ada beberapa faktor yang mempengaruhi nilai dari evaluasi, yaitu kelengkapan data, parameter input, dan hyperparameter. MAPE adalah nilai persentase *error*, sehingga semakin kecil nilai MAPE maka nilai kesalahan antara nilai prediksi dan nilai sebenarnya juga semakin kecil.

Kota Maumere, Kota Ternate memiliki nilai MAPE yang cukup baik **(tabel 4.2)** didukung dengan kelengkapan dan variasi data yang cukup baik serta pemilihan *hyperparameter* kombinasi yang pas **(LAMPIRAN 11)** membuat nilai R2 tinggi dan MAPE yang relatif kecil. Kabupaten Polewali Mandar dan Kota Balikpapan memiliki nilai aktual yang sama di semua titik data uji, meskipun pada data latih persebaran harga tidak konstan di nilai yang sama, sehingga menyebabkan *baseline* (rata-rata) dapat memprediksi harga lebih baik dibandingkan model yang telah dibuat.

Tabel 4.3 Daftar 5 Kota dengan $MAPE$ terendah

Kota	R2	MAE	RMSE	MSE	MAPE(%)
Kota Maumere	0.9049	29.4354	79.4812	6317.265	0.13
Kota Ternate	0.9358	22.5659	50.6214	2562.526	0.1
Kab. Polewali Mandar	0	10.8551	14.4827	209.7495	0.05
Kota Balikpapan	0	7.3557	7.6596	58.6697	0.03
Kota Banda Aceh	0	7.3557	7.6596	58.6697	0.03

Kota – kota dengan nilai MAPE tertinggi dapat dilihat pada **tabel 4.3**. Kota

Bandar Lampung memiliki perbedaan harga di nilai uji yang cukup jauh mulai bulan April hingga Juli 2025 mengakibatkan persentase error yang tinggi, hal ini disebabkan data yang tiba – tiba melonjak di bulan April – Juli, padahal di periode waktu sebelumnya data menunjukkan persebaran harga yang cukup stabil.

Tabel 4.3 Daftar 5 Kota dengan $MAPE$ tertinggi

Kota	R2	MAE	RMSE	MSE	MAPE(%)
Kota Bandar Lampung	-0.2004	1378.905	2815.002	7924235	7.08
Kota Banggai	-2.1861	1032.051	1209.355	1462539	5.47
Kota Batam	0.8125	326.0091	400.7366	160589.8	1.71
Kota Malang	0.8455	294.4779	408.9303	167224	1.4
Kab. Manokwari	0.7173	292.3017	423.2198	179115	1.25

4.2.1.4. Analisa Pengaruh Hyperparameter dan Parameter dalam Performa Model

Analisa hanya dilakukan pada 12 eksperimen skenario yang telah ditentukan. Beberapa Kabupaten/Kota tidak menunjukkan perubahan performa yang signifikan dalam 12 kombinasi skenario eksperimen yang ada, namun ada beberapa kota yang menunjukkan perubahan yang drastis terhadap nilai R^2 di eksperimen yang berbeda seperti pada kota berikut.

1. Kabupaten Klaten

   Perbedaan drastis nilai R^2pada hasil eksperimen Kabupaten Klaten terutama disebabkan oleh kombinasi learning rate, jumlah iterasi, dan fitur lag/rolling yang memengaruhi kemampuan model menangkap pola musiman harga. Model dengan learning_rate=0.05, max_iter tinggi (300–450), dan

kombinasi lag-rolling seperti [1,7] atau [1,14] berhasil mempelajari tren kenaikan dan penurunan harga dengan baik, sehingga garis prediksi (oranye) mengikuti pola aktual (biru) secara halus. Sebaliknya, saat learning_rate diturunkan ke 0.01 tanpa menambah jumlah iterasi, model menjadi underfit karena proses boosting tidak sempat konvergen, menghasilkan prediksi yang cenderung datar dan tertinggal jauh dari nilai aktual. Selain itu, hilangnya fitur rolling atau lag yang relevan menyebabkan model kehilangan konteks waktu dan pola berulang yang penting dalam data deret waktu, memperparah penurunan performa. Secara visual, grafik menegaskan hal ini: konfigurasi optimal memperlihatkan prediksi yang naik dan turun mengikuti harga sebenarnya, sementara konfigurasi buruk menunjukkan prediksi yang lemah dan tidak responsif terhadap perubahan tren. Kombinasi tersebut membuktikan bahwa keseimbangan antara laju pembelajaran, kapasitas model, dan desain fitur waktu menjadi kunci utama untuk mencapai prediksi yang stabil dan akurat.

Tabel 4.4 Daftar Uji coba eksperimen Kabupaten Klaten

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab.Klaten	[1, 7]	[30]	0.05	3	300	0.885
Kab.Klaten	[1, 14]	[7]	0.05	3	150	0.8844
Kab.Klaten	[1, 14]	[30]	0.05	3	450	0.8828
Kab.Klaten	[1]	[30]	0.05	3	450	0.8827
Kab.Klaten	[1, 30]	[7]	0.05	3	150	0.8782
Kab.Klaten	[1, 14]	[]	0.05	3	150	0.878
Kab.Klaten	[1]	[7]	0.05	3	150	0.8756
Kab.Klaten	[1, 30]	[]	0.05	3	150	0.8676
Kab.Klaten	[1, 30]	[30]	0.05	3	150	0.8645
Kab.Klaten	[1]	[]	0.01	3	150	-1.1137

Kab.Klaten	[1, 7]	[]	0.01	3	150	-1.1377
Kab.Klaten	[1, 7]	[7]	0.01	2	150	-1.9158

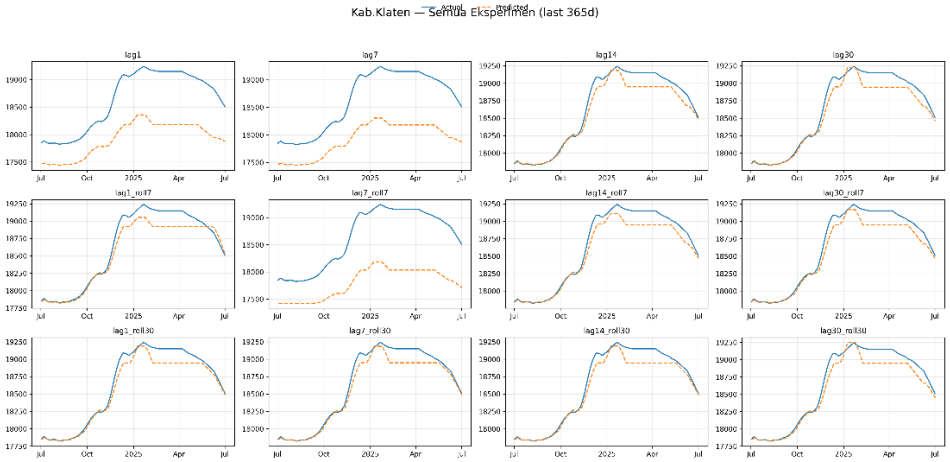

Gambar 4.18 Daftar Ekperimen Kabupaten Klaten

2. Kota Kendari

Penurunan drastis nilai R^2 pada Kota Kendari disebabkan oleh kombinasi faktor antara struktur fitur dan pengaturan hyperparameter yang memengaruhi stabilitas model. Pada konfigurasi sederhana dengan lag 1, learning rate 0.05, dan depth 2, model mampu menangkap pola autokorelasi kuat harga minyak—karena seri ini bersifat persisten—sehingga prediksi mengikuti tren aktual dengan baik. Namun, saat ditambah banyak lag atau rolling window, fitur menjadi sangat berkorelasi dan jika tidak diselaraskan dengan benar (misalnya tidak menggunakan .shift(1) pada rolling), model berisiko mengalami data leakage atau kehilangan informasi temporal yang valid. Kombinasi learning rate terlalu kecil, depth lebih dalam, dan iterasi tinggi membuat model overfitting pada noise atau malah *underfitting* karena pembelajaran terlalu lambat, menghasilkan prediksi yang hampir konstan dan

menjatuhkan R^2 hingga negatif. Grafik memperlihatkan hal ini: pada model bagus, garis oranye (prediksi) mengikuti tren naik biru (aktual), sedangkan pada model gagal prediksinya datar atau tertinggal jauh. Jadi, perubahan kecil pada lag, rolling, dan hyperparameter mengganggu keseimbangan antara kompleksitas, regularisasi, dan ketepatan waktu fitur, menyebabkan performa model menurun tajam.

Tabel 4.5 Daftar Uji coba eksperimen Kota Kendari

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Kendari	[1]	[]	0.05	2	150	0.8886
Kota Kendari	[1]	[30]	0.05	2	150	0.8405
Kota Kendari	[1, 14]	[30]	0.05	2	300	0.8235
Kota Kendari	[1, 7]	[30]	0.05	2	150	0.8207
Kota Kendari	[1, 30]	[30]	0.01	3	300	0.6275
Kota Kendari	[1, 30]	[]	0.01	3	300	0.62
Kota Kendari	[1, 30]	[7]	0.01	3	300	0.5939
Kota Kendari	[1, 14]	[7]	0.01	3	300	0.4089
Kota Kendari	[1, 14]	[]	0.03	1	150	0.2248
Kota Kendari	[1, 7]	[7]	0.01	3	150	-0.7836
Kota Kendari	[1, 7]	[]	0.01	3	150	-0.7852
Kota Kendari	[1]	[7]	0.01	3	150	-0.85

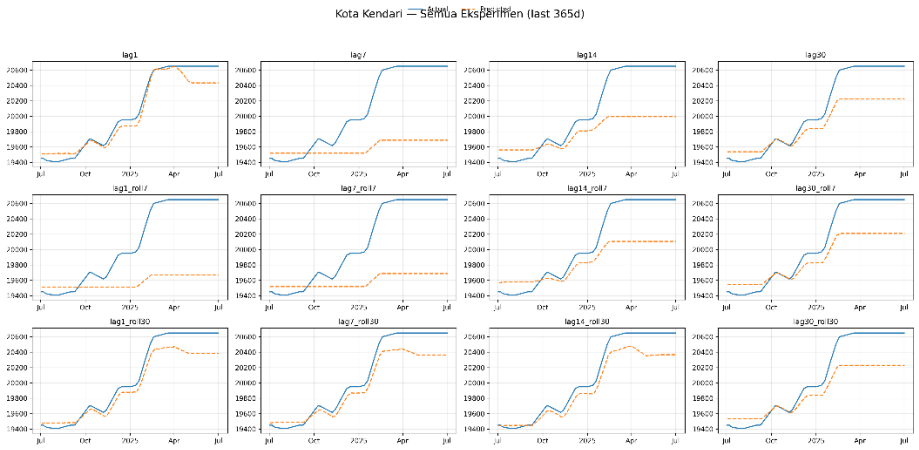

Gambar 4.19 Daftar Ekperimen Kota Kendari

3. Kota Maluku

Pada Kota Maluku, perubahan nilai R^2 yang sangat drastis terutama

disebabkan oleh kombinasi antara kompleksitas model dan jenis fitur waktu yang digunakan (lags dan rolling). Konfigurasi sederhana seperti lag1 dengan max_depth=1, learning_rate kecil, dan iterasi tinggi menghasilkan R^2 tinggi (≈0.94) karena model mampu menangkap hubungan langsung antar waktu tanpa noise berlebih. Namun, ketika fitur rolling seperti roll7 atau roll30 ditambahkan, sinyal perubahan cepat menjadi terlalu halus sehingga model kehilangan kemampuan mendeteksi lonjakan harga yang tajam, sementara peningkatan *depth* justru menyebabkan overfitting terhadap data latih yang tidak merepresentasikan kondisi uji. Hal ini terlihat pada grafik, di mana prediksi model dengan rolling besar menjadi lebih lambat merespons kenaikan harga atau bahkan stagnan ketika harga sebenarnya naik tajam. Selain itu, kombinasi learning rate tinggi dengan iterasi sedikit memperparah instabilitas, membuat model gagal beradaptasi terhadap pola perubahan harga minyak yang bersifat non-linear dan tidak stasioner. Akibatnya, model-model kompleks justru memiliki performa lebih buruk, bahkan sampai R^2 negatif, karena tidak lagi mampu merepresentasikan dinamika data secara akurat.

Tabel 4.6 Daftar Uji Coba Eksperimen Kota Maluku

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Maluku	[1]	[]	0.03	1	450	0.9392
Kota Maluku	[1, 14]	[7]	0.05	1	450	0.935
Kota Maluku	[1, 7]	[7]	0.05	1	150	0.9339
Kota Maluku	[1, 7]	[]	0.05	1	150	0.9323
Kota Maluku	[1, 14]	[]	0.01	1	450	0.8713
Kota Maluku	[1, 7]	[30]	0.03	1	450	0.6079
Kota Maluku	[1, 30]	[30]	0.05	3	150	0.5347

Kota Maluku	[1, 14]	[30]	0.03	1	450	0.4634
Kota Maluku	[1]	[30]	0.03	1	450	0.4596
Kota Maluku	[1, 30]	[]	0.05	1	300	0.4547
Kota Maluku	[1, 30]	[7]	0.05	3	150	0.4117
Kota Maluku	[1]	[7]	0.05	3	150	-0.2683

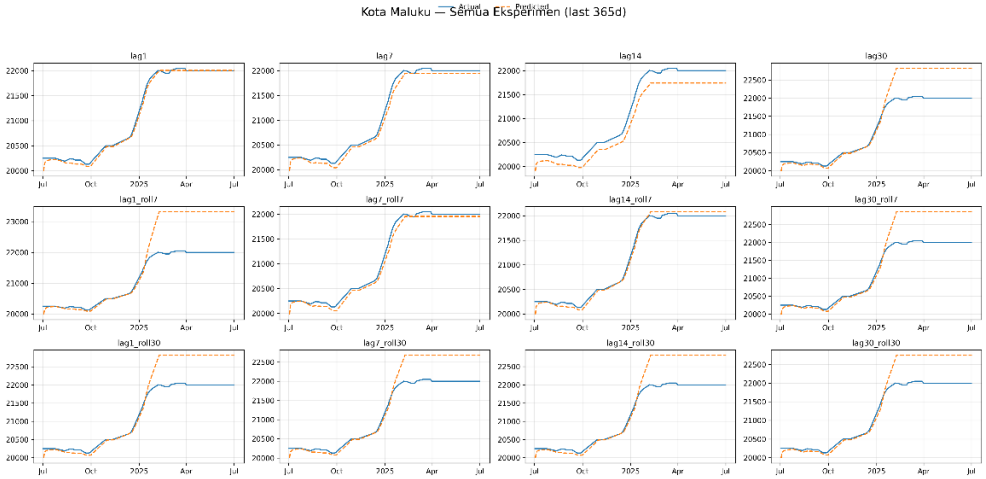

Gambar 4.20 Daftar Ekperimen Kota Maluku

4. Kota Palangkaraya

Pada Kota Palangkaraya, perbedaan drastis R^2 muncul karena interaksi antara pemilihan fitur lag/rolling dan konfigurasi hyperparameter yang mengubah kemampuan model menangkap autokorelasi seri; konfigurasi sederhana dengan lag [1,30], depth rendah (1), dan learning rate moderat (0.05) menghasilkan R^2 tinggi (~0.91–0.92) karena model memanfaatkan sifat persisten harga (nilai t−1 dan informasi jangka panjang dari lag30) tanpa over-parametrisasi, sedangkan kombinasi lain (banyak lag/roll + lr kecil 0.01 + depth 2–3 dengan iterasi kecil/menengah) menyebabkan model either overfit

pada noise training atau underfit/“collapse” ke prediksi konstan pada test; penyebab teknis yang paling mungkin termasuk **(1)** fitur rolling/lag yang tidak di-shift dengan benar (data leakage atau penggunaan informasi masa depan), **(2)** multikolinearitas tinggi antar lag (lag1,7,14,30) yang membuat pembelajaran tidak stabil, **(3)** lr rendah tanpa iterasi/early stopping yang efektif sehingga model gagal konvergen ke pola yang berguna atau malah overfit dengan iterasi yang keliru, dan **(4)** pengurangan sampel efektif karena banyak shift sehingga model dilatih pada subset kecil dan tidak generalis; pada grafik konfigurasi baik menunjukkan garis prediksi mengikuti kenaikan aktual, sedangkan konfigurasi gagal menampilkan prediksi datar/tertahan di belakang lonjakan aktual—menandakan masalah alignment, split time-aware, dan kebutuhan regularisasi/subsampling serta validasi walk-forward untuk mengembalikan kestabilan.

Tabel 4.7 Daftar Uji Coba Eksperimen Kota Palangkaraya

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Palangkaraya	[1, 30]	[7]	0.05	1	450	0.9181
Kota Palangkaraya	[1, 30]	[]	0.05	1	450	0.9155
Kota Palangkaraya	[1, 30]	[30]	0.05	1	450	0.9106
Kota Palangkaraya	[1, 14]	[30]	0.03	3	300	0.8997
Kota Palangkaraya	[1, 7]	[30]	0.01	3	450	0.8836
Kota Palangkaraya	[1]	[30]	0.01	3	450	0.8833
Kota Palangkaraya	[1, 7]	[]	0.01	3	300	0.8222
Kota Palangkaraya	[1, 7]	[7]	0.01	3	300	0.8222
Kota Palangkaraya	[1, 14]	[]	0.01	3	150	-0.3005
Kota Palangkaraya	[1, 14]	[7]	0.01	3	150	-0.3025
Kota Palangkaraya	[1]	[]	0.01	2	150	-0.7155
Kota Palangkaraya	[1]	[7]	0.01	2	150	-0.78

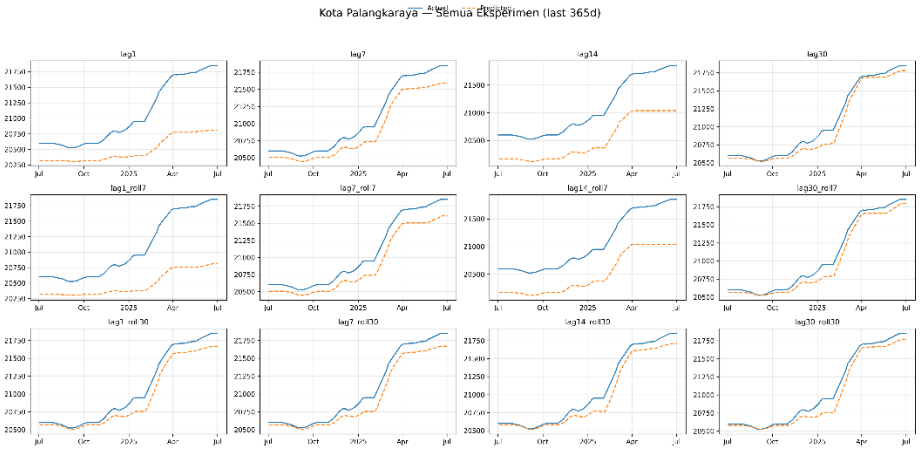

Gambar 4.21 Daftar Ekperimen Kota Palangkaraya

4.2.1.5 Analisa Korelasi Performa Model berdasarkan Pembagian Tertil Provinsi disertai dengan Kaitannya dengan Isu Sosial

Analisa dilakukan dengan melakukan pengelompokkan pada provinsi – provinsi yang ada di Pulau yang sama untuk melihat dan menguji perbandingan harga sebenarnya dan harga prediksi melalui peta persebaran Indonesia, sekaligus melihat sifat pola perbedaan harga antar Kota yang ada di Indonesia. Proses analisis dilakukan dengan melakukan pengelompokan niai rata-rata hasil prediksi dan nilai aktual berdasarkan ukuran statistik tertile.

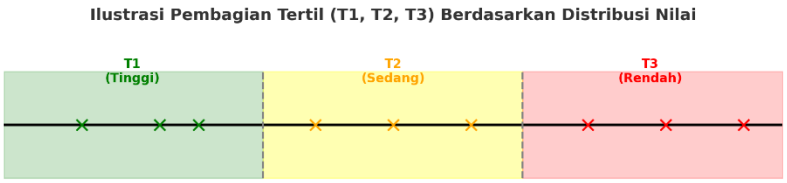

Tertile merupakan metode pengelompokan data yang membagi sekumpulan data menjadi tiga bagian sama besar, masing-masing mewakili 33,3% bagian dari keseluruhan distribusi nilai. Perhitungan dibagi menjadi 2 skema. Pada

skema pertama, perhitungan batas T1 dan T2 dilakukan dengan menggunakan seluruh provinsi di Indonesia sebagai dasar distribusi data.

Dengan demikian, tertile nasional menunjukkan posisi relatif antarprovinsi secara keseluruhan, tanpa memperhatikan letak geografis pulau. Pendekatan ini menghasilkan peta klasifikasi yang merepresentasikan kondisi provinsi secara nasional, di mana setiap provinsi dibandingkan langsung dengan provinsi lain di seluruh wilayah Indonesia.

Pada skema kedua, perhitungan dilakukan terpisah untuk setiap pulau. Artinya, batas tertile (T1 dan T2) dihitung berdasarkan distribusi rata-rata nilai antarprovinsi di dalam satu pulau yang sama. Dengan pendekatan ini, klasifikasi T1, T2, dan T3 bersifat relatif terhadap kondisi dalam pulau tersebut, bukan terhadap seluruh Indonesia.

Sebagai contoh, provinsi di Pulau Jawa dibandingkan hanya dengan provinsi lain di Pulau Jawa, sehingga pembagian kategori lebih merefleksikan perbedaan regional di dalam pulau daripada perbedaan skala nasional.

Analisa dilakukan dengan membandingkan harga actual di tahun 2025 dengan harga *predicted* sampai tanggal 22 Oktober 2025 pada semua pulau dengan 2 jenis rata2

1. Berdasarkan rata – rata Per pulau secara *actual*

   Pada tahun 2025, perbedaan antara T1 (hijau), T2 (Kuning) dan T3 (Merah), dapat dilihat pada **gambar 4.25**, dimana p ada data (sampai dengan Oktober), T1 adalah rentang harga $\leq$ Rp20167, T2 adalah rentang harga

antara Rp 20167 sampai dengan Rp 21159, dan T3 adalah harga minyak goreng ≥ Rp 21159.

Pada Pulau Kalimantan dapat dilihat pembagian tertil, T1 berada di Provinsi Kalimantan Selatan dengan Kota Banjarmasin, Kota Tanjung dan Kabupaten Kotabaru. Kota Tanjung memiliki rata – rata terendah dengan harga Rp 19677. Kalimantan Barat juga berada di posisi T1 dengan Kabupaten Sintang (Rp 21748), Kota Pontianak (Rp 20114), dan Kota Singkawang (Rp 19239). Pada posisi T2, terdapat Provinsi Kalimantan Tengah yaitu Kota Palangkaraya (Rp 21733) dan Kota Sampit (Rp 20164) dan posisi T3 terdapat pada Provinsi Kalimantan Timur dan dan Kalimantan Utara

Pada Pulau Sumatera, Provinsi Bangka Belitung, Riau, dan Sumatera Selatan berada di posisi T1. Pada posisi T2 berada di Provinsi Sumatera Barat, Jambi dan Bengkulu. Posisi Tertil ketiga berada di berada di Provinsi Sumatera Utara, Aceh, dan Sumatera Selatan dengan harga rata – rata tertinggi terdapat pada Kota Gunung Sitoli yang terdapat di Provinsi Sumatera Utara.

Pada Provinsi Jawa, Posisi T1 berada di Provinsi Banten, Jawa Tengah. Posisi T2 terdapat pada D.I Yogyakarta dan Provinsi Jawa Timur, dan T3 berada di Provinsi Jakarta, Jawa Barat. Pada Pulau Sulawesi, T1 berada pada Provinsi Sulawesi Utara, dan Sulawesi Selatan. T2 berada pada Provinsi Sulawesi Tengah, dan T3 berada pada Provinsi Gorontalo dan Sulawesi Tenggara. Pada Bali-NTT, posisi T1 berada di Provinsi NTB, dengan T3 berada di Provinsi Bali. Pada Pulau Papua, karena terdapat 2 provinsi maka dibagi menjadi T1 dan T3,

dimana T1 berada di Provinsi Papua Barat dan T3 berada di Provinsi Papua

2. Pada distrbusi Harga secara prediktif (**gambar 4.26**), posisi tertil tidak terlalu jauh berbeda, namun di Pulau – Pulau tertentu seperti bagian Bali, NTB, dan Maluku memiliki sedikit perbedaan pada posisi Tertil. Pada Bali – NTB, Provinsi NTT menempati T1, NTB menempati T2, dan Bali menempati T3. Pada Maluku, Provinsi Maluku Utara menempati posisi Tertil T2 dan Maluku menempati posisi Tertil T1,

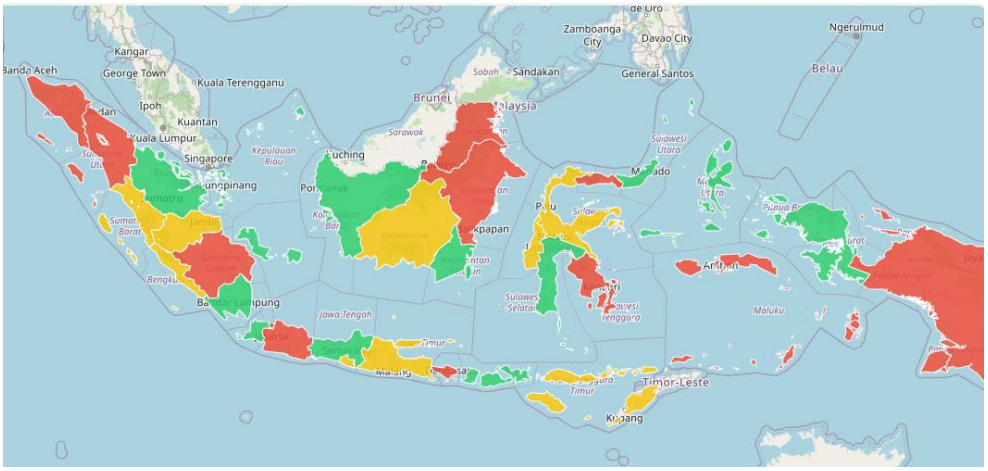

Gambar 4.22 Harga *Actual* semua pulau di tahun 2025

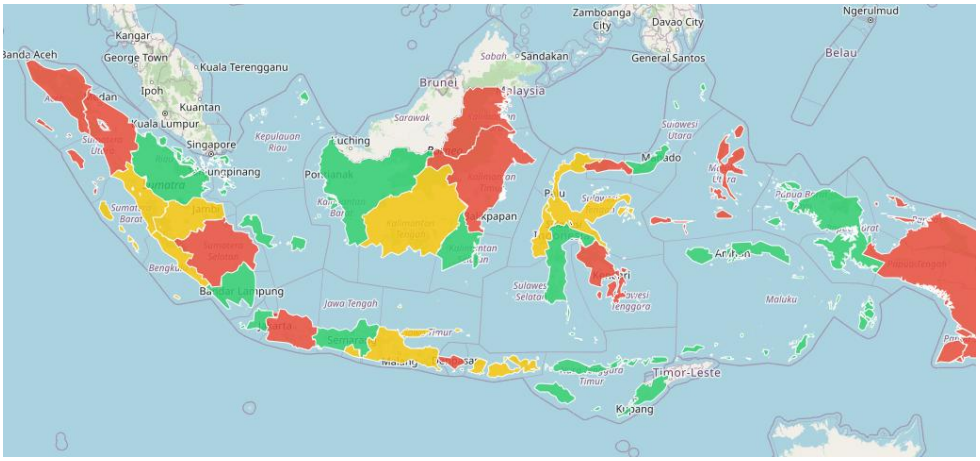

Gambar 4.23 Harga *predicted* semua pulau di tahun 2025

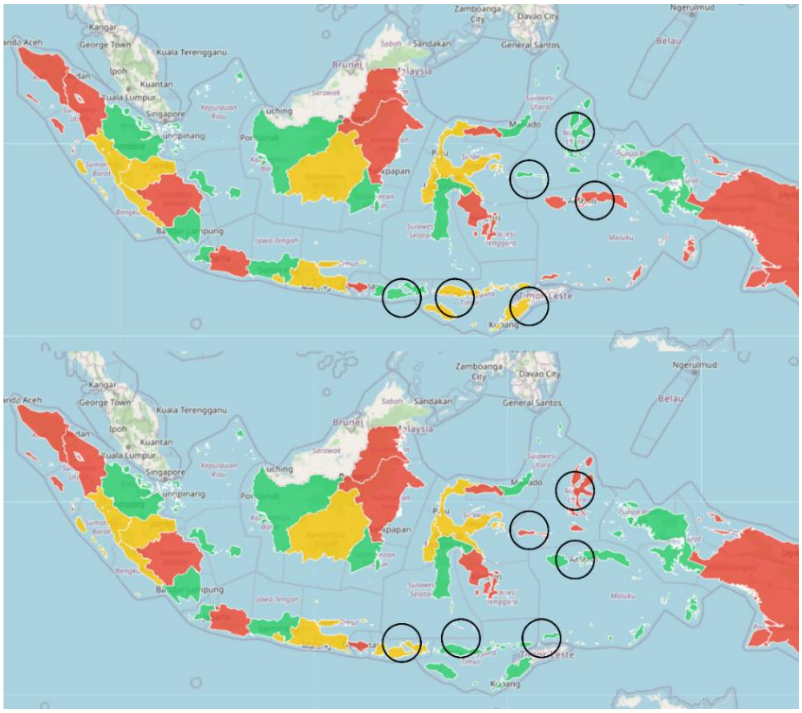

Gambar 4.24 Perbedaan Harga Per Pulau

Pada distrbusi Harga secara prediktif, posisi tertil tidak terlalu jauh berbeda, namun di Pulau – Pulau tertentu seperti bagian Bali, NTB, dan Maluku memiliki sedikit perbedaan pada posisi Tertil. Pada Bali – NTB, Provinsi NTT menempati T1, NTB menempati T2, dan Bali menempati T3. Pada Maluku, Provinsi Maluku Utara menempati posisi Tertil T2 dan Maluku menempati posisi Tertil T1. Persebaran (R^2) jika dikelompokkan pada pulau – pulau yang ada di Indonesia. Pulau Jawa memiliki nilai (R^2) diatas rata – rata yaitu R^2= 0.914 dan model cenderung dapat memprediksi dengan baik meskipun memiliki daftar Kabupaten/Kota yang paling banyak. Pulau Sulawesi adalah pulau dengan nilai (R^2) paling rendah yaitu $R^2 = 0.45$ kemudian diikuti dengan Pulau Papua dengan nilai $R^2 = 0.48$.

3. Berdasarkan rata- rata Nasional, terlihat jelas pada peta persebaran harga

baik *actual* mapun *predicted*, bahwa di Pulau yang sama, seperti pulau Kalimantan, Papua,Maluku, NTT-NTB, kecuali Pulau Sulawesi dan sekitar memiliki pola harga provinsi – provinsi yang relatif sama di sepanjang tahun 2025. Hal ini ditunjukkan pada posisi tertil daerah – daerah yang berada di Pulau tersebut.

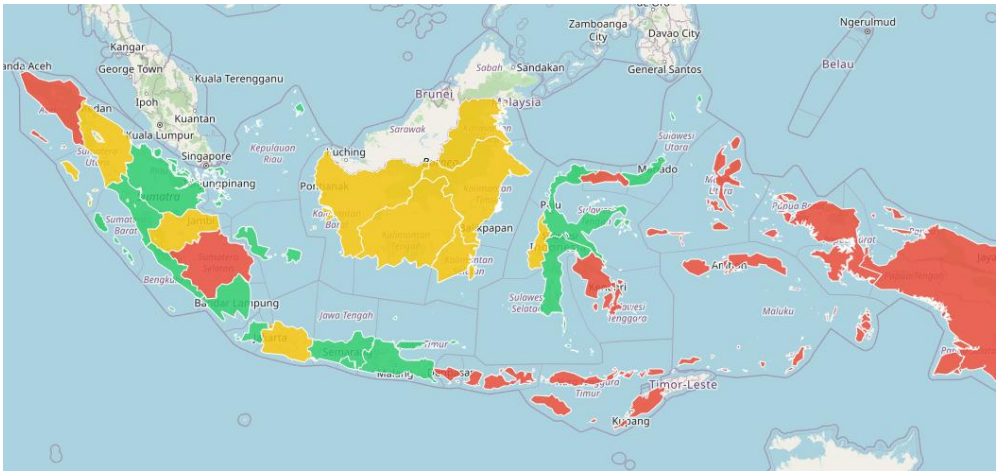

Gambar 4.25 Harga Actual semua pulau di tahun 2025 (nasional avg)

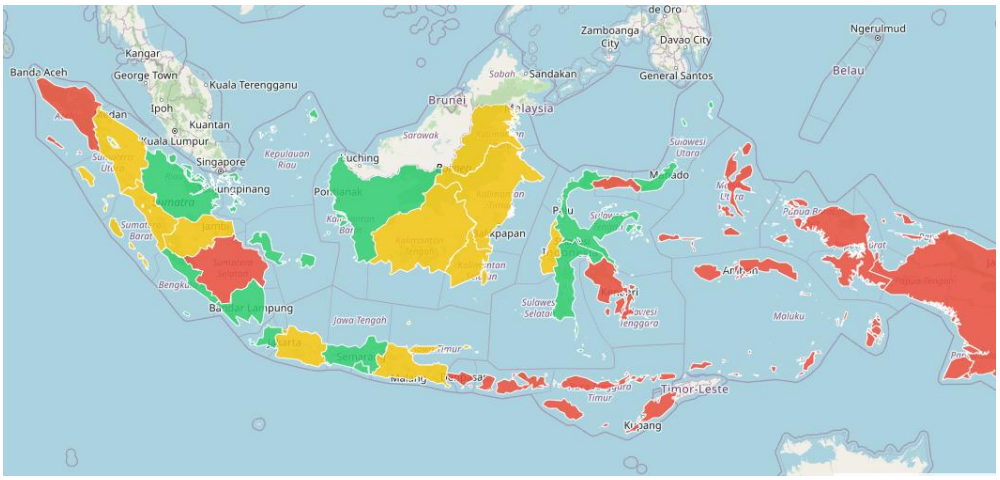

Gambar 4.26 Harga *predicted* semua pulau di tahun 2025 (nasional avg)

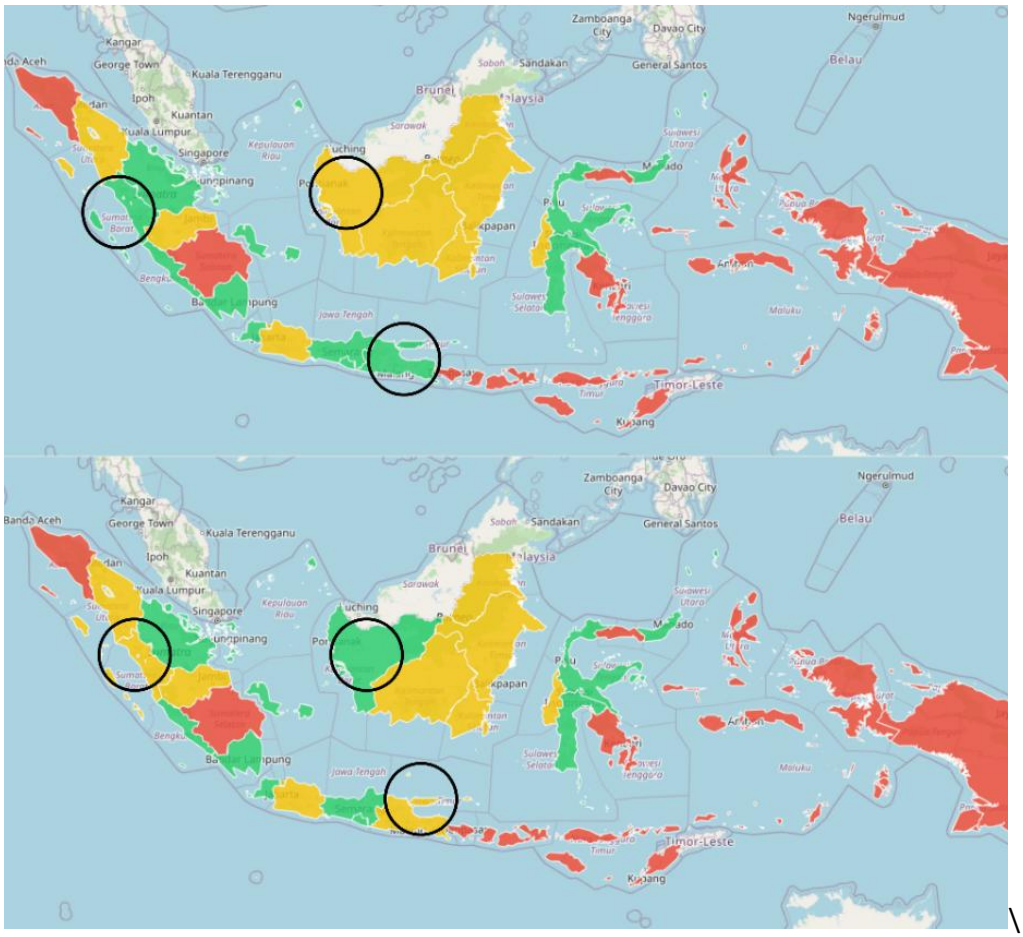

\

Gambar 4.27 Perbedaan Harga Nasional

Berdasarkan keseluruhan harga, Pembagian tertil harga minyak goreng pada tahun 2025 menunjukkan pola yang cukup konsisten antara hasil prediksi dan data aktual, terutama terkait karakteristik wilayah yang berada pada kelompok harga rendah (T1), menengah (T2), dan tinggi (T3). T1 dihuni oleh wilayah-wilayah dengan harga paling rendah, yang umumnya memiliki akses logistik yang baik, dekat dengan jalur distribusi utama, serta memiliki pasar dengan volume besar sehingga persaingan harga lebih ketat. Contohnya terdapat di Pulau Jawa bagian tengah dan barat seperti Banten dan Jawa Tengah, serta

beberapa wilayah Sulawesi seperti Sulawesi Utara, Tengah, dan Selatan. Kota-kota tersebut biasanya mudah dijangkau dari pelabuhan besar atau pusat distribusi nasional, sehingga biaya logistik relatif rendah dan harga minyak goreng lebih stabil di kisaran tertil bawah.

Sementara itu, T2 dihuni oleh wilayah dengan rentang harga antara T1 dengan T3, yang secara geografis tidak terlalu jauh dari pusat distribusi namun tidak seefisien wilayah T1. Wilayah pada tertil ini memiliki akses logistik yang masih memadai tetapi biaya distribusinya sedikit lebih tinggi, seperti di Jawa Barat, Kalimantan (seluruh provinsi), Sumatera Utara, serta Jambi. Pada wilayah T2, pasokan barang relatif stabil, namun kondisi geografis dan jarak yang lebih jauh dari pusat produksi membuat harga tidak serendah wilayah T1. Selain itu, wilayah-wilayah ini umumnya memiliki pasar yang cukup besar dan aktif, namun tetap dipengaruhi hambatan logistik seperti jalur sungai, kondisi pelabuhan, atau distribusi antar-kepulauan.

Adapun T3 merupakan kelompok wilayah dengan harga minyak goreng paling tinggi, yang didominasi oleh daerah-daerah yang jauh dari pusat produksi minyak goreng maupun pusat distribusi besar sehingga memiliki Margin Perdagangan dan Pengangkutan Total (MPPt) Komoditas Minyak Goreng yang tinggi. Wilayah syyeperti Papua, Maluku, Bali–NTT, Aceh, serta sebagian Sumatera Selatan dan Sulawesi Tenggara berada dalam kelompok ini karena karakteristik geografis yang menantang, kondisi logistik yang mahal, serta volume pasar yang cenderung kecil sehingga kompetisi harga tidak sekuat di wilayah lain. Distribusi

barang ke wilayah-wilayah ini sangat bergantung pada transportasi laut atau udara yang biayanya tinggi dan mudah dipengaruhi cuaca. Akibatnya, harga minyak goreng cenderung berada di tertil tertinggi. Konsistensi wilayah timur Indonesia yang hampir selalu berada di T3, baik dalam data prediksi maupun aktual, menunjukkan bahwa beban logistik menjadi faktor utama penentu harga di daerah tersebut.

Tabel 4.8 Pembagian Tertil *Predicted* Harga Minyak Goreng di Indonesia pada Tahun 2025

Pembagian Tertil *Predicted* Harga Minyak Goreng di Indonesia pada Tahun 2025		
No	**Jenis Tertil**	**Nama Kota**
1	T1	Pulau Jawa Provinsi : 1. Banten : Kota Cilegon, Kota Serang, Kota Tanggerang 2. Jawa Tengah : Kabupaten Banyumas, Kabupaten Boyolali, Kabupaten Cilacap, Kabupaten Karanganyar, Kabupaten Klaten, Kabupaten Kudus, Kabupaten Sragen, Kabupaten Sukoharjo, Kabupaten Wonogiri, Kota Semarang, Kota Surakarta (Solo) 3. Jakarta : Kota Jakarta Pusat Pulau Sumatera: 1. Provinsi Lampung : Kota Bandar Lampung, Kota Metro 2. Provinsi Bangka Belitung : Kota Pangkal Pinang, Kota Tanjung Pandan 3. Provinsi Bengkulu : Kota Bengkulu Pulau Kalimantan : 1. Provinsi Kalimantan Barat : Kabupaten Sintang, Kota Pontianak, Kota Singkawang Pulau Sulawesi : 1. Provinsi Sulawesi Utara : Kota Manado, Kotamobagu 2. Provinsi Sulawesi Tengah :

Pembagian Tertil *Predicted* Harga Minyak Goreng di Indonesia pada Tahun 2025		
No	**Jenis Tertil**	**Nama Kota**
		Kota Banggai dan Kota Palu 3. Provinsi Sulawesi Selatan : Kabupaten Bulukomba, Kota Makasar, Kota Palopo, Kota Pare – Pare, Kota Watampone
2	T2	Pulau Jawa Provinsi : 1. Jawa Barat : Kabupaten Cirebon, Kota Bandung, Kota Bekasi, Kota Bogor, Kota Cirebon, Kota Depok, Kota Sukabumi, Kota Tasikmalaya 2. Jawa Timur : Kabupaten Banyuwangi, Kabupaten Jember, Kabupaten Sumenep, Kota Blitar, Kota Kediri, Kota Madiun, Kota Malang, Kota Probolinggo, Kota Sumenep, Kota Surabaya Pulau Sumatera: 1. Provinsi Sumatera Barat : Kota Padang 2. Provinsi Jambi : Kabupaten Bungo, Kota Jambi 3. Provinsi Sumatera Utara : Kota Gunung Sitoli, Kota Medan, Kota Padang Sidempuan, Kota Pematang Siantar, Kota Sibolga Pulau Kalimantan : 1. Provinsi Kalimantan Timur : Kota Balikpapan, Kota Bontang, Kota Samarinda 2. Provinsi Kalimantan Tengah : Kota Palangkaraya, Kota Sampit 2. Provinsi Kalimantan Selatan : Kabupaten Kotabaru, Kota Banjarmasin, Kota Tanjung 3. Provinsi Kalimantan Utara : Kabupaten Bulungan, Kota Tarakan Pulau Sulawesi : 1. Provinsi Sulawesi Barat : Kota Majene, Kabupaten Polewali Mandar, Kota Mamuju Pulau Bali-NTT : 1. Kabupaten Sumba Timur, Kabupaten Sumbawa, Kota Kupang, Kota Maumere
3	T3	Pulau Sumatera: 1. Provinsi Sumatera Selatan : Kota Lubuk Linggau, Kota Palembang 2. Provinsi Aceh : Kota Banda Aceh, Kota Lhokseumawe Pulau Sulawesi : 1. Provinsi Sulawesi Tenggara : Kota Bau – Bau, Kota Kendari.

Pembagian Tertil *Predicted* Harga Minyak Goreng di Indonesia pada Tahun 2025		
No	**Jenis Tertil**	**Nama Kota**
		2. Provinsi Gorontalo : Kota Gorontalo Pulau Bali-NTT : 1. Provinsi Bali : Kota Denpasar 2. Provinsi NTT : Kabupaten Sumba Timur, Kabupaten Sumbawa, Kota Kupang, Kota Maumere Pulau Maluku : 1. Provinsi Maluku Utara : Kota Ternate 2. Provinsi Maluku : Kota Maluku, Kota Tual Pulau Papua : 1. Provinsi Papua Barat : Kabupaten Manokwari, Kota Sorong 2. Provinsi Papua : Kabupaten Jayawijaya, Kabupaten Mearuke, Kabupaten Mimika, Kabupaten Nabire, Kota Jayapura

Tabel 4.9 Pembagian Tertil *actual* di Tahun 2025

Pembagian Tertil *actual* di Tahun 2025		
No	**Jenis Tertil**	**Nama Kota**
1	T1	Pulau Jawa : 1. Provinsi Banten : Kota Cilegon, Kota Serang, Kota Tanggerang 2. Jawa Tengah : Kabupaten Banyumas, Kabupaten fi, Kabupaten Cilacap, Kabupaten Karanganyar, Kabupaten Klaten, Kabupaten Kudus, Kabupaten Sragen, Kabupaten Sukoharjo, Kabupaten Wonogiri, Kota Semarang, Kota Surakarta (Solo) 3. Provinsi Jawa Timur : Kabupaten Banyuwangi, Kabupaten Jember, Kabupaten Sumenep, Kota Blitar, Kota Kediri, Kota Madiun, Kota Malang, Kota Probolinggo, Kota Sumenep, Kota Surabaya Pulau Sulawesi : 1. Provinsi Sulawesi Utara : Kota Manado, Kotamobagu 2. Provinsi Sulawesi Tengah : Kota Banggai dan Kota Palu 3. Provinsi Sulawesi Selatan : Kabupaten Bulukomba, Kota Makasar, Kota Palopo, Kota Pare – Pare, Kota Watampone

Pembagian Tertil *actual* di Tahun 2025		
No	**Jenis Tertil**	**Nama Kota**
		Pulau Sumatera : 1. Provinsi Sumatera Barat : Kota Padang 2. Provinsi Bengkulu : Kota Bengkulu 3. Provinsi Lampung : Kota Bandar Lampung, dan kota Metro
2	T2	Pulau Jawa : 1. Jawa Barat : Kabupaten Cirebon, Kota Bandung, Kota Bekasi, Kota Bogor, Kota Cirebon, Kota Depok, Kota Sukabumi, Kota Tasikmalaya Pulau Kalimantan : 1. Provinsi Kalimantan Timur : Kota Balikpapan, Kota Bontang, Kota Samarinda 2. Provinsi Kalimantan Tengah : Kota Palangkaraya, Kota Sampit 3. Provinsi Kalimantan Selatan : Kabupaten Kotabaru, Kota Banjarmasin, Kota Tanjung 4. Provinsi Kalimantan Utara : Kabupaten Bulungan, Kota Tarakan 5. Provinsi Kalimantan Barat : Kabupaten Sintang, Kota Pontianak, Kota Singkawang Pulau Sulawesi : 1. Provinsi Sulawesi Barat : Kabupaten Majene, Kabupaten Polewali Mandar, Kota Mamuju Pulau Sumatera 1. Provinsi Sumatera Utara : Kota Gunung Sitoli, Kota Medan, Kota Padang Sidempuan, Kota Pematang Siantar, Kota Sibolga 2. Provinsi Jambi : Kabupaten Bungo, Kota Jambi
3	T3	Pulau Sumatera: 1. Provinsi Sumatera Selatan : Kota Lubuk Linggau, Kota Palembang 2. Provinsi Aceh : Kota Banda Aceh, Kota Lhokseumawe Pulau Sulawesi 1. Provinsi Sulawesi Tenggara : Kota Bau – Bau, Kota Kendari. 2. Provinsi Gorontalo : Kota Gorontalo Pulau Bali-NTT 1. Provinsi Bali : Kota Denpasar 2. Provinsi NTT

Pembagian Tertil *actual* di Tahun 2025		
No	**Jenis Tertil**	**Nama Kota**
		Kabupaten Sumba Timur, Kabupaten Sumbawa, Kota Kupang, Kota Maumer Pulau Maluku 1. Provinsi Maluku Utara : Kota Ternate 2. Provinsi Maluku : Kota Maluku, Kota Tual Pulau Papua 1. Provinsi Papua Barat : Kabupaten Manokwari, Kota Sorong 2. Provinsi Papua : Kabupaten Jayawijaya, Kabupaten Mearuke, Kabupaten Mimika, Kabupaten Nabire, Kota Jayapura

4.2.1.6 Analisa Kelebihan dan Kekurangan Model dalam Memprediksi Harga Minyak Goreng

Daerah – daerah dengan nilai R2 yang tinggi seperti Kota Bogor, dapat memprediksi data uji dengan sangat baik, dapat dilihat pada gambar **L12.42** terkait grafik perbandingan harga aktual dan prediksi kota Bogor menunjukkan grafik dengan hasil prediksi yang mengikuti pola data harga aktual dengan sangat baik dari periode awal sampai periode akhir dari data uji.

Daerah dengan nilai R2 rendah seperti kota Banggai dan Kabupaten Jayawijaya cenderung berkinerja buruk karena data aktualnya hanya menunjukkan pola *step* atau diskrit, dimana nilai tetap konstan untuk waktu yang lama, namun melonjak tinggi ke nilai konstan baru di sekitar bulan April 2025.

Model dapat menangkap tren naik/turun dan momentum karena nilai hari ini adalah kelanjutan logis dari nilai hari-hari sebelumnya. *Rolling mean* sangat baik dalam menghilangkan *noise* dan memperkirakan arah tren. Fitur lag terutama lag-

1 sangat optimal dalam prediksi dikarenakan nilai pada waktu sebelumnya (t-1) memiliki korelasi yang kuat dengan nilai saat ini (t). Hal ini mencerminkan adanya autokorelasi temporal dimana pola pergerakan harga dari satu periode ke periode berikutnya relatif berkelanjutan sehingga informasi historis terbaru tren menjadi indikator utama arah tren.

Namun adanya fitur roll dan lag tidak cukup jika data actual hanya konstan di 1 nilai atau memiliki pola yang jauh berbeda antara data latih dengan data uji, sehingga proses pelatihan tidak akan membuat model yang dapat memprediksi dengan baik. Model akan gagal dalam memprediksi ketika terjadi perubahan nilai yang mendadak, tidak terduga, atau diskrit karena tidak ada informasi dari lag sebelumnya yang mengindikasikan lompatan besar akan terjadi. Model hanya memprediksi berdasarkan *inertia* (kelembaman) data sebelumnya. Jika data terlalu fluktuatif tanpa pola, model akan kesulitan membedakan antara noise acak dan perubahan tren yang sebenarnya, sehingga akan lebih efektif jika model di*training* kembali apabila ada data baru, karena pola grafik terutama kota – kota dengan evaluasi yang rendah memiliki kesulitan memprediksi data terutama di beberapa bulan terakhir, sebab semakin jauh prediksinya maka *error* atau ketidaktepatan akan semakin tinggi.

4.2.2. Pengujian *Black Box Testing* (Internal)

Pengujian *blackbox testing* dilakukan untuk mengetahui fungsionalitas dan *output* dari sistem tanpa memperhatikan bagaimana proses internal atau kode

program nya bekerja. Tujuan dari pengujian ini adalah untuk memastikan bahwa setiap fitur pada aplikasi dapat berjalan dengan lancar dan memeriksa apakah *output* sesuai dengan apa yang diharapkan. Dalam konteks aplkasi prediksi harga minyak goreng Indonesia, pengujian *black box testing* dilakukan untuk memverifikasi bahwa setiap fitur utama mulai dari navigasi halaman, tampilan peta interaktif, prediksi harga, hingga proses unggah dan unduh data berfungsi sebagaimana mestinya. Setiap skenario diuji dengan langkah – langkah dan masukan tertentu untuk memastikan bahwa sistem menampilkan keluaran yang tepat. Tabel Pengujian dapat dilihat pada **LAMPIRAN 13**

4.2.3. Pengujian *User Acceptance System* oleh Masyarakat Umum

Pengujian *User Acceptance System* (UAT) dalam bentuk *Black Box Testing* dilakukan kepada 10 orang diantaranya masyarakat umum dan pemilik usaha kecil secara langsung dengan media *handphone* atau laptop. Lokasi pengujian dibagi menjadi 3 area tempat yaitu di Area Universitas Tarumanagara (Kantin Gedung M), Gedung PT Pharos Indonesia, dan Wilayah Cengkareng Timur. Pengujian dilakukan sesuai dengan skenario yang ada pada tabel *blackbox testing*. Hasil pengujian dalam bentuk tabel dan dokumentasi dapat di lihat pada **LAMPIRAN 14**.

Pengujian aplikasi dilakukan sebagai langkah untuk memastikan bahwa sistem yang dikembangkan telah berfungsi dengan baik dan layak digunakan oleh pengguna akhir. Tujuan utama dari proses pengujian ini adalah untuk menilai sejauh mana aplikasi dapat memenuhi kebutuhan serta memberikan manfaat nyata bagi masyarakat luas.

Target pengguna dari aplikasi ini mencakup masyarakat umum yang secara rutin mengonsumsi minyak goreng dalam kehidupan sehari-hari, serta pelaku usaha kecil dan menengah (UMKM) yang memanfaatkan minyak goreng sebagai bahan utama dalam kegiatan produksinya. Melalui pengujian ini, diharapkan dapat diketahui apakah aplikasi mampu memberikan informasi yang relevan, mudah dipahami, dan membantu pengguna dalam mengambil keputusan terkait konsumsi maupun pengelolaan harga minyak goreng.

Selain itu, pengujian juga berfungsi sebagai bentuk evaluasi terhadap aspek kegunaan (*usability*), keandalan (*reliability*), dan efektivitas (*effectiveness*) dari aplikasi agar dapat dipastikan bahwa sistem benar-benar siap digunakan oleh berbagai kalangan masyarakat tanpa memerlukan kemampuan teknis yang tinggi.

Adapun tahapan pengujian dilakukan secara langsung kepada pengguna dengan langkah-langkah sebagai berikut:

1. Pengenalan dan Penjelasan Aplikasi

   Pada tahap awal, peneliti memberikan penjelasan umum mengenai tujuan aplikasi, manfaat yang diharapkan, serta cara kerja sistem aplikasi prediksi harga minyak goreng. Pengguna diinformasikan bahwa aplikasi ini menampilkan data aktual dan prediksi harga minyak goreng dalam bentuk peta interaktif dan tabel perbandingan antarwilayah.

2. Pemberian Akses untuk Uji Coba Aplikasi

   Setelah penjelasan diberikan, pengguna menerima tautan (link) menuju halaman aplikasi agar dapat mencoba langsung fitur-fitur yang

tersedia, dan juga ada yang menggunakan laptop pribadi. Pengguna diminta untuk mengeksplorasi tampilan peta, memilih wilayah, serta melihat perbandingan harga aktual dan hasil prediksi sesuai periode waktu yang diinginkan.

3. Pemberian dan Penjelasan Dokumen UAT (*User Acceptance Test*)

   Pengembang aplikasi kemudian memberikan dokumen UAT yang berisi daftar fungsi utama aplikasi beserta kolom penilaian dan catatan pengguna. Peserta diberikan panduan mengenai cara mengisi dokumen tersebut, seperti menilai tingkat kemudahan penggunaan, kejelasan informasi, dan kesesuaian hasil yang ditampilkan.

4. Pelaksanaan Pengujian dan Pengisian UAT

   Pengguna melakukan uji coba langsung pada aplikasi dengan panduan yang telah disediakan, lalu mengisi dokumen UAT sesuai pengalaman penggunaan masing-masing. Setiap responden diminta memberikan saran atau komentar secara tertulis terkait fitur yang sulit digunakan atau informasi yang kurang jelas, atau fitur yang tidak sesuai dengan harapan.

5. Persetujuan dan Dokumentasi

   Setelah pengujian selesai, pengembang aplikasi meminta izin kepada peserta untuk melakukan dokumentasi kegiatan pengujian berupa foto atau tanda tangan sebagai bukti bahwa pengguna telah mengikuti proses uji. Dokumen UAT yang telah diisi kemudian dikumpulkan sebagai bukti validasi bahwa aplikasi telah diuji langsung oleh calon pengguna akhir.

Proses pengujian ini dilaksanakan pada periode 18 hingga 24 Oktober 2025, melibatkan beberapa responden yang mewakili masyarakat umum dan pelaku usaha kecil sebagai pengguna sasaran aplikasi. Dari 21 *test scenario* yang ada, semua fungsional aplikasi berjalan sesuai dengan semestinya, dimana aplikasi dalam melakukan prediksi di hari mendatang. Adapun *feedback* dari *user* terkait aplikasi adalah terkait halaman yang kurang responsif. Form Uji UAT terdapat pada **LAMPIRAN 14**.

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Perancangan ini digunakan untuk mengimplementasikan sistem prediksi serta analisis harga minyak goreng dengan membuat 100 model untuk 100 kabupaten/kota di Indonesia dengan menggunakan pendekatan *Gradient Boosting* dan dapat disimpulkan bahwa :

- Dari 100 kabupaten/kota, 91 wilayah mencapai $R^2 \geq 0,5$. Rata-rata R^2 keseluruhan ≈ 0,78203, menunjukkan model mampu memprediksi variasi harga dengan baik pada mayoritas wilayah.
- Pada model prediksi, adanya pengaruh kombinasi *hyperparameter* terhadap beberapa kota sehingga mempengaruhi hasil evaluasi.
- Analisis spasial dengan metode tertil (T1–T3) menunjukkan adanya ketimpangan harga antar wilayah yang dapat diidentifikasi baik secara nasional maupun antar-pulau.
- Berdasarkan pengujian dengan UAT melalui *black box testing* yang dilakukan oleh 10 *user* melalui 21 *test scenario* menunjukkan bahwa fungsionalitas aplikasi berjalan sesuai dengan semestinya.

5.2. Saran

Beberapa saran yang dapat dipertimbangkan untuk meningkatkan performa sistem adalah:

1. Perancangan selanjutnya disarankan untuk menambahkan variabel eksternal yang relevan seperti harga CPO, biaya logistik, indeks cuaca, pergerakan nilai tuka. Penambahan variabel-variabel ini berpotensi meningkatkan kemampuan model dalam menangkap dinamika harga yang dipengaruhi faktor eksternal yang tidak tercermin hanya dari pola historis harga minyak goreng.
2. Memperbanyak kombinasi *hyperparameter* dan menggunakan strategi imputasi yang lebih spesifik per kota juga sangat disarankan. Proses *tuning* sebaiknya tidak dibatasi pada grid kecil, tetapi diperluas dengan ruang pencarian yang lebih besar, misalnya dengan menambahkan variasi *learning rate*, jumlah estimator, kedalaman pohon, dan parameter regularisasi—terutama jika waktu komputasi dan kapasitas sistem memungkinkan. Selain itu, penanganan *missing value* tidak perlu disamaratakan di semua kota; penggunaan *forward* atau *backward fill* saja dapat menyebabkan nilai deret menjadi konstan pada kota yang memiliki rentang hilang panjang. Oleh karena itu, dapat diterapkan strategi imputasi bertingkat seperti interpolasi berbasis waktu, *seasonal interpolation*, atau kombinasi keduanya, yang dapat dipilih sesuai karakteristik data masing-masing kota, selama sumber daya pemrosesan mendukung.
3. Memperbanyak variasi model dengan membandingkan *Gradient Boosting* dengan algoritma *boosting modern* lainnya seperti XGBoost, LightGBM, atau CatBoost. Model-model tersebut sering memberikan performa lebih stabil pada data tabular dan mampu mengatasi non-linearitas yang kompleks. Pendekatan *ensemble* atau *stacking* juga dapat dipertimbangkan untuk memperoleh prediksi yang lebih konsisten pada wilayah dengan volatilitas tinggi.

DAFTAR PUSTAKA

[1] A. R. Dewi *et al.*, “Indonesia Economic Journal,” vol. 1, no. 1, pp. 206–219, 2025.

[2] Kemendag, “Kebijakan Pemerintah Dalam Mengatasi Kenaikan Harga Minyak Goreng,” *Trade Policy J.*, vol. 1 Desember, 2022, [Online]. Available: https://jurnal.kemendag.go.id/index.php/TPJ/article/view/758/385

[3] N. Halim, S. J. Pririzki, I. Alviari, D. Desy, and Y. Dalimunthe, “Prediksi Harga Minyak Goreng Sebagai Sumber Kebutuhan Masyarakat Di Kota Pangkalpinang,” *Semin. Nas. Penelit. dan Pengabdi. pada Masy. 2022*, pp. 41–44, 2022, [Online]. Available: https://journal.ubb.ac.id/snppm/article/view/3687

[4] S. H. Ulin Nuhaella Almayaa , Wahyu Hidayat Riantoa, “Jurnal Ilmu Ekonomi,” *J. Ilmu Ekon. Terap.*, vol. 1, no. 2, pp. 88–104, 2016.

[5] T. Handhayani, I. Lewenusa, and M. Y. R. Arpipi, “Forecasting Volatile Fresh Chili Prices In Indonesia Using Support Vector Regression,” *Proceeding - 2024 Int. Conf. Inf. Technol. Res. Innov. ICITRI 2024*, pp. 281–286, 2024, doi: 10.1109/ICITRI62858.2024.10699118.

[6] A. N. Bukit, U. Hasanah, K. Na’im, and E. Elyani, “Kenaikan Harga Minyak Goreng Dalam Perspektif Hukum Persaingan Usaha Dan Ekonomi,” *J. Justisia J. Ilmu Hukum, Perundang-undangan dan Pranata Sos.*, vol. 7, no. 1, p. 61, 2022, doi: 10.22373/justisia.v7i1.13212.

[7] “Studi Literatur Kelola Perusahaan Minyak Goreng di Indonesia Studi Literatur Fenomena Kelangkaan dan Kenaikan Harga Minyak Goreng di Indonesia.pdf.”

[8] L. R. Dewi, “Dampak Kenaikan Harga Minyak Goreng Bagi Pedagang Kecil,” 2022. doi: 10.59525/jess.v1i2.117.

[9] A. H. Aziz and Moniruzzaman, “Challenges in Achieving SDG 2-Zero Hunger in Bangladesh: An Analytical Study on Food Certainty in Bangladesh from Zakat Perspective,” *Int. J. Zakat*, vol. 8, no. 1, pp. 43–63, 2023.

[10] J. E. Pertanian *et al.*, “Analisis Volatilitas Harga Dan Integrasi Vertikal Pasar Minyak Goreng Di Indonesia Analysis of Price Volatility and Vertical Integration of Cooking Oil Market in Indonesia,” *J. Ekon. Pertan. dan Agribisnis*, vol. 9, pp. 642–655, 2025, [Online]. Available: https://doi.org/10.21776/ub.jepa.2025.009.02.18

[11] Y. I. M. E. U. Supriyanto, “Prediksi Harga Minyak Kelapa Sawit Menggunakan Linear Regression Dan Random,” *J. Ilm. Wahana Pendidik.*, vol. 8, no. 7, pp. 178–185, 2022, doi: 10.5281/zenodo.6559603.

[12] M. Pangalila, C. E. Mongi, and D. Hatidja, “Peramalan Harga Minyak Goreng di Provinsi Sulawesi Utara dengan Menggunakan Metode Analisis Autoregressive Integrated Moving Average (ARIMA),” *d’Cartesian*, vol. 13, no. 1, pp. 23–29, 2024, doi: 10.35799/dc.13.1.2024.53818.

[13] E. A. Ilmani, F. F. Amatullah, K. A. Notodiputro, Y. Angraini, and L. N. A. Mualifah, “the Perfomance of the Arimax Model on Cooking Oil Price Data in Indonesia,” *Barekeng*, vol. 19, no. 2, pp. 819–828, 2025, doi: 10.30598/barekengvol19iss2pp819-828.

[14] B. W. Sari and D. Prabowo, “Analisis Perbandingan Prediksi Harga Rumah Dengan Random Forest , Gradient Boosting , dan XGBoost,” 2025.

[15] P. A. Saputra, S. S. Irawan, R. Rahmaddeni, R. Prianto, and T. Hidayat, “Prediksi Dan Analisis Pola Perubahan Iklim Menggunakan Algoritma Gradient Boosting,” 2025. doi: 10.23960/jitet.v13i2.6230.

[16] M. A. Sholeh, “Perbandingan Model Lstm Dan Gru Untuk Memprediksi Harga Minyak Goreng Di Indonesia,” *EDUSAINTEK J. Pendidikan, Sains dan Teknol.*, vol. 9, no. 3, pp. 800–811, 2022, doi: 10.47668/edusaintek.v9i3.593.

[17] P. Dan, A. Harga, and M. Di, “PENDEKATAN BERBASIS GRU DAN LSTM,” vol. 9, no. 5, pp. 7600–7607, 2025.

[18] E. Amalia, L. Amalia, and S. Aminah, “Pengaruh Penggorengan Berulang Terhdadap Bilangan Peroksida pada Minyak Goreng,” *Karimah Tauhid*, vol. 3, no. 5, pp. 5588–5599, 2024, doi: 10.30997/karimahtauhid.v3i5.13255.

[19] Y. Handini, J. Wahyudi, and J. Fredricka, “Prediksi Jumlah Pendaftaran Siswa Baru Dengan Metode Time Series,” *J. Sci. Soc. Res.*, vol. 4307, no. 1, pp. 251–258, 2024, [Online]. Available: http://jurnal.goretanpena.com/index.php/JSSR

[20] A. Sutaryani, S. Sunarno, and D. Djuniadi, “Perbandingan Performa Model Machine Learning Dalam Prediksi Suhu Di Semarang,” *J. Inform. dan Tek. Elektro Terap.*, vol. 12, no. 3, 2024, doi: 10.23960/jitet.v12i3.4884.

[21] S. Sharma and P. Chaudhary, “Machine learning and deep learning,” *Quantum Comput. Artif. Intell. Train. Mach. Deep Learn. Algorithms Quantum Comput.*, pp. 71–84, 2023, doi: 10.1515/9783110791402-004.

[22] H. Karnati, A. Soma, A. Alam, and B. Kalaavathi, “Comprehensive analysis of various imputation and forecasting models for predicting PM2.5 pollutant in Delhi,” *Neural Comput. Appl.*, vol. 37, no. 17, pp. 11441–11458, 2025, doi: 10.1007/s00521-025-11047-2.

[23] C. S. Kulkarni, “Advancing Gradient Boosting: A Comprehensive Evaluation of the CatBoost Algorithm for Predictive Modeling,” *J. Artif. Intell. Mach. Learn. Data Sci.*, vol. 1, no. 5, pp. 54–57, 2022, doi: 10.51219/jaimld/chinmay-shripad-kulkarni/29.

[24] R. Rofik, R. A. Hakim, J. Unjung, B. Prasetiyo, and M. A. Muslim, “Optimization of SVM and Gradient Boosting Models Using GridSearchCV in Detecting Fake Job Postings,” *MATRIK J. Manajemen, Tek. Inform. dan Rekayasa Komput.*, vol. 23, no. 2, pp. 419–430, 2024, doi: 10.30812/matrik.v23i2.3566.

[25] R. Sibindi, R. W. Mwangi, and A. G. Waititu, “A boosting ensemble learning based hybrid light gradient boosting machine and extreme gradient boosting model for predicting house prices,” *Eng. Reports*, vol. 5, no. 4, pp. 1–19, 2023, doi: 10.1002/eng2.12599.

[26] H.-H. Chen, “Understanding Gradient Boosting Classifier: Training, Prediction, and the Role of $γ_j$,” vol. 1, no. 1, pp. 1–13, 2024, [Online]. Available: http://arxiv.org/abs/2410.05623

[27] R. Alfatih, M. Data, and R. A. Siregar, “Analisis Pengaruh Pemilihan Fitur dan Hyperparameter Terhadap Kinerja Model Machine Learning dalam Deteksi Serangan Distributed Denial of Service (DDoS),” vol. 9, no. 10, pp. 1–10, 2025.

[28] V. Verma, “Exploring Key XGBoost Hyperparameters: A Study on Optimal Search Spaces and Practical Recommendations for Regression and Classification,” *Int. J. All Res. Educ. Sci. Methods*, vol. 12, no. 10, pp. 3259–3266, 2024, doi: 10.56025/ijaresm.2024.1210243259.

[29] M. R. Salmanpour *et al.*, “Machine Learning Evaluation Metric Discrepancies Across Programming Languages and Their Components in Medical Imaging Domains: Need for Standardization,” *IEEE Access*, vol. 13, no. February, pp. 47217–47229, 2025, doi: 10.1109/ACCESS.2025.3549702.

[30] A. K. Rad, M. J. Nematollahi, A. Pak, and M. Mahmoudi, “Predictive modeling of air quality in the Tehran megacity via deep learning techniques,” *Sci. Rep.*, vol. 15, no. 1, pp. 1–20, 2025, doi: 10.1038/s41598-024-84550-6.

[31] P. K. Ozili, “The acceptable R-square in empirical modelling for social science research,” *Soc. Res. Methodol. Publ. Results A Guid. to Non-Native English Speak.*, no. 115769, pp. 134–143, 2023, doi: 10.4018/978-1-6684-6859-3.ch009.

[32] I. Kennedy, “Sample Size Determination in Test-Retest and Cronbach Alpha Reliability Estimates,” *Br. J. Contemp. Educ.*, vol. 2, no. 1, pp. 17–29, 2022, doi: 10.52589/bjce-fy266hk9.

[33] Y. Hou, Q. Wang, and T. Tan, “Prediction of Carbon Dioxide Emissions in China Using Shallow Learning with Cross Validation,” *Energies*, vol. 15, no. 22, 2022, doi: 10.3390/en15228642.

[34] “feature engineering.pdf.”

[35] N. M. Ali, R. Besar, and N. A. A. Aziz, “A case study of microarray breast cancer classification using machine learning algorithms with grid search cross validation,” *Bull. Electr. Eng. Informatics*, vol. 12, no. 2, pp. 1047–1054, 2023, doi: 10.11591/eei.v12i2.4838.

[36] S. Tjahyadi, J. Gajah, M. B. Sei, and L. Batam, “Development Of QR Code-Based Data Sharing Web Application Using System Development Life Cycle Method,” *J. Inf. Syst. Technol.*, vol. 02, no. 02, pp. 64–73, 2021.

[37] A. DEMİRAG, E. N. DEMİRKOL ÖZTÜRK, and C. ÜNAL, “Analysis and Comparison of Waterfall Model and Agile Approach in Software Projects,” *AJIT-e Acad. J. Inf. Technol.*, vol. 14, no. 54, pp. 183–203, 2023, doi: 10.5824/ajite.2023.03.002.x.

[38] F. Fahrullah, H. Haerullah, and A. Ridhawani, “Analisis Blackbox Testing dan User Acceptance Testing terhadap Sistem Informasi Posyandu Dondang,” *J. Pract. Comput. Sci.*, vol. 5, no. 1, pp. 42–50, 2025, doi: 10.37366/jpcs.v5i1.5780.

[39] T. Mariyani, I. Rosyida, and M. Si, “Implementasi Metode Double Exponential Smoothing untuk Peramalan Luas Panen Padi di Kabupaten Pati dengan Bantuan Software Minitab 16,” vol. 6, pp. 707–713, 2023.

[40] D. Odion *et al.*, “Towards improving farmers livelihood in Nigeria using food price forecasting,” *J. Agric. Food Res.*, vol. 24, no. July, p. 102365, 2025, doi: 10.1016/j.jafr.2025.102365.

[41] Maryani, H. Prabowo, F. L. Gaol, and A. N. Hidayanto, “Comparison of the System Development Life Cycle and Prototype Model for Software Engineering,” *Int. J. Emerg. Technol. Adv. Eng.*, vol. 12, no. 4, pp. 155–162,

2022, doi: 10.46338/ijetae0422_19.

[42] F. N. Hasanah, *Buku Ajar Rekayasa Perangkat Lunak*. 2020. doi: 10.21070/2020/978-623-6833-89-6.

LAMPIRAN 1

PERHITUNGAN MODEL

Contoh perhitungan berikut diambil sampel dataset pada kota Banjarmasin mulai dari tanggal 11 Januari 2020 sampai dengan 23 Januari 2020 pada Tabel L1.1.

Tabel L1.1 Harga minyak Kota Banjarmasin

Date	Kota Banjarmasin
11/1/2020	13050
12/1/2020	13050
13/1/2020	13050
14/1/2020	13050
15/1/2020	13150
16/1/2020	13150
17/1/2020	13150
18/1/2020	13150
19/1/2020	13250
20/01/2020	13250
21/01/2020	13250
22/ 01/ 2020	13250
23/01/2020	13250

Proses pelatihan dan evaluasi model dilakukan dengan kriteria penghentian (*stopping threshold*) apabila nilai koefisien determinasi (R^2) ≥ 0,80.

1. Pada perhitungan ini, akan dimasukkan *input* data dari tanggal 12 Januari 2020 sampai dengan tanggal dan *output* yang akan diprediksikan di tanggal 22 Januari 2020 dan 23 Januari 2020. Data akan dilakukan splitting pada tabel L1.2.

Tabel L1.2 Data *Split* (Input - Output)

Date	Harga	Split
12/1/2020	13050	Train
13/ 01/ 2020	13050	Train
14/ 01/ 2020	13050	Train
15/ 01/ 2020	13150	Train

Date	Harga	Split
16/ 01/ 2020	13150	Train
17/ 01/ 2020	13150	Train
18 01/ 2020	13150	Train
19/1/2020	13250	Train
20/ 01/ 2020	13250	Train
21/ 01/ 2020	?	Test
22/ 01/ 2020	?	Test
23/ 01/ 2020	?	Test

2. Penentuan Data Input – output

Data input = [13050, 13050, 13050, 13150, 13150, 13150, 13150, 13150, 13250, 13250, 13250, 13250]

Data Output = (*predicted price* di tanggal 21 Januari 2020 - 23 Januari 2020)

3. Inisialisasi F_0

Di awal iterasi (iterasi 0), dibutuhkan model paling sederhana yang bisa dipakai sebelum menambah pohon. *Gradient Boosting* untuk regresi memakai fungsi *loss* sebagai konstanta pada F0

Rumus dasar *Gradient Boosting*

$$F_0 = \arg\min \sum_i (y_i - c)^2 = \bar{y}$$

$$F_1(x) = F_0 + n \,.\, r_{i1}$$

dengan $n = 1{,}5$

$$F_0 = \bar{y}$$

$$L(c) = \sum_{i=1}^{n} (y_i - c)^2$$

$$\frac{\partial L}{\partial c} = \sum_{i=1}^{n} -2(y_i - c)$$

$$\frac{\partial L}{\partial c} = -2 \sum_{i=1}^{n} (y_i - c)$$

Cari titik minimum (set turunan = 0)

$$-2\sum_{i=1}^{n}(y_i - c) = 0$$

Bagi -2 :

$$\sum_{i=1}^{n}(y_i - c) = 0$$

Pisahkan suku :

$$\sum_{i=1}^{n}(y_i - nc) = 0$$

$$nc = \sum_{i=1}^{n} y_i$$

$$c = \frac{1}{n}\sum_{i=1}^{n} y_i$$

$$F_0 = \bar{y}$$

$$F_0 = \frac{13050\ (3) + 13150\ (4) + 13250\ (2)}{9}$$

$$F_0 = \frac{118250}{9}$$

$$F_0 = 13138.889$$

4. Hitung residual Ri1

$$r_{i1} = y_i - F_0$$

$$r_{i2} = y_i - F_1(x_i)x`$$

Tabel L1.3 Perhitungan Residual R1

t	y	F_0	$y_i - F_0$
12	13050	13139	-89
13	13050	13139	-89
14	13050	13139	-89
15	13150	13139	11
16	13150	13139	11
17	13150	13139	11
18	13150	13139	11
19	13250	13139	111
20	13250	13139	111

Terdapat 2 *split*

a. t < 15 untuk blok kiri dengan harga 13050

b. t $\geq$ 15 untuk blok kanan dengan harga 13150 dan 13250

$$h_1(t) \text{ untuk } t \ < 15 = \text{-89}$$

$$h_1(t) \text{ untuk } t \ \geq 15 :$$

$$h_1(t) \ = \frac{11(4) + \ 111(2)}{6}$$

$$\text{Iterasi } h_1(t) \ = 44{,}33$$

5. Menghitung $F_1(x)$

$$F_1(x) = F_0 + n.h_1(x)$$

dengan $n = 1{,}5$

Tabel L1.4 Perhitungan F1(x)

F_0	r_1	$F_1(x)$
13139	-89	13005.5
13139	-89	13005.5
13139	-89	13005.5
13139	44,33	13205.495
13139	44,33	13205.495
13139	44,33	13205.495
13139	44,33	13205.495
13139	44,33	13205.495
13139	44,33	13205.495

6. Predict

$$F_1(x) = 13039 + 0{,}75 \,.\, (44{,}33)$$

$$= 13172{,}24$$

tanggal 21 - 23 memiliki $t \geq 15$ sehingga :

$$\hat{y}_{21} = \hat{y}_{22} = \hat{y}_{23} = 13172{,}24$$

Tabel L1.5 Perbandingan actual price vs predicted price

Date	t	Actual Price	Predicted Price
12/1/2020	12	13050	13050
13/ 01/ 2020	13	13050	13050
14/ 01/ 2020	14	13050	13050
15/ 01/ 2020	15	13150	13150
16/ 01/ 2020	16	13150	13150
17/ 01/ 2020	17	13150	13150
18 01/ 2020	18	13150	13150
19/1/2020	19	13250	13150
20/ 01/ 2020	20	13250	13250
21/ 01/ 2020	21	13250	**13172**
22/ 01/ 2020	22	13250	**13172**
23/ 01/ 2020	23	13250	**13172**

7. Evaluasi

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_1 - \hat{y}_i)^2$$

$$e = \sum_{i=1}^{n}(y_1 - \hat{y}_i)^2$$

$$\text{SST} = \sum_{i=1}^{12} e_i^2$$

$$\begin{aligned}\text{SSE} = ((&13050 - 13072{,}25)^2 + (13050 - 13072{,}25)^2 \\ &+ (13050 - 13072{,}25)^2 + (13150 - 13172.2475)^2 \\ &+ (13150 - 13172{,}2475)^2 + (13150 - 13172{,}2475)^2 \\ &+ (13150 - 13172{,}2475)^2 + (13250 - 13172{,}2475)^2 \\ &+ (13250 - 13172{,}2475)^2 + (13250 - 13172{,}2475)^2 \\ &+ (13250 - 13172{,}2475)^2 + (13250 - 13172{,}2475)^2) \\ &= 61210\end{aligned}$$

$$\begin{aligned}\text{SST} = ((&13050 - 13138.889)^2 + (13050 - 13138.889)^2 \\ &+ (13050 - 13138.889)^2 + (13150 - 13138.889)^2 \\ &+ (13150 - 13138.889)^2 + (13150 - 13138.889)^2 \\ &+ (13150 - 13138.889)^2 + (13250 - 13138.889)^2 \\ &+ (13250 - 13138.889)^2 + (13250 - 13138.889)^2 \\ &+ (13250 - 13138.889)^2 + (13250 - 13138.889)^2) \\ &= 15555.89504\end{aligned}$$

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_1 - \hat{y}_i)^2$$

$$\text{SSE} = \sum_{i=1}^{12} e_i^2$$

$$\text{MSE} = \frac{\text{SSE}}{n}$$

$$\text{MSE} = \frac{15555.89504}{12}$$

$$= 1296{,}32$$

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n}\sum_{i-1}^{n}(y_1 - \hat{y}_i)^2}$$

$$= \sqrt{1296{,}32}$$

$$= 648{,}1622932$$

$$\text{MAPE} = \frac{100\%}{12}\sum_{t=1}^{12}\left[\frac{y_i - f_1}{y_t}\right]$$

$$= \frac{100\%}{12}\sum_{t=1}^{12}\left[\frac{\overline{y_t} - \overline{f_1}}{\overline{y_t}}\right]$$

$$=$$

$$R^2 = 1 - \frac{\sum_{i-1}^{n}(y_1 - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_1 - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{SSE}{SST}$$

$$= 1 - \frac{61210}{15555.89504}$$

$$= 0{,}745$$

Tabel L1.6 Evaluasi iterasi 1

Evaluasi Iterasi 1						
day_index	Yi	(yi-mean)^2	F1	ei	ei^2	|ei|
1	13050	7921	13072.25	-22.25	495.0625	22.25
2	13050	7921	13072.25	-22.25	495.0625	22.25
3	13050	7921	13072.25	-22.25	495.0625	22.25
4	13150	121	13172.2475	-22.2475	494.9512562	22.2475
5	13150	121	13172.2475	-22.2475	494.9512562	22.2475
6	13150	121	13172.2475	-22.2475	494.9512562	22.2475
7	13150	121	13172.2475	-22.2475	494.9512562	22.2475
8	13250	12321	13172.2475	77.7525	6045.451256	77.7525
9	13250	12321	13172.2475	77.7525	6045.451256	77.7525
10	13250	12321	13172.2475	77.7525	6045.451256	77.7525
11	13250	12321	13172.2475	77.7525	6045.451256	77.7525
12	13250	12321	13172.2475	77.7525	6045.451256	77.7525
Total	118250	61210	118250.235	-0.235	15555.89504	311.245
mean Yi	13138.88889	6121				
MSE						1296.324586
RMSE						648.1622932
MAPE						-2.2081E-07
MAE						34.58277778
R2						0.745860235

8. Iterasi 2

   a. Hitung residual

      Terdapat 3 *split*

      1) t < 15 untuk harga 13050

      2) 15 $\leq$ t < 20 untuk harga 13150

      3) t $\geq$ 20 untuk harga 13250

Tabel L1.7 Residual R2

t	$F0$	F_1	$y_i - F_0$
12	13050	**13072.25**	**-22.25**
13	13050	**13072.25**	**-22.25**
14	13050	**13072.25**	**-22.25**
15	13150	**13172.2475**	**-22.2475**
16	13150	**13172.2475**	**-22.2475**
17	13150	**13172.2475**	**-22.2475**
18	13150	**13172.2475**	**-22.2475**
19	13250	**13172.2475**	**77.7525**
20	13250	**13172.2475**	**77.7525**

b. F2

Tabel L1.8 Perhitungan F2(x)

F_1	r_2	$F_2(x)$
13072.25	-22.25	13055.5625
13072.25	-22.25	13055.5625
13072.25	-22.25	13055.5625
13172.2475	-22.2475	13155.56188
13172.2475	-22.2475	13155.56188
13172.2475	-22.2475	13155.56188
13172.2475	-22.2475	13155.56188
13172.2475	77.7525	13230.56188
13172.2475	77.7525	13230.56188

c. Evaluasi

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_1 - \hat{y}_i)^2$$

$$e = \sum_{i=1}^{n}(y_1 - \hat{y}_i)^2$$

$$\text{SST} = \sum_{i=1}^{12} e_i^2$$

$$\begin{aligned}\text{SSE} = ((&13050 - 13055{,}56)^2 + (13050 - 13055{,}56)^2 \\ &+ (13050 - 13055{,}56)^2 + (13150 - 13155.56)^2 \\ &+ (13150 - 13155.56)^2 + (13150 - 13155.56)^2 \\ &+ (13150 - 13155.56)^2 + (13250 - 13172{,}2475)^2 \\ &+ (13250 - 13172{,}2475)^2 + (13250 - 13172{,}2475)^2 \\ &+ (13250 - 13172{,}2475)^2 + (13250 - 13172{,}2475)^2) \\ &= 972{,}2434\end{aligned}$$

$$\begin{aligned}\text{SST} = ((&13050 - 13138.889)^2 + (13050 - 13138.889)^2 \\ &+ (13050 - 13138.889)^2 + (13150 - 13138.889)^2 \\ &+ (13150 - 13138.889)^2 + (13150 - 13138.889)^2 \\ &+ (13150 - 13138.889)^2 + (13250 - 13138.889)^2 \\ &+ (13250 - 13138.889)^2 + (13250 - 13138.889)^2 \\ &+ (13250 - 13138.889)^2 + (13250 - 13138.889)^2) \\ &= 15555.89504\end{aligned}$$

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_1 - \hat{y}_i)^2$$

$$\text{SSE} = \sum_{i=1}^{12} e_i^2$$

$$\text{MSE} = \frac{\text{SSE}}{n}$$

$$\text{MSE} = \frac{972{,}2434}{12}$$

$$= 81{,}02$$

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n}\sum_{i-1}^{n}(y_1 - \hat{y}_i)^2}$$

$$= \sqrt{81{,}02}$$

$$= 40{,}51$$

$$\text{MAPE} = \frac{100\%}{12}\sum_{t=1}^{12}\left[\frac{y_i - f_1}{y_t}\right]$$

$$= \frac{100\%}{12}\sum_{t=1}^{12}\left[\frac{\overline{y_t} - \overline{f_1}}{\overline{y_t}}\right]$$

$$=$$

$$R^2 = 1 - \frac{\sum_{i-1}^{n}(y_1 - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_1 - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{SSE}{SST}$$

$$= 1 - \frac{972{,}2434}{15555.89504}$$

$$R^2 = 0{,}98$$

LAMPIRAN 2

PERBANDINGAN PENELITIAN

Perbandingan penelitian – penelitian terdahulu yang berkaitan pada penelitian yang dikembangkan dapat dilihat pada Tabel L2.1.

Tabel L2.1 Penelitian Terdahulu

Penulis	Judul Penelitian	Algoritme	Fokus Penelitian	Hasil Penelitian	Research Gap
Marchel Yusuf Rumlawang Arpipi, Teny Handhayani, Irvan Lewenusa	*Forecasting Volatile Fresh Chili Prices in Indonesia Using Support Vector Regression*	SVR	Prediksi harga cabai merah & rawit di 87 kota (2018–2023)	SVR Linear terbaik, R^2 = 0.94	Dataset berfokus pada cabai metode SVR fokus komoditas spesifik, belum diuji pada minyak goreng
Clara Tanudy, Teny Handhayani, Janson Hendryli	Prediksi Harga Emas di Indonesia Menggunakan GRU	GRU	Prediksi harga emas dengan variabel emas, saham Antam, USD	GRU akurat, R^2 = 0.97	Dataset berbeda (emas, bukan pangan); metode deep learning kompleks, kurang interpretabel untuk kebijakan harga
Nikken Halim dkk.	Analisis harga minyak goreng di Pasar Pagi Pangkalpinang	Exponential Smoothing	Prediksi minyak goreng lokal (2018–2022)	Model Holt terbaik, RMSE 1,18736	Dataset sempit (1 pasar lokal); metode sederhana (linear) kurang tangguh

Penulis	Judul Penelitian	Algoritme	Fokus Penelitian	Hasil Penelitian	Research Gap
					untuk data volatil
Marsela Pangalila dkk.	-Forecasting Harga Minyak Goreng di Sulawesi Utara dengan ARIMA	Arima (1,2,1)	Prediksi bulanan minyak goreng (2018–2022, Sulut)	MSE 350.248; tren naik Jan 2023–Jun 2024	Dataset terbatas (1 provinsi, bulanan); metode ARIMA linear, kurang fleksibel untuk pola non-linear
Carin Gunawan, Teny Handhayani	Prediksi Harga Minyak Goreng di Papua dengan LSTM & GRU	LSTM dan GRU	Prediksi harga minyak goreng harian Papua (2022–2024) + CPO	GRU lebih unggul: MSE 229.454,2; MAE 226,89	Dataset terbatas (1 provinsi, 2 tahun); metode deep learning kompleks dan kurang interpretabel

LAMPIRAN 3

SIMBOL USE CASE DIAGRAM

Simbol – simbol *use case* diagram yang berkaitan pada penelitian dapat dilihat pada tabel

Tabel L3.1 Simbol *Use Case* Diagram

Simbol	Nama	Keterangan
	Actor	*Actor* adalah pengguna yang berinteraksi dengan *system*
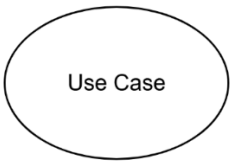	*Use Case*	*Usecase* adalah gambaran atau bentuk fungsi dari *system*
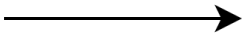	*Associations*	Relasi adalah penghubung antara *actor* dengan *use case*.
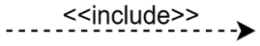	*Include*	Relasi sebagai penghubung antara *use case* dengan *use case* lainnya yang menjadi aktivitas tersendiri.
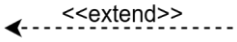	*Extend*	Relasi sebagai hubungan tambahan *use case* apabila suatu kondisi terpenuhi

Sumber : [42]

LAMPIRAN 4

USECASE DIAGRAM DAN TABEL USECASE SCENARIO

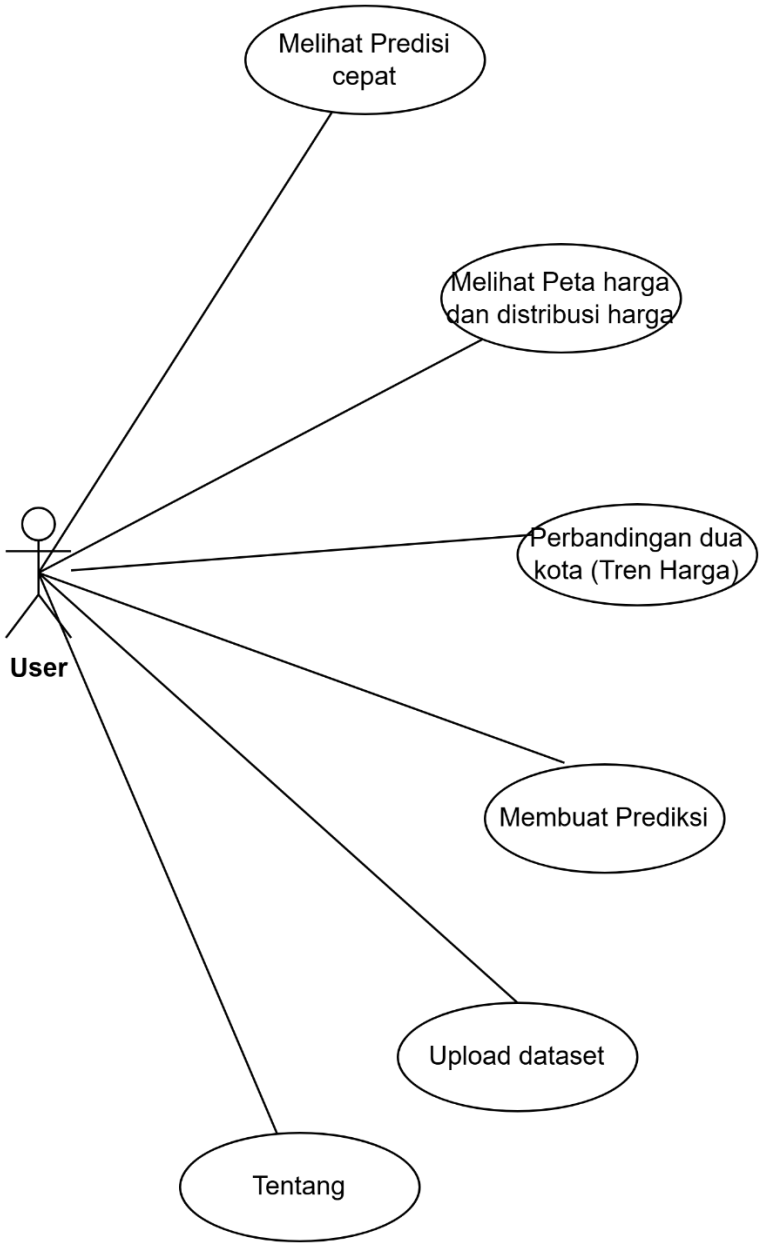

Gambar L4.1 *Use Case* Diagram *website* yang akan dibuat

Tabel L4.1 Usease Scenario

Elemen	Deskripsi
Use Case ID	UC-01
Nama Use Case	Melihat Prediksi Cepat
Deskripsi Singkat	User membuka halaman beranda, memilih kabupaten/kota, lalu sistem menampilkan hasil prediksi harga untuk wilayah yang dipilih dalam periode tertentu (misalnya 1 hari, 7 hari, 30 hari).
Precondition	1. Halaman beranda dapat diakses. 2. Daftar kabupaten/kota telah dimuat. 3. Model prediksi sudah tersedia di sistem.
Postcondition	1. Hasil prediksi harga tampil di halaman beranda. 2. User dapat melanjutkan ke fitur lain seperti melihat detail atau mengunduh hasil.
Alur Utama (Main Flow)	1. User membuka halaman Beranda. 2. Sistem menampilkan dropdown daftar kabupaten/kota dan area tampilan hasil prediksi (kosong/default). 3. User memilih Kabupaten/Kota dari dropdown. 4. User menekan tombol Lihat Prediksi Cepat. 5. Sistem menampilkan indikator loading dan memproses permintaan. 6. Sistem mengambil hasil prediksi dari model atau cache. 7. Sistem menampilkan hasil prediksi di layar (angka dan grafik mini). 8. User melihat hasil prediksi.

Elemen	Deskripsi
Use Case ID	UC-02
Nama Use Case	Melihat Peta Harga dan Distribusi Harga
Deskripsi Singkat	User dapat melihat visualisasi peta harga dan distribusi harga berdasarkan wilayah (pulau), tahun, dan periode waktu tertentu. Fitur ini membantu pengguna memahami pola harga antar daerah secara geografis.
Precondition	1. Halaman beranda dapat diakses. 2. Data harga dan prediksi untuk wilayah sudah tersedia di sistem. 3. Model peta harga telah dikonfigurasi untuk menampilkan data berdasarkan filter wilayah dan waktu.
Postcondition	1. Peta harga dan tabel informasi berhasil ditampilkan di halaman. 2. User dapat melihat sebaran harga dan perbandingan antar daerah dalam satu pulau.
Alur Utama (Main Flow)	1. **User** membuka halaman **Beranda**. 2. **Sistem** menampilkan halaman beranda dengan menu pilihan “Peta Harga”. 3. **User** memilih opsi **Pulau** dan **Tahun** (wajib) 4. **Sistem** memeriksa apakah Pulau dan Tahun telah dipilih. 5. Jika valid, **sistem** menyiapkan tampilan prediksi dan memuat

	data harga. 6. **Sistem** mengambil data harga untuk semua kota di pulau yang dipilih. 7. **Sistem** menampilkan **peta harga interaktif** dan **tabel informasi harga per kota**. 8. **User** dapat melihat hasil visualisasi dan menganalisis distribusi harga.

Elemen	**Deskripsi**
Use Case ID	**UC-03**
Nama Use Case	**Tren Harga (Perbandingan Dua Kota)**
Deskripsi Singkat	Pengguna dapat membandingkan tren harga antara dua kabupaten/kota pada periode waktu tertentu (tahun wajib; bulan/minggu opsional). Sistem menampilkan grafik perbandingan dan ringkasan statistik untuk membantu analisis tren.
Precondition	1. Halaman tinjauan tren dapat diakses. 2. Data harga historis dan/atau prediksi untuk kota tersedia di sistem. 3. Daftar kabupaten/kota dan periode (tahun/bulan/minggu) tersedia di UI.
Postcondition	1. Grafik perbandingan tren harga kedua kota ditampilkan. 2. Tabel/summary statistik (mis. rata-rata, perubahan %) tersedia untuk kedua kota.
Alur Utama (Main Flow)	1. User membuka halaman Tinjauan Tren. 2. Sistem menampilkan UI dengan kontrol pemilihan: Kab/Kota 1, Kab/Kota 2, Tahun (wajib), Bulan dan Minggu (opsional), serta tombol Tampilkan Tren. 3. User memilih Kab/Kota 1 dan Kab/Kota 2 dari daftar. 4. User memilih Tahun (wajib) dan opsional Bulan/Minggu bila ingin mempersempit periode. 5. User menekan tombol Tampilkan Tren. 6. Sistem menampilkan indikator loading dan mengirim request ke backend untuk mengambil data yang relevan untuk kedua kota pada periode terpilih. 7. Backend mengumpulkan data historis/prediksi untuk kedua kota dan mengembalikan dataset terstruktur (seri waktu). 8. Sistem memproses data untuk visualisasi (normalisasi/penyelarasan waktu jika perlu) dan menyiapkan grafik perbandingan (mis. garis waktu) serta ringkasan statistik (rata-rata, selisih, persentase perubahan). 9. Sistem menampilkan grafik perbandingan tren dan tabel ringkasan; menyediakan kontrol tambahan (zoom, tooltip, export) jika tersedia. 10. User melihat dan menganalisis hasil (dapat memilih detail pada titik waktu tertentu atau mengunduh hasil).

Elemen	Deskripsi
Use Case ID	UC-04
Nama Use Case	Prediksi Harga
Deskripsi Singkat	Pengguna dapat memilih kota, mode analisis, dan rentang waktu untuk melihat hasil prediksi harga. Sistem mengambil data sesuai pilihan pengguna, menjalankan model prediksi, dan menampilkan hasil berupa grafik serta tabel prediksi.
Precondition	1. Halaman prediksi dapat diakses. 2. Data historis harga tersedia untuk kota yang dipilih. 3. Model prediksi sudah dilatih dan siap digunakan oleh sistem.
Postcondition	1. Hasil prediksi harga tampil di halaman (grafik dan tabel). 2. User dapat melihat nilai prediksi dan analisis per periode waktu.
Alur Utama (Main Flow)	1. **User** membuka halaman **Prediksi**. 2. **Sistem** menampilkan halaman prediksi yang berisi form pemilihan opsi (kota, mode, dan range waktu). 3. **User** memilih **Kota**, **Mode Prediksi** (mis. harian, mingguan, bulanan), dan **Range Waktu** untuk periode analisis. 4. **User** menekan tombol **Lihat Prediksi** atau sistem otomatis memproses input setelah pilihan lengkap. 5. **Sistem** menampilkan indikator loading dan mengambil data historis harga kota yang dipilih dari basis data. 6. **Sistem** menjalankan proses prediksi menggunakan model yang sesuai (mis. regresi, gradient boosting, dsb.). 7. **Sistem** menyiapkan tampilan hasil berupa **grafik tren prediksi** dan **tabel data prediksi**. 8. **Sistem** menampilkan hasil akhir di halaman prediksi. 9. **User** melihat hasil, dapat mengubah parameter untuk prediksi ulang, atau melanjutkan ke fitur download hasil.

Elemen	Deskripsi
Use Case ID	UC-05
Nama Use Case	Upload Data (Upload Dataset & Analisis)
Deskripsi Singkat	User mengunggah file dataset (mis. Excel), menyimpan dan memicu proses analisis / training. Sistem memproses file, membuat model (jika perlu), menyiapkan hasil analisis dan prediksi, serta menampilkan file dan hasil kepada user. User dapat mengunduh hasil (PDF/Excel).
Precondition	1. User dapat mengakses halaman Upload. 2. Format file yang diunggah sesuai spesifikasi (kolom wajib ada). 3. Sistem punya kapasitas untuk memproses file (resource/job queue tersedia).
Postcondition	1. File tersimpan di server/penyimpanan. 2. Hasil analisis dan/atau model tersedia dan ditampilkan ke user. 3. File hasil (report/PDF/Excel) dapat diunduh oleh user.
Alur Utama (Main Flow)	1. User membuka halaman **Upload**. 2. Sistem menampilkan form upload dan instruksi format file.

	3. User memilih file Excel dari perangkat dan menekan **Unggah**. 4. Sistem menerima file dan melakukan validasi format dasar (kolom, tipe data). 5. User menekan **Simpan dan Analisis** untuk memulai proses. 6. Sistem menyimpan file ke storage dan menempatkan job analisis/training ke queue (atau memproses langsung). 7. Sistem melakukan preprocessing dan (jika diperlukan) training model menggunakan data yang diunggah. 8. Sistem membuat model/hasil analisis dan menyiapkan output (grafik, tabel, ringkasan, serta file report). 9. Sistem menampilkan file yang diunggah beserta hasil analisis/prediksi pada halaman (status selesai). 10. Jika user ingin, user menekan tombol **Download Hasil** → sistem menyiapkan file (PDF/Excel) dan mengirimkan file untuk diunduh.

Elemen	**Deskripsi**
Use Case ID	UC-06
Nama Use Case	Halaman Tentang
Deskripsi Singkat	Pengguna membuka halaman *Tentang* untuk melihat informasi umum terkait aplikasi, seperti tujuan, tim pengembang, teknologi yang digunakan, serta versi sistem.
Precondition	1. Aplikasi atau website dapat diakses dengan koneksi internet. 2. Halaman *Tentang* telah tersedia di menu navigasi atau footer.
Postcondition	1. Halaman *Tentang* ditampilkan dengan konten informatif. 2. Pengguna dapat membaca deskripsi aplikasi tanpa error tampilan atau loading gagal.
Alur Utama (Main Flow)	1. **User** membuka menu atau link **Tentang** dari navigasi utama atau footer 2. **Sistem** menerima permintaan dan memuat konten halaman *Tentang*. 3. **Sistem** menampilkan informasi berupa deskripsi aplikasi, tujuan pengembangan, tim pembuat, teknologi yang digunakan, serta versi aplikasi. 4. **User** membaca informasi yang ditampilkan. 5. Use case selesai.

LAMPIRAN 5

ACTIVITY DIAGRAM

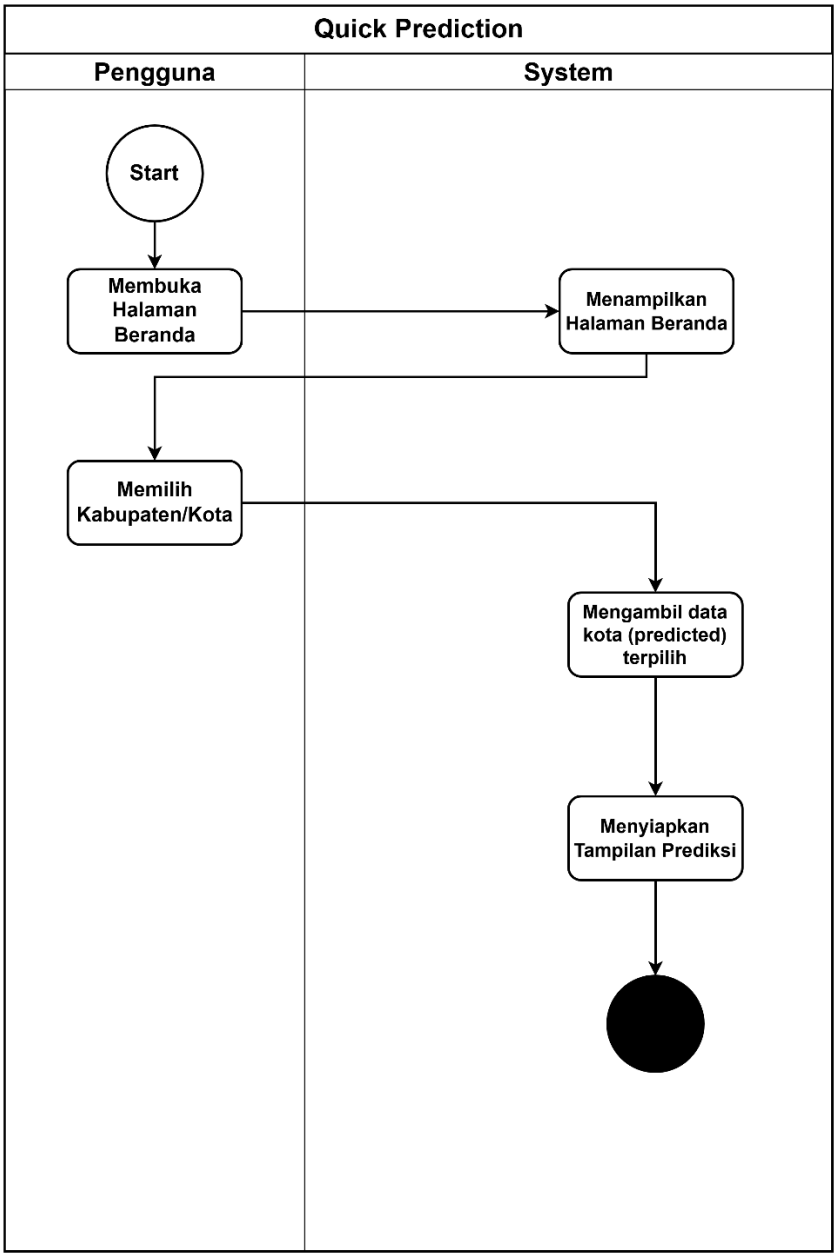

Gambar L5.1 Melihat Prediksi Cepat

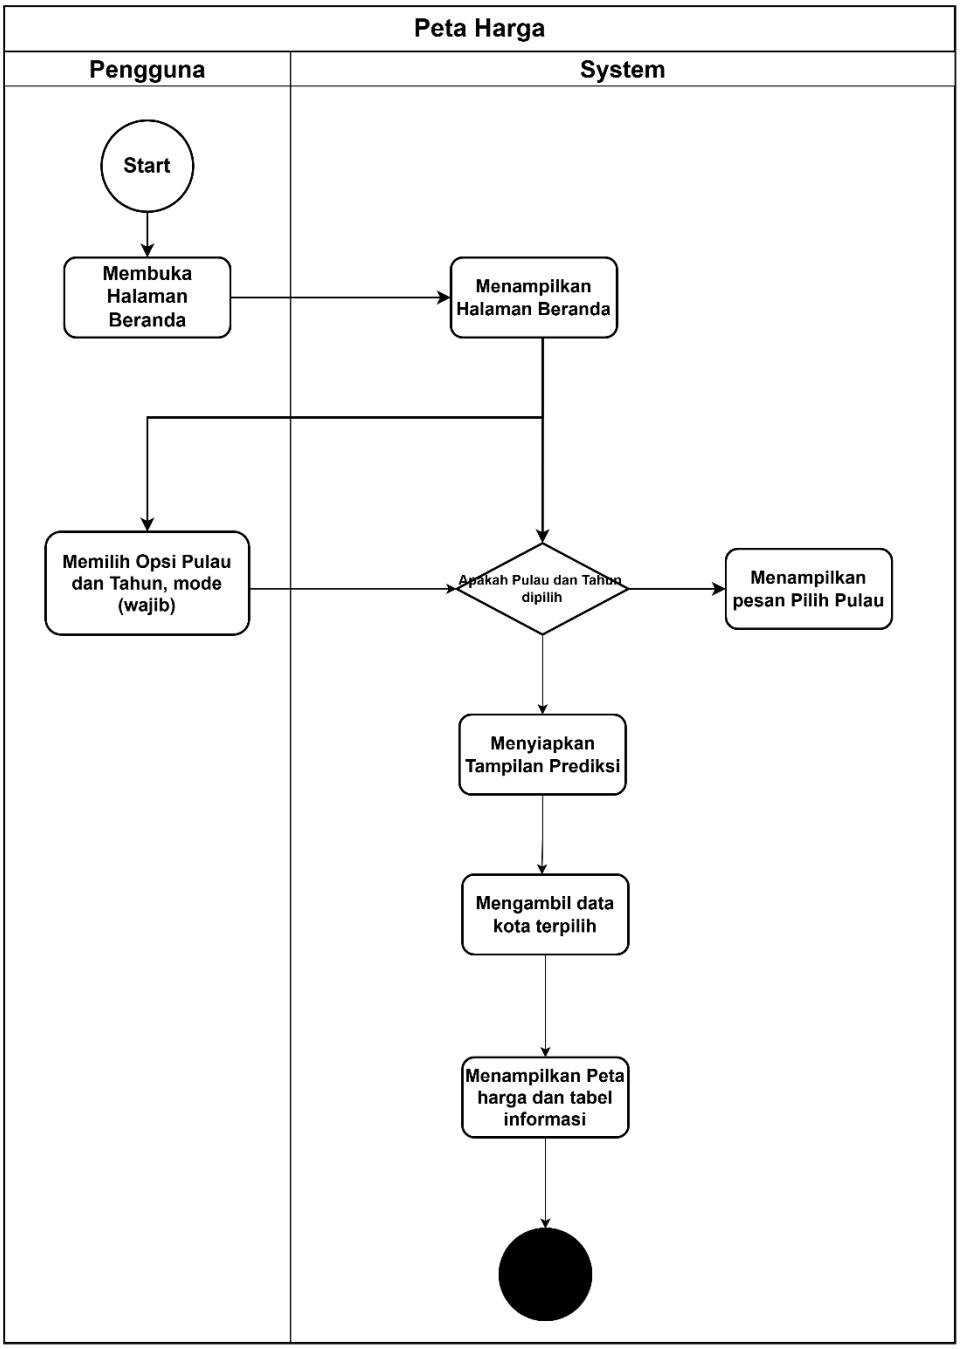

Gambar L5.2 Peta Harga

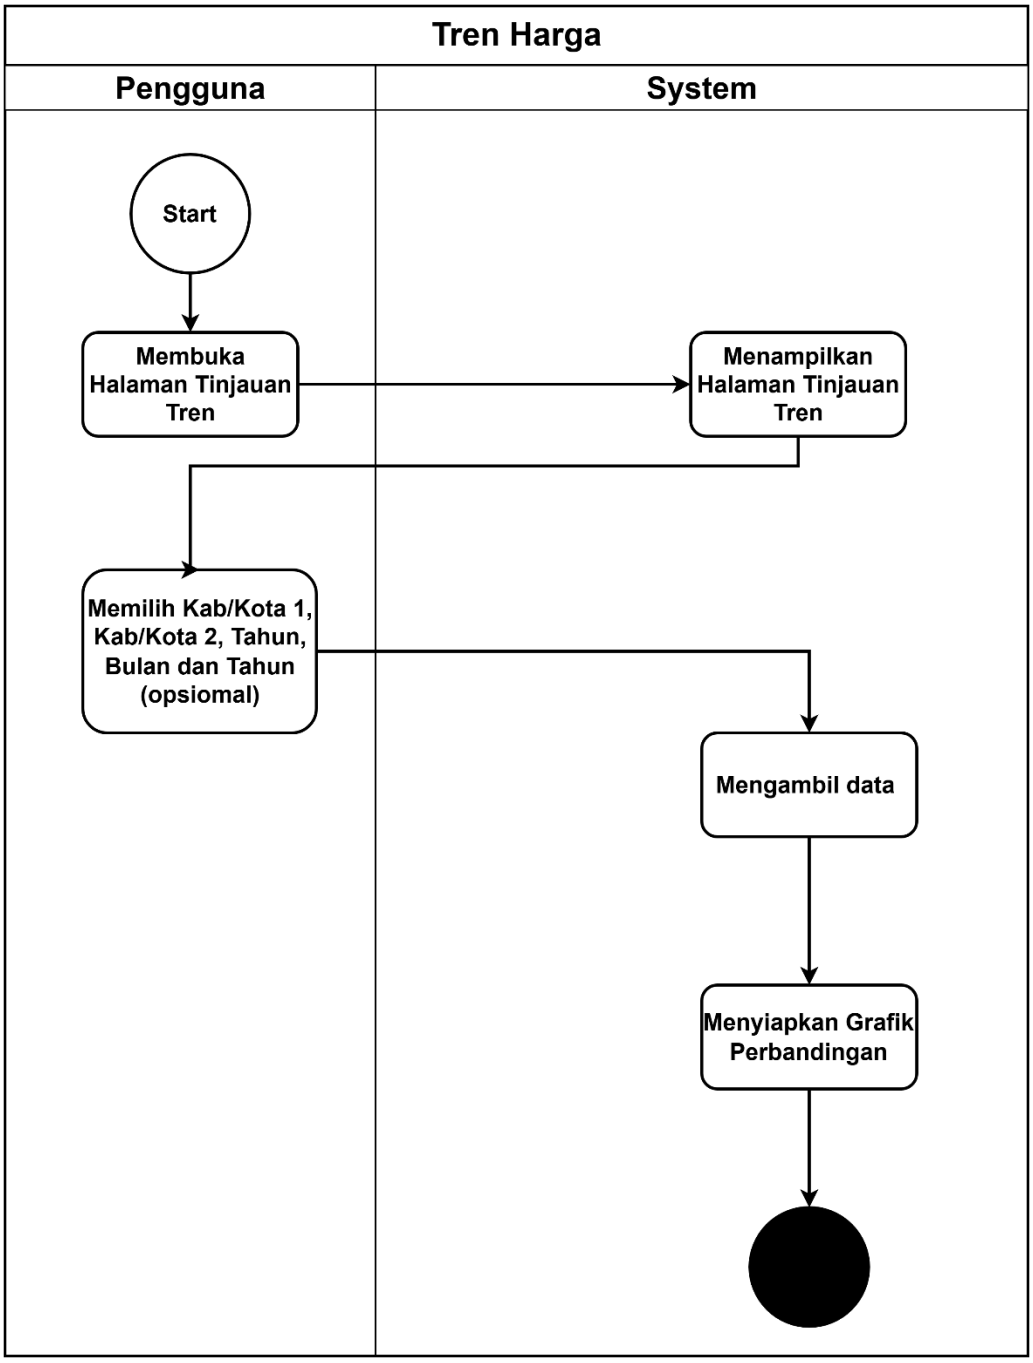

Gambar L5.3 Tren Harga

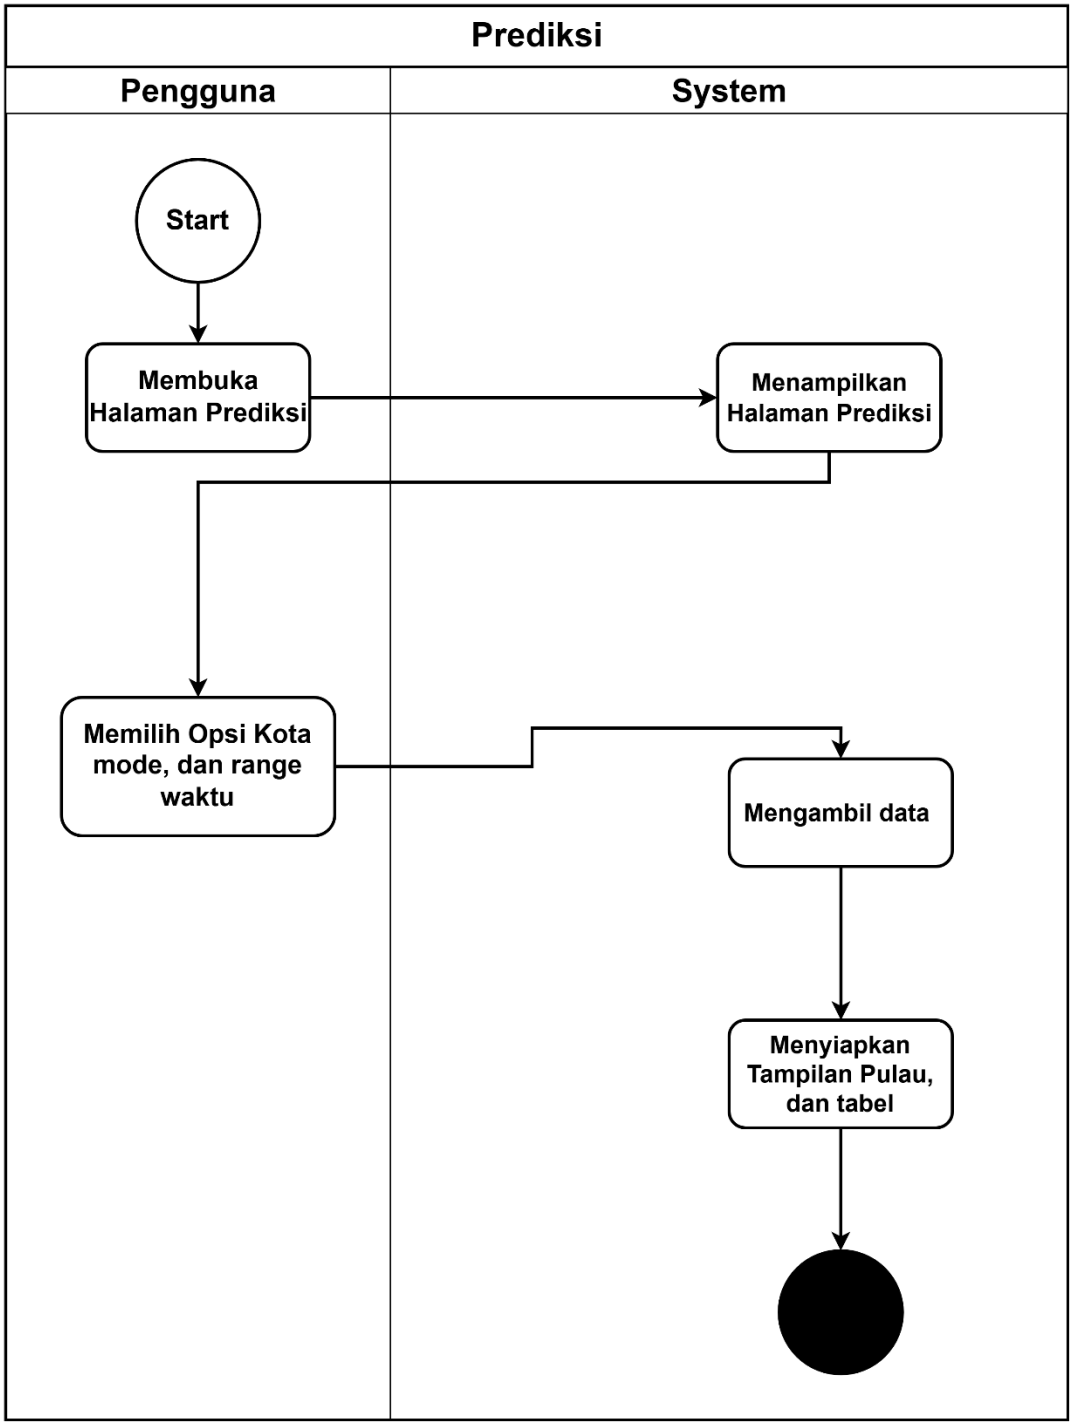

Gambar L5.4 Prediksi

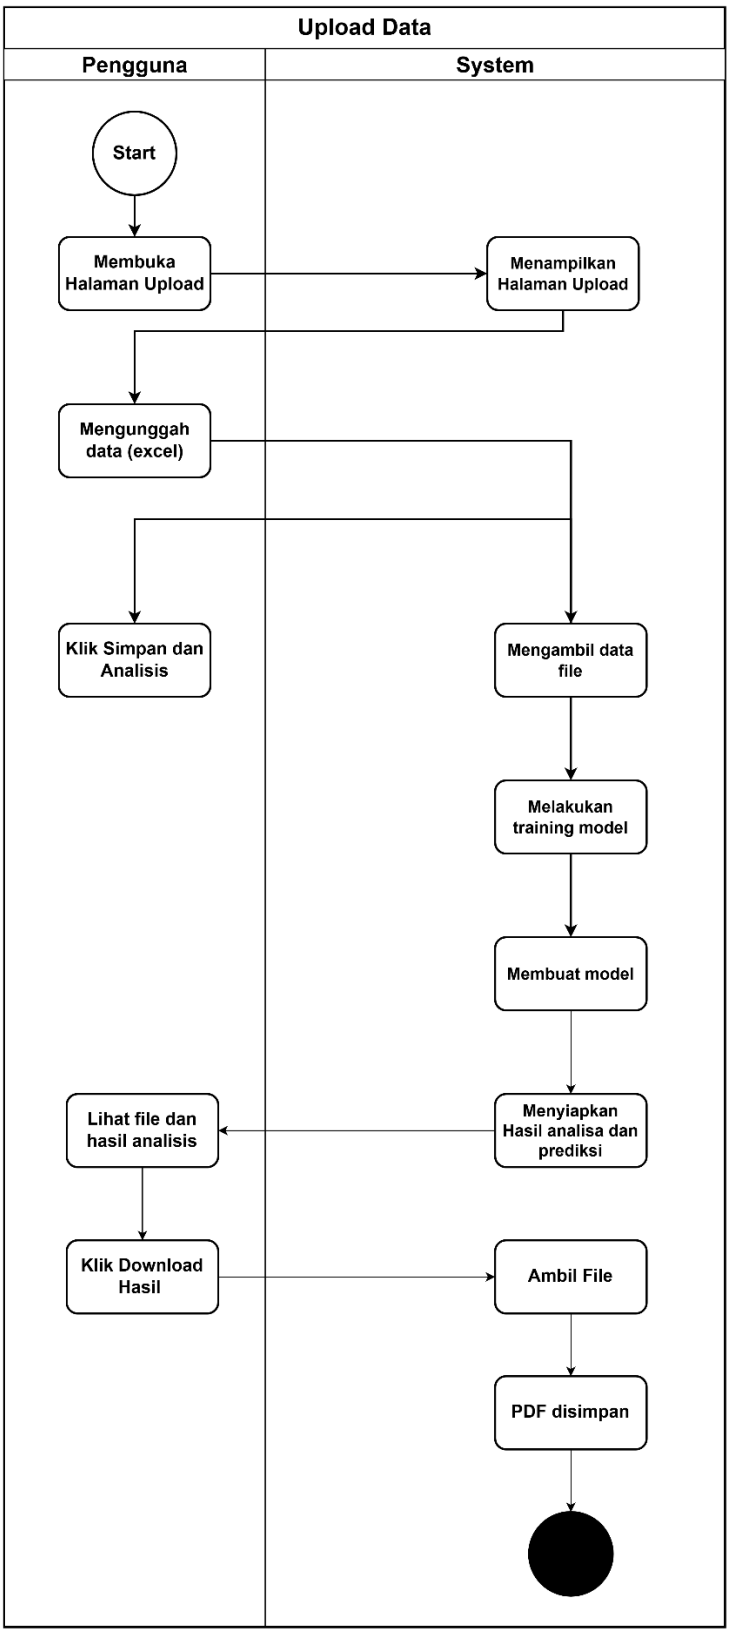

Gambar L5.5 *Upload* Data

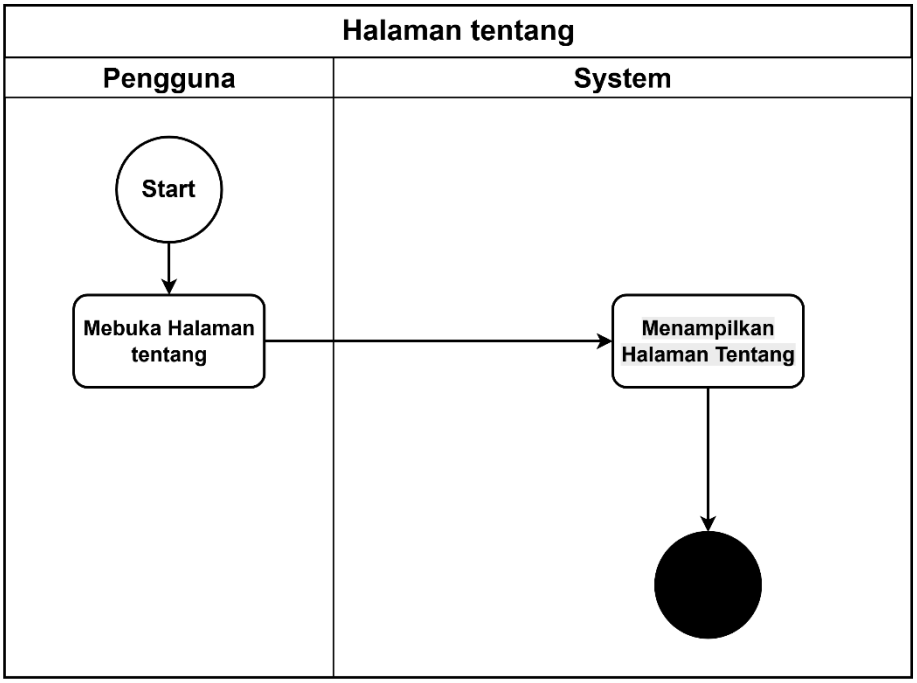

Gambar L5.6 Halaman Tentang

LAMPIRAN 6

DATA PIPELINE DIAGRAM

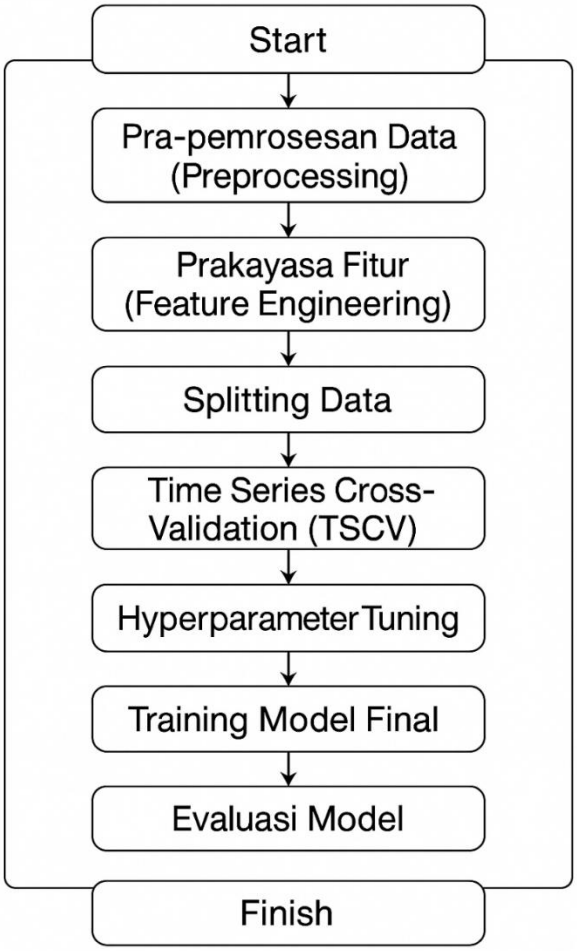

Gambar L6.1 Diagram Data Pipeline

LAMPIRAN 7

ANTARMUKA RANCANGAN

Gambar L7.1 Tampilan Halaman *Homepage* (beranda)

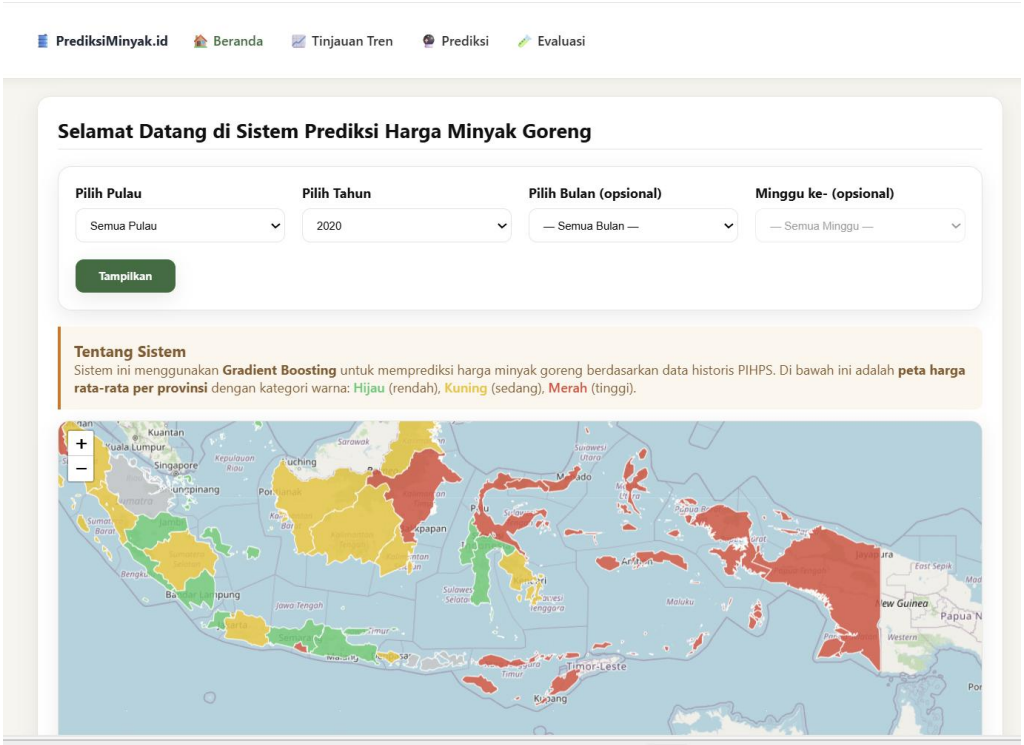

Gambar L7.2 Tampilan *Homepage* Pilih Dropdown Daerah

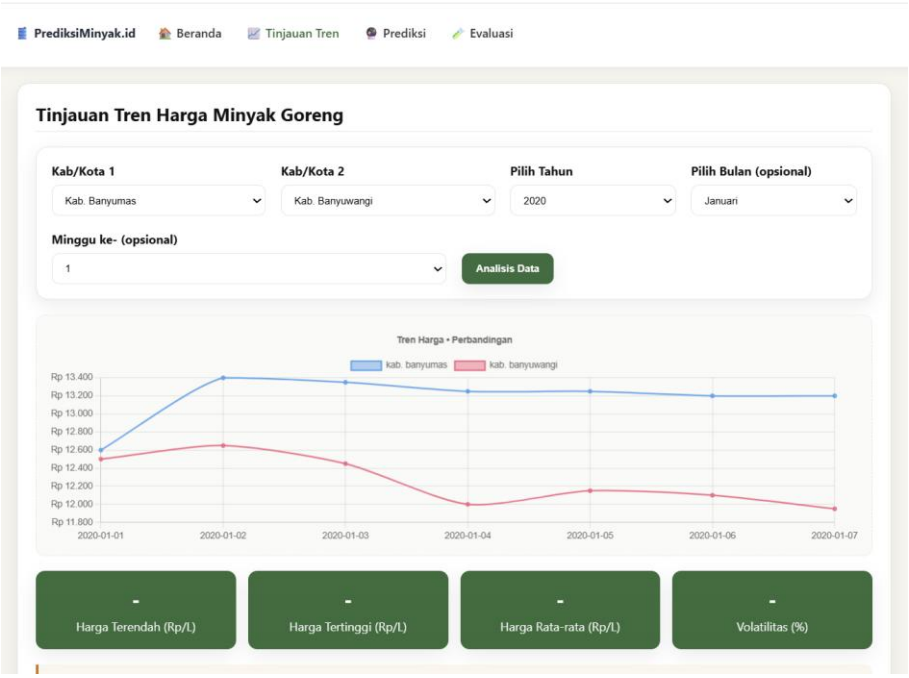

Gambar L7.3 Tampilan Halaman Tinjauan Tren

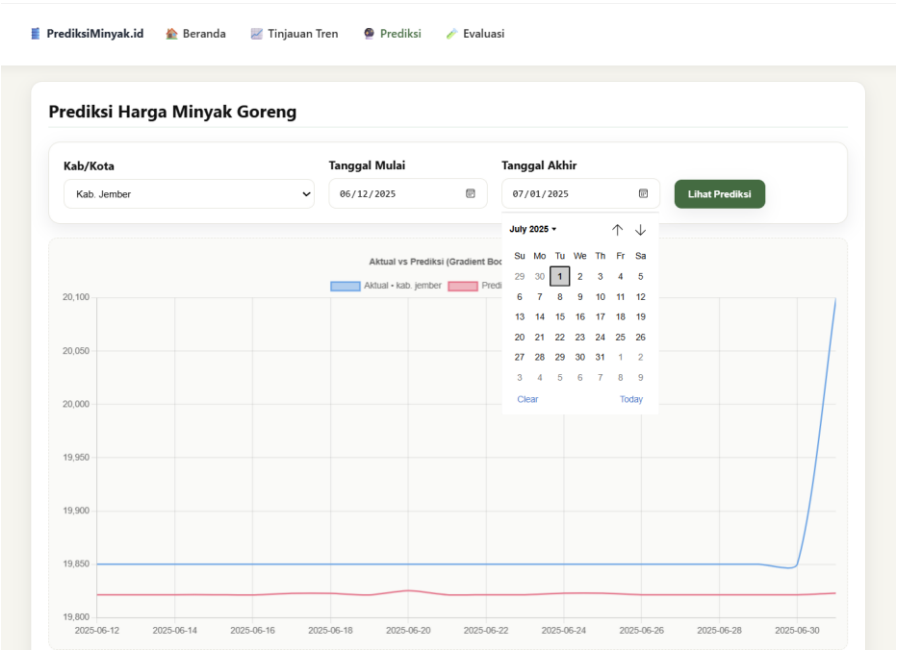

Gambar L7.4 Tampilan halaman prediksi untuk memilih waktu

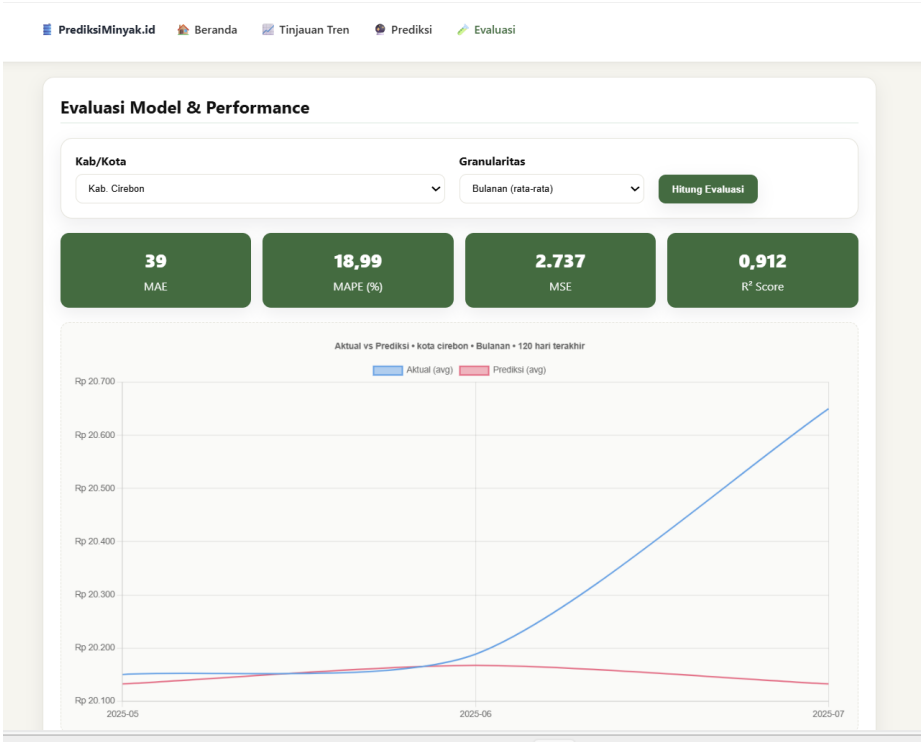

Gambar L7.5 Tampilan halaman evaluasi

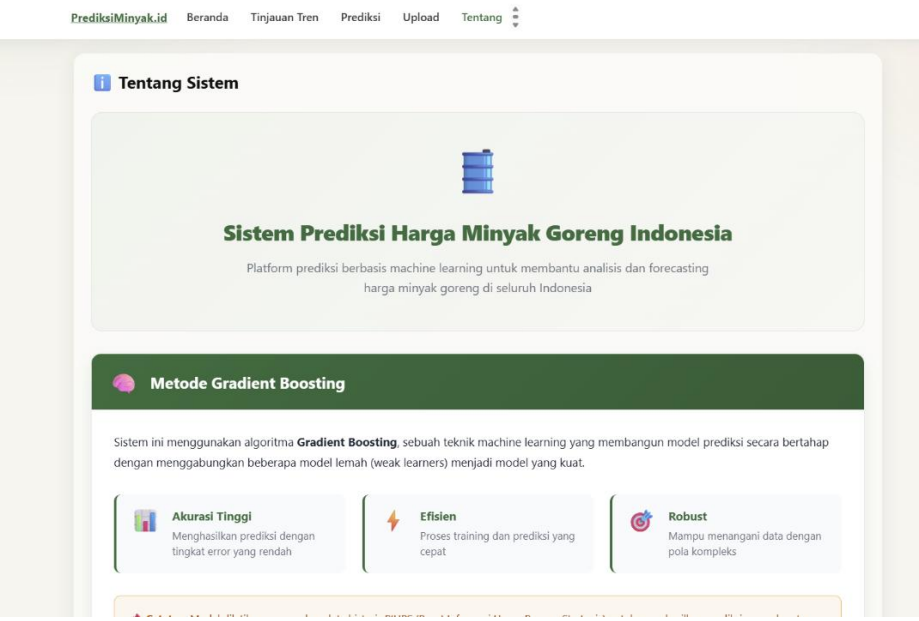

Gambar L7.6 Tampilan halaman Tentang

LAMPIRAN 8

RANGKAIAN WAKTU PENGERJAAN SISTEM

Tabel L8.1 Rangkaian Waktu Pngerjaan Sistem

	Juli 2025	**Ags 2025**	**Sep 2025**	**Okt 2025**	**Nov 2025**	**Dec 2025**
Perancanaan Sistem						
Analisis Kebutuhan Sistem						
Rancangan Sistem (Diagram)						
Implementasi						
Integration & Testing						
operation & maintenance						

LAMPIRAN 9

TABEL UJI EKSPERIMEN TRAINING (PELATIHAN MODEL)

Tabel L9.1 Parameter Input Eksperimen

No	Lag	Roll	Keterangan
1.	[ ]	[ ]	Hanya pakai lag_1 (hari sebelumnya)
2.	[7]	[ ]	Tambah lag 7 hari (mingguan)
3.	[14]	[ ]	Tambah lag 14 hari (dua mingguan)
4.	[30]	[ ]	Tambah lag 30 hari (bulanan)
5.	[ ]	[7]	Gunakan rata-rata 7 hari terakhir (rolling mingguan)
6.	[7]	[7]	Lag 7 hari + rata-rata 7 hari terakhir
7.	[14]	[7]	Lag 14 hari + rolling 7 hari
8.	[30]	[7]	Lag 30 hari + rolling 7 hari
9.	[ ]	[30]	Rolling 30 hari (rata-rata sebulan)
10.	[7]	[30]	Lag 7 hari + rolling 30 hari
11.	[14]	[30]	Lag 14 hari + rolling 30 hari
12.	[30]	[30]	Lag 30 hari + rolling 30 hari (paling panjang & smooth)

Tabel L9.2 List *Hyperparameter* yang digunakan

No.	Jenis Hyperparamter	List
1.	Learning Rate	[0.05, 0.03, 0.01]
2.	Max Iter	[150, 300, 450]
3.	Max depth	[1, 2, 3]

LAMPIRAN 10

TABEL UJI EKSPERIMEN TRAINING (PELATIHAN MODEL)

Tabel L10.1 Daftar Seluruh Kabupaten/Kota dengan evaluasi model terbaik

Kota	R2	MAE	RMSE	MSE	MAPE(%)
Kab Sragen	0.9365	101.005	133.1554	17730.37	0.53
Kab. Banyumas	0.9089	132.5309	178.8345	31981.78	0.65
Kab. Banyuwangi	0.928	85.9349	119.7436	14338.53	0.44
Kab. Boyolali	0.9169	106.6569	138.6104	19212.83	0.58
Kab. Bulukomba	0.9235	64.0562	97.9102	9586.403	0.33
Kab. Bulungan	0.8702	86.9395	133.7684	17893.99	0.42
Kab. Bungo	0.895	197.7119	244.9855	60017.92	0.97
Kab. Cilacap	0.9219	131.2021	169.5825	28758.22	0.65
Kab. Cirebon	0.9275	95.7512	135.315	18310.15	0.48
Kab. Gorontalo	-1.8656	1216.071	1423.347	2025917	4.96
Kab. Jayawijaya	-0.2993	198.0822	412.7257	170342.5	0.63
Kab. Jember	0.9244	99.75	155.2548	24104.06	0.51
Kab. Karanganyar	0.9341	108.371	133.6925	17873.68	0.55
Kab. Kudus	0.937	100.2354	142.9692	20440.2	0.52
Kab. Lombok Timur	0.9347	148.2507	192.023	36872.83	0.73
Kab. Majene	0.8953	176.9518	214.9607	46208.1	0.9
Kab. Manokwari	0.7173	292.3017	423.2198	179115	1.25
Kab. Merauke	0.9246	33.0337	77.8316	6057.761	0.15
Kab. Mimika	0.9043	68.6383	123.7165	15305.78	0.31
Kab. Nabire	-0.113	133.2877	418.3873	175047.9	0.59
Kab. Polewali Mandar	0	10.8551	14.4827	209.7495	0.05
Kab. Sintang	0.8388	35.1397	63.4039	4020.048	0.16
Kab. Sukoharjo	0.914	151.6516	221.7382	49167.85	0.77
Kab. Sumba Timur	0.8409	208.4862	313.6417	98371.1	0.9
Kab. Sumbawa	0.9261	103.3344	144.3384	20833.58	0.5
Kab. Sumenep	0.9425	57.6662	92.5287	8561.561	0.3
Kab. Wonogiri	0.9214	94.9996	126.7662	16069.68	0.5
Kab.Klaten	0.885	101.005	133.1554	17730.37	0.53
Kota Balikpapan	0	7.3557	7.6596	58.6697	0.03
Kota Banda Aceh	0	7.3557	7.6596	58.6697	0.03
Kota Bandar Lampung	-0.2004	1378.905	2815.002	7924235	7.08
Kota Bandung	0.924	90.8223	128.8937	16613.59	0.45
Kota Banggai	-2.1861	1032.051	1209.355	1462539	5.47
Kota Banjarmasin	0.883	96.4936	223.6201	50005.93	0.48

Kota	R2	MAE	RMSE	MSE	MAPE(%)
Kota Batam	0.8125	326.0091	400.7366	160589.8	1.71
Kota Bau - Bau	0.8463	262.7245	341.8803	116882.1	1.18
Kota Bekasi	0.9413	66.3981	108.6712	11809.44	0.32
Kota Bengkulu	0.9248	106.6438	137.7415	18972.72	0.55
Kota Bima	0.9409	70.7225	99.7814	9956.321	0.34
Kota Blitar	0.9071	53.4988	90.2123	8138.254	0.29
Kota Bogor	0.9435	58.0028	85.6368	7333.655	0.28
Kota Bontang	0.9359	64.695	99.1671	9834.123	0.32
Kota Cilegon	0.8914	112.573	150.7522	22726.23	0.6
Kota Cirebon	0.8718	194.7776	222.332	49431.51	0.99
Kota Denpasar	0.9204	80.323	146.5389	21473.64	0.37
Kota Depok	0.9417	77.5219	96.7505	9360.665	0.39
Kota Dumai	0.8905	174.3663	226.0217	51085.82	0.9
Kota Gorontalo	0.9283	77.6256	129.3321	16726.79	0.3
Kota Gunung Sitoli	0.9292	103.5683	137.1231	18802.74	0.46
Kota Jakarta Pusat	0.9403	56.6796	74.6707	5575.706	0.28
Kota Jambi	0.9033	133.8958	175.2765	30721.86	0.67
Kota Jayapura	0.8223	184.135	245.3775	60210.14	0.83
Kota Kediri	0.9348	92.2783	111.2381	12373.9	0.47
Kota Kendari	0.8886	96.7199	124.5993	15524.98	0.48
Kota Kupang	0.9211	41.734	72.9193	5317.224	0.21
Kota Lhokseumawe	0.9377	68.6131	99.2913	9858.772	0.33
Kota Madiun	0.93	65.8888	95.3018	9082.433	0.33
Kota Makassar	0.9138	39.743	104.4596	10911.81	0.21
Kota Malang	0.8455	294.4779	408.9303	167224	1.4
Kota Maluku	0.9392	39.8732	84.1051	7073.674	0.19
Kota Mamuju	0.9069	95.1161	172.5661	29779.07	0.48
Kota Manado	0.911	38.6315	75.0073	5626.102	0.22
Kota Mataram	0.8433	61.5119	126.9317	16111.67	0.29
Kota Maumere	0.9049	29.4354	79.4812	6317.265	0.13
Kota Medan	0.8838	129.9699	175.0689	30649.14	0.66
Kota Metro	0.9424	101.4709	134.0501	17969.43	0.5
Kota Meulaboh	0.9344	65.7723	94.7128	8970.509	0.33
Kota Padang	0.9388	69.7197	90.3337	8160.172	0.35
Kota Padang Sidempuan	0.495	170.999	199.4136	39765.78	0.87
Kota Palangkaraya	0.9181	71.4915	91.7839	8424.284	0.34
Kota Palembang	0.7173	292.3017	423.2198	179115	1.25
Kota Palu	0.8845	115.1216	168.639	28439.12	0.55

Kota	R2	MAE	RMSE	MSE	MAPE(%)
Kota Pangkalpinang	0.9214	94.9996	126.7662	16069.68	0.5
Kota Pare -Pare	0.9348	47.3872	72.4312	5246.275	0.25
Kota Pekanbaru	0.9375	61.8468	86.2191	7433.74	0.32
Kota Pematang Siantar	0.8974	71.5331	157.4248	24782.58	0.35
Kota Pontianak	0.9404	50.8621	70.3454	4948.474	0.26
Kota Probolinggo	0.9323	90.1401	108.6656	11808.21	0.46
Kota Sampit	0.8257	70.536	115.8817	13428.56	0.35
Kota Semarang	0.8164	254.0999	345.8703	119626.3	1.25
Kota Serang	0.9249	54.1755	91.8367	8433.978	0.28
Kota Sibolga	0.9239	125.275	149.2607	22278.76	0.64
Kota Singkawang	0.9385	45.5873	59.9004	3588.059	0.24
Kota Sorong	0.8752	105.4108	211.626	44785.55	0.46
Kota Sukabumi	0.936	91.2563	125.2041	15676.06	0.46
Kota Sumenep	0.9348	92.2783	111.2381	12373.9	0.47
Kota Surabaya	0.9414	46.0152	85.7445	7352.118	0.23
Kota Surakarta (Solo)	0.934	66.2206	89.3979	7991.981	0.33
Kota Tanggerang	0.8415	84.503	147.1458	21651.9	0.44
Kota Tanjung	0.9191	83.2124	117.2717	13752.66	0.43
Kota Tanjung Pandan	0.9289	90.523	143.4565	20579.78	0.52
Kota Tarakan	0.9147	48.524	71.0495	5048.03	0.23
Kota Tasikmalaya	0.9223	104.6503	149.4708	22341.53	0.52
Kota Tembilahan	0.9209	149.8427	242.0687	58597.25	0.8
Kota Ternate	0.9358	22.5659	50.6214	2562.526	0.1
Kota Tual	0.9283	78.633	117.6872	13850.28	0.34
Kota Watampone	0.9181	72.1083	103.6088	10734.78	0.39
Kota Yogyakarta	0.9418	45.6276	71.0718	5051.195	0.24
Kotamobagu	0.9418	45.6276	71.0718	5051.195	0.24

LAMPIRAN 11

TABEL UJI EKSPERIMEN HYPERPARAMETER

Tabel L11.1 Kota Banyumas

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Banyumas	[1, 30]	[7]	0.03	1	300	0.9089
Kab. Banyumas	[1, 30]	[30]	0.03	1	300	0.8997
Kab. Banyumas	[1, 14]	[7]	0.05	3	300	0.8991
Kab. Banyumas	[1, 30]	[]	0.03	1	300	0.8981
Kab. Banyumas	[1]	[]	0.03	2	150	0.8895
Kab. Banyumas	[1]	[7]	0.03	3	450	0.8892
Kab. Banyumas	[1, 14]	[]	0.05	3	450	0.883
Kab. Banyumas	[1, 7]	[30]	0.05	2	150	0.8348
Kab. Banyumas	[1, 7]	[]	0.01	3	300	0.8311
Kab. Banyumas	[1, 7]	[7]	0.01	3	300	0.8279
Kab. Banyumas	[1]	[30]	0.05	2	150	0.8191
Kab. Banyumas	[1, 14]	[30]	0.03	1	300	0.7643

Tabel L11.2 Kabupaten Banyuwangi

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Banyuwangi	[1, 14]	[30]	0.05	1	300	0.928
Kab. Banyuwangi	[1]	[30]	0.05	1	300	0.922
Kab. Banyuwangi	[1, 30]	[7]	0.03	1	300	0.9218
Kab. Banyuwangi	[1, 7]	[30]	0.05	1	300	0.9218
Kab. Banyuwangi	[1, 30]	[30]	0.03	1	300	0.9208
Kab. Banyuwangi	[1, 30]	[]	0.03	1	300	0.92
Kab. Banyuwangi	[1]	[7]	0.01	3	450	0.916
Kab. Banyuwangi	[1]	[]	0.03	3	150	0.9097
Kab. Banyuwangi	[1, 14]	[7]	0.05	3	150	0.9079
Kab. Banyuwangi	[1, 14]	[]	0.05	3	150	0.9013
Kab. Banyuwangi	[1, 7]	[7]	0.05	3	300	0.8996
Kab. Banyuwangi	[1, 7]	[]	0.05	3	450	0,8974

Tabel L11.3 Kabupaten Boyolali

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Boyolali	[1, 30]	[]	0.03	1	300	0.9169
Kab. Boyolali	[1, 30]	[7]	0.03	1	300	0.9152
Kab. Boyolali	[1, 30]	[30]	0.03	1	300	0.9135
Kab. Boyolali	[1, 14]	[7]	0.05	1	150	0.8945
Kab. Boyolali	[1]	[7]	0.05	1	150	0.8941

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Boyolali	[1]	[30]	0.03	1	300	0.8938
Kab. Boyolali	[1, 14]	[30]	0.03	1	300	0.8938
Kab. Boyolali	[1, 14]	[]	0.05	1	150	0.8936
Kab. Boyolali	[1, 7]	[30]	0.03	1	300	0.8936
Kab. Boyolali	[1]	[]	0.01	2	300	0.8909
Kab. Boyolali	[1, 7]	[7]	0.01	2	300	0.8296
Kab. Boyolali	[1, 7]	[]	0.01	2	300	0.8268

Tabel L11.4 Kabupaten Bulukomba

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Bulukomba	[1, 7]	[30]	0.03	1	300	0.9235
Kab. Bulukomba	[1, 14]	[30]	0.03	1	300	0.9224
Kab. Bulukomba	[1]	[30]	0.03	1	300	0.9222
Kab. Bulukomba	[1, 7]	[7]	0.03	1	300	0.921
Kab. Bulukomba	[1, 7]	[]	0.03	1	300	0.9207
Kab. Bulukomba	[1, 30]	[7]	0.03	1	300	0.897
Kab. Bulukomba	[1, 30]	[]	0.03	1	300	0.8962
Kab. Bulukomba	[1, 30]	[30]	0.03	1	300	0.8962
Kab. Bulukomba	[1, 14]	[7]	0.03	1	300	0.8952
Kab. Bulukomba	[1, 14]	[]	0.03	1	300	0.8938
Kab. Bulukomba	[1]	[7]	0.03	1	300	0.8842
Kab. Bulukomba	[1]	[]	0.03	1	300	0.8806

Tabel L11.5 Kabupaten Bulungan

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Bulungan	[1]	[7]	0.05	1	300	0.8702
Kab. Bulungan	[1]	[]	0.03	1	450	0.8583
Kab. Bulungan	[1, 14]	[7]	0.05	1	300	0.8379
Kab. Bulungan	[1, 30]	[7]	0.03	1	450	0.8181
Kab. Bulungan	[1, 7]	[7]	0.03	1	450	0.8023
Kab. Bulungan	[1, 14]	[]	0.05	1	300	0.8003
Kab. Bulungan	[1, 7]	[]	0.03	1	450	0.7879
Kab. Bulungan	[1, 30]	[]	0.03	1	450	0.7787
Kab. Bulungan	[1, 7]	[30]	0.03	1	300	0.7684
Kab. Bulungan	[1, 14]	[30]	0.03	1	300	0.7682
Kab. Bulungan	[1]	[30]	0.03	1	300	0.765
Kab. Bulungan	[1, 30]	[30]	0.03	1	450	0.7114

Tabel L11.6 Kabupaten Bungo

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Bungo	[1]	[30]	0.05	3	150	0.895
Kab. Bungo	[1, 14]	[30]	0.05	3	150	0.8939
Kab. Bungo	[1, 7]	[30]	0.03	3	300	0.889
Kab. Bungo	[1, 14]	[]	0.05	3	150	0.8827
Kab. Bungo	[1, 14]	[7]	0.05	3	150	0.8782
Kab. Bungo	[1]	[7]	0.03	3	150	0.8516
Kab. Bungo	[1, 7]	[7]	0.03	3	150	0.8335
Kab. Bungo	[1]	[]	0.01	3	450	0.8323
Kab. Bungo	[1, 30]	[30]	0.05	3	150	0.8215
Kab. Bungo	[1, 30]	[]	0.05	3	300	0.8185
Kab. Bungo	[1, 30]	[7]	0.03	3	450	0.8143
Kab. Bungo	[1, 7]	[]	0.01	3	300	0.7811

Tabel L11.7 Kabupaten Cilacap

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Cilacap	[1, 14]	[30]	0.05	1	450	0.9219
Kab. Cilacap	[1, 30]	[30]	0.05	1	300	0.9191
Kab. Cilacap	[1, 30]	[]	0.03	1	450	0.9168
Kab. Cilacap	[1]	[30]	0.05	1	450	0.914
Kab. Cilacap	[1, 7]	[]	0.05	2	300	0.9005
Kab. Cilacap	[1, 14]	[]	0.05	2	150	0.8992
Kab. Cilacap	[1]	[]	0.05	2	150	0.8901
Kab. Cilacap	[1, 30]	[7]	0.03	1	450	0.8658
Kab. Cilacap	[1, 7]	[30]	0.05	1	450	0.8623
Kab. Cilacap	[1]	[7]	0.03	2	450	0.8065
Kab. Cilacap	[1, 7]	[7]	0.05	3	450	0.8037
Kab. Cilacap	[1, 14]	[7]	0.03	1	450	0.8032

Tabel L11.8 Kabupaten Cirebon

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Cirebon	[1]	[30]	0.05	1	300	0.9275
Kab. Cirebon	[1, 14]	[30]	0.05	1	300	0.9274
Kab. Cirebon	[1]	[7]	0.05	3	450	0.9219
Kab. Cirebon	[1, 7]	[30]	0.05	1	300	0.9213
Kab. Cirebon	[1, 30]	[30]	0.05	1	450	0.9201
Kab. Cirebon	[1, 30]	[]	0.05	1	450	0.9199
Kab. Cirebon	[1, 30]	[7]	0.03	1	450	0.9181
Kab. Cirebon	[1, 7]	[7]	0.03	3	450	0.9109
Kab. Cirebon	[1, 7]	[]	0.03	3	450	0.909
Kab. Cirebon	[1]	[]	0.01	3	450	0.9049

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Cirebon	[1, 14]	[7]	0.01	3	450	0.9037
Kab. Cirebon	[1, 14]	[]	0.03	3	150	0.9021

Tabel L11.9 Kabupaten Gorontolo

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Gorontalo	[1]	[7]	0.05	1	150	-1.8656
Kab. Gorontalo	[1, 7]	[7]	0.05	1	150	-1.8857
Kab. Gorontalo	[1, 30]	[7]	0.05	1	150	-1.9025
Kab. Gorontalo	[1]	[]	0.05	1	150	-1.9436
Kab. Gorontalo	[1, 7]	[]	0.05	1	150	-2.0228
Kab. Gorontalo	[1, 14]	[7]	0.05	1	150	-2.1359
Kab. Gorontalo	[1, 30]	[]	0.05	1	150	-2.1504
Kab. Gorontalo	[1, 30]	[30]	0.05	1	150	-2.1504
Kab. Gorontalo	[1, 14]	[]	0.05	1	150	-2.2427
Kab. Gorontalo	[1]	[30]	0.05	1	150	-2.3492
Kab. Gorontalo	[1, 7]	[30]	0.05	1	150	-2.3492
Kab. Gorontalo	[1, 14]	[30]	0.05	1	150	-2.3992

Tabel L11.10 Kabupaten Jayawijaya

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Jayawijaya	[1]	[]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1, 7]	[]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1, 14]	[]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1, 30]	[]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1]	[7]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1, 7]	[7]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1, 14]	[7]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1, 30]	[7]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1]	[30]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1, 7]	[30]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1, 14]	[30]	0.05	1	150	-0.2993
Kab. Jayawijaya	[1, 30]	[30]	0.05	1	150	-0.2993

Tabel L11.11 Kabupaten Jember

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Jember	[1]	[7]	0.03	1	450	0.9244
Kab. Jember	[1, 14]	[]	0.03	1	450	0.9237
Kab. Jember	[1, 7]	[7]	0.03	1	450	0.9236
Kab. Jember	[1, 14]	[7]	0.03	1	450	0.9235
Kab. Jember	[1, 7]	[]	0.05	1	450	0.9212
Kab. Jember	[1]	[]	0.03	2	450	0.9182

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Jember	[1, 7]	[30]	0.03	1	300	0.9175
Kab. Jember	[1, 30]	[7]	0.03	2	450	0.9108
Kab. Jember	[1, 14]	[30]	0.03	2	450	0.9048
Kab. Jember	[1, 30]	[30]	0.05	2	300	0.9013
Kab. Jember	[1, 30]	[]	0.05	2	450	0.8951
Kab. Jember	[1]	[30]	0.05	2	450	0.895

Tabel L11.12 Kabupaten Karangayar

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Karanganyar	[1, 30]	[]	0.05	1	450	0.9341
Kab. Karanganyar	[1, 30]	[7]	0.05	2	450	0.9335
Kab. Karanganyar	[1]	[]	0.05	2	450	0.933
Kab. Karanganyar	[1, 14]	[30]	0.05	1	300	0.933
Kab. Karanganyar	[1]	[30]	0.05	1	300	0.9329
Kab. Karanganyar	[1, 30]	[30]	0.03	2	450	0.9318
Kab. Karanganyar	[1, 7]	[30]	0.05	1	300	0.937
Kab. Karanganyar	[1]	[7]	0.01	2	450	0.9041
Kab. Karanganyar	[1, 7]	[]	0.03	2	450	0.8978
Kab. Karanganyar	[1, 7]	[7]	0.05	3	150	0.874
Kab. Karanganyar	[1, 14]	[]	0.05	2	450	0.8699
Kab. Karanganyar	[1, 14]	[7]	0.05	3	300	0.8518

Tabel L11.13 Kabupaten Kudus

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Kudus	[1, 14]	[]	0.01	3	450	0.937
Kab. Kudus	[1]	[30]	0.01	3	450	0.9355
Kab. Kudus	[1, 14]	[30]	0.01	3	450	0.9353
Kab. Kudus	[1]	[7]	0.03	3	150	0.9345
Kab. Kudus	[1, 7]	[7]	0.03	3	450	0.9339
Kab. Kudus	[1, 30]	[]	0.01	3	450	0.9337
Kab. Kudus	[1, 7]	[30]	0.01	3	450	0.933
Kab. Kudus	[1, 30]	[7]	0.03	2	150	0.9313
Kab. Kudus	[1, 30]	[30]	0.03	1	300	0.9311
Kab. Kudus	[1, 7]	[]	0.01	3	300	0.9134
Kab. Kudus	[1, 14]	[7]	0.05	3	150	0.9057
Kab. Kudus	[1]	[]	0.01	2	300	0.893

Tabel L11.14 Kabupaten Lombok Timur

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Lombok Timur	[1, 30]	[30]	0.05	1	450	0.9347
Kab. Lombok Timur	[1]	[7]	0.05	1	450	0.9344
Kab. Lombok Timur	[1, 30]	[7]	0.05	2	150	0.9321
Kab. Lombok Timur	[1, 30]	[]	0.05	2	150	0.931
Kab. Lombok Timur	[1, 7]	[30]	0.03	1	450	0.931
Kab. Lombok Timur	[1]	[]	0.05	2	300	0.9309
Kab. Lombok Timur	[1]	[30]	0.03	1	450	0.9309
Kab. Lombok Timur	[1, 7]	[7]	0.03	2	150	0.9299
Kab. Lombok Timur	[1, 14]	[30]	0.03	1	450	0.9299
Kab. Lombok Timur	[1, 14]	[]	0.05	1	450	0.9281
Kab. Lombok Timur	[1, 7]	[]	0.03	2	150	0.9273
Kab. Lombok Timur	[1, 14]	[7]	0.05	1	150	0.9237

Tabel L11.15 Kabupaten Majene

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Majene	[1, 30]	[30]	0.03	3	300	0.8953
Kab. Majene	[1, 7]	[30]	0.05	3	150	0.8933
Kab. Majene	[1, 7]	[7]	0.05	2	300	0.8904
Kab. Majene	[1, 7]	[]	0.01	3	450	0.8873
Kab. Majene	[1]	[7]	0.03	3	450	0.8739
Kab. Majene	[1]	[]	0.05	2	450	0.8639
Kab. Majene	[1, 14]	[]	0.03	2	150	0.8514
Kab. Majene	[1, 14]	[30]	0.03	3	150	0.8483
Kab. Majene	[1, 14]	[7]	0.01	3	450	0.8374
Kab. Majene	[1, 30]	[]	0.05	1	300	0.8312
Kab. Majene	[1, 30]	[7]	0.03	1	450	0.8247
Kab. Majene	[1]	[30]	0.05	3	300	0.7583

Tabel L11.16 Kabupaten Manokwari

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Manokwari	[1, 7]	[7]	0.05	3	150	0.7173
Kab. Manokwari	[1]	[]	0.05	3	450	0.711
Kab. Manokwari	[1, 7]	[]	0.05	2	450	0.693
Kab. Manokwari	[1, 30]	[]	0.05	1	450	0.6788
Kab. Manokwari	[1, 14]	[]	0.05	3	450	0.6702
Kab. Manokwari	[1, 30]	[30]	0.05	2	450	0.6679
Kab. Manokwari	[1, 14]	[7]	0.05	2	450	0.6254
Kab. Manokwari	[1]	[7]	0.05	3	150	0.6173
Kab. Manokwari	[1]	[30]	0.03	1	300	0.5911
Kab. Manokwari	[1, 7]	[30]	0.03	1	300	0.5911

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Manokwari	[1, 14]	[30]	0.03	1	300	0.5911
Kab. Manokwari	[1, 30]	[7]	0.05	1	450	0.5848

Tabel L11.17 Kabupaten Merauke

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Merauke	[1, 7]	[30]	0.03	3	300	0.9246
Kab. Merauke	[1]	[30]	0.03	3	300	0.9234
Kab. Merauke	[1, 14]	[30]	0.03	3	300	0.9218
Kab. Merauke	[1]	[]	0.05	1	150	0.917
Kab. Merauke	[1, 14]	[]	0.05	1	150	0.9165
Kab. Merauke	[1, 7]	[7]	0.01	3	450	0.9149
Kab. Merauke	[1, 14]	[7]	0.05	1	150	0.9131
Kab. Merauke	[1, 30]	[30]	0.03	3	450	0.8872
Kab. Merauke	[1, 7]	[]	0.01	3	300	0.8067
Kab. Merauke	[1]	[7]	0.01	3	300	0.7622
Kab. Merauke	[1, 30]	[]	0.01	3	300	0.7242
Kab. Merauke	[1, 30]	[7]	0.01	3	300	0.718

Tabel L11.18 Kabupaten Mimika

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Mimika	[1, 14]	[7]	0.05	2	450	0.9043
Kab. Mimika	[1, 14]	[]	0.05	2	300	0.9033
Kab. Mimika	[1]	[30]	0.05	1	150	0.9019
Kab. Mimika	[1, 30]	[]	0.03	2	450	0.9016
Kab. Mimika	[1, 14]	[30]	0.05	1	150	0.9014
Kab. Mimika	[1]	[7]	0.01	3	450	0.8989
Kab. Mimika	[1, 30]	[30]	0.03	2	450	0.8981
Kab. Mimika	[1, 7]	[]	0.03	3	150	0.8966
Kab. Mimika	[1, 7]	[30]	0.05	1	150	0.8949
Kab. Mimika	[1, 30]	[7]	0.05	1	150	0.8931
Kab. Mimika	[1, 7]	[7]	0.01	3	300	0.8576
Kab. Mimika	[1]	[]	0.01	2	300	0.8523

Tabel L11.19 Kabupaten Nabire

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Nabire	[1]	[]	0.05	1	150	-0.113
Kab. Nabire	[1, 7]	[]	0.05	1	150	-0.113
Kab. Nabire	[1, 14]	[]	0.05	1	150	-0.113
Kab. Nabire	[1, 30]	[]	0.05	1	150	-0.113
Kab. Nabire	[1]	[7]	0.05	1	150	-0.113
Kab. Nabire	[1, 7]	[7]	0.05	1	150	-0.113

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Nabire	[1, 14]	[7]	0.05	1	150	-0.113
Kab. Nabire	[1, 30]	[7]	0.05	1	150	-0.113
Kab. Nabire	[1]	[30]	0.05	1	150	-0.113
Kab. Nabire	[1, 7]	[30]	0.05	1	150	-0.113
Kab. Nabire	[1, 14]	[30]	0.05	1	150	-0.113
Kab. Nabire	[1, 30]	[30]	0.05	1	150	-0.113

Tabel L11.20 Kabupaten Polewali Mandar

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Polewali Mandar	[1]	[]	0.05	3	450	0
Kab. Polewali Mandar	[1, 7]	[]	0.05	2	150	0
Kab. Polewali Mandar	[1, 14]	[]	0.03	3	300	0
Kab. Polewali Mandar	[1, 30]	[]	0.05	3	300	0
Kab. Polewali Mandar	[1]	[7]	0.03	2	300	0
Kab. Polewali Mandar	[1, 7]	[7]	0.05	2	150	0
Kab. Polewali Mandar	[1, 14]	[7]	0.05	2	300	0
Kab. Polewali Mandar	[1, 30]	[7]	0.03	3	300	0
Kab. Polewali Mandar	[1]	[30]	0.05	1	150	0
Kab. Polewali Mandar	[1, 7]	[30]	0.05	1	150	0
Kab. Polewali Mandar	[1, 14]	[30]	0.05	1	150	0
Kab. Polewali Mandar	[1, 30]	[30]	0.05	3	150	0

Tabel L11.21 Kabupaten Sintang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Sintang	[1, 7]	[]	0.05	3	150	0.8388
Kab. Sintang	[1, 14]	[7]	0.05	3	300	0.8329
Kab. Sintang	[1]	[7]	0.05	3	450	0.8315
Kab. Sintang	[1, 14]	[30]	0.05	1	150	0.8247
Kab. Sintang	[1, 7]	[30]	0.05	1	150	0.8225
Kab. Sintang	[1, 30]	[]	0.05	3	150	0.7867
Kab. Sintang	[1, 30]	[30]	0.05	1	150	0.7676
Kab. Sintang	[1]	[30]	0.05	1	300	0.7604
Kab. Sintang	[1, 30]	[7]	0.03	1	450	0.7394
Kab. Sintang	[1, 14]	[]	0.01	3	300	0.5944
Kab. Sintang	[1]	[]	0.01	3	300	0.4652
Kab. Sintang	[1, 7]	[7]	0.01	3	300	0.3035

Tabel L11.22 Kabupaten Sukoharjo

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Sukoharjo	[1]	[]	0.03	2	150	0.914
Kab. Sukoharjo	[1, 7]	[]	0.05	2	150	0.9089
Kab. Sukoharjo	[1]	[7]	0.05	2	450	0.9068
Kab. Sukoharjo	[1]	[30]	0.03	2	300	0.9031
Kab. Sukoharjo	[1, 7]	[30]	0.03	2	450	0.902
Kab. Sukoharjo	[1, 14]	[]	0.05	2	150	0.901
Kab. Sukoharjo	[1, 14]	[7]	0.05	2	150	0.8987
Kab. Sukoharjo	[1, 14]	[30]	0.03	2	300	0.8983
Kab. Sukoharjo	[1, 30]	[]	0.05	1	450	0.8846
Kab. Sukoharjo	[1, 30]	[7]	0.05	1	450	0.8841
Kab. Sukoharjo	[1, 7]	[7]	0.03	2	150	0.8759
Kab. Sukoharjo	[1, 30]	[30]	0.05	2	150	0.8713

Tabel L11.23 Kabupaten Sumba Timur

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Sumba Timur	[1, 14]	[]	0.03	2	150	0.8409
Kab. Sumba Timur	[1, 14]	[7]	0.03	2	150	0.84
Kab. Sumba Timur	[1]	[7]	0.03	2	150	0.838
Kab. Sumba Timur	[1, 30]	[]	0.01	2	450	0.836
Kab. Sumba Timur	[1, 30]	[30]	0.01	2	450	0.8358
Kab. Sumba Timur	[1, 30]	[7]	0.05	1	150	0.8354
Kab. Sumba Timur	[1, 7]	[30]	0.05	1	150	0.8279
Kab. Sumba Timur	[1]	[30]	0.05	1	150	0.8277
Kab. Sumba Timur	[1, 14]	[30]	0.05	1	150	0.8275
Kab. Sumba Timur	[1, 7]	[7]	0.01	3	300	0.7915
Kab. Sumba Timur	[1, 7]	[]	0.01	3	300	0.7863
Kab. Sumba Timur	[1]	[]	0.01	3	300	0.7734

Tabel L11.24 Kabupaten Sumbawa

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Sumbawa	[1]	[7]	0.03	3	150	0.9261
Kab. Sumbawa	[1, 7]	[30]	0.05	1	450	0.9241
Kab. Sumbawa	[1, 30]	[30]	0.05	1	450	0.9218
Kab. Sumbawa	[1, 14]	[30]	0.05	1	450	0.9208
Kab. Sumbawa	[1]	[30]	0.05	1	450	0.9201
Kab. Sumbawa	[1, 30]	[]	0.05	1	450	0.9183
Kab. Sumbawa	[1, 14]	[]	0.03	1	300	0.8894
Kab. Sumbawa	[1]	[]	0.03	2	150	0.8798
Kab. Sumbawa	[1, 14]	[7]	0.03	1	300	0.8229
Kab. Sumbawa	[1, 30]	[7]	0.05	1	450	0.7931

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Sumbawa	[1, 7]	[]	0.01	3	300	0.7804
Kab. Sumbawa	[1, 7]	[7]	0.01	3	300	0.6109

Tabel L11.25 Kabupaten Sumenep

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Sumenep	[1]	[7]	0.01	2	450	0.9425
Kab. Sumenep	[1, 30]	[30]	0.03	1	450	0.9423
Kab. Sumenep	[1]	[30]	0.05	1	450	0.9422
Kab. Sumenep	[1, 14]	[30]	0.05	1	450	0.9418
Kab. Sumenep	[1, 7]	[30]	0.05	1	300	0.9416
Kab. Sumenep	[1, 30]	[]	0.03	1	450	0.9414
Kab. Sumenep	[1, 30]	[7]	0.05	1	450	0.941
Kab. Sumenep	[1, 14]	[7]	0.03	2	150	0.9369
Kab. Sumenep	[1, 7]	[]	0.01	2	300	0.9181
Kab. Sumenep	[1]	[]	0.01	2	300	0.9179
Kab. Sumenep	[1, 7]	[7]	0.01	2	300	0.9178
Kab. Sumenep	[1, 14]	[]	0.01	2	300	0.912

Tabel L11.26 Kabupaten Wonogiri

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Wonogiri	[1, 30]	[]	0.05	2	300	0.9214
Kab. Wonogiri	[1, 30]	[7]	0.05	2	300	0.9205
Kab. Wonogiri	[1]	[30]	0.03	1	450	0.9177
Kab. Wonogiri	[1, 7]	[30]	0.03	1	450	0.9176
Kab. Wonogiri	[1, 14]	[30]	0.03	2	300	0.9164
Kab. Wonogiri	[1, 30]	[30]	0.03	3	300	0.9155
Kab. Wonogiri	[1]	[]	0.03	2	300	0.9152
Kab. Wonogiri	[1, 7]	[]	0.05	3	150	0.913
Kab. Wonogiri	[1, 7]	[7]	0.05	3	150	0.9109
Kab. Wonogiri	[1, 14]	[]	0.03	3	450	0.91
Kab. Wonogiri	[1, 14]	[7]	0.03	3	300	0.9083
Kab. Wonogiri	[1]	[7]	0.05	3	150	0.905

Tabel L11.27 Kabupaten Klaten

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab.Klaten	[1, 7]	[30]	0.05	3	300	0.885
Kab.Klaten	[1, 14]	[7]	0.05	3	150	0.8844
Kab.Klaten	[1, 14]	[30]	0.05	3	450	0.8828
Kab.Klaten	[1]	[30]	0.05	3	450	0.8827
Kab.Klaten	[1, 30]	[7]	0.05	3	150	0.8782
Kab.Klaten	[1, 14]	[]	0.05	3	150	0.878

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab.Klaten	[1]	[7]	0.05	3	150	0.8756
Kab.Klaten	[1, 30]	[]	0.05	3	150	0.8676
Kab.Klaten	[1, 30]	[30]	0.05	3	150	0.8645
Kab.Klaten	[1]	[]	0.01	3	150	-1.1137
Kab.Klaten	[1, 7]	[]	0.01	3	150	-1.1377
Kab.Klaten	[1, 7]	[7]	0.01	2	150	-1.9158

Tabel L11.28 Kabupaten Sragen

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab Sragen	[1]	[30]	0.05	1	300	0.9365
Kab Sragen	[1, 14]	[30]	0.03	1	450	0.9363
Kab Sragen	[1, 7]	[30]	0.03	1	450	0.9357
Kab Sragen	[1]	[]	0.03	2	300	0.934
Kab Sragen	[1, 30]	[7]	0.05	2	150	0.934
Kab Sragen	[1, 30]	[30]	0.03	2	300	0.9339
Kab Sragen	[1, 30]	[]	0.03	2	300	0.9338
Kab Sragen	[1, 14]	[7]	0.05	3	150	0.93
Kab Sragen	[1, 7]	[]	0.03	2	150	0.9289
Kab Sragen	[1, 7]	[7]	0.03	2	150	0.9277
Kab Sragen	[1]	[7]	0.03	3	300	0.926
Kab Sragen	[1, 14]	[]	0.01	3	300	0.849

Tabel L11.29 Kota Balikpapan

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Balikpapan	[1]	[]	0.05	3	150	0
Kota Balikpapan	[1, 7]	[]	0.05	3	150	0
Kota Balikpapan	[1, 14]	[]	0.05	2	300	0
Kota Balikpapan	[1, 30]	[]	0.03	2	150	0
Kota Balikpapan	[1]	[7]	0.03	3	300	0
Kota Balikpapan	[1, 7]	[7]	0.05	3	150	0
Kota Balikpapan	[1, 14]	[7]	0.03	2	450	0
Kota Balikpapan	[1, 30]	[7]	0.01	3	450	0
Kota Balikpapan	[1]	[30]	0.05	1	450	0
Kota Balikpapan	[1, 7]	[30]	0.05	1	450	0
Kota Balikpapan	[1, 14]	[30]	0.05	1	450	0
Kota Balikpapan	[1, 30]	[30]	0.03	2	450	0

Tabel L11.30 Kota Banda Aceh

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Banda Aceh	[1]	[]	0.05	3	150	0
Kota Banda Aceh	[1, 7]	[]	0.05	3	150	0
Kota Banda Aceh	[1, 14]	[]	0.05	2	300	0
Kota Banda Aceh	[1, 30]	[]	0.03	2	150	0
Kota Banda Aceh	[1]	[7]	0.03	3	300	0
Kota Banda Aceh	[1, 7]	[7]	0.05	3	150	0
Kota Banda Aceh	[1, 14]	[7]	0.03	2	450	0
Kota Banda Aceh	[1, 30]	[7]	0.01	3	450	0
Kota Banda Aceh	[1]	[30]	0.05	1	450	0
Kota Banda Aceh	[1, 7]	[30]	0.05	1	450	0
Kota Banda Aceh	[1, 14]	[30]	0.05	1	450	0
Kota Banda Aceh	[1, 30]	[30]	0.03	2	450	0

Tabel L11.31 Kota Bandar Lampung

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Bandar Lampung	[1, 30]	[30]	0.05	1	300	-0.2004
Kota Bandar Lampung	[1, 30]	[7]	0.05	1	300	-0.2006
Kota Bandar Lampung	[1]	[30]	0.03	1	300	-0.2037
Kota Bandar Lampung	[1, 30]	[]	0.05	2	150	-0.2038
Kota Bandar Lampung	[1, 7]	[30]	0.05	2	300	-0.2046
Kota Bandar Lampung	[1, 14]	[]	0.05	2	300	-0.2049
Kota Bandar Lampung	[1, 14]	[7]	0.05	2	300	-0.2051
Kota Bandar Lampung	[1]	[]	0.05	1	150	-0.2077
Kota Bandar Lampung	[1, 14]	[30]	0.05	1	150	-0.2092
Kota Bandar Lampung	[1, 7]	[]	0.05	1	150	-0.2093
Kota Bandar Lampung	[1, 7]	[7]	0.05	1	150	-0.2093
Kota Bandar Lampung	[1]	[7]	0.05	1	150	-0.2098

Tabel L11.32 Kota Banggai

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Banggai	[1, 14]	[7]	0.01	2	150	-2.1861
Kota Banggai	[1]	[30]	0.01	2	150	-2.3419
Kota Banggai	[1, 14]	[30]	0.01	2	150	-2.3419
Kota Banggai	[1]	[7]	0.01	3	150	-2.6349
Kota Banggai	[1, 7]	[7]	0.01	3	150	-2.641
Kota Banggai	[1, 7]	[]	0.01	3	150	-2.6523
Kota Banggai	[1, 30]	[7]	0.01	3	150	-3.166
Kota Banggai	[1, 14]	[]	0.01	1	150	-3.1754
Kota Banggai	[1, 7]	[30]	0.01	1	150	-3.1803
Kota Banggai	[1]	[]	0.01	1	150	-3.269

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Banggai	[1, 30]	[]	0.01	2	150	-3.2706
Kota Banggai	[1, 30]	[30]	0.01	2	150	-3.2706

Tabel L11.33 Kota Banjarmasin

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Banjarmasin	[1, 30]	[7]	0.05	1	300	0.883
Kota Banjarmasin	[1, 30]	[]	0.05	1	300	0.8827
Kota Banjarmasin	[1, 30]	[30]	0.05	1	300	0.8826
Kota Banjarmasin	[1]	[30]	0.05	1	450	0.8798
Kota Banjarmasin	[1, 7]	[30]	0.05	1	450	0.8796
Kota Banjarmasin	[1, 14]	[30]	0.05	1	450	0.8795
Kota Banjarmasin	[1]	[]	0.01	3	450	0.8714
Kota Banjarmasin	[1, 14]	[]	0.01	3	450	0.8694
Kota Banjarmasin	[1, 14]	[7]	0.01	3	450	0.8691
Kota Banjarmasin	[1, 7]	[]	0.05	1	150	0.8663
Kota Banjarmasin	[1, 7]	[7]	0.01	2	450	0.8656
Kota Banjarmasin	[1]	[7]	0.01	3	300	0.8324

Tabel L11.34 Kabupaten Sukoharjo

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Sukoharjo	[1]	[]	0.03	2	150	0.914
Kab. Sukoharjo	[1, 7]	[]	0.05	2	150	0.9089
Kab. Sukoharjo	[1]	[7]	0.05	2	450	0.9068
Kab. Sukoharjo	[1]	[30]	0.03	2	300	0.9031
Kab. Sukoharjo	[1, 7]	[30]	0.03	2	450	0.902
Kab. Sukoharjo	[1, 14]	[]	0.05	2	150	0.9001
Kab. Sukoharjo	[1, 14]	[7]	0.05	2	150	0.8987
Kab. Sukoharjo	[1, 14]	[30]	0.03	2	300	0.8983
Kab. Sukoharjo	[1, 30]	[]	0.05	1	450	0.8846
Kab. Sukoharjo	[1, 30]	[7]	0.05	1	450	0.8841
Kab. Sukoharjo	[1, 7]	[7]	0.03	2	150	0.8759
Kab. Sukoharjo	[1, 30]	[30]	0.05	2	150	0.8713

Tabel L11.35 Kabupaten Sumba Timur

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Sumba Timur	[1, 14]	[]	0.03	2	150	0.8409
Kab. Sumba Timur	[1, 14]	[7]	0.03	2	150	0.84
Kab. Sumba Timur	[1]	[7]	0.03	2	150	0.838
Kab. Sumba Timur	[1, 30]	[]	0.01	2	450	0.836
Kab. Sumba Timur	[1, 30]	[30]	0.01	2	450	0.8358
Kab. Sumba Timur	[1, 30]	[7]	0.05	1	150	0.8354

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Sumba Timur	[1, 7]	[30]	0.05	1	150	0.8279
Kab. Sumba Timur	[1]	[30]	0.05	1	150	0.8277
Kab. Sumba Timur	[1, 14]	[30]	0.05	1	150	0.8275
Kab. Sumba Timur	[1, 7]	[7]	0.01	3	300	0.7915
Kab. Sumba Timur	[1, 7]	[]	0.01	3	300	0.7863
Kab. Sumba Timur	[1]	[]	0.01	3	300	0.7734

Tabel L11.36 Kabupaten Sumbawa

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kab. Sumbawa	[1]	[7]	0.03	3	150	0.8761
Kab. Sumbawa	[1, 7]	[30]	0.05	1	450	0.8741
Kab. Sumbawa	[1, 30]	[30]	0.05	1	450	0.8718
Kab. Sumbawa	[1, 14]	[30]	0.05	1	450	0.8708
Kab. Sumbawa	[1]	[30]	0.05	1	450	0.8701
Kab. Sumbawa	[1, 30]	[]	0.05	1	450	0.8783
Kab. Sumbawa	[1, 14]	[]	0.03	1	300	0.8394
Kab. Sumbawa	[1]	[]	0.03	2	150	0.8298
Kab. Sumbawa	[1, 14]	[7]	0.03	1	300	0.7729
Kab. Sumbawa	[1, 30]	[7]	0.05	1	450	0.7431
Kab. Sumbawa	[1, 7]	[]	0.01	3	300	0.7304
Kab. Sumbawa	[1, 7]	[7]	0.01	3	300	0.5609

Tabel L11.37 Kota Bandung

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Bandung	[1, 30]	[7]	0.05	1	300	0.924
Kota Bandung	[1, 30]	[]	0.05	1	300	0.9273
Kota Bandung	[1, 14]	[]	0.05	2	450	0.9229
Kota Bandung	[1, 30]	[30]	0.05	1	450	0.918
Kota Bandung	[1]	[7]	0.05	1	150	0.9089
Kota Bandung	[1, 7]	[7]	0.05	1	150	0.9008
Kota Bandung	[1, 7]	[]	0.05	1	150	0.8987
Kota Bandung	[1]	[30]	0.03	1	300	0.8927
Kota Bandung	[1, 14]	[7]	0.05	1	150	0.8915
Kota Bandung	[1]	[]	0.05	1	150	0.8881
Kota Bandung	[1, 14]	[30]	0.05	1	300	0.8794
Kota Bandung	[1, 7]	[30]	0.05	1	300	0.8782

Tabel L11.38 Kota Batam

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Batam	[1, 30]	[]	0.05	2	150	0.8125
Kota Batam	[1, 30]	[30]	0.05	2	150	0.8018
Kota Batam	[1, 30]	[7]	0.03	2	450	0.7971
Kota Batam	[1]	[30]	0.03	2	450	0.7678
Kota Batam	[1, 7]	[30]	0.03	2	300	0.7665
Kota Batam	[1, 14]	[30]	0.03	2	450	0.7639
Kota Batam	[1, 7]	[7]	0.05	2	300	0.752
Kota Batam	[1, 7]	[]	0.05	2	450	0.7455
Kota Batam	[1, 14]	[]	0.01	2	450	0.7305
Kota Batam	[1]	[7]	0.01	3	450	0.7094
Kota Batam	[1, 14]	[7]	0.01	2	450	0.7077
Kota Batam	[1]	[]	0.03	3	300	0.6653

Tabel L11.39 Kota Bau – Bau

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Bau - Bau	[1, 30]	[30]	0.03	1	450	0.8463
Kota Bau - Bau	[1, 30]	[7]	0.03	1	450	0.8449
Kota Bau - Bau	[1, 30]	[]	0.03	1	450	0.8447
Kota Bau - Bau	[1]	[30]	0.03	3	150	0.843
Kota Bau - Bau	[1, 7]	[30]	0.05	3	150	0.8362
Kota Bau - Bau	[1, 14]	[30]	0.05	3	150	0.8304
Kota Bau - Bau	[1]	[7]	0.01	3	150	0.7068
Kota Bau - Bau	[1]	[]	0.01	3	150	0.7041
Kota Bau - Bau	[1, 14]	[]	0.01	3	150	0.6796
Kota Bau - Bau	[1, 14]	[7]	0.01	3	150	0.6796
Kota Bau - Bau	[1, 7]	[7]	0.01	3	150	0.6722
Kota Bau - Bau	[1, 7]	[]	0.01	3	150	0.7215

Tabel L11.40 Kota Bekasi

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Bekasi	[1]	[7]	0.05	3	300	0.9413
Kota Bekasi	[1, 14]	[]	0.03	3	150	0.9409
Kota Bekasi	[1, 14]	[7]	0.03	2	300	0.9409
Kota Bekasi	[1, 7]	[7]	0.03	2	450	0.9403
Kota Bekasi	[1, 7]	[30]	0.05	1	300	0.9399
Kota Bekasi	[1, 30]	[]	0.03	1	450	0.9396
Kota Bekasi	[1, 30]	[30]	0.03	1	450	0.9396
Kota Bekasi	[1, 30]	[7]	0.03	1	450	0.9394
Kota Bekasi	[1]	[30]	0.03	1	450	0.9394
Kota Bekasi	[1, 14]	[30]	0.03	1	450	0.9392

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Bekasi	[1, 7]	[]	0.03	2	450	0.9386
Kota Bekasi	[1]	[]	0.01	3	300	0.9335

Tabel L11.41 Kota Bengkulu

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Bengkulu	[1]	[7]	0.05	1	300	0.9248
Kota Bengkulu	[1, 14]	[7]	0.03	1	450	0.9234
Kota Bengkulu	[1, 7]	[]	0.03	1	300	0.9122
Kota Bengkulu	[1, 14]	[]	0.03	1	300	0.9112
Kota Bengkulu	[1, 7]	[7]	0.03	1	300	0.9112
Kota Bengkulu	[1]	[]	0.03	1	300	0.9091
Kota Bengkulu	[1, 30]	[7]	0.05	1	150	0.8978
Kota Bengkulu	[1, 30]	[]	0.05	1	150	0.897
Kota Bengkulu	[1, 30]	[30]	0.05	1	150	0,8969
Kota Bengkulu	[1]	[30]	0.05	1	150	0.8919
Kota Bengkulu	[1, 7]	[30]	0.05	1	150	0.8919
Kota Bengkulu	[1, 14]	[30]	0.05	1	150	0.8919

Tabel L11.42 Kota Bima

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Bima	[1, 7]	[7]	0.05	1	450	0.9409
Kota Bima	[1, 7]	[30]	0.05	1	450	0.9406
Kota Bima	[1]	[30]	0.05	1	450	0.9398
Kota Bima	[1]	[7]	0.03	1	450	0.9393
Kota Bima	[1, 14]	[7]	0.03	1	450	0.9377
Kota Bima	[1, 30]	[30]	0.05	1	450	0.9373
Kota Bima	[1, 30]	[7]	0.05	2	450	0.9336
Kota Bima	[1, 14]	[]	0.05	2	300	0.9322
Kota Bima	[1, 14]	[30]	0.05	2	300	0.9306
Kota Bima	[1, 30]	[]	0.05	1	150	0.9262
Kota Bima	[1, 7]	[]	0.01	3	450	0.9158
Kota Bima	[1]	[]	0.01	3	300	0.8786

Tabel L11.43 Kota Blitar

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Blitar	[1]	[]	0.05	1	150	0.9071
Kota Blitar	[1, 14]	[]	0.05	2	450	0.9066
Kota Blitar	[1, 14]	[7]	0.03	2	450	0.9058
Kota Blitar	[1, 7]	[]	0.03	3	300	0.8955
Kota Blitar	[1, 7]	[7]	0.05	1	150	0.8901
Kota Blitar	[1]	[30]	0.03	1	300	0.8646

Kota Blitar	[1]	[7]	0.05	1	450	0.8524
Kota Blitar	[1, 30]	[]	0.05	1	300	0.8483
Kota Blitar	[1, 30]	[7]	0.05	1	300	0.8483
Kota Blitar	[1, 30]	[30]	0.05	1	450	0.8483
Kota Blitar	[1, 14]	[30]	0.05	1	450	0.8353
Kota Blitar	[1, 7]	[30]	0.05	1	450	0.8321

Tabel L11.44 Kota Bogor

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Bogor	[1, 30]	[30]	0.05	1	300	0.9435
Kota Bogor	[1, 14]	[7]	0.03	1	450	0.9433
Kota Bogor	[1]	[30]	0.05	1	450	0.9433
Kota Bogor	[1, 7]	[30]	0.05	1	450	0.9431
Kota Bogor	[1, 14]	[]	0.03	1	450	0.9426
Kota Bogor	[1, 14]	[30]	0.03	1	450	0.9424
Kota Bogor	[1, 30]	[7]	0.05	1	450	0.9423
Kota Bogor	[1, 30]	[]	0.05	1	450	0.9422
Kota Bogor	[1, 7]	[]	0.05	3	150	0.9372
Kota Bogor	[1, 7]	[7]	0.05	3	150	0.9372
Kota Bogor	[1]	[7]	0.05	1	150	0.9325
Kota Bogor	[1]	[]	0.01	3	450	0.9307

Tabel L11.45 Kota Bontang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Bontang	[1]	[7]	0.01	3	450	0.9359
Kota Bontang	[1]	[]	0.05	3	300	0.9344
Kota Bontang	[1]	[30]	0.05	1	450	0.9297
Kota Bontang	[1, 7]	[30]	0.05	1	450	0.9294
Kota Bontang	[1, 14]	[7]	0.05	3	150	0.9289
Kota Bontang	[1, 14]	[30]	0.03	1	450	0.9286
Kota Bontang	[1, 7]	[]	0.05	3	300	0.9253
Kota Bontang	[1, 14]	[]	0.03	2	450	0.925
Kota Bontang	[1, 30]	[7]	0.05	1	450	0.9235
Kota Bontang	[1, 7]	[7]	0.03	3	300	0.9223
Kota Bontang	[1, 30]	[30]	0.05	2	150	0.9193
Kota Bontang	[1, 30]	[]	0.05	2	300	0.9176

Tabel L11.46 Kota Cilegon

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Cilegon	[1, 14]	[30]	0.03	1	450	0.8914
Kota Cilegon	[1]	[30]	0.03	1	450	0.8912
Kota Cilegon	[1, 7]	[30]	0.03	1	450	0.8905
Kota Cilegon	[1, 30]	[30]	0.05	1	450	0.8877
Kota Cilegon	[1, 30]	[]	0.05	1	450	0.8873
Kota Cilegon	[1, 30]	[7]	0.05	1	450	0.8873
Kota Cilegon	[1, 14]	[]	0.05	3	300	0.8829
Kota Cilegon	[1]	[7]	0.05	3	150	0.8828
Kota Cilegon	[1, 14]	[7]	0.03	3	450	0.8811
Kota Cilegon	[1, 7]	[]	0.01	2	300	0.8253
Kota Cilegon	[1]	[]	0.01	2	300	0.824
Kota Cilegon	[1, 7]	[7]	0.01	2	300	0.8237

Tabel L11.47 Kota Cirebon

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Cirebon	[1, 14]	[]	0.05	1	300	0.8718
Kota Cirebon	[1, 14]	[7]	0.05	1	300	0.871
Kota Cirebon	[1, 7]	[]	0.03	1	450	0.8709
Kota Cirebon	[1, 7]	[7]	0.03	1	450	0.8707
Kota Cirebon	[1]	[7]	0.03	1	450	0.8621
Kota Cirebon	[1]	[]	0.05	1	450	0.8426
Kota Cirebon	[1, 7]	[30]	0.05	1	150	0.8235
Kota Cirebon	[1]	[30]	0.05	1	150	0.8202
Kota Cirebon	[1, 14]	[30]	0.05	1	150	0.8202
Kota Cirebon	[1, 30]	[]	0.05	1	150	0.8151
Kota Cirebon	[1, 30]	[30]	0.05	1	150	0.8131
Kota Cirebon	[1, 30]	[7]	0.05	1	150	0.8128

Tabel L11.48 Kota Denpasar

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Denpasar	[1, 30]	[30]	0.05	1	450	0.9204
Kota Denpasar	[1, 14]	[7]	0.05	2	300	0.9192
Kota Denpasar	[1]	[30]	0.03	1	450	0.9185
Kota Denpasar	[1, 7]	[30]	0.05	1	300	0.9182
Kota Denpasar	[1, 14]	[30]	0.03	1	450	0.9166
Kota Denpasar	[1, 7]	[7]	0.05	3	300	0.9156
Kota Denpasar	[1, 30]	[7]	0.05	1	450	0.911
Kota Denpasar	[1, 7]	[]	0.05	1	450	0.9107
Kota Denpasar	[1, 30]	[]	0.05	1	450	0.9098
Kota Denpasar	[1]	[7]	0.05	2	300	0.9059

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Denpasar	[1]	[]	0.05	2	150	0.9049
Kota Denpasar	[1, 14]	[]	0.05	2	450	0.8906

Tabel L11.49 Kota Depok

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Depok	[1, 14]	[]	0.05	2	450	0.9417
Kota Depok	[1, 14]	[7]	0.05	3	300	0.9398
Kota Depok	[1]	[7]	0.03	3	300	0.938
Kota Depok	[1, 30]	[30]	0.05	1	300	0.9251
Kota Depok	[1, 30]	[]	0.03	1	450	0.925
Kota Depok	[1, 7]	[30]	0.03	1	450	0.924
Kota Depok	[1, 14]	[30]	0.03	1	450	0.924
Kota Depok	[1]	[30]	0.03	1	450	0.238
Kota Depok	[1, 30]	[7]	0.05	1	450	0.923
Kota Depok	[1, 7]	[]	0.05	3	300	0.9162
Kota Depok	[1, 7]	[7]	0.05	3	150	0.9155
Kota Depok	[1]	[]	0.05	2	150	0.9146

Tabel L11.50 Kota Dumai

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Dumai	[1]	[7]	0.05	3	300	0.8905
Kota Dumai	[1, 7]	[7]	0.01	2	450	0.8819
Kota Dumai	[1, 7]	[]	0.05	2	150	0.8771
Kota Dumai	[1]	[]	0.03	2	450	0.8739
Kota Dumai	[1, 14]	[30]	0.03	1	300	0.8678
Kota Dumai	[1, 14]	[]	0.03	1	300	0.8666
Kota Dumai	[1, 14]	[7]	0.03	1	300	0.8623
Kota Dumai	[1, 7]	[30]	0.03	1	300	0.8612
Kota Dumai	[1, 30]	[7]	0.03	1	300	0.8577
Kota Dumai	[1]	[30]	0.03	1	300	0.8562
Kota Dumai	[1, 30]	[30]	0.03	1	300	0.8553
Kota Dumai	[1, 30]	[]	0.03	1	300	0.8548

Tabel L11.51 Kota Gorontolo

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Gorontalo	[1, 14]	[]	0.03	1	450	0.9283
Kota Gorontalo	[1, 7]	[30]	0.03	1	450	0.9275
Kota Gorontalo	[1, 14]	[30]	0.03	1	450	0.9272
Kota Gorontalo	[1]	[30]	0.03	1	450	0.9271
Kota Gorontalo	[1, 30]	[]	0.03	1	450	0.9264
Kota Gorontalo	[1, 30]	[7]	0.03	1	450	0.9264

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Gorontalo	[1, 30]	[30]	0.03	1	450	0.9257
Kota Gorontalo	[1]	[]	0.05	2	150	0.925
Kota Gorontalo	[1]	[7]	0.05	3	450	0.9117
Kota Gorontalo	[1, 7]	[7]	0.03	3	150	0.9058
Kota Gorontalo	[1, 7]	[]	0.03	3	150	0.9039
Kota Gorontalo	[1, 14]	[7]	0.03	3	150	0.8958

Tabel L11.52 Kota Gunung Sitoli

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Gunung Sitoli	[1]	[]	0.03	1	450	0.9292
Kota Gunung Sitoli	[1, 30]	[7]	0.01	2	450	0.9201
Kota Gunung Sitoli	[1, 30]	[]	0.01	3	450	0.9104
Kota Gunung Sitoli	[1]	[7]	0.03	2	150	0.9084
Kota Gunung Sitoli	[1, 14]	[7]	0.01	3	450	0.9071
Kota Gunung Sitoli	[1, 14]	[]	0.01	3	450	0.9067
Kota Gunung Sitoli	[1, 7]	[]	0.01	1	450	0.8475
Kota Gunung Sitoli	[1, 7]	[7]	0.01	1	450	0.8475
Kota Gunung Sitoli	[1, 30]	[30]	0.01	2	300	0.8421
Kota Gunung Sitoli	[1, 14]	[30]	0.01	1	300	0.6761
Kota Gunung Sitoli	[1, 7]	[30]	0.01	1	300	0.6718
Kota Gunung Sitoli	[1]	[30]	0.01	1	300	0.6704

Tabel L11.53 Kota Jakarta Pusat

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Jakarta Pusat	[1, 14]	[]	0.03	3	450	0.9403
Kota Jakarta Pusat	[1, 30]	[]	0.05	2	300	0.9387
Kota Jakarta Pusat	[1]	[7]	0.05	2	450	0.9386
Kota Jakarta Pusat	[1, 30]	[30]	0.05	2	300	0.9384
Kota Jakarta Pusat	[1, 14]	[7]	0.03	2	300	0.9381
Kota Jakarta Pusat	[1, 30]	[7]	0.03	2	450	0.9378
Kota Jakarta Pusat	[1, 7]	[30]	0.05	2	150	0.9299
Kota Jakarta Pusat	[1]	[]	0.05	3	450	0.9254
Kota Jakarta Pusat	[1]	[30]	0.05	2	150	0.9226
Kota Jakarta Pusat	[1, 7]	[]	0.03	3	300	0.9193
Kota Jakarta Pusat	[1, 7]	[7]	0.03	3	300	0.914
Kota Jakarta Pusat	[1, 14]	[30]	0.05	1	450	0.9135

Tabel L11.54 Kota Jambi

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Jambi	[1]	[]	0.05	2	150	0.9033
Kota Jambi	[1]	[7]	0.05	2	150	0.903
Kota Jambi	[1, 14]	[7]	0.05	3	300	0.9025
Kota Jambi	[1, 7]	[30]	0.05	2	150	0.8987
Kota Jambi	[1, 14]	[30]	0.05	1	450	0.8967
Kota Jambi	[1]	[30]	0.05	2	150	0.896
Kota Jambi	[1, 7]	[]	0.05	1	150	0.8957
Kota Jambi	[1, 14]	[]	0.05	3	300	0.8878
Kota Jambi	[1, 7]	[7]	0.03	1	300	0.886
Kota Jambi	[1, 30]	[30]	0.05	1	450	0.8744
Kota Jambi	[1, 30]	[]	0.05	1	450	0.8736
Kota Jambi	[1, 30]	[7]	0.05	1	450	0.8705

Tabel L11.55 Kota Jayapura

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Jayapura	[1, 30]	[7]	0.05	1	300	0.8223
Kota Jayapura	[1, 7]	[]	0.05	1	300	0.8199
Kota Jayapura	[1]	[]	0.03	1	450	0.8151
Kota Jayapura	[1, 7]	[7]	0.03	1	450	0.8108
Kota Jayapura	[1]	[30]	0.03	1	450	0.8086
Kota Jayapura	[1, 7]	[30]	0.03	1	450	0.8084
Kota Jayapura	[1, 14]	[30]	0.03	1	450	0.8083
Kota Jayapura	[1, 14]	[]	0.03	1	450	0.8024
Kota Jayapura	[1, 14]	[7]	0.05	1	450	0.7997
Kota Jayapura	[1, 30]	[]	0.03	1	450	0.7948
Kota Jayapura	[1]	[7]	0.03	1	450	0.7942
Kota Jayapura	[1, 30]	[30]	0.03	1	450	0.7902

Tabel L11.56 Kota Kediri

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Kediri	[1]	[7]	0.05	3	150	0.9348
Kota Kediri	[1]	[30]	0.03	1	450	0.9191
Kota Kediri	[1, 7]	[30]	0.05	1	300	0.9134
Kota Kediri	[1, 14]	[30]	0.05	1	300	0.9125
Kota Kediri	[1, 30]	[]	0.05	1	300	0.911
Kota Kediri	[1, 30]	[7]	0.05	1	300	0.9103
Kota Kediri	[1, 30]	[30]	0.05	1	300	0.9092
Kota Kediri	[1, 14]	[7]	0.05	3	150	0.9028
Kota Kediri	[1, 14]	[]	0.05	3	450	0.8944
Kota Kediri	[1, 7]	[]	0.03	3	150	0.8835

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Kediri	[1, 7]	[7]	0.01	3	450	0.8808
Kota Kediri	[1]	[]	0.03	3	150	0.854

Tabel L11.57 Kota Kendari

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Kendari	[1]	[]	0.05	2	150	0.8886
Kota Kendari	[1]	[30]	0.05	2	150	0.8405
Kota Kendari	[1, 14]	[30]	0.05	2	300	0.8235
Kota Kendari	[1, 7]	[30]	0.05	2	150	0.8207
Kota Kendari	[1, 30]	[30]	0.01	3	300	0.6275
Kota Kendari	[1, 30]	[]	0.01	3	300	0.62
Kota Kendari	[1, 30]	[7]	0.01	3	300	0.5939
Kota Kendari	[1, 14]	[7]	0.01	3	300	0.4089
Kota Kendari	[1, 14]	[]	0.03	1	150	0.2248
Kota Kendari	[1, 7]	[7]	0.01	3	150	-0.7836
Kota Kendari	[1, 7]	[]	0.01	3	150	-0.7852
Kota Kendari	[1]	[7]	0.01	3	150	-0.85

Tabel L11.58 Kota Kupang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Kupang	[1, 14]	[]	0.03	3	300	0.9211
Kota Kupang	[1, 14]	[7]	0.03	3	450	0.921
Kota Kupang	[1]	[7]	0.05	3	150	0.9112
Kota Kupang	[1, 7]	[]	0.03	3	450	0.9092
Kota Kupang	[1, 30]	[30]	0.05	1	150	0.9054
Kota Kupang	[1, 30]	[]	0.05	1	150	0.9019
Kota Kupang	[1, 7]	[30]	0.03	1	300	0.9012
Kota Kupang	[1, 30]	[7]	0.05	1	150	0.901
Kota Kupang	[1]	[30]	0.03	1	300	0.9009
Kota Kupang	[1, 14]	[30]	0.03	1	300	0.9006
Kota Kupang	[1, 7]	[7]	0.03	3	150	0.9001
Kota Kupang	[1]	[]	0.01	3	300	0.8174

Tabel L11.59 Kota Lhokseumawe

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Lhokseumawe	[1]	[30]	0.03	2	450	0.9377
Kota Lhokseumawe	[1, 14]	[30]	0.05	2	300	0.9377
Kota Lhokseumawe	[1]	[7]	0.05	1	300	0.9373
Kota Lhokseumawe	[1, 30]	[30]	0.03	2	150	0.9373
Kota Lhokseumawe	[1, 7]	[30]	0.03	2	450	0.9364
Kota Lhokseumawe	[1, 14]	[]	0.05	2	300	0.936

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Lhokseumawe	[1, 14]	[7]	0.01	2	450	0.9357
Kota Lhokseumawe	[1, 30]	[7]	0.03	1	300	0.931
Kota Lhokseumawe	[1, 7]	[7]	0.03	1	300	0.9276
Kota Lhokseumawe	[1, 7]	[]	0.03	2	450	0.9275
Kota Lhokseumawe	[1, 30]	[]	0.03	1	300	0.9269
Kota Lhokseumawe	[1]	[]	0.05	2	450	0.9192

Tabel L11.60 Kota Madiun

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Madiun	[1, 14]	[]	0.03	1	450	0.93
Kota Madiun	[1, 30]	[]	0.03	2	450	0.9289
Kota Madiun	[1, 7]	[]	0.03	1	450	0.9257
Kota Madiun	[1]	[30]	0.03	1	450	0.9239
Kota Madiun	[1]	[]	0.03	2	300	0.9236
Kota Madiun	[1, 7]	[7]	0.05	1	300	0.9221
Kota Madiun	[1, 14]	[30]	0.03	1	450	0.9209
Kota Madiun	[1, 14]	[7]	0.03	1	450	0.9185
Kota Madiun	[1, 30]	[30]	0.05	2	300	0.9176
Kota Madiun	[1, 30]	[7]	0.03	2	450	0.9122
Kota Madiun	[1, 7]	[30]	0.03	1	450	0.9079
Kota Madiun	[1]	[7]	0.05	3	300	0.8738

Tabel L11.61 Kota Makassar

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Makassar	[1, 30]	[7]	0.03	1	300	0.9138
Kota Makassar	[1]	[7]	0.03	1	450	0.9108
Kota Makassar	[1, 7]	[7]	0.03	1	450	0.9094
Kota Makassar	[1, 30]	[30]	0.05	1	450	0.9086
Kota Makassar	[1, 7]	[]	0.03	1	450	0.9082
Kota Makassar	[1, 14]	[7]	0.05	1	450	0.9074
Kota Makassar	[1]	[]	0.01	2	450	0.9067
Kota Makassar	[1, 30]	[]	0.05	1	150	0.9055
Kota Makassar	[1, 14]	[]	0.05	2	300	0.9046
Kota Makassar	[1, 7]	[30]	0.03	1	450	0.8971
Kota Makassar	[1]	[30]	0.03	1	450	0.8951
Kota Makassar	[1, 14]	[30]	0.03	1	450	0.8949

Tabel L11.62 Kota Malang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Malang	[1]	[30]	0.03	1	300	0.8455
Kota Malang	[1, 14]	[30]	0.03	1	300	0.8451
Kota Malang	[1, 7]	[30]	0.03	1	300	0.8444
Kota Malang	[1, 14]	[7]	0.03	3	150	0.8399
Kota Malang	[1, 14]	[]	0.01	2	450	0.8333
Kota Malang	[1, 7]	[]	0.01	2	300	0.7441
Kota Malang	[1, 7]	[7]	0.01	2	300	0.7436
Kota Malang	[1]	[7]	0.01	2	300	0.7411
Kota Malang	[1]	[]	0.01	2	300	0.7337
Kota Malang	[1, 30]	[30]	0.03	1	300	0.7235
Kota Malang	[1, 30]	[]	0.03	1	300	0.7231
Kota Malang	[1, 30]	[7]	0.05	1	150	0.6771

Tabel L11.63 Kota Maluku

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Maluku	[1]	[]	0.03	1	450	0.9392
Kota Maluku	[1, 14]	[7]	0.05	1	450	0.935
Kota Maluku	[1, 7]	[7]	0.05	1	150	0.9339
Kota Maluku	[1, 7]	[]	0.05	1	150	0.9323
Kota Maluku	[1, 14]	[]	0.01	1	450	0.8713
Kota Maluku	[1, 7]	[30]	0.03	1	450	0.6079
Kota Maluku	[1, 30]	[30]	0.05	3	150	0.5347
Kota Maluku	[1, 14]	[30]	0.03	1	450	0.4634
Kota Maluku	[1]	[30]	0.03	1	450	0.4596
Kota Maluku	[1, 30]	[]	0.05	1	300	0.4547
Kota Maluku	[1, 30]	[7]	0.05	3	150	0.4117
Kota Maluku	[1]	[7]	0.05	3	150	-0.2683

Tabel L11.64 Kota Mamuju

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Mamuju	[1, 30]	[7]	0.03	1	450	0.9069
Kota Mamuju	[1, 7]	[30]	0.03	1	300	0.9057
Kota Mamuju	[1, 14]	[30]	0.03	1	300	0.9054
Kota Mamuju	[1]	[7]	0.05	1	300	0.9048
Kota Mamuju	[1, 14]	[]	0.05	1	450	0.9024
Kota Mamuju	[1, 30]	[]	0.05	1	300	0.9022
Kota Mamuju	[1, 7]	[7]	0.03	3	450	0.9021
Kota Mamuju	[1, 30]	[30]	0.05	1	300	0.9019
Kota Mamuju	[1, 14]	[7]	0.05	1	300	0.9015
Kota Mamuju	[1, 7]	[]	0.05	3	150	0.899

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Mamuju	[1]	[30]	0.05	1	150	0.8936
Kota Mamuju	[1]	[]	0.05	2	300	0.8929

Tabel L11.65 Kota Manado

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Manado	[1, 14]	[30]	0.05	1	450	0.911
Kota Manado	[1]	[30]	0.05	1	450	0.9109
Kota Manado	[1, 7]	[30]	0.05	1	450	0.9104
Kota Manado	[1, 14]	[]	0.05	1	300	0.9084
Kota Manado	[1, 14]	[7]	0.05	1	450	0.9077
Kota Manado	[1, 7]	[]	0.05	1	450	0.9071
Kota Manado	[1, 30]	[]	0.05	2	150	0.906
Kota Manado	[1, 30]	[30]	0.05	1	450	0.9039
Kota Manado	[1, 30]	[7]	0.05	1	450	0.9025
Kota Manado	[1]	[]	0.05	1	300	0.902
Kota Manado	[1, 7]	[7]	0.03	3	150	0.8961
Kota Manado	[1]	[7]	0.03	3	150	0.8951

Tabel L11.66 Kota Mataram

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Mataram	[1, 14]	[7]	0.05	1	300	0.8433
Kota Mataram	[1]	[]	0.05	1	300	0.8427
Kota Mataram	[1]	[30]	0.05	1	300	0.8403
Kota Mataram	[1, 14]	[30]	0.05	1	300	0.8402
Kota Mataram	[1, 7]	[30]	0.05	1	300	0.84
Kota Mataram	[1, 30]	[7]	0.03	2	300	0.8392
Kota Mataram	[1, 30]	[]	0.03	2	300	0.835
Kota Mataram	[1]	[7]	0.03	2	150	0.819
Kota Mataram	[1, 14]	[]	0.03	3	150	0.8138
Kota Mataram	[1, 30]	[30]	0.05	1	150	0.8023
Kota Mataram	[1, 7]	[7]	0.03	2	150	0.7962
Kota Mataram	[1, 7]	[]	0.03	2	150	0.7949

Tabel L11.67 Kota Maumere

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Maumere	[1, 14]	[30]	0.05	1	150	0.9049
Kota Maumere	[1, 7]	[30]	0.05	1	450	0.9043
Kota Maumere	[1]	[30]	0.05	2	300	0.9042
Kota Maumere	[1, 14]	[]	0.03	1	300	0.9007
Kota Maumere	[1, 30]	[30]	0.05	1	150	0.8968
Kota Maumere	[1, 14]	[7]	0.03	1	450	0.8948

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Maumere	[1, 7]	[]	0.05	1	450	0.8946
Kota Maumere	[1, 7]	[7]	0.05	1	450	0.8929
Kota Maumere	[1, 30]	[7]	0.05	1	450	0.8872
Kota Maumere	[1]	[7]	0.05	1	450	0.8866
Kota Maumere	[1]	[]	0.03	1	450	0.8861
Kota Maumere	[1, 30]	[]	0.05	1	450	0.8851

Tabel L11.68 Kota Medan

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Medan	[1, 30]	[7]	0.05	1	300	0.8838
Kota Medan	[1, 30]	[]	0.05	1	300	0.8775
Kota Medan	[1, 30]	[30]	0.05	1	300	0.8774
Kota Medan	[1, 14]	[]	0.05	1	450	0.816
Kota Medan	[1, 7]	[7]	0.05	1	450	0.8131
Kota Medan	[1, 7]	[]	0.05	1	450	0.812
Kota Medan	[1]	[7]	0.05	1	450	0.8059
Kota Medan	[1, 14]	[7]	0.05	2	450	0.8006
Kota Medan	[1]	[30]	0.05	2	150	0.7935
Kota Medan	[1, 14]	[30]	0.05	2	150	0.7873
Kota Medan	[1, 7]	[30]	0.05	2	150	0.7689
Kota Medan	[1]	[]	0.01	3	300	0.6286

Tabel L11.69 Kota Metro

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Metro	[1, 7]	[7]	0.05	1	450	0.9424
Kota Metro	[1, 14]	[7]	0.05	1	450	0.9423
Kota Metro	[1, 7]	[]	0.05	1	450	0.9421
Kota Metro	[1, 14]	[]	0.03	1	450	0.9421
Kota Metro	[1]	[]	0.05	3	150	0.9418
Kota Metro	[1, 30]	[30]	0.03	1	450	0.9417
Kota Metro	[1, 30]	[]	0.05	1	450	0.9416
Kota Metro	[1, 30]	[7]	0.05	1	450	0.9415
Kota Metro	[1, 7]	[30]	0.03	1	450	0.9413
Kota Metro	[1, 14]	[30]	0.03	1	450	0.941
Kota Metro	[1]	[7]	0.05	1	450	0.9405
Kota Metro	[1]	[30]	0.05	1	450	0.9393

Tabel L11.70 Kota Meulaboh

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Meulaboh	[1, 14]	[]	0.05	1	450	0.9344
Kota Meulaboh	[1, 14]	[7]	0.05	1	450	0.9334
Kota Meulaboh	[1, 7]	[7]	0.05	1	450	0.9331
Kota Meulaboh	[1, 7]	[]	0.05	1	450	0.9328
Kota Meulaboh	[1, 7]	[30]	0.05	1	450	0.9324
Kota Meulaboh	[1]	[7]	0.05	1	450	0.9322
Kota Meulaboh	[1]	[]	0.05	1	300	0.9311
Kota Meulaboh	[1, 14]	[30]	0.05	3	450	0.9311
Kota Meulaboh	[1, 30]	[]	0.05	1	300	0.9305
Kota Meulaboh	[1, 30]	[30]	0.05	1	450	0.9293
Kota Meulaboh	[1, 30]	[7]	0.05	1	450	0.9281
Kota Meulaboh	[1]	[30]	0.05	2	450	0.9262

Tabel L11.71 Kota Padang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Padang	[1]	[30]	0.03	1	450	0.9388
Kota Padang	[1, 30]	[7]	0.03	1	300	0.9306
Kota Padang	[1, 30]	[]	0.03	1	300	0.9304
Kota Padang	[1, 30]	[30]	0.03	1	300	0.9304
Kota Padang	[1, 14]	[30]	0.03	1	300	0.9298
Kota Padang	[1, 7]	[30]	0.03	1	300	0.9297
Kota Padang	[1, 14]	[]	0.03	1	300	0.9279
Kota Padang	[1, 14]	[7]	0.03	1	300	0.9279
Kota Padang	[1, 7]	[]	0.01	3	300	0.8951
Kota Padang	[1, 7]	[7]	0.01	3	300	0.8945
Kota Padang	[1]	[]	0.01	3	300	0.8834
Kota Padang	[1]	[7]	0.01	3	300	0.8819

Tabel L11.72 Kota Padang Sidempuan

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Padang Sidempuan	[1]	[]	0.01	3	450	0.595
Kota Padang Sidempuan	[1, 30]	[]	0.03	1	300	0.5644
Kota Padang Sidempuan	[1, 14]	[7]	0.03	1	300	0.6
Kota Padang Sidempuan	[1, 14]	[]	0.03	1	300	0.5987
Kota Padang Sidempuan	[1]	[7]	0.03	2	450	0.5923
Kota Padang Sidempuan	[1, 7]	[]	0.03	1	300	0.567
Kota Padang Sidempuan	[1, 7]	[7]	0.03	1	300	0.562
Kota Padang Sidempuan	[1, 30]	[30]	0.03	1	450	0.5317
Kota Padang Sidempuan	[1, 7]	[30]	0.05	1	450	0.5231
Kota Padang Sidempuan	[1, 14]	[30]	0.05	1	450	0.5195

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Padang Sidempuan	[1, 30]	[7]	0.03	1	450	0.5154
Kota Padang Sidempuan	[1]	[30]	0.05	1	450	0.5101

Tabel L11.73 Kota Palangkaraya

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Palangkaraya	[1, 30]	[7]	0.05	1	450	0.9181
Kota Palangkaraya	[1, 30]	[]	0.05	1	450	0.9155
Kota Palangkaraya	[1, 30]	[30]	0.05	1	450	0.9106
Kota Palangkaraya	[1, 14]	[30]	0.03	3	300	0.8997
Kota Palangkaraya	[1, 7]	[30]	0.01	3	450	0.8836
Kota Palangkaraya	[1]	[30]	0.01	3	450	0.8833
Kota Palangkaraya	[1, 7]	[]	0.01	3	300	0.8222
Kota Palangkaraya	[1, 7]	[7]	0.01	3	300	0.8222
Kota Palangkaraya	[1, 14]	[]	0.01	3	150	-0.3005
Kota Palangkaraya	[1, 14]	[7]	0.01	3	150	-0.3025
Kota Palangkaraya	[1]	[]	0.01	2	150	-0.7155
Kota Palangkaraya	[1]	[7]	0.01	2	150	-0.78

Tabel L11.74 Kota Palembang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Palembang	[1, 7]	[7]	0.05	3	150	0.7173
Kota Palembang	[1]	[]	0.05	3	450	0.711
Kota Palembang	[1, 7]	[]	0.05	2	450	0.693
Kota Palembang	[1, 30]	[]	0.05	1	450	0.6788
Kota Palembang	[1, 14]	[]	0.05	3	450	0.6702
Kota Palembang	[1, 30]	[30]	0.05	2	450	0.6679
Kota Palembang	[1, 14]	[7]	0.05	2	450	0.6254
Kota Palembang	[1]	[7]	0.05	3	150	0.6173
Kota Palembang	[1]	[30]	0.03	1	300	0.5911
Kota Palembang	[1, 7]	[30]	0.03	1	300	0.5911
Kota Palembang	[1, 14]	[30]	0.03	1	300	0.5911
Kota Palembang	[1, 30]	[7]	0.05	1	450	0.5848

Tabel L11.75 Kota Palu

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Palu	[1]	[]	0.05	3	450	0.8845
Kota Palu	[1]	[7]	0.05	2	450	0.8845
Kota Palu	[1, 14]	[7]	0.05	3	300	0.8845
Kota Palu	[1, 14]	[]	0.05	3	300	0.8837
Kota Palu	[1, 14]	[30]	0.03	1	450	0.8747
Kota Palu	[1, 7]	[30]	0.03	1	450	0.8746

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Palu	[1]	[30]	0.03	1	450	0.8744
Kota Palu	[1, 7]	[]	0.05	3	150	0.8542
Kota Palu	[1, 7]	[7]	0.05	3	450	0.8492
Kota Palu	[1, 30]	[7]	0.05	1	300	0.8319
Kota Palu	[1, 30]	[30]	0.05	1	300	0.8316
Kota Palu	[1, 30]	[]	0.05	1	300	0.8313

Tabel L11.76 Kota Pangkalpinang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Pangkalpinang	[1, 30]	[]	0.05	2	300	0.9214
Kota Pangkalpinang	[1, 30]	[7]	0.05	2	300	0.9205
Kota Pangkalpinang	[1]	[30]	0.03	1	450	0.9177
Kota Pangkalpinang	[1, 7]	[30]	0.03	1	450	0.9176
Kota Pangkalpinang	[1, 14]	[30]	0.03	2	300	0.9164
Kota Pangkalpinang	[1, 30]	[30]	0.03	3	300	0.9155
Kota Pangkalpinang	[1]	[]	0.03	2	300	0.9152
Kota Pangkalpinang	[1, 7]	[]	0.05	3	150	0.913
Kota Pangkalpinang	[1, 7]	[7]	0.05	3	150	0.9109
Kota Pangkalpinang	[1, 14]	[]	0.03	3	450	0.91
Kota Pangkalpinang	[1, 14]	[7]	0.03	3	300	0.9083
Kota Pangkalpinang	[1]	[7]	0.05	3	150	0.905

Tabel L11.77 Kota Pare – Pare

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Pare -Pare	[1]	[7]	0.03	1	450	0.9348
Kota Pare -Pare	[1, 14]	[]	0.05	1	450	0.9327
Kota Pare -Pare	[1, 14]	[7]	0.05	1	450	0.9312
Kota Pare -Pare	[1]	[]	0.05	1	450	0.927
Kota Pare -Pare	[1]	[30]	0.03	1	450	0.9191
Kota Pare -Pare	[1, 7]	[7]	0.05	2	300	0.918
Kota Pare -Pare	[1, 14]	[30]	0.03	1	450	0.9165
Kota Pare -Pare	[1, 7]	[]	0.03	2	300	0.9159
Kota Pare -Pare	[1, 7]	[30]	0.03	1	450	0.9133
Kota Pare -Pare	[1, 30]	[]	0.05	1	450	0.9062
Kota Pare -Pare	[1, 30]	[7]	0.05	1	450	0.9017
Kota Pare -Pare	[1, 30]	[30]	0.03	1	450	0.898

Tabel L11.78 Kota Pekanbaru

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Pekanbaru	[1]	[7]	0.03	2	450	0.9375
Kota Pekanbaru	[1, 30]	[7]	0.03	2	450	0.9369
Kota Pekanbaru	[1, 14]	[]	0.05	2	150	0.9349
Kota Pekanbaru	[1, 14]	[30]	0.03	2	450	0.9344
Kota Pekanbaru	[1, 14]	[7]	0.03	2	450	0.9343
Kota Pekanbaru	[1, 30]	[]	0.03	1	450	0.9335
Kota Pekanbaru	[1, 30]	[30]	0.03	1	450	0.9335
Kota Pekanbaru	[1, 7]	[]	0.01	2	450	0.9321
Kota Pekanbaru	[1, 7]	[7]	0.01	2	450	0.9319
Kota Pekanbaru	[1]	[30]	0.03	2	450	0.9314
Kota Pekanbaru	[1, 7]	[30]	0.03	2	450	0.9306
Kota Pekanbaru	[1]	[]	0.03	2	150	0.9294

Tabel L11.79 Kota Pematang Siantar

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Pematang Siantar	[1]	[7]	0.03	1	300	0.8974
Kota Pematang Siantar	[1, 30]	[]	0.05	1	300	0.8825
Kota Pematang Siantar	[1, 30]	[30]	0.05	2	300	0.8813
Kota Pematang Siantar	[1, 30]	[7]	0.05	2	300	0.8791
Kota Pematang Siantar	[1, 14]	[30]	0.05	1	450	0.8756
Kota Pematang Siantar	[1, 14]	[7]	0.05	1	450	0.8755
Kota Pematang Siantar	[1, 7]	[30]	0.03	1	450	0.8752
Kota Pematang Siantar	[1, 14]	[]	0.03	2	450	0.8749
Kota Pematang Siantar	[1]	[30]	0.03	1	450	0.8747
Kota Pematang Siantar	[1]	[]	0.05	2	450	0.8727
Kota Pematang Siantar	[1, 7]	[7]	0.05	3	300	0.8714
Kota Pematang Siantar	[1, 7]	[]	0.03	1	300	0.869

Tabel L11.80 Kota Pontianak

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Pontianak	[1, 14]	[7]	0.05	3	150	0.9404
Kota Pontianak	[1, 14]	[]	0.05	3	150	0.9398
Kota Pontianak	[1, 30]	[30]	0.03	1	450	0.9379
Kota Pontianak	[1, 30]	[7]	0.03	1	450	0.9378
Kota Pontianak	[1, 7]	[30]	0.05	2	150	0.9349
Kota Pontianak	[1]	[30]	0.05	2	150	0.9348
Kota Pontianak	[1, 30]	[]	0.05	1	300	0.9341
Kota Pontianak	[1, 14]	[30]	0.05	2	300	0.9284
Kota Pontianak	[1, 7]	[7]	0.03	2	150	0.9122
Kota Pontianak	[1, 7]	[]	0.03	2	150	0.9115

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Pontianak	[1]	[7]	0.03	3	150	0.9083
Kota Pontianak	[1]	[]	0.01	1	450	0.764

Tabel L11.81 Kota Probolinggo

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Probolinggo	[1, 30]	[7]	0.05	2	300	0.9323
Kota Probolinggo	[1, 30]	[]	0.05	2	300	0.9312
Kota Probolinggo	[1, 30]	[30]	0.05	1	450	0.9277
Kota Probolinggo	[1, 14]	[]	0.03	2	300	0.9051
Kota Probolinggo	[1]	[30]	0.05	1	300	0.9029
Kota Probolinggo	[1, 14]	[30]	0.05	1	300	0.8995
Kota Probolinggo	[1, 7]	[30]	0.05	1	300	0.8985
Kota Probolinggo	[1, 14]	[7]	0.03	3	300	0.8944
Kota Probolinggo	[1, 7]	[]	0.03	2	150	0.8932
Kota Probolinggo	[1, 7]	[7]	0.03	2	150	0.8886
Kota Probolinggo	[1]	[7]	0.03	2	150	0.8799
Kota Probolinggo	[1]	[]	0.03	2	150	0.8289

Tabel L11.82 Kota Semarang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Semarang	[1, 30]	[7]	0.05	1	450	0.8164
Kota Semarang	[1, 30]	[30]	0.05	1	450	0.8158
Kota Semarang	[1, 30]	[]	0.05	1	450	0.8151
Kota Semarang	[1]	[7]	0.03	3	450	0.8092
Kota Semarang	[1]	[30]	0.03	1	300	0.804
Kota Semarang	[1, 7]	[30]	0.03	1	300	0.8033
Kota Semarang	[1, 14]	[30]	0.03	1	300	0.8022
Kota Semarang	[1, 14]	[7]	0.01	3	300	0.7089
Kota Semarang	[1, 14]	[]	0.01	3	300	0.7084
Kota Semarang	[1, 7]	[7]	0.01	2	300	0.6643
Kota Semarang	[1]	[]	0.01	2	300	0.6627
Kota Semarang	[1, 7]	[]	0.01	2	300	0.6609

Tabel L11.83 Kota Sampit

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Sampit	[1, 30]	[]	0.03	2	450	0.8257
Kota Sampit	[1, 30]	[7]	0.03	2	450	0.8236
Kota Sampit	[1, 30]	[30]	0.03	2	450	0.818
Kota Sampit	[1, 7]	[30]	0.05	2	150	0.8084
Kota Sampit	[1]	[30]	0.05	2	150	0.8069
Kota Sampit	[1, 14]	[30]	0.05	2	300	0.7988

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Sampit	[1, 14]	[7]	0.01	3	450	0.8436
Kota Sampit	[1, 14]	[]	0.01	3	450	0.7902
Kota Sampit	[1]	[]	0.05	2	150	0.7783
Kota Sampit	[1, 7]	[7]	0.05	3	150	0.7216
Kota Sampit	[1]	[7]	0.01	2	300	0.7192
Kota Sampit	[1, 7]	[]	0.01	2	300	0.6506

Tabel L11.84 Kota Serang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Serang	[1, 14]	[30]	0.03	2	300	0.9249
Kota Serang	[1]	[30]	0.03	2	300	0.9244
Kota Serang	[1, 7]	[30]	0.03	2	300	0.924
Kota Serang	[1]	[7]	0.05	2	150	0.9205
Kota Serang	[1, 30]	[7]	0.05	2	150	0.9164
Kota Serang	[1, 30]	[]	0.05	2	300	0.9161
Kota Serang	[1, 14]	[7]	0.03	2	300	0.9145
Kota Serang	[1, 14]	[]	0.05	2	150	0.9141
Kota Serang	[1, 30]	[30]	0.03	2	450	0.9131
Kota Serang	[1, 7]	[]	0.01	2	300	0.8387
Kota Serang	[1, 7]	[7]	0.01	2	300	0.8374
Kota Serang	[1]	[]	0.01	2	300	0.8319

Tabel L11.85 Kota Sibolga

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Sibolga	[1]	[]	0.03	3	450	0.9239
Kota Sibolga	[1, 30]	[7]	0.05	1	300	0.9212
Kota Sibolga	[1, 30]	[30]	0.03	1	450	0.9183
Kota Sibolga	[1, 30]	[]	0.03	2	300	0.9173
Kota Sibolga	[1, 7]	[7]	0.03	3	150	0.9102
Kota Sibolga	[1, 14]	[7]	0.05	2	150	0.9062
Kota Sibolga	[1]	[30]	0.05	1	450	0.9047
Kota Sibolga	[1, 7]	[30]	0.05	1	450	0.9045
Kota Sibolga	[1, 14]	[30]	0.03	1	450	0.9015
Kota Sibolga	[1, 14]	[]	0.03	3	300	0.901
Kota Sibolga	[1]	[7]	0.01	3	300	0.8813
Kota Sibolga	[1, 7]	[]	0.01	3	300	0.8791

Tabel L11.86 Kota Singkawang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Singkawang	[1, 30]	[7]	0.03	1	450	0.9385
Kota Singkawang	[1, 30]	[]	0.03	1	450	0.9375
Kota Singkawang	[1, 30]	[30]	0.03	1	450	0.9375
Kota Singkawang	[1, 14]	[7]	0.05	2	150	0.9364
Kota Singkawang	[1, 7]	[30]	0.03	1	450	0.936
Kota Singkawang	[1]	[30]	0.03	1	450	0.9347
Kota Singkawang	[1, 7]	[7]	0.05	3	450	0.9343
Kota Singkawang	[1, 14]	[30]	0.03	1	450	0.9343
Kota Singkawang	[1, 7]	[]	0.05	3	300	0.9261
Kota Singkawang	[1, 14]	[]	0.05	2	150	0.9204
Kota Singkawang	[1]	[]	0.05	3	150	0.918
Kota Singkawang	[1]	[7]	0.05	3	300	0.9166

Tabel L11.87 Kota Sorong

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Sorong	[1, 7]	[]	0.03	1	450	0.8752
Kota Sorong	[1, 7]	[7]	0.05	1	450	0.8738
Kota Sorong	[1, 30]	[30]	0.05	1	300	0.8735
Kota Sorong	[1, 30]	[]	0.05	1	300	0.8731
Kota Sorong	[1, 30]	[7]	0.05	1	450	0.872
Kota Sorong	[1, 14]	[]	0.05	1	150	0.86
Kota Sorong	[1, 7]	[30]	0.05	1	150	0.859
Kota Sorong	[1, 14]	[7]	0.03	1	300	0.856
Kota Sorong	[1]	[7]	0.03	1	300	0.849
Kota Sorong	[1]	[]	0.03	1	300	0.842
Kota Sorong	[1]	[30]	0.05	1	150	0.835
Kota Sorong	[1, 14]	[30]	0.05	1	150	0.832

Tabel L11.88 Kota Sukabumi

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Sukabumi	[1, 7]	[]	0.05	3	150	0.936
Kota Sukabumi	[1, 30]	[30]	0.05	1	450	0.937
Kota Sukabumi	[1, 30]	[7]	0.05	1	450	0.9369
Kota Sukabumi	[1, 14]	[30]	0.05	1	450	0.9333
Kota Sukabumi	[1, 30]	[]	0.03	1	450	0.9331
Kota Sukabumi	[1, 7]	[30]	0.05	1	450	0.933
Kota Sukabumi	[1]	[30]	0.05	1	450	0.9326
Kota Sukabumi	[1, 14]	[]	0.03	3	300	0.925
Kota Sukabumi	[1, 14]	[7]	0.03	3	300	0.9244
Kota Sukabumi	[1, 7]	[7]	0.03	2	150	0.9233

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Sukabumi	[1]	[7]	0.03	2	300	0.9224
Kota Sukabumi	[1]	[]	0.01	2	300	0.844

Tabel L11.89 Kota Sumenep

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Sumenep	[1]	[7]	0.05	3	150	0.9348
Kota Sumenep	[1]	[30]	0.03	1	450	0.9191
Kota Sumenep	[1, 7]	[30]	0.05	1	300	0.9134
Kota Sumenep	[1, 14]	[30]	0.05	1	300	0.9125
Kota Sumenep	[1, 30]	[]	0.05	1	300	0.911
Kota Sumenep	[1, 30]	[7]	0.05	1	300	0.9103
Kota Sumenep	[1, 30]	[30]	0.05	1	300	0.9092
Kota Sumenep	[1, 14]	[7]	0.05	3	150	0.9028
Kota Sumenep	[1, 14]	[]	0.05	3	450	0.8944
Kota Sumenep	[1, 7]	[]	0.03	3	150	0.8835
Kota Sumenep	[1, 7]	[7]	0.01	3	450	0.8808
Kota Sumenep	[1]	[]	0.03	3	150	0.854

Tabel L11.90 Kota Surabaya

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Surabaya	[1]	[30]	0.03	1	450	0.9414
Kota Surabaya	[1, 7]	[30]	0.03	1	450	0.9414
Kota Surabaya	[1, 14]	[]	0.01	3	450	0.9395
Kota Surabaya	[1, 14]	[7]	0.01	3	450	0.9393
Kota Surabaya	[1, 30]	[7]	0.03	1	450	0.9387
Kota Surabaya	[1]	[7]	0.01	3	450	0.9385
Kota Surabaya	[1, 14]	[30]	0.03	1	300	0.9383
Kota Surabaya	[1, 30]	[30]	0.05	2	300	0.9349
Kota Surabaya	[1, 30]	[]	0.05	2	300	0.9313
Kota Surabaya	[1, 7]	[7]	0.01	3	300	0.9047
Kota Surabaya	[1, 7]	[]	0.01	3	300	0.9046
Kota Surabaya	[1]	[]	0.01	1	450	0.8582

Tabel L11.91 Kota Surakarta (Solo)

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Surakarta (Solo)	[1]	[7]	0.05	3	150	0.934
Kota Surakarta (Solo)	[1]	[30]	0.03	1	450	0.9284
Kota Surakarta (Solo)	[1, 14]	[30]	0.03	1	450	0.9283
Kota Surakarta (Solo)	[1, 7]	[30]	0.03	1	450	0.9279
Kota Surakarta (Solo)	[1, 7]	[7]	0.03	2	150	0.9267
Kota Surakarta (Solo)	[1, 7]	[]	0.01	2	450	0.9263

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Surakarta (Solo)	[1, 30]	[7]	0.03	1	450	0.922
Kota Surakarta (Solo)	[1, 30]	[]	0.03	1	450	0.921
Kota Surakarta (Solo)	[1, 30]	[30]	0.03	1	450	0.9209
Kota Surakarta (Solo)	[1, 14]	[7]	0.03	3	300	0.915
Kota Surakarta (Solo)	[1]	[]	0.01	3	450	0.9111
Kota Surakarta (Solo)	[1, 14]	[]	0.03	3	150	0.9156

Tabel L11.92 Kota Tanggerang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Tanggerang	[1, 30]	[7]	0.05	1	450	0.8415
Kota Tanggerang	[1, 14]	[30]	0.05	1	300	0.8397
Kota Tanggerang	[1, 30]	[30]	0.05	1	300	0.8366
Kota Tanggerang	[1, 30]	[]	0.03	2	450	0.8364
Kota Tanggerang	[1, 7]	[7]	0.05	3	300	0.8356
Kota Tanggerang	[1, 7]	[]	0.03	3	300	0.8335
Kota Tanggerang	[1]	[]	0.05	2	300	0.8286
Kota Tanggerang	[1, 14]	[7]	0.05	3	300	0.8211
Kota Tanggerang	[1]	[7]	0.05	3	450	0.8147
Kota Tanggerang	[1, 7]	[30]	0.05	2	150	0.8141
Kota Tanggerang	[1]	[30]	0.05	2	150	0.8111
Kota Tanggerang	[1, 14]	[]	0.05	3	300	0.8109

Tabel L11.93 Kota Tanjung

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Tanjung	[1, 7]	[30]	0.01	3	300	0.9191
Kota Tanjung	[1, 14]	[30]	0.01	3	300	0.919
Kota Tanjung	[1]	[30]	0.01	3	300	0.9189
Kota Tanjung	[1]	[7]	0.01	3	300	0.914
Kota Tanjung	[1, 14]	[]	0.01	3	300	0.9119
Kota Tanjung	[1, 30]	[]	0.01	3	300	0.9109
Kota Tanjung	[1, 30]	[30]	0.01	3	300	0.9109
Kota Tanjung	[1]	[]	0.01	3	300	0.91
Kota Tanjung	[1, 7]	[]	0.01	3	300	0.9094
Kota Tanjung	[1, 30]	[7]	0.01	3	300	0.9063
Kota Tanjung	[1, 7]	[7]	0.01	3	300	0.9062
Kota Tanjung	[1, 14]	[7]	0.01	3	300	0.9056

Tabel L11.94 Kota Tanjung Pandan

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Tanjung Pandan	[1, 14]	[7]	0.03	1	450	0.9289
Kota Tanjung Pandan	[1, 14]	[]	0.03	1	450	0.9276
Kota Tanjung Pandan	[1, 7]	[]	0.01	2	300	0.8957
Kota Tanjung Pandan	[1]	[]	0.01	2	300	0.8951
Kota Tanjung Pandan	[1, 7]	[7]	0.01	2	300	0.8934
Kota Tanjung Pandan	[1, 30]	[7]	0.05	1	150	0.8664
Kota Tanjung Pandan	[1, 30]	[]	0.05	1	150	0.8663
Kota Tanjung Pandan	[1, 30]	[30]	0.05	1	150	0.866
Kota Tanjung Pandan	[1]	[30]	0.03	1	300	0.8641
Kota Tanjung Pandan	[1, 7]	[30]	0.03	1	300	0.8641
Kota Tanjung Pandan	[1, 14]	[30]	0.03	1	300	0.8641
Kota Tanjung Pandan	[1]	[7]	0.01	3	300	0.8549

Tabel L11.95 Kota Tanjung Pinang

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Tanjung Pinang	[1, 14]	[7]	0.03	1	450	0.9289
Kota Tanjung Pinang	[1, 14]	[]	0.03	1	450	0.9276
Kota Tanjung Pinang	[1, 7]	[]	0.01	2	300	0.8957
Kota Tanjung Pinang	[1]	[]	0.01	2	300	0.8951
Kota Tanjung Pinang	[1, 7]	[7]	0.01	2	300	0.8934
Kota Tanjung Pinang	[1, 30]	[7]	0.05	1	150	0.8664
Kota Tanjung Pinang	[1, 30]	[]	0.05	1	150	0.8663
Kota Tanjung Pinang	[1, 30]	[30]	0.05	1	150	0.866
Kota Tanjung Pinang	[1]	[30]	0.03	1	300	0.8641
Kota Tanjung Pinang	[1, 7]	[30]	0.03	1	300	0.8641
Kota Tanjung Pinang	[1, 14]	[30]	0.03	1	300	0.8641
Kota Tanjung Pinang	[1]	[7]	0.01	3	300	0.8549

Tabel L11.96 Kota Tarakan

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Tarakan	[1]	[30]	0.03	1	450	0.9147
Kota Tarakan	[1, 14]	[30]	0.03	1	450	0.9099
Kota Tarakan	[1, 7]	[30]	0.03	1	450	0.9051
Kota Tarakan	[1, 7]	[]	0.05	2	450	0.8977
Kota Tarakan	[1, 7]	[7]	0.03	1	450	0.8953
Kota Tarakan	[1, 30]	[30]	0.03	1	300	0.8857
Kota Tarakan	[1, 30]	[]	0.03	1	300	0.8849
Kota Tarakan	[1]	[]	0.05	2	150	0.8835
Kota Tarakan	[1]	[7]	0.05	2	150	0.8824
Kota Tarakan	[1, 30]	[7]	0.03	1	300	0.8623

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Tarakan	[1, 14]	[7]	0.03	3	450	0.857
Kota Tarakan	[1, 14]	[]	0.05	3	300	0.8434

Tabel L11.97 Kotak Tasikmalaya

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Tasikmalaya	[1, 14]	[30]	0.05	1	450	0.9223
Kota Tasikmalaya	[1, 7]	[30]	0.03	1	450	0.9203
Kota Tasikmalaya	[1]	[30]	0.03	1	450	0.9202
Kota Tasikmalaya	[1, 30]	[]	0.05	2	300	0.9192
Kota Tasikmalaya	[1, 30]	[30]	0.05	2	300	0.9185
Kota Tasikmalaya	[1, 14]	[]	0.05	3	150	0.9142
Kota Tasikmalaya	[1, 30]	[7]	0.05	3	150	0.9131
Kota Tasikmalaya	[1, 14]	[7]	0.05	3	150	0.9128
Kota Tasikmalaya	[1, 7]	[7]	0.05	3	300	0.9104
Kota Tasikmalaya	[1]	[7]	0.05	3	300	0.9072
Kota Tasikmalaya	[1]	[]	0.05	1	150	0.8869
Kota Tasikmalaya	[1, 7]	[]	0.01	2	300	0.7973

Tabel L11.98 Kota Tembilahan

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Tembilahan	[1]	[30]	0.03	2	150	0.9209
Kota Tembilahan	[1, 14]	[30]	0.03	2	150	0.9209
Kota Tembilahan	[1, 7]	[30]	0.03	2	150	0.9204
Kota Tembilahan	[1]	[7]	0.01	2	450	0.9058
Kota Tembilahan	[1, 7]	[]	0.03	3	150	0.9001
Kota Tembilahan	[1, 14]	[]	0.01	2	300	0.8959
Kota Tembilahan	[1, 30]	[7]	0.03	1	450	0.8908
Kota Tembilahan	[1, 30]	[30]	0.05	1	150	0.8871
Kota Tembilahan	[1, 14]	[7]	0.01	2	300	0.8869
Kota Tembilahan	[1, 30]	[]	0.05	2	150	0.8867
Kota Tembilahan	[1, 7]	[7]	0.01	3	300	0.8798
Kota Tembilahan	[1]	[]	0.03	2	150	0.8795

Tabel L11.99 Kota Ternate

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Ternate	[1, 7]	[30]	0.05	1	450	0.9358
Kota Ternate	[1, 30]	[30]	0.03	3	300	0.9357
Kota Ternate	[1]	[30]	0.05	1	450	0.9356
Kota Ternate	[1, 14]	[]	0.03	1	450	0.935
Kota Ternate	[1, 14]	[7]	0.03	1	450	0.935
Kota Ternate	[1, 14]	[30]	0.05	1	450	0.935

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Ternate	[1]	[]	0.05	1	300	0.9254
Kota Ternate	[1, 7]	[]	0.03	1	450	0.9248
Kota Ternate	[1, 7]	[7]	0.03	1	450	0.9248
Kota Ternate	[1]	[7]	0.03	1	450	0.9239
Kota Ternate	[1, 30]	[7]	0.05	1	450	0.9239
Kota Ternate	[1, 30]	[]	0.05	1	450	0.9221

Tabel L11.100 Kota Tual

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Tual	[1, 7]	[7]	0.05	1	450	0.9283
Kota Tual	[1, 7]	[30]	0.05	1	150	0.9267
Kota Tual	[1]	[30]	0.05	1	150	0.9266
Kota Tual	[1, 14]	[30]	0.05	1	150	0.9265
Kota Tual	[1, 7]	[]	0.03	3	450	0.9226
Kota Tual	[1]	[7]	0.03	2	150	0.9202
Kota Tual	[1]	[]	0.03	3	150	0.9175
Kota Tual	[1, 30]	[7]	0.05	1	150	0.9166
Kota Tual	[1, 30]	[30]	0.05	1	300	0.9152
Kota Tual	[1, 30]	[]	0.05	1	150	0.9148
Kota Tual	[1, 14]	[]	0.05	1	450	0.9147
Kota Tual	[1, 14]	[7]	0.05	2	150	0.9112

Tabel L11.101 Kota Watampone

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Watampone	[1]	[30]	0.03	1	300	0.9181
Kota Watampone	[1, 7]	[30]	0.03	1	300	0.9179
Kota Watampone	[1, 14]	[30]	0.03	1	300	0.9179
Kota Watampone	[1, 30]	[7]	0.05	3	300	0.9126
Kota Watampone	[1, 14]	[7]	0.05	1	150	0.9078
Kota Watampone	[1, 30]	[]	0.03	3	450	0.9063
Kota Watampone	[1, 30]	[30]	0.03	3	300	0.905
Kota Watampone	[1, 7]	[]	0.01	3	450	0.9025
Kota Watampone	[1]	[7]	0.01	3	300	0.8484
Kota Watampone	[1]	[]	0.01	3	300	0.8305
Kota Watampone	[1, 7]	[7]	0.01	3	300	0.8294
Kota Watampone	[1, 14]	[]	0.01	3	300	0.8267

Tabel L11.102 Kota Yogyakarta

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kota Yogyakarta	[1]	[7]	0.03	1	450	0.9418
Kota Yogyakarta	[1, 7]	[7]	0.03	1	450	0.938
Kota Yogyakarta	[1, 14]	[7]	0.03	1	450	0.9363
Kota Yogyakarta	[1, 7]	[]	0.03	1	300	0.936
Kota Yogyakarta	[1, 30]	[]	0.05	1	150	0.9327
Kota Yogyakarta	[1, 30]	[30]	0.05	1	150	0.9325
Kota Yogyakarta	[1]	[]	0.03	1	300	0.9323
Kota Yogyakarta	[1, 30]	[7]	0.05	1	150	0.9322
Kota Yogyakarta	[1, 14]	[]	0.05	1	150	0.9307
Kota Yogyakarta	[1]	[30]	0.03	2	150	0.9298
Kota Yogyakarta	[1, 14]	[30]	0.05	1	150	0.9295
Kota Yogyakarta	[1, 7]	[30]	0.05	1	150	0.9293

Tabel L11.103 Kotamobagu

Kota	LAGS	ROLLS	learning_rate	max_depth	max_iter	Test_R2
Kotamobagu	[1]	[7]	0.03	1	450	0.9418
Kotamobagu	[1, 7]	[7]	0.03	1	450	0.938
Kotamobagu	[1, 14]	[7]	0.03	1	450	0.9363
Kotamobagu	[1, 7]	[]	0.03	1	300	0.936
Kotamobagu	[1, 30]	[]	0.05	1	150	0.9327
Kotamobagu	[1, 30]	[30]	0.05	1	150	0.9325
Kotamobagu	[1]	[]	0.03	1	300	0.9323
Kotamobagu	[1, 30]	[7]	0.05	1	150	0.9322
Kotamobagu	[1, 14]	[]	0.05	1	150	0.9307
Kotamobagu	[1]	[30]	0.03	2	150	0.9298
Kotamobagu	[1, 14]	[30]	0.05	1	150	0.9295
Kotamobagu	[1, 7]	[30]	0.05	1	150	0.9293

LAMPIRAN 12

GRAFIK PERBANDINGAN HARGA SEBENARNYA DENGAN HARGA TERPREDIKSI

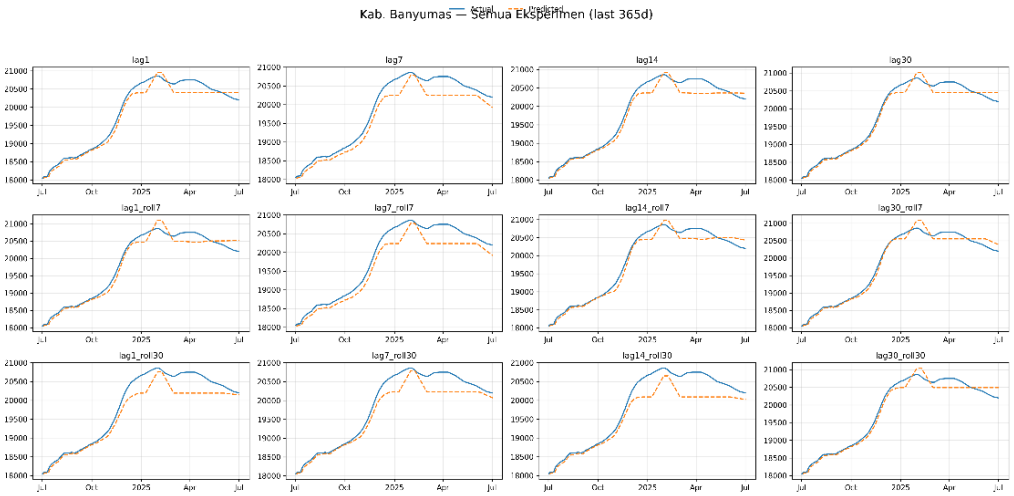

Gambar L12.1 Kabupaten Banyumas

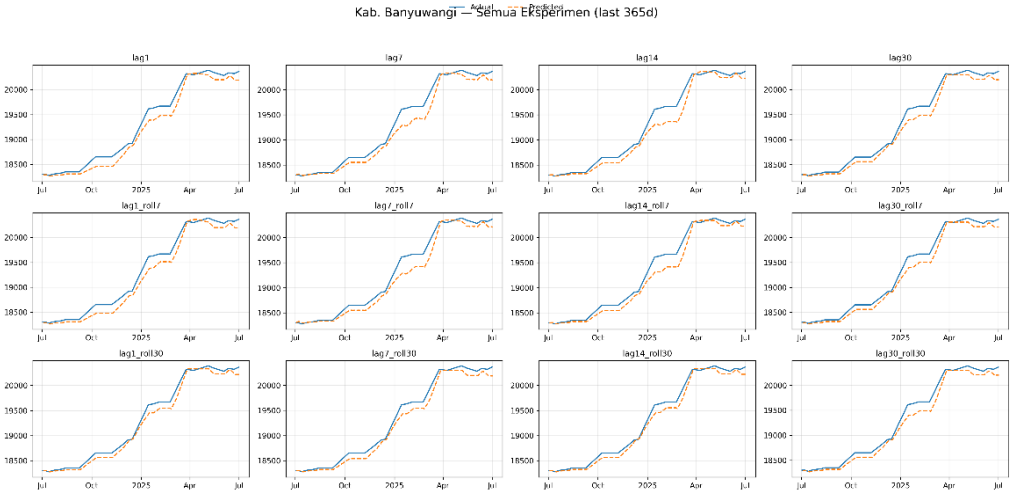

Gambar L12.2 Kabupaten Banyuwangi

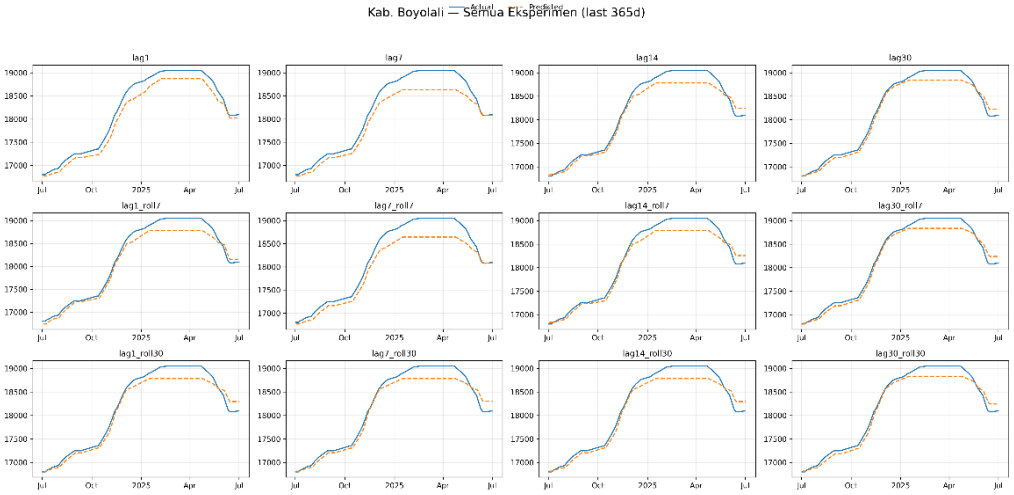

Gambar L12.3 Kabupaten Boyolali

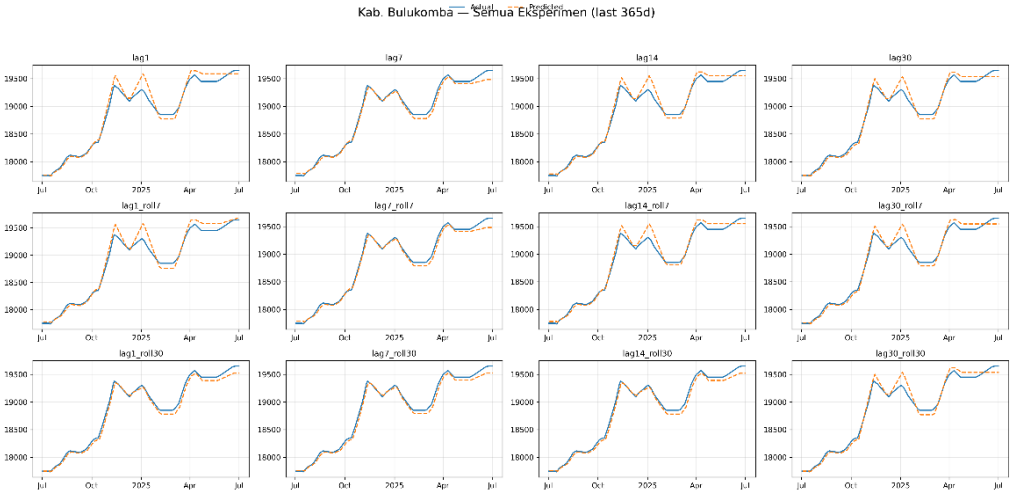

Gambar L12.4 Kabupaten Bulukomba

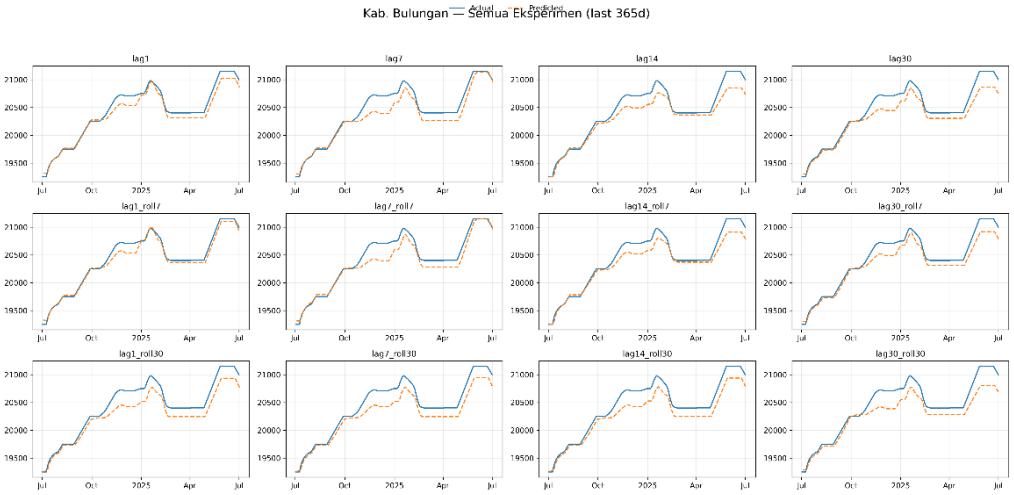

Gambar L12.5 Kabupaten Bulungan

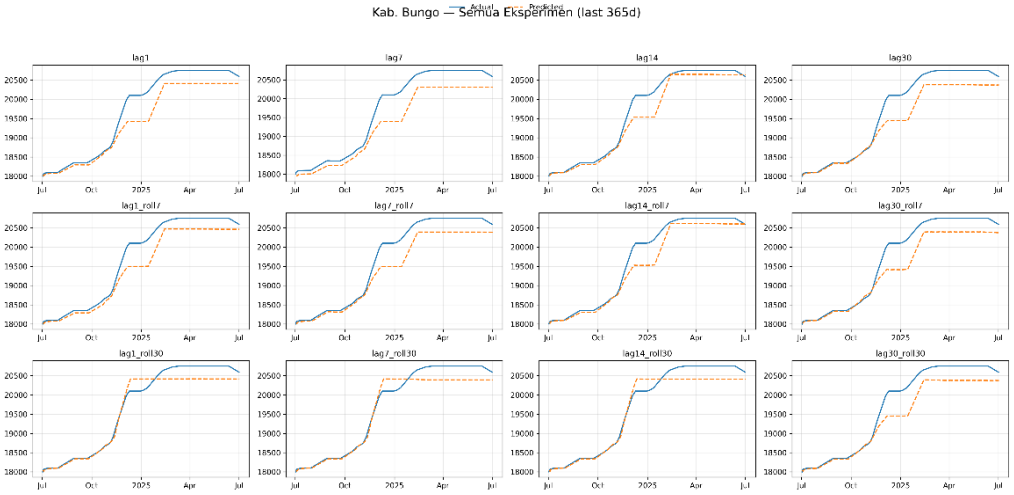

Gambar L12.6 Kabupaten Bungo

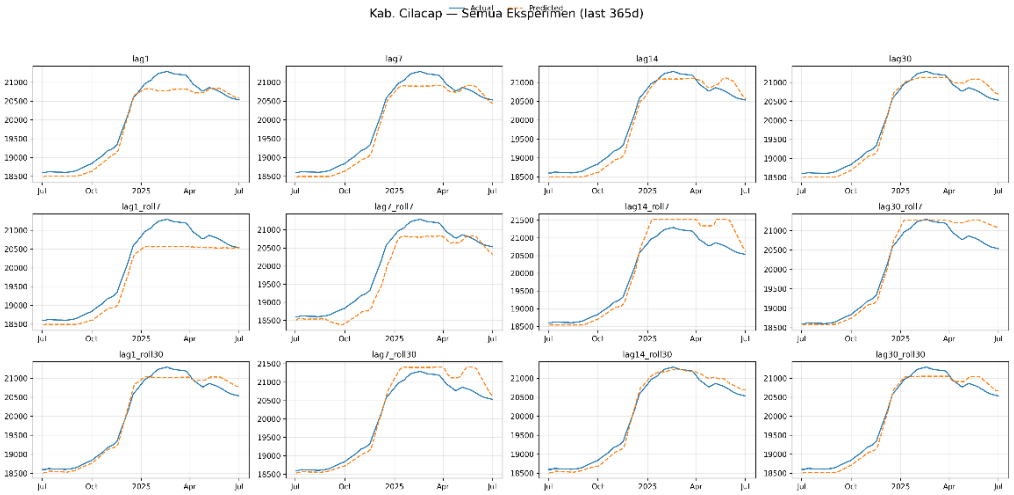

Gambar L12.7 Kabupaten Cilacap

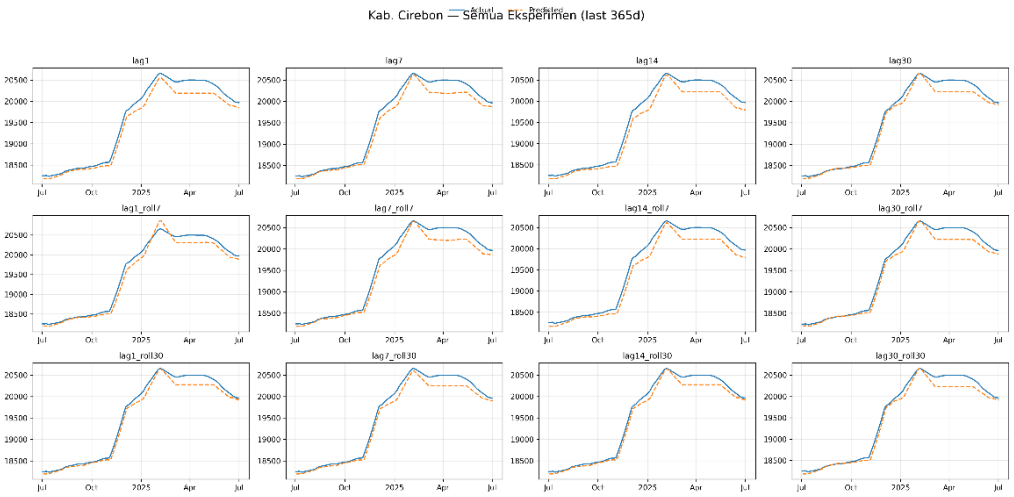

Gambar L12.8 Kabupaten Cirebon

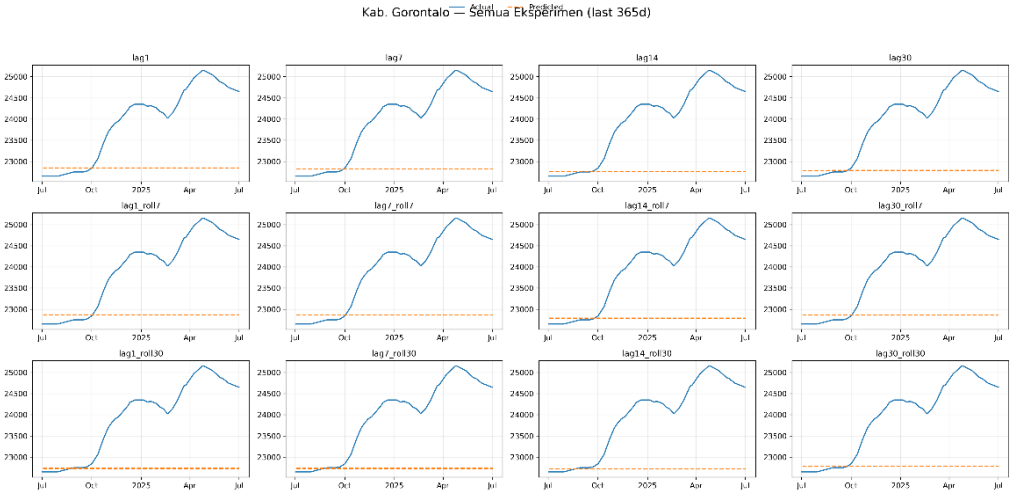

Gambar L12.9 Kabupaten Gorontolo

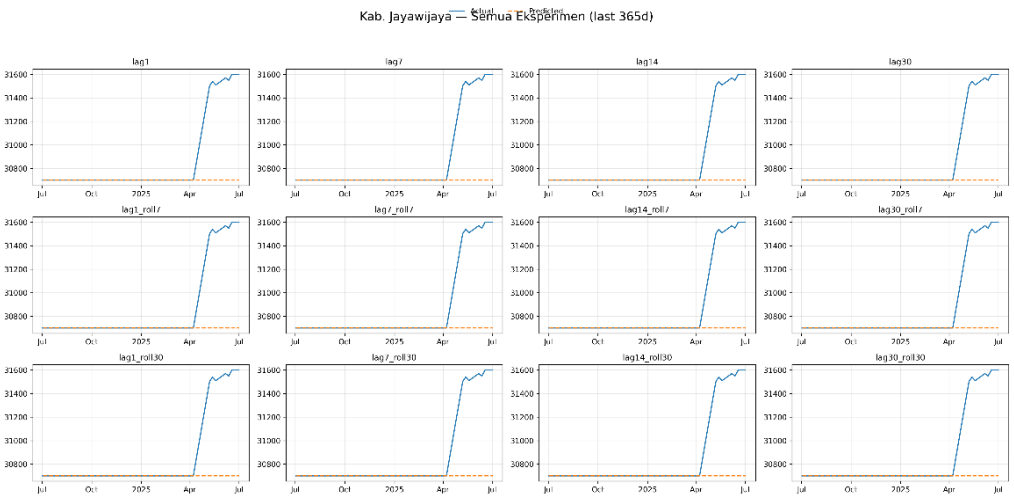

Gambar L12.10 Kabupaten Jayawijaya

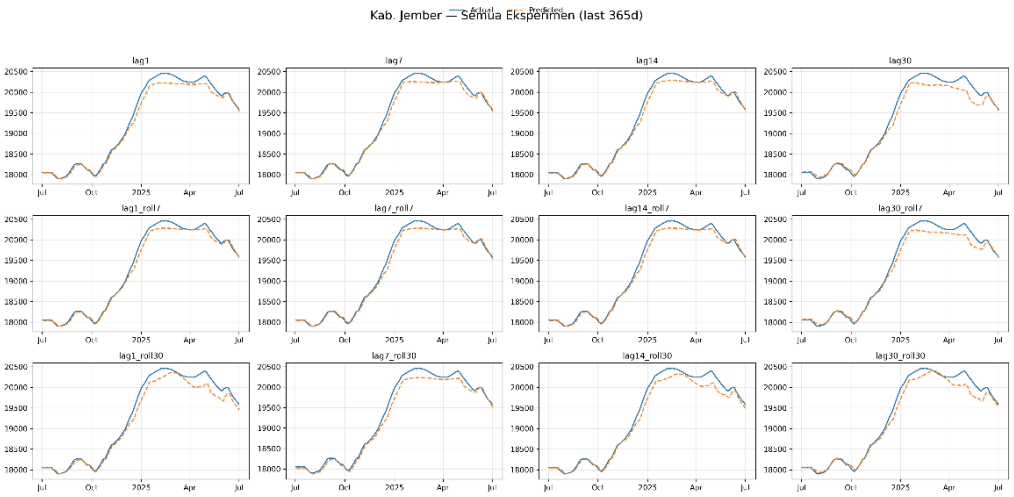

Gambar L12.11 Kabupaten Jember

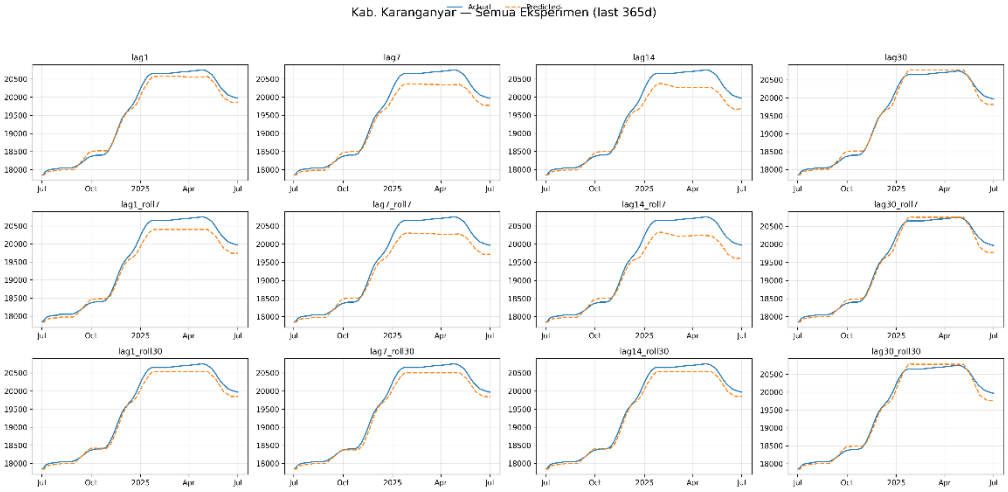

Gambar L12.12 Kabupaten Karangayar

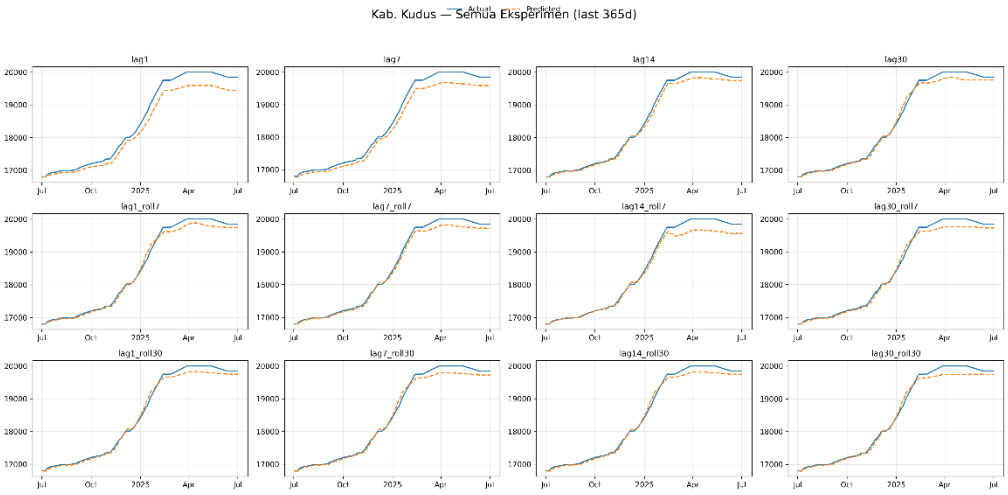

Gambar L12.13 Kabupaten Kudus

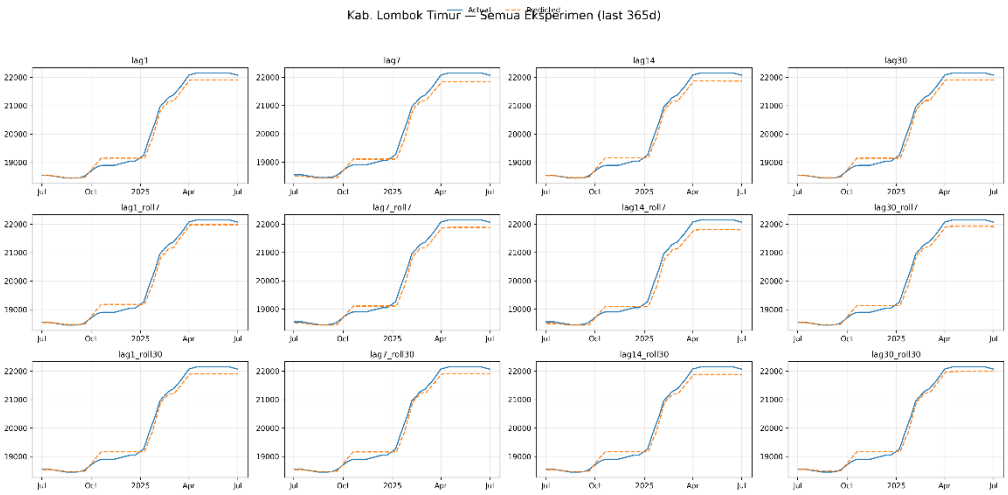

Gambar L12.14 Kabupaten Lombok Timur

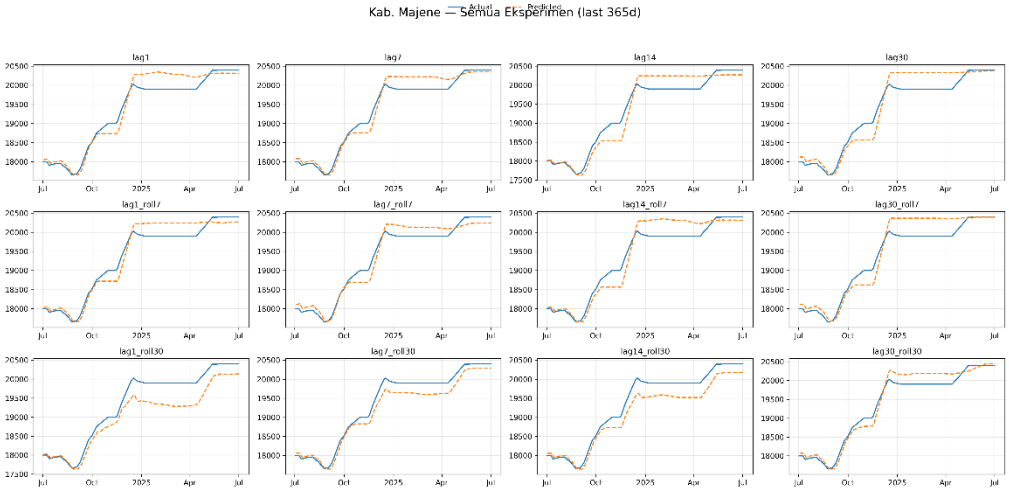

Gambar L12.15 Kabupaten Majene

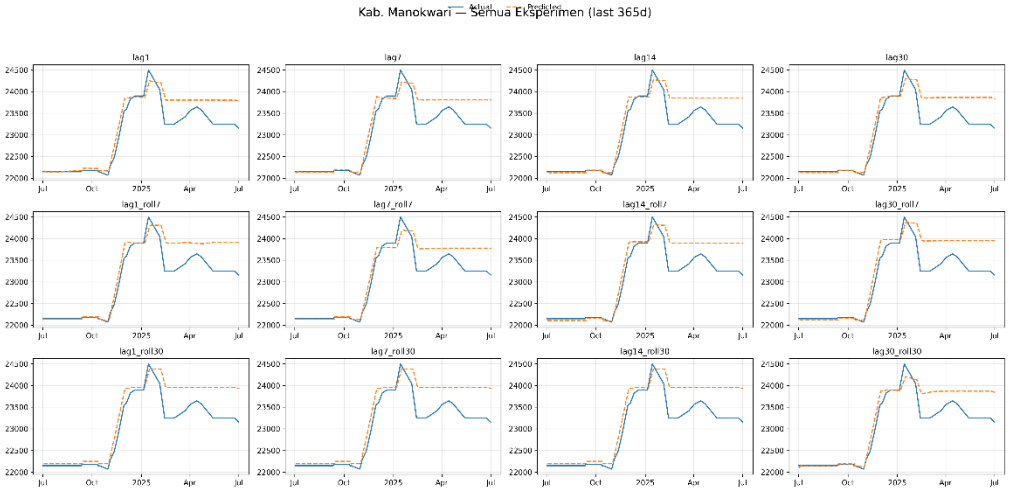

Gambar L12.16 Kabupaten Manokwari

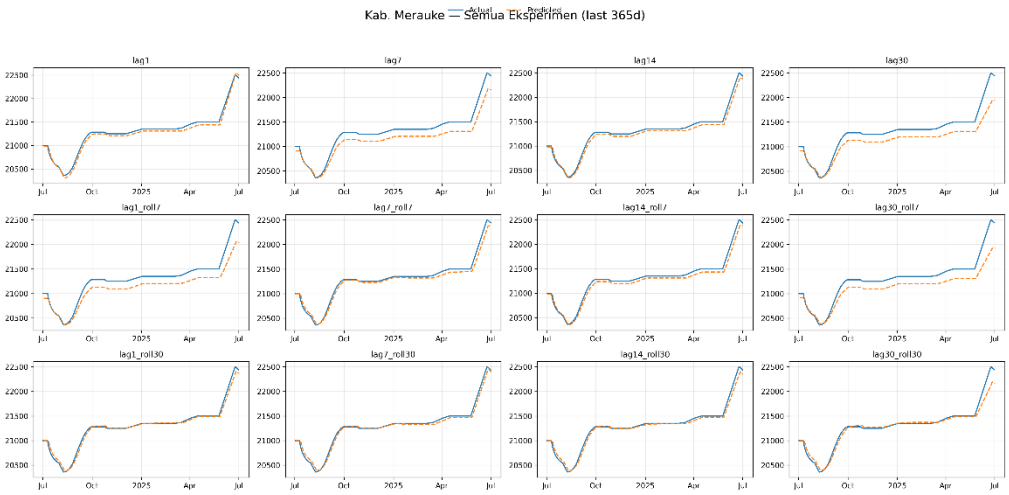

Gambar L12.17 Kabupaten Merauke

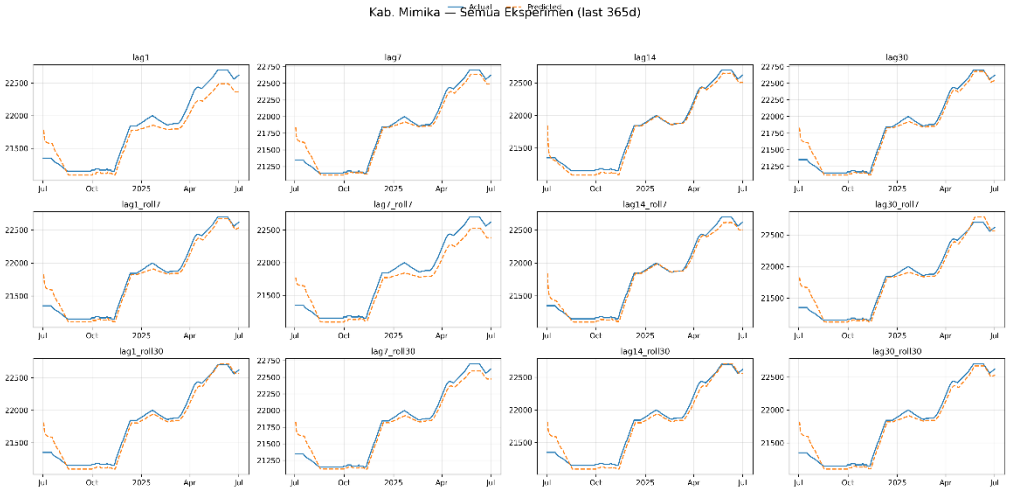

Gambar L12.18 Kabupaten Mimika

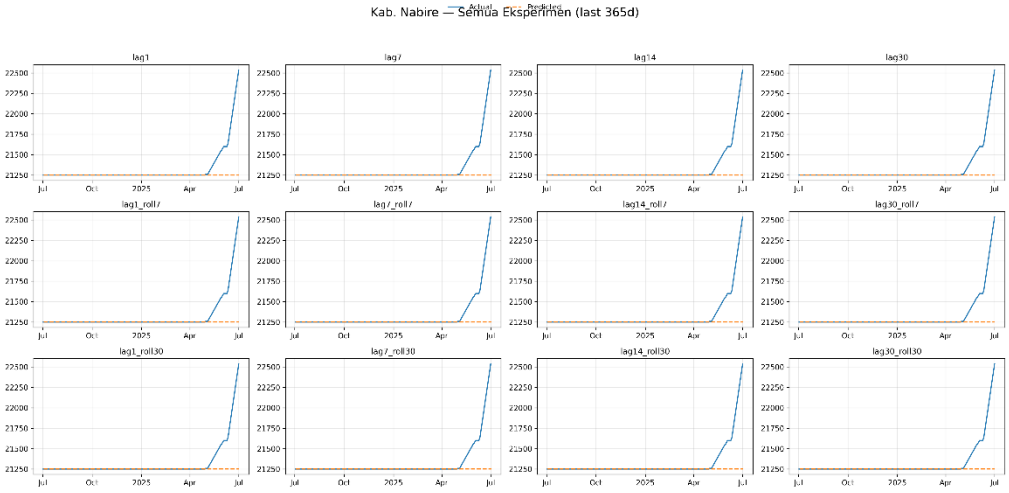

Gambar L12.19 Kabupaten Nabire

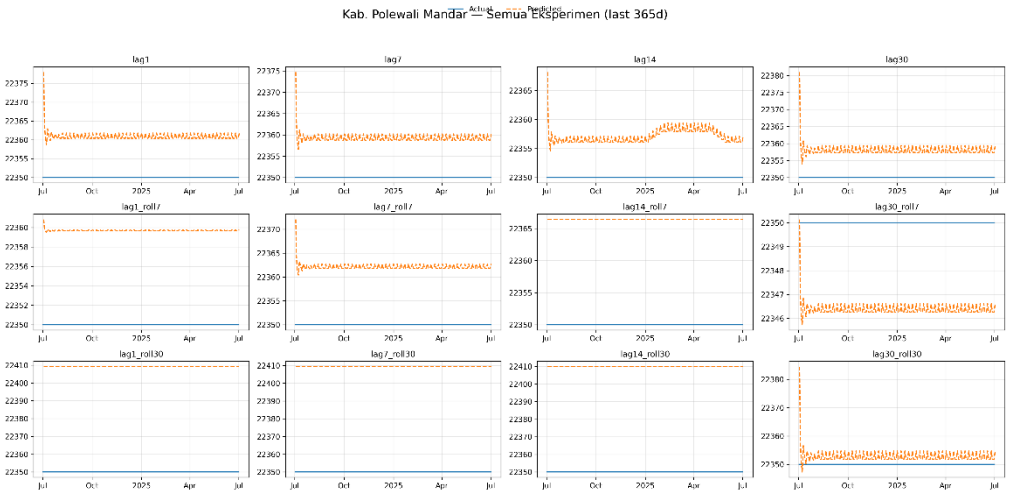

Gambar L12.20 Kabupaten Polewali Mandar

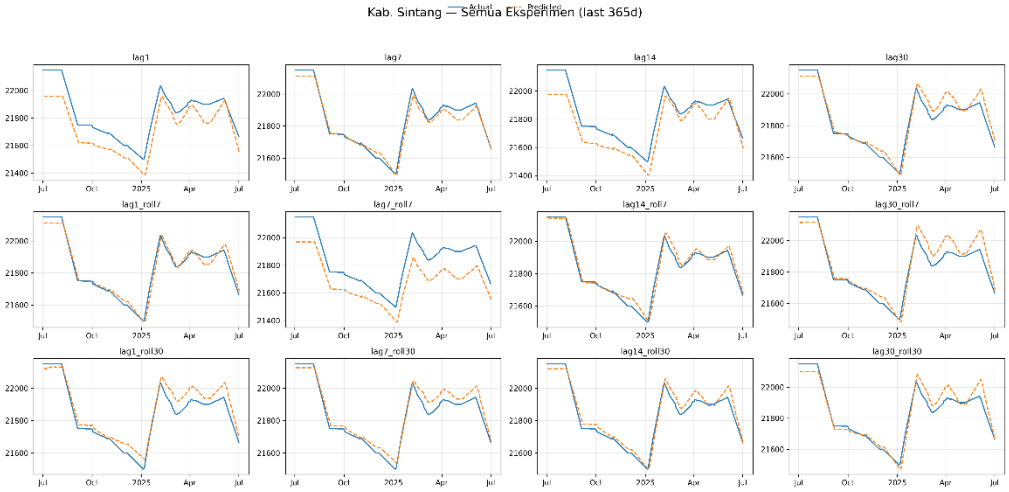

Gambar L12.21 Kabupaten Sintang

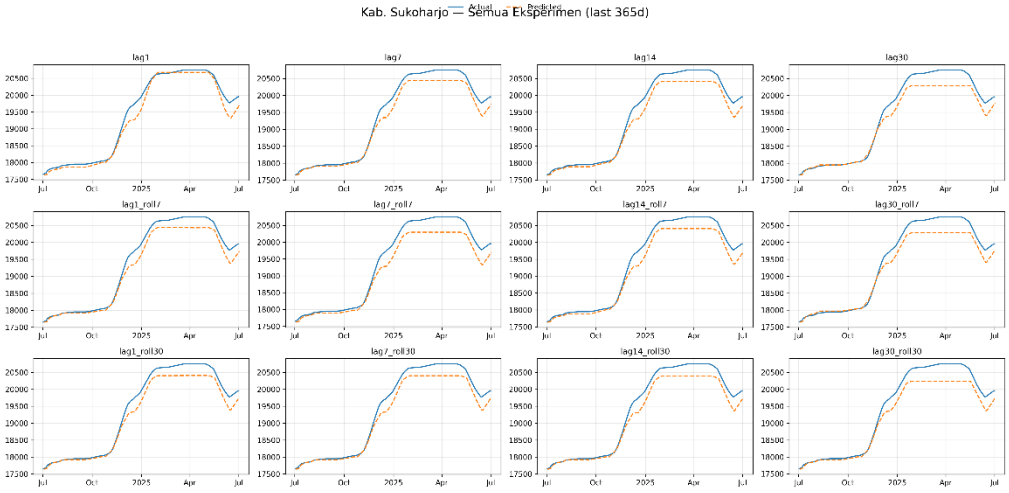

Gambar L12.22 Kabupaten Sukoharjo

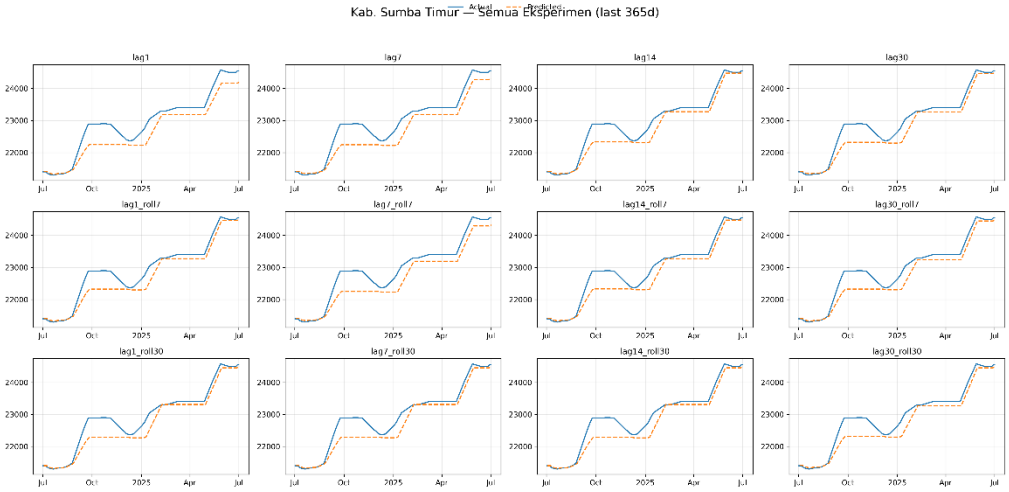

Gambar L12.23 Kabupaten Sumba Timur

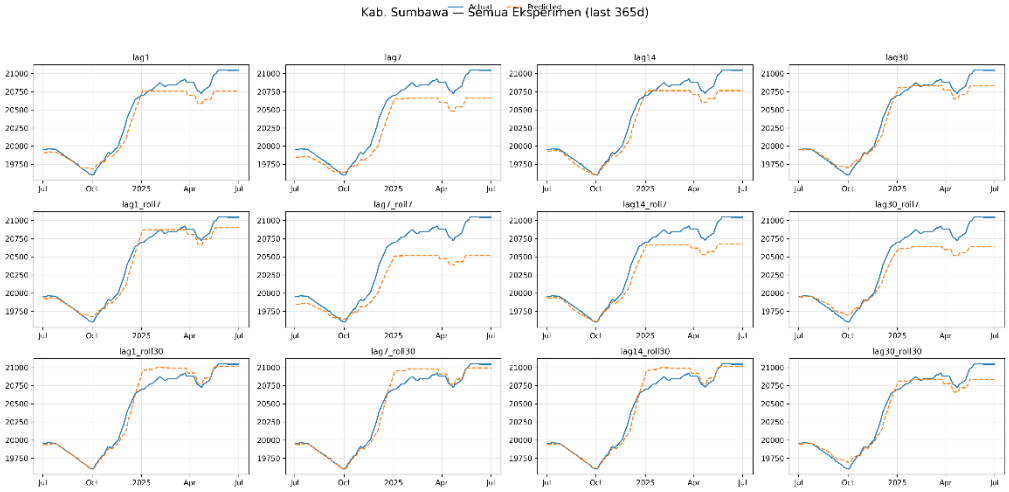

Gambar L12.24 Kabupaten Sumbawa

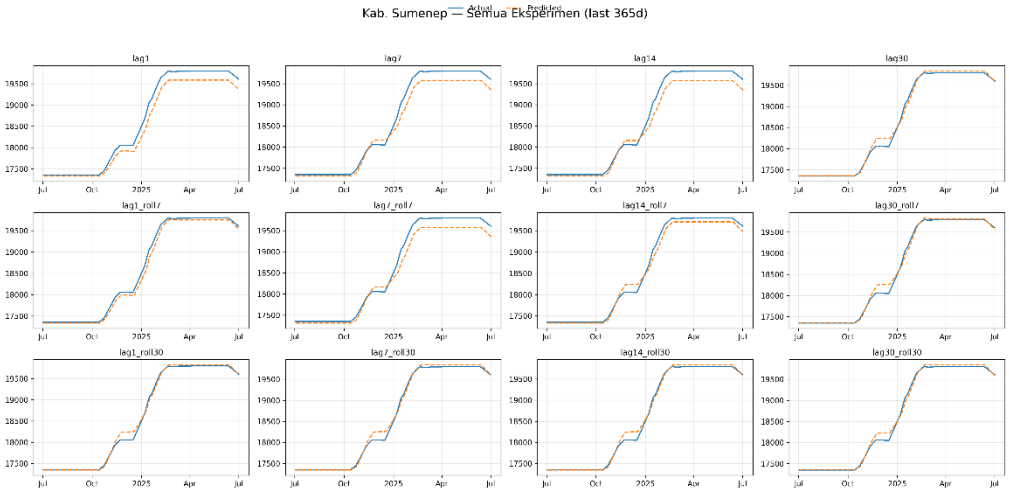

Gambar L12.25 Kabupaten Sumenep

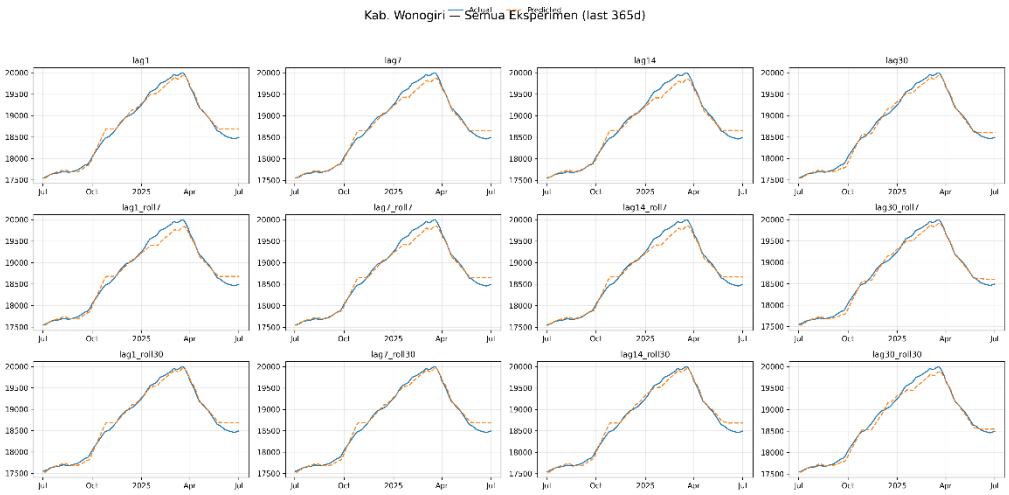

Gambar L12.26 Kabupaten Wonogiri

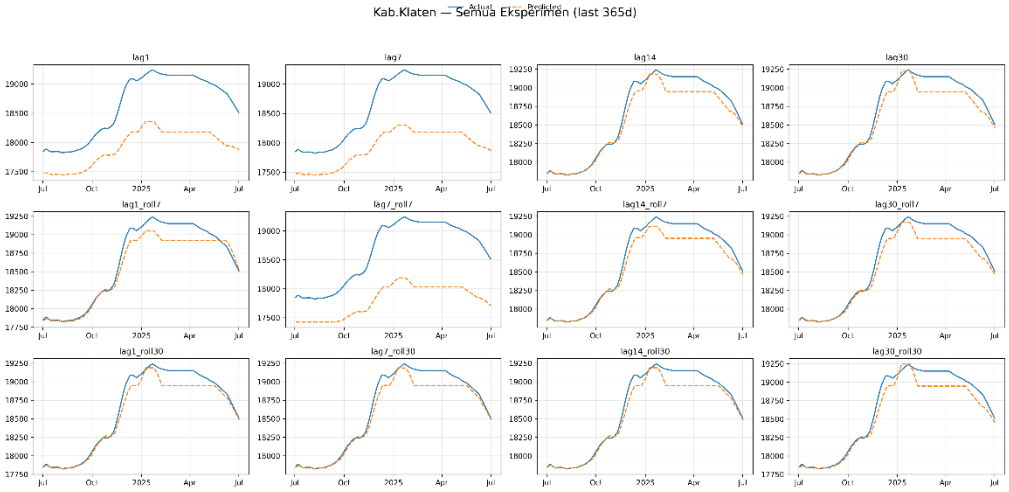

Gambar L12.27 Kabupaten Klaten

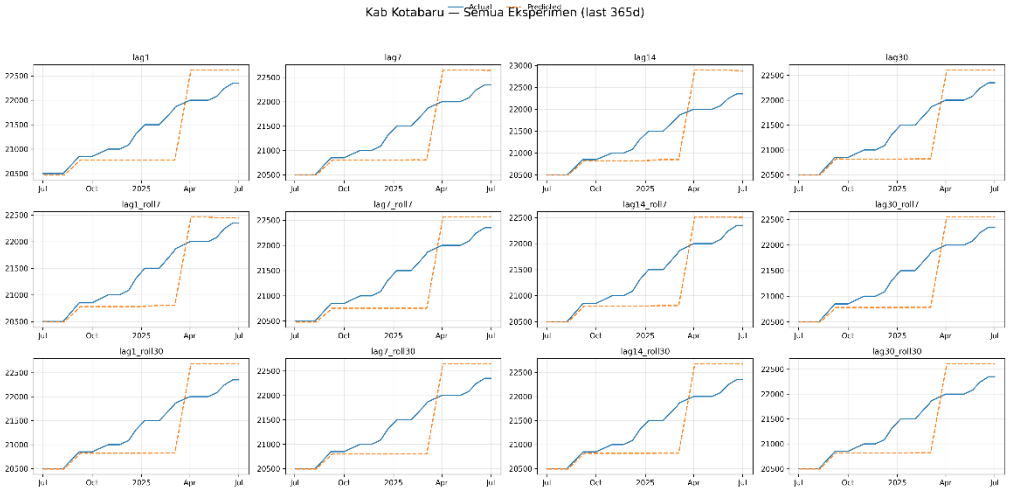

Gambar L12.28 Kabupaten Kotabaru

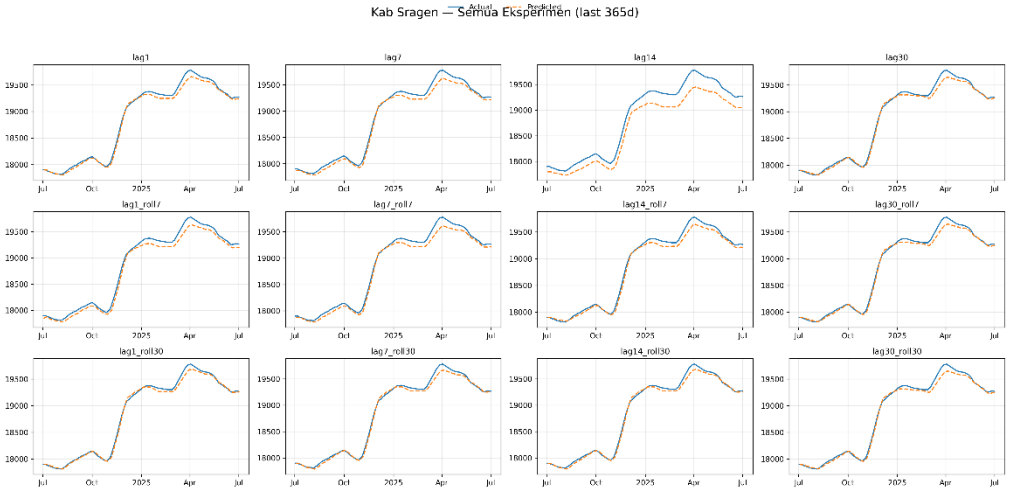

Gambar L12.29 Kabupaten Sragen

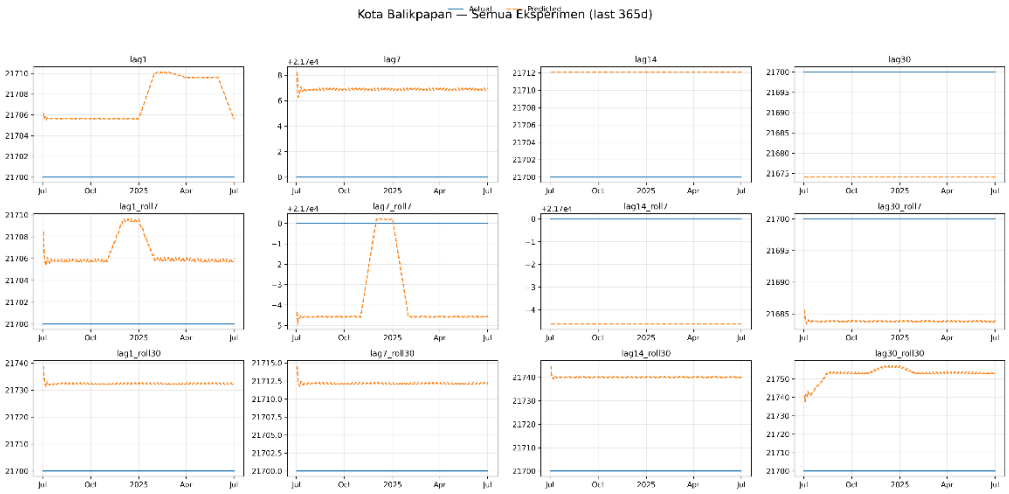

Gambar L12.30 Kota Balikpapan

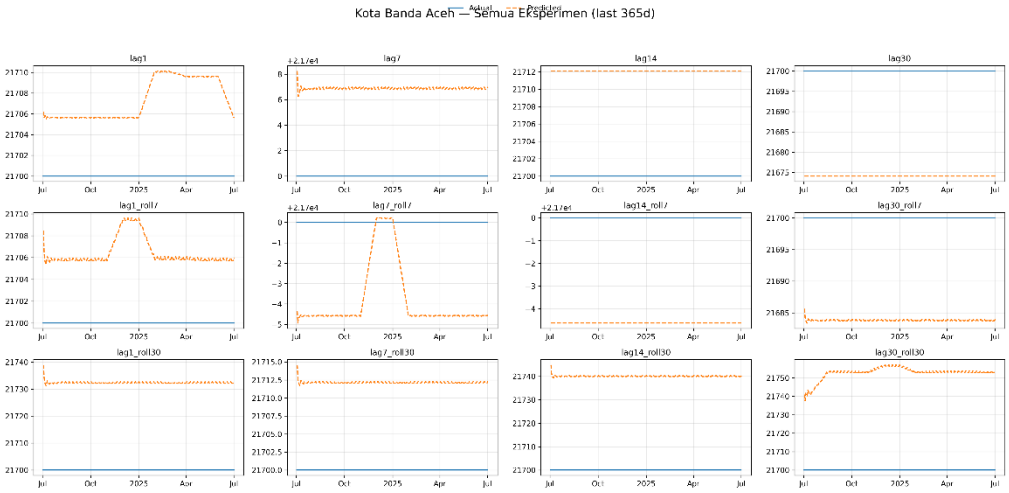

Gambar L12.31 Kota Banda Aceh

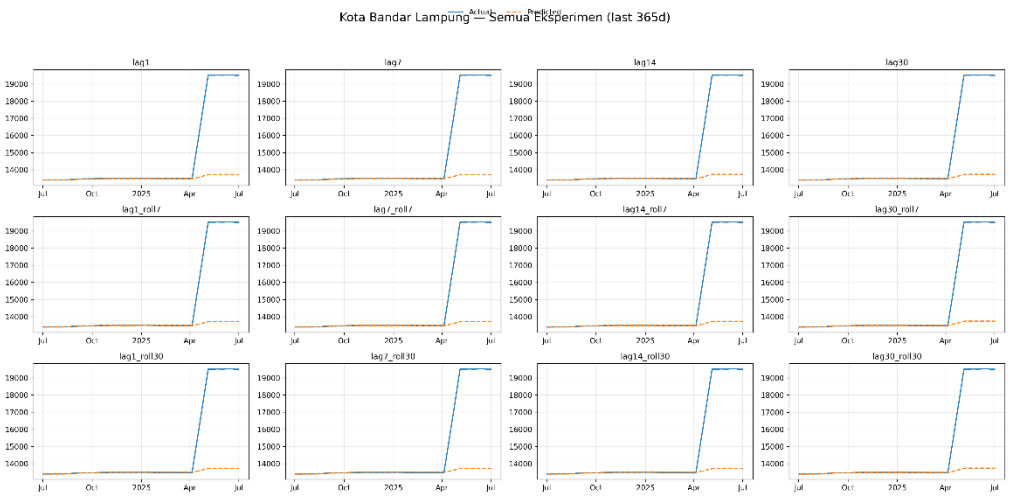

Gambar L12.32 Kota Bandar Lampung

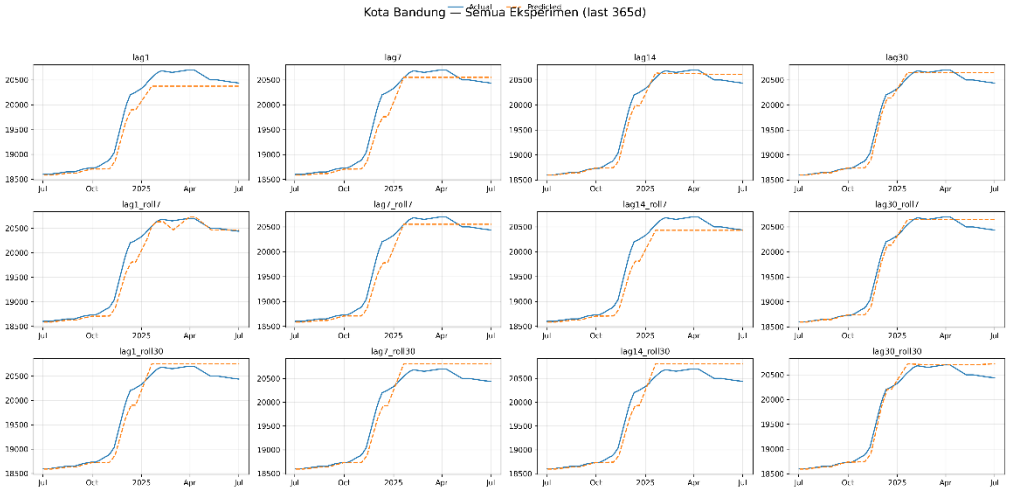

Gambar L12.33 Kota Bandung

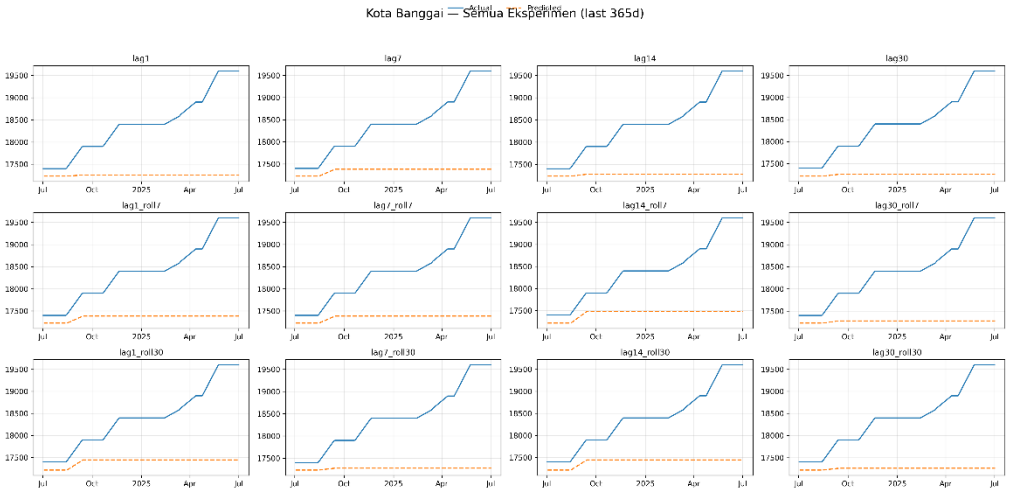

Gambar L12.34 Kota Banggai

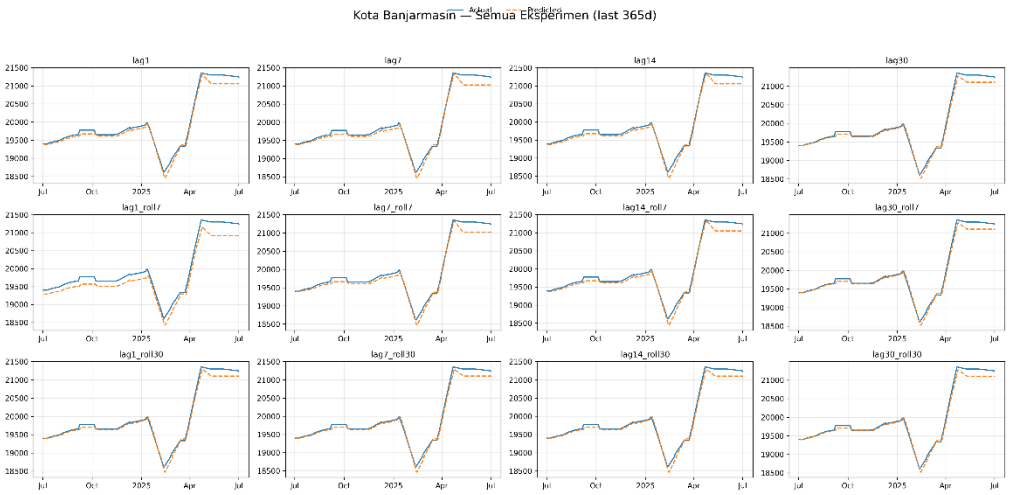

Gambar L12.35 Kota Banjarmasin

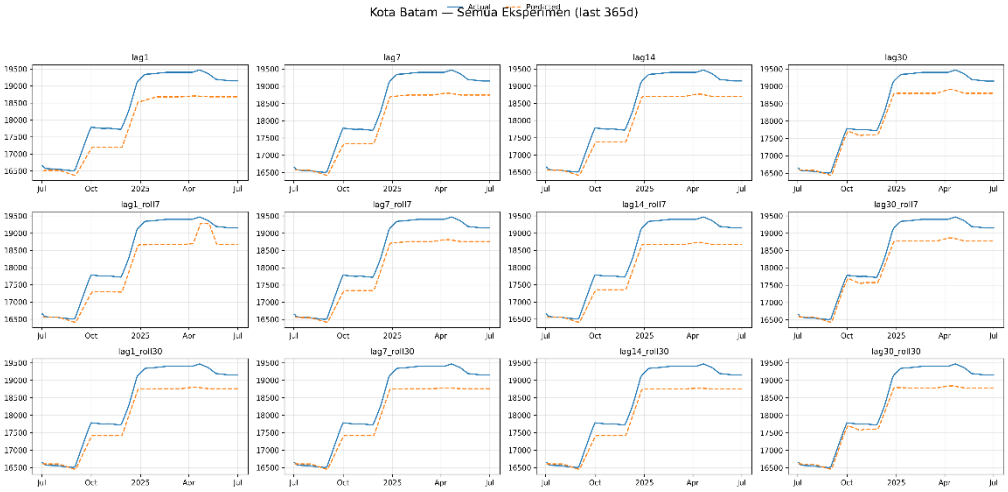

Gambar L12.36 Kota Batam

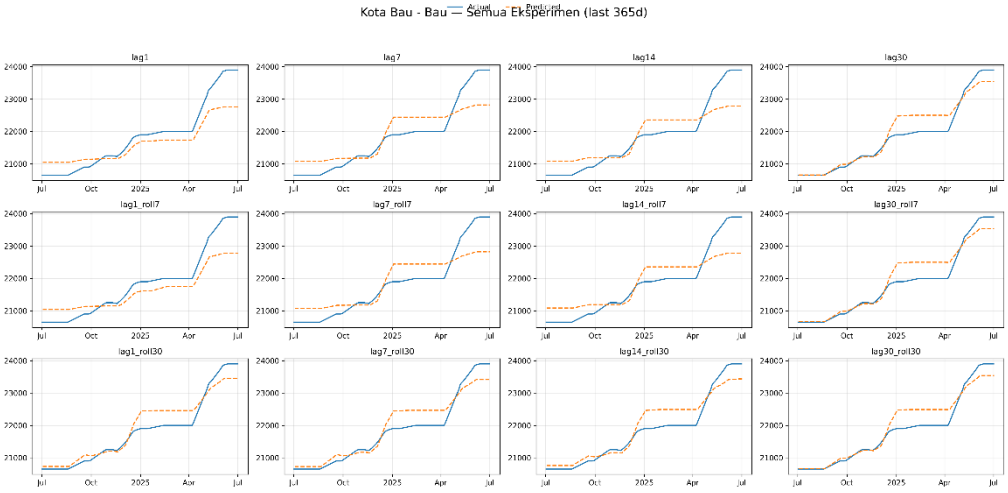

Gambar L12.37 Kota Bau – Bau

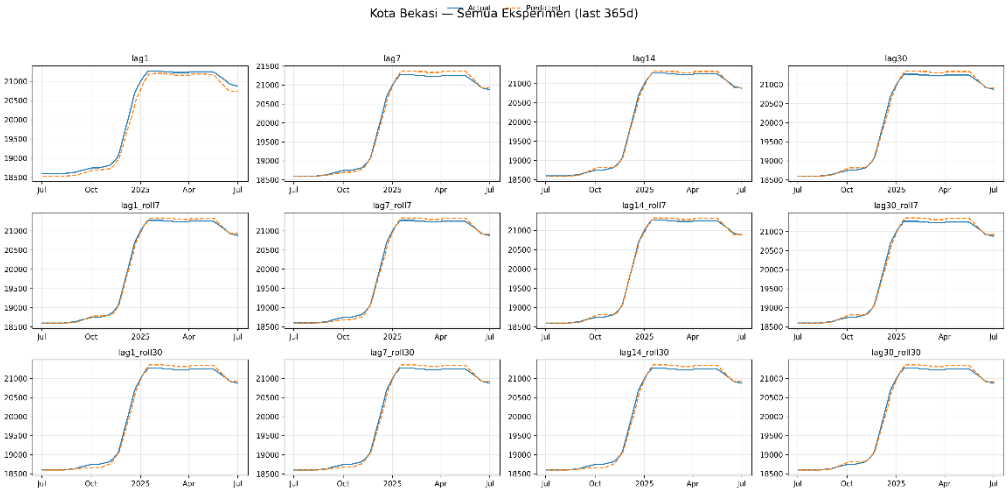

Gambar L12.38 Kota Bekasi

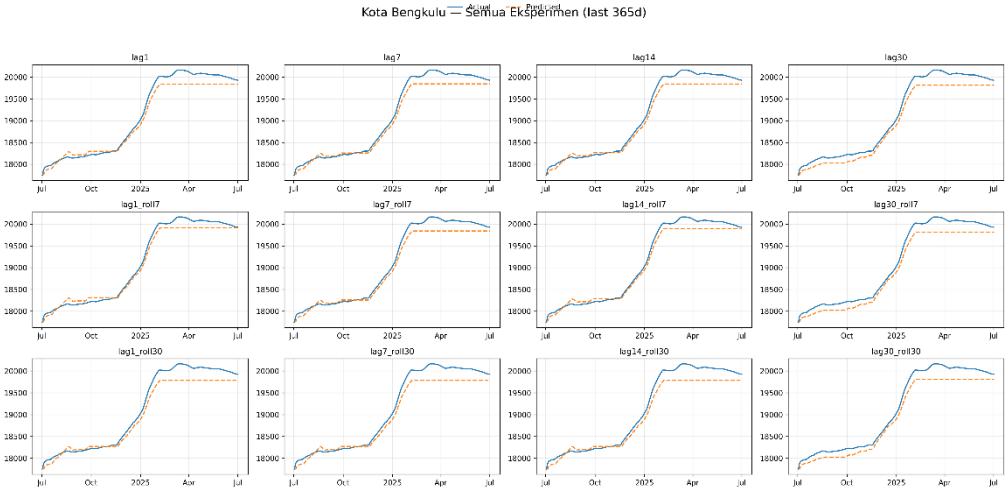

Gambar L12.39 Kota Bengkulu

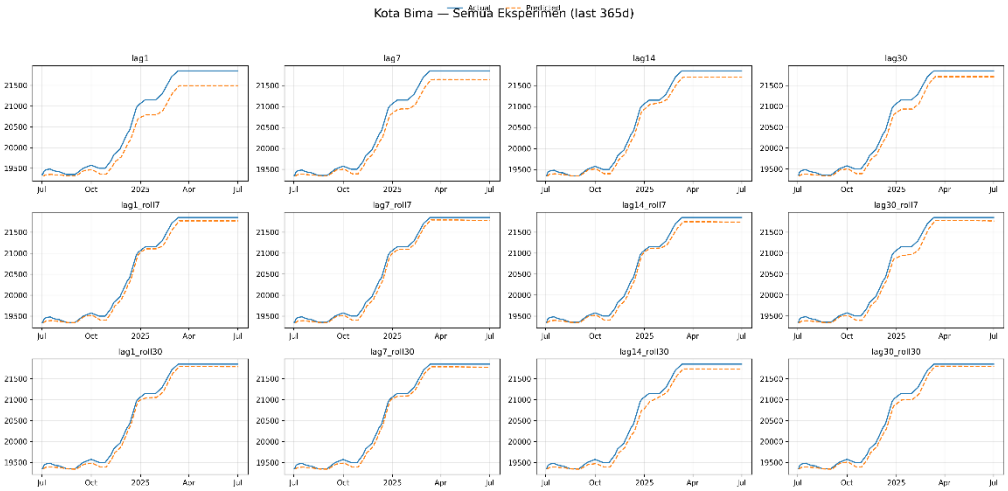

Gambar L12.40 Kota Bima

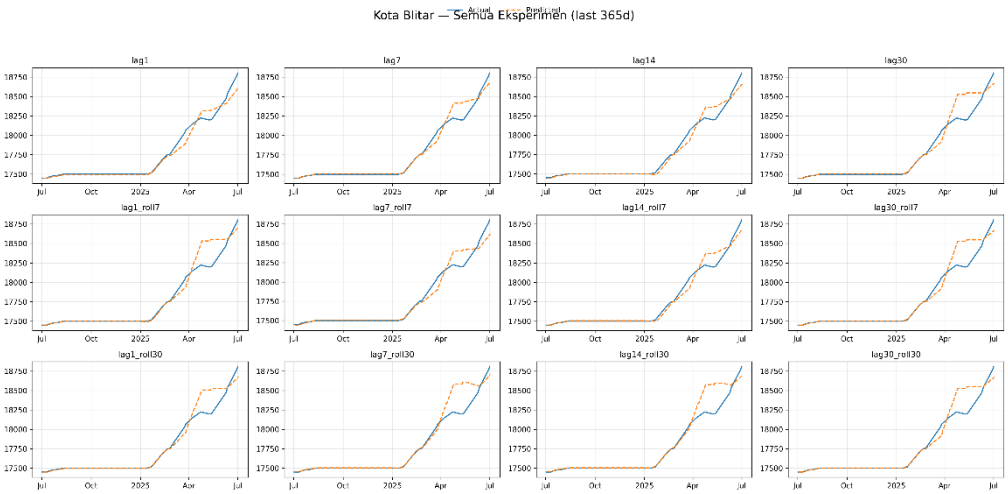

Gambar L12.41 Kota Blitar

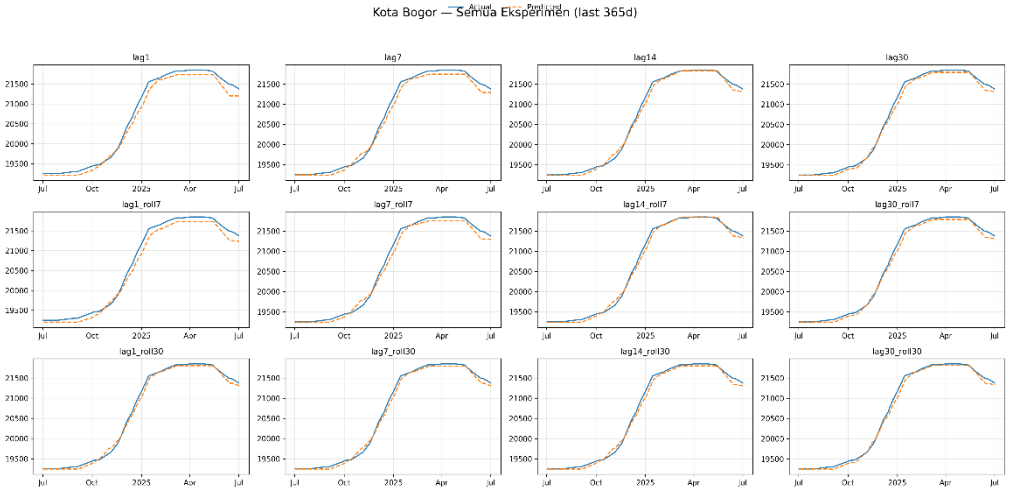

Gambar L12.42 Kota Bogor

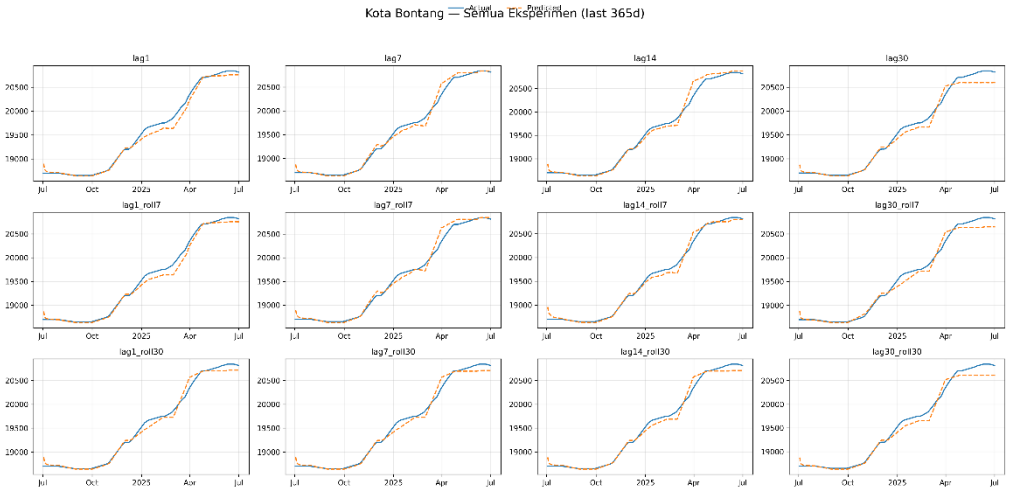

Gambar L12.43 Kota Bontang

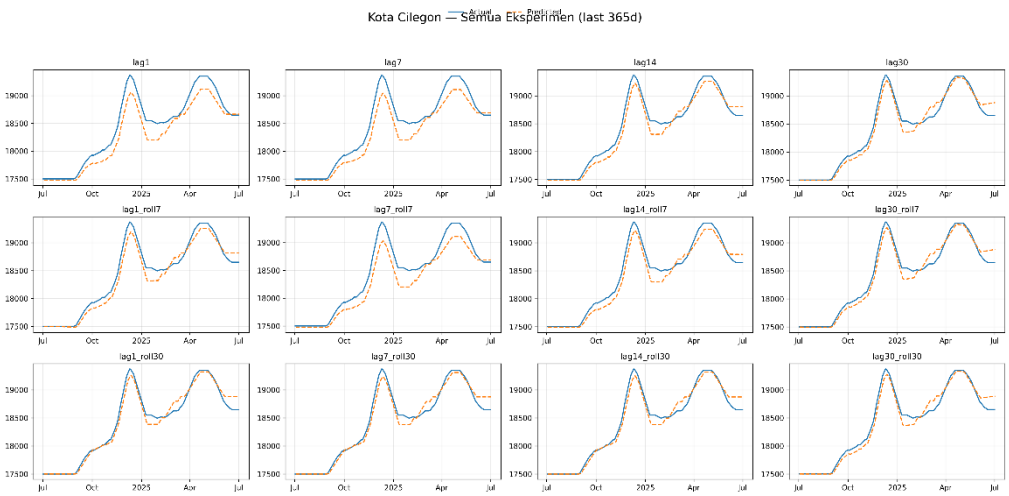

Gambar L12.44 Kota Cilegon

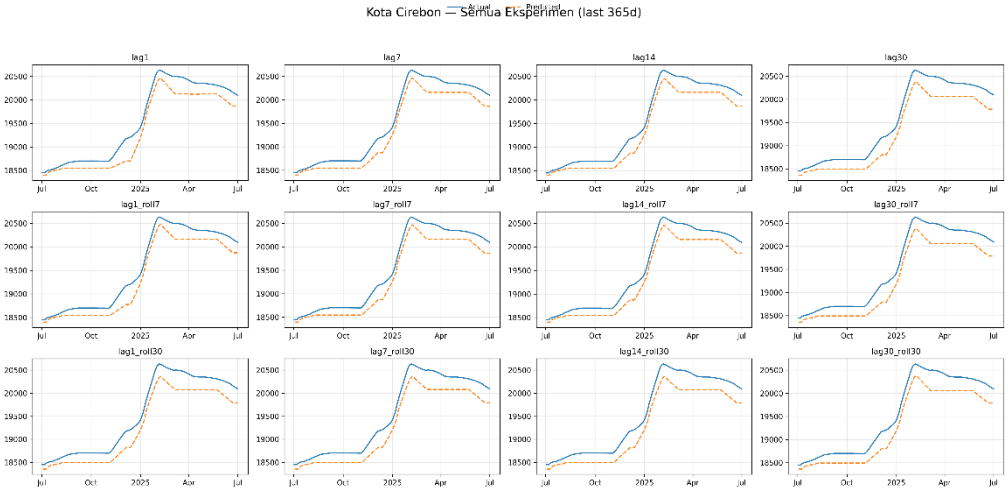

Gambar L12.45 Kota Cirebon

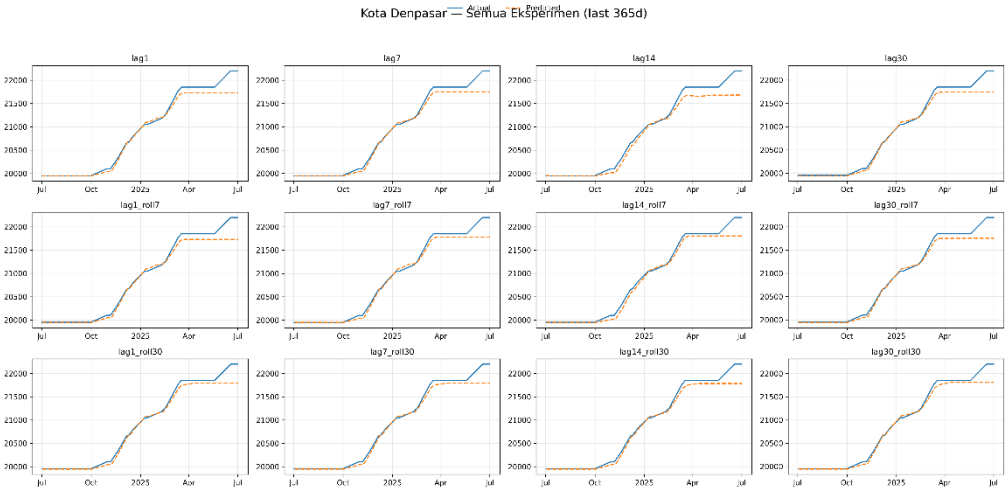

Gambar L12.46 Kota Denpasar

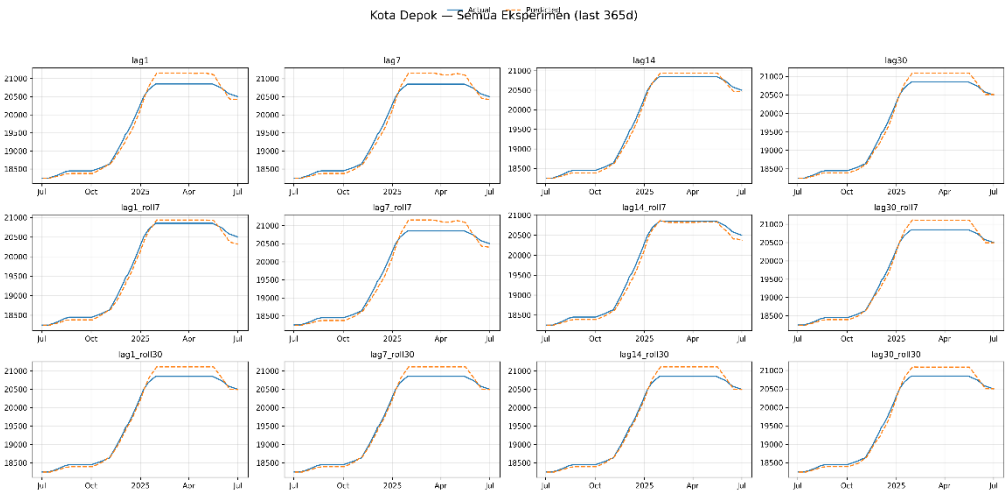

Gambar L12.47 Kota Depok

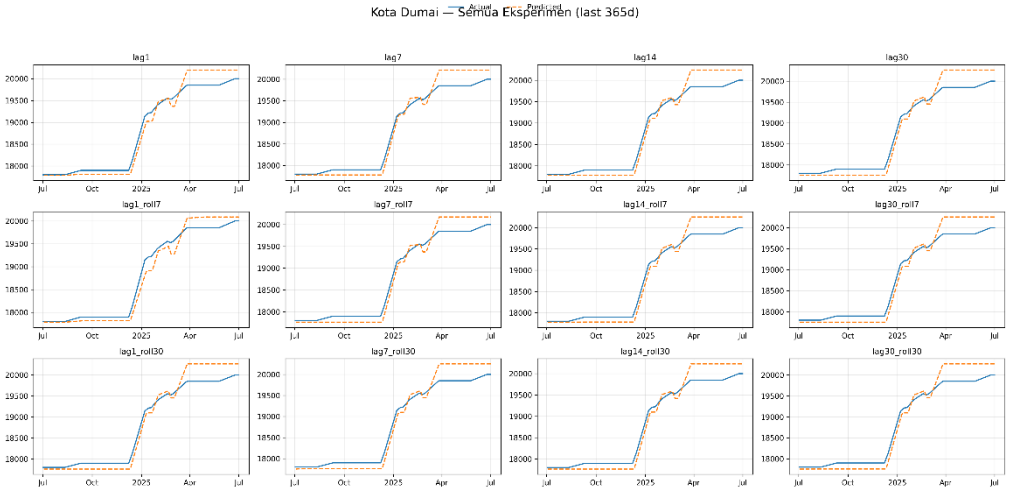

Gambar L12.48 Kota Dumai

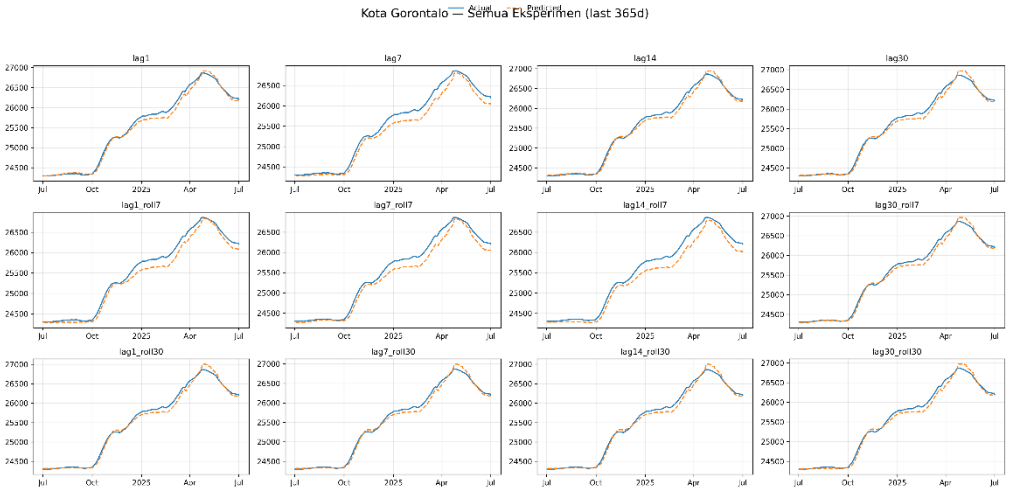

Gambar L12.49 Kota Gorontolo

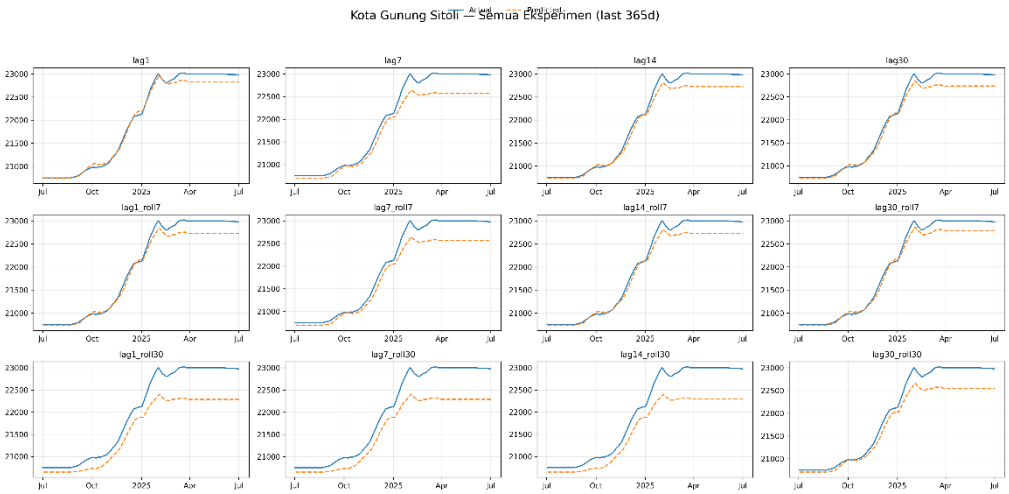

Gambar L12.50 Kota Gunung Sitoli

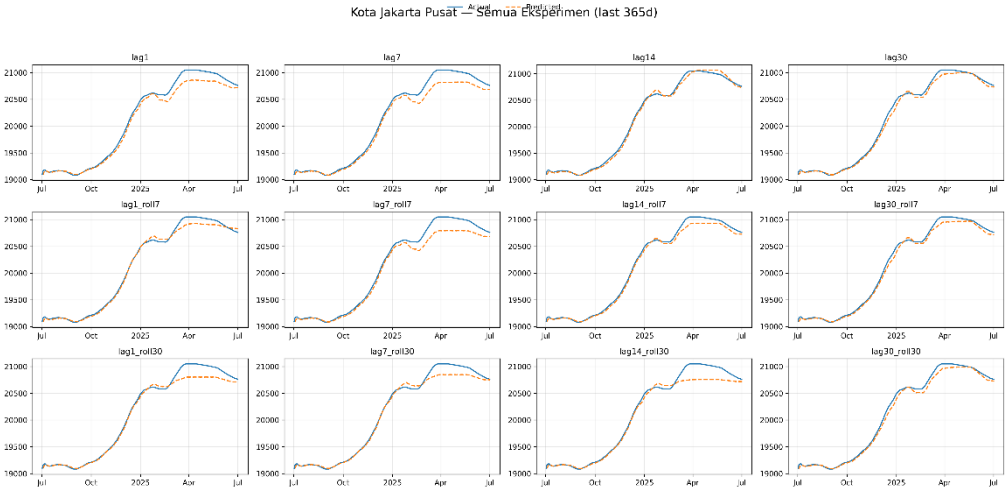

Gambar L12.51 Kota Jakarta Pusat

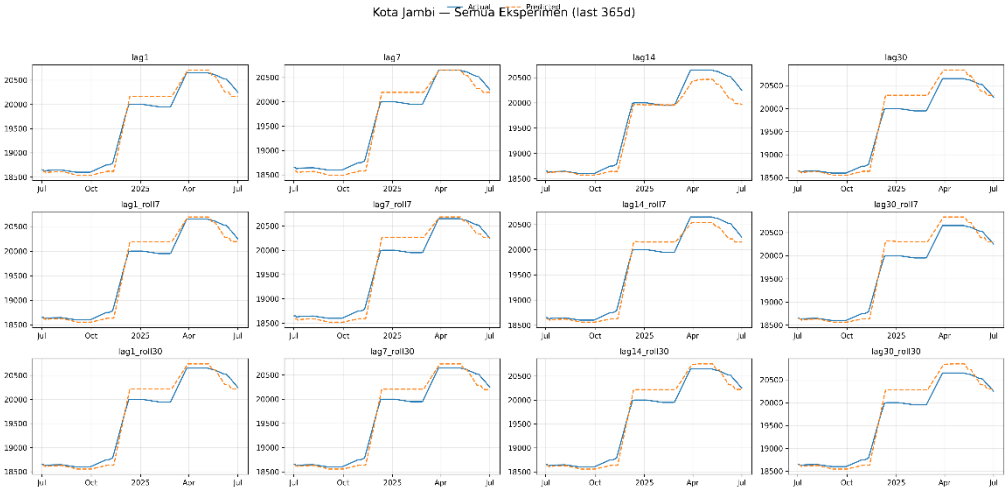

Gambar L12.52 Kota Jambi

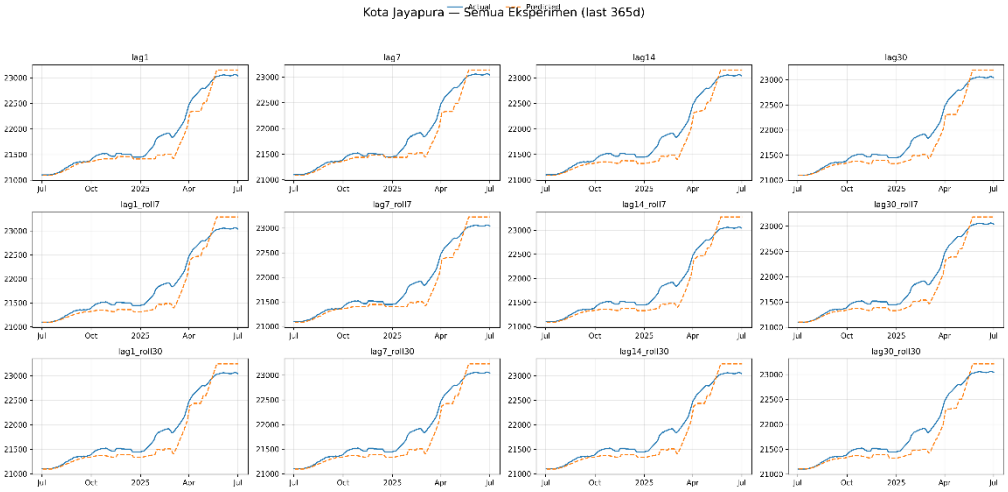

Gambar L12.53 Kota Jayapura

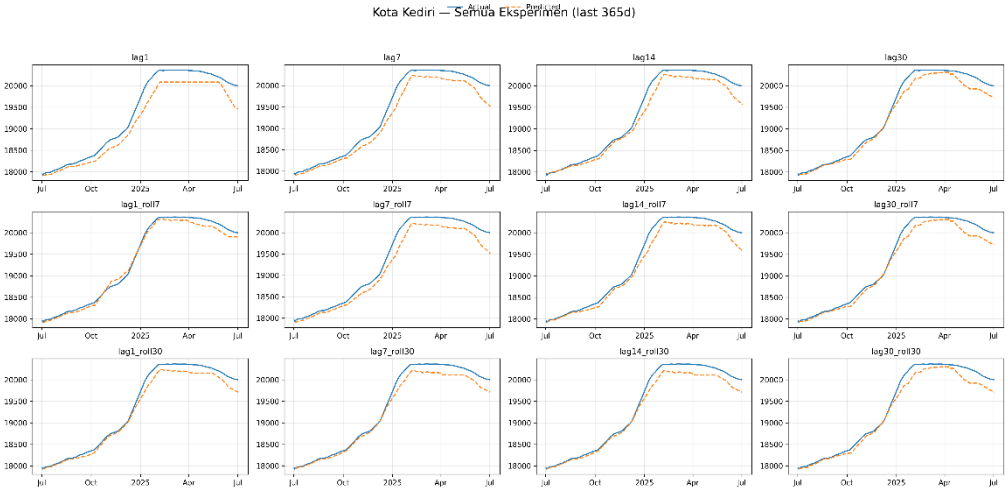

Gambar L12.54 Kota Kediri

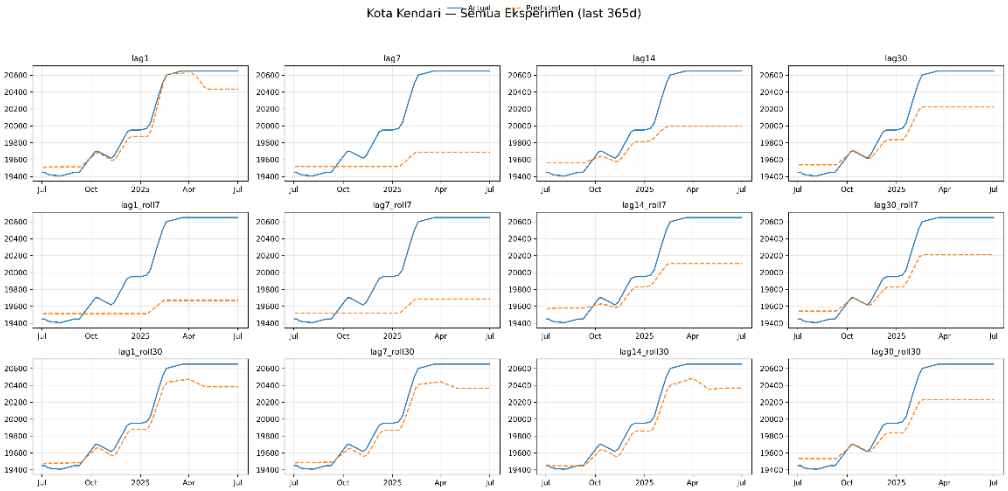

Gambar L12.55 Kota Kendari

Gambar L12.56 Kota Kupang

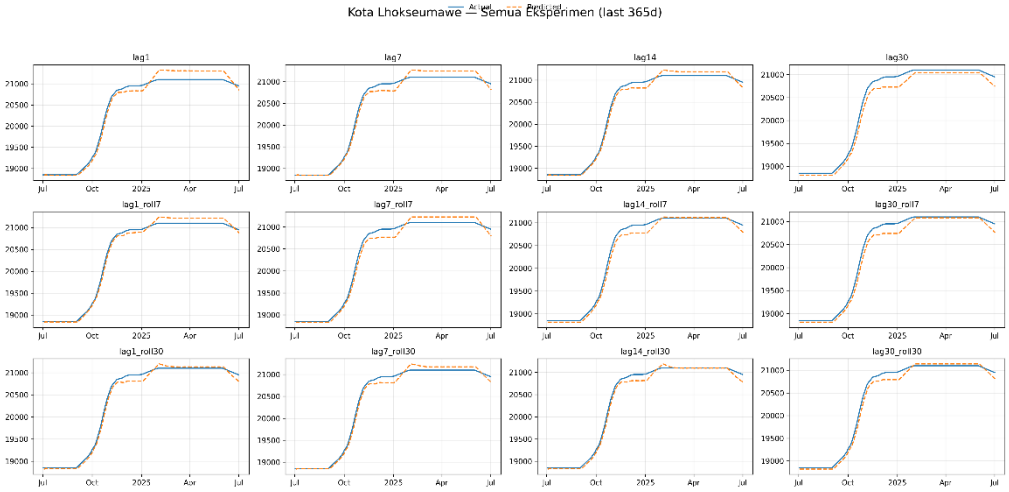

Gambar L12.57 Kota Lhokseumawe

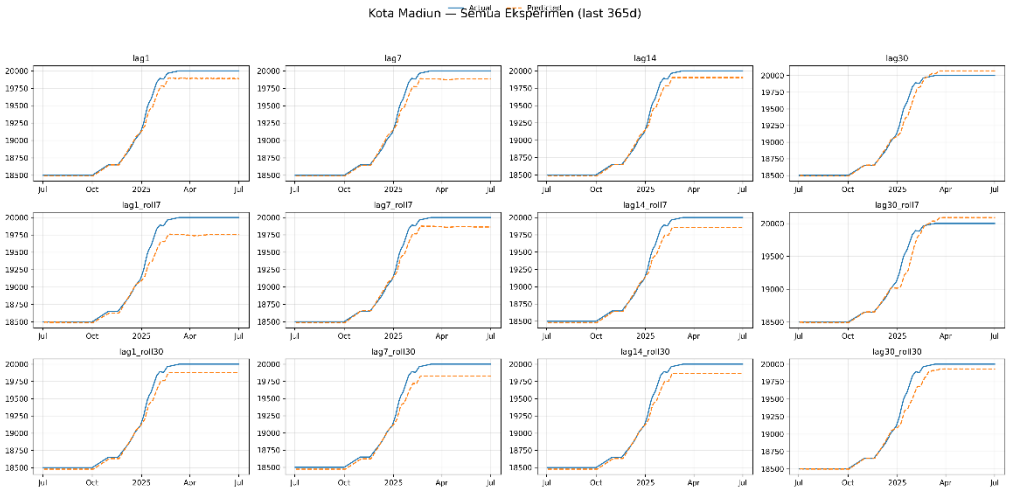

Gambar L12.58 Kota Madiun

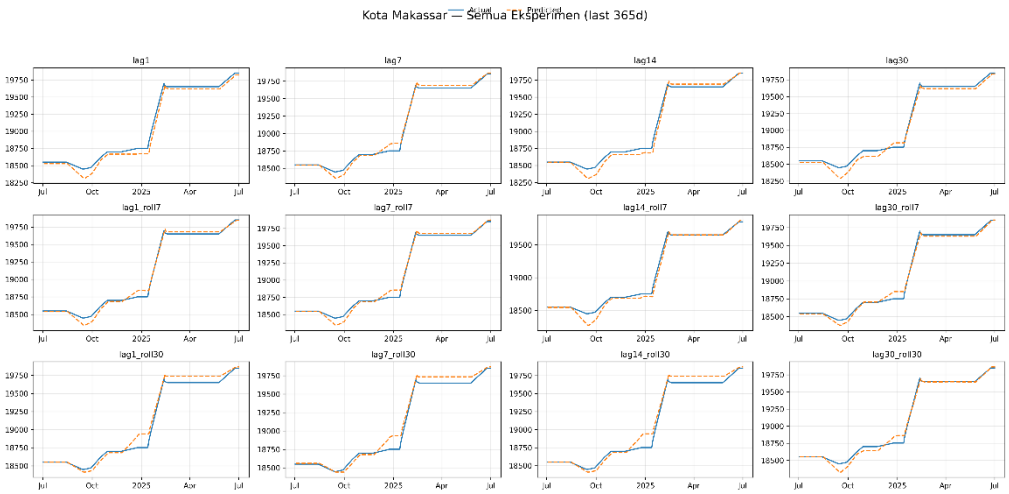

Gambar L12.59 Kota Makassar

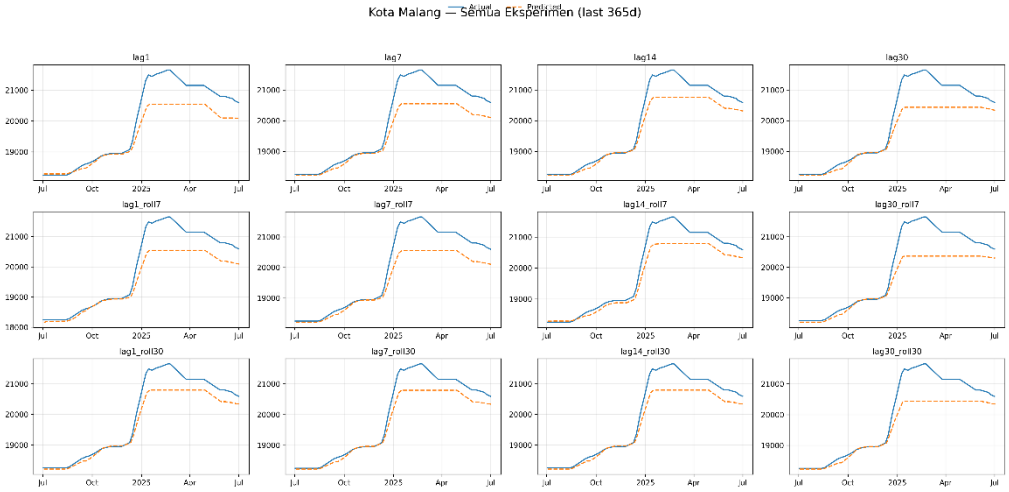

Gambar L12.60 Kota Malang

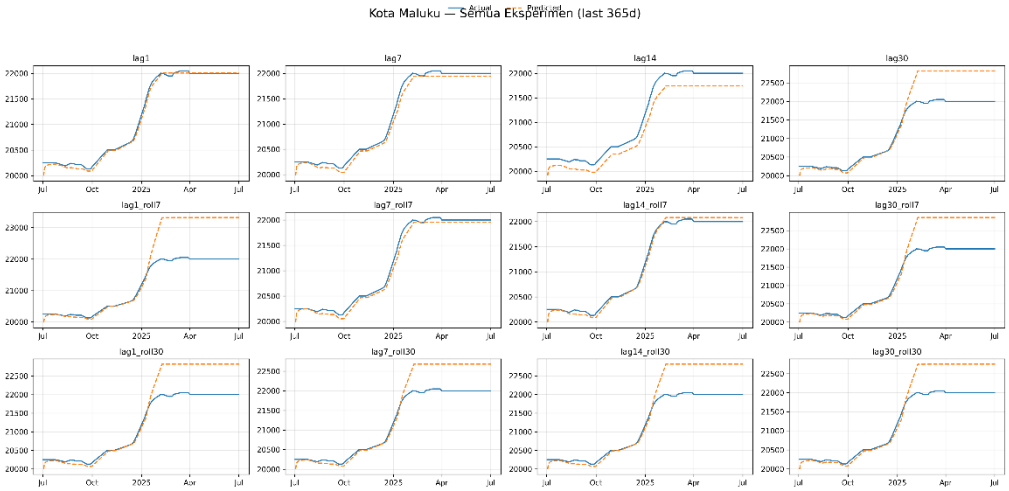

Gambar L12.61 Kota Maluku

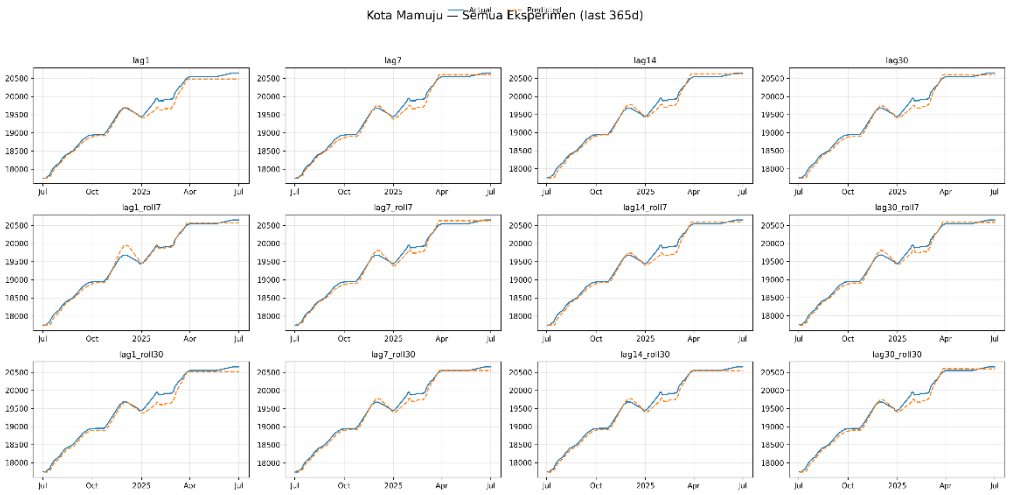

Gambar L12.62 Kota Mamuju

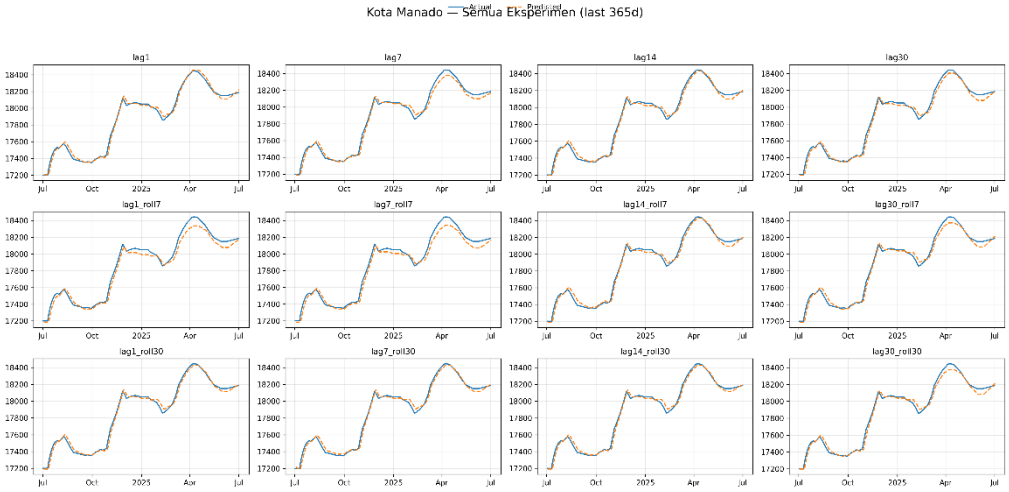

Gambar L12.63 Kota Manado

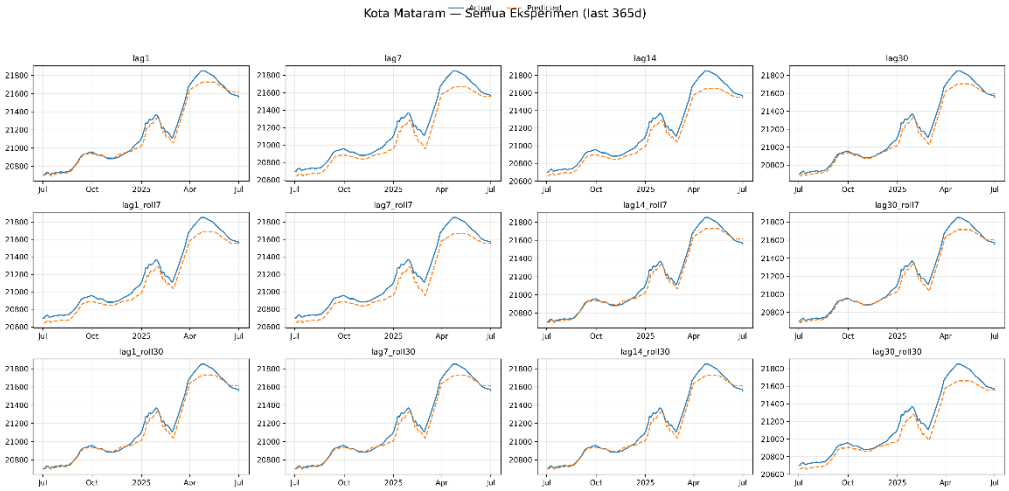

Gambar L12.64 Kota Mataram

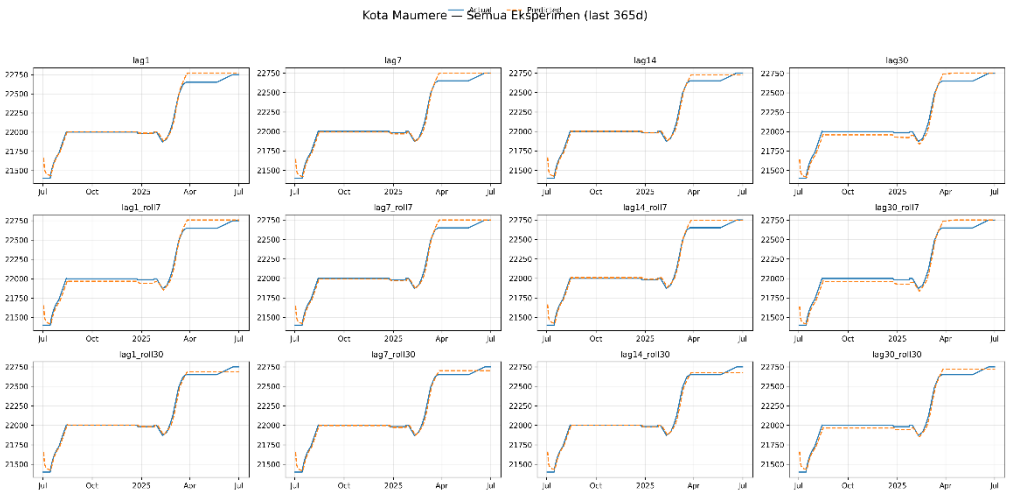

Gambar L12.65 Kota Maumere

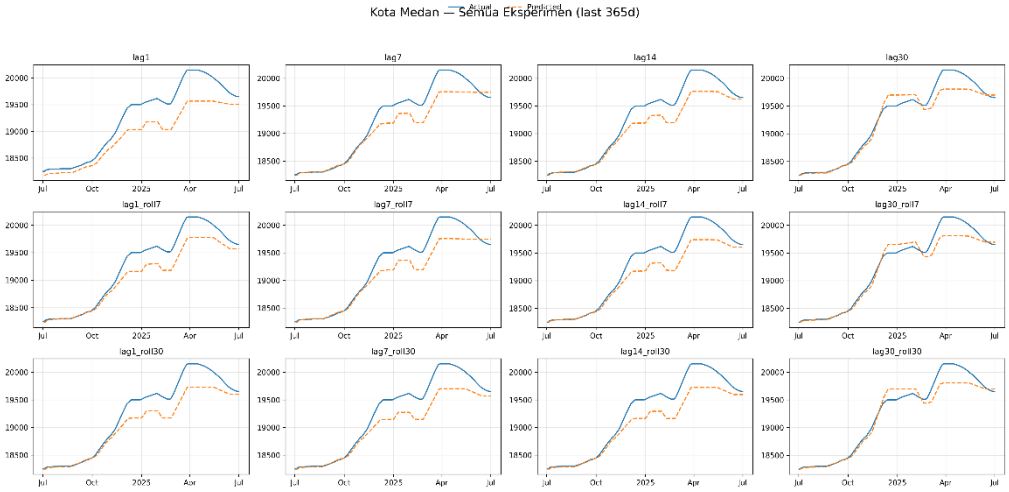

Gambar L12.66 Kota Medan

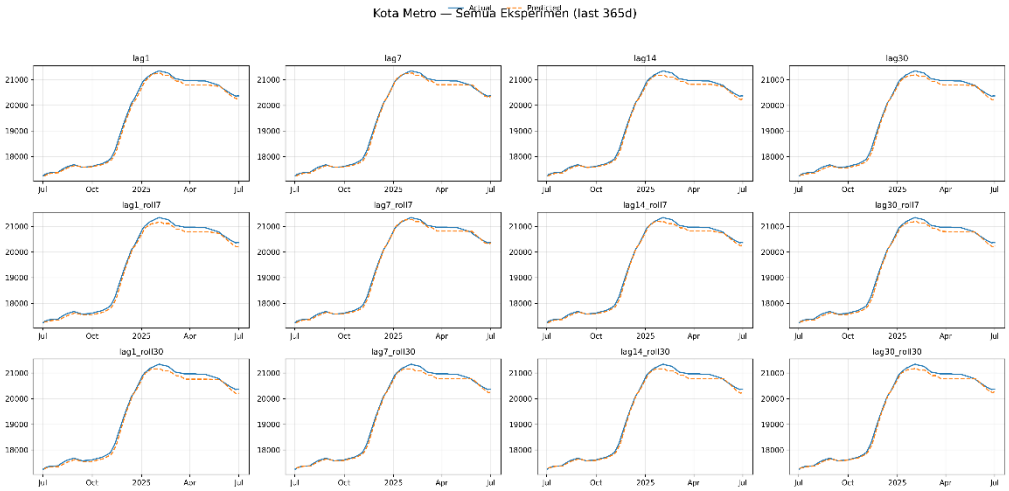

Gambar L12.67 Kota Metro

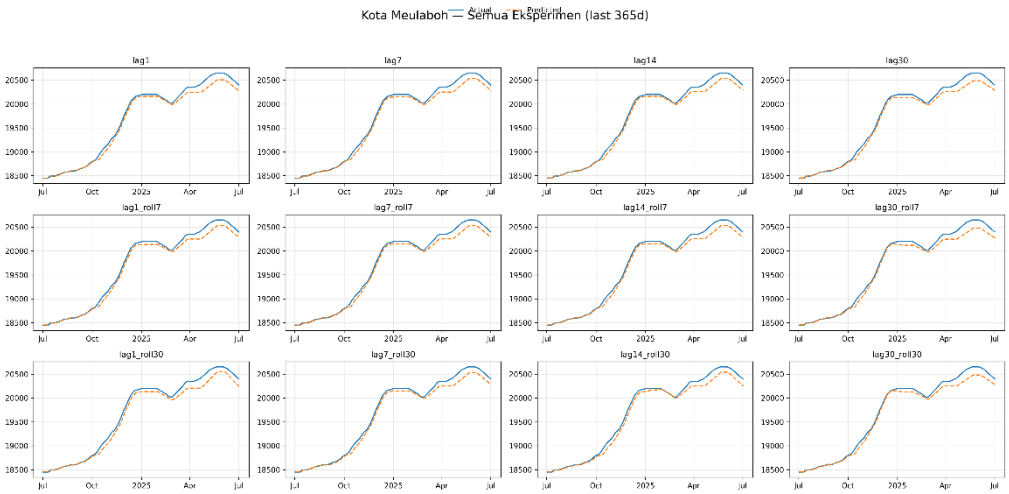

Gambar L12.68 Kota Meulaboh

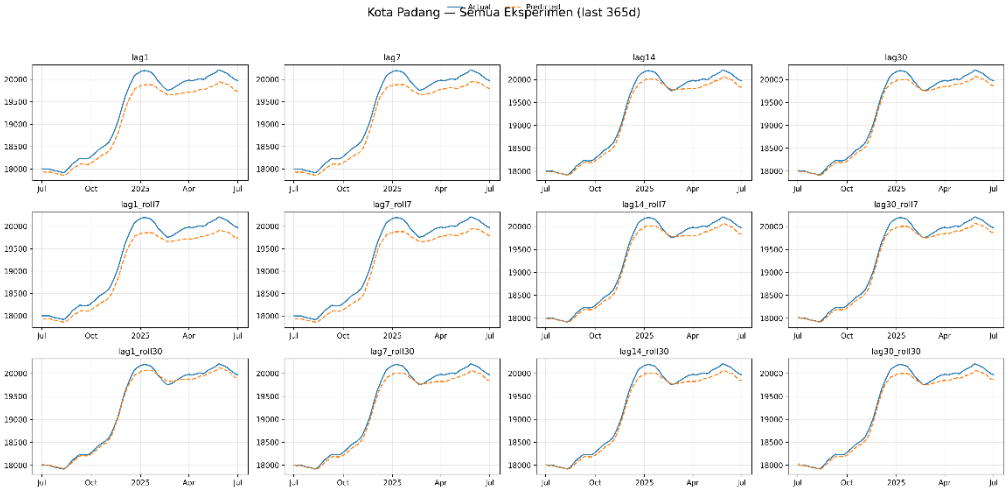

Gambar L12.69 Kota Padang

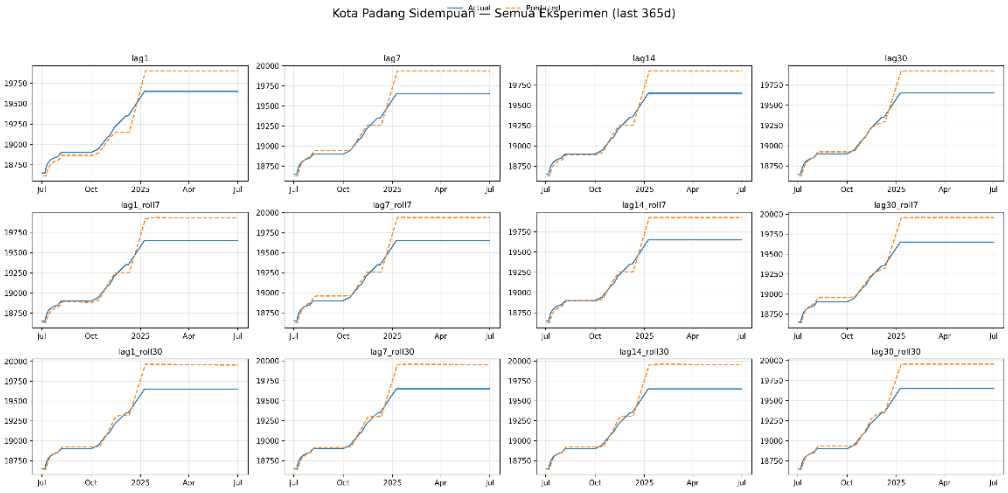

Gambar L12.70 Kota Padang Sidempuan

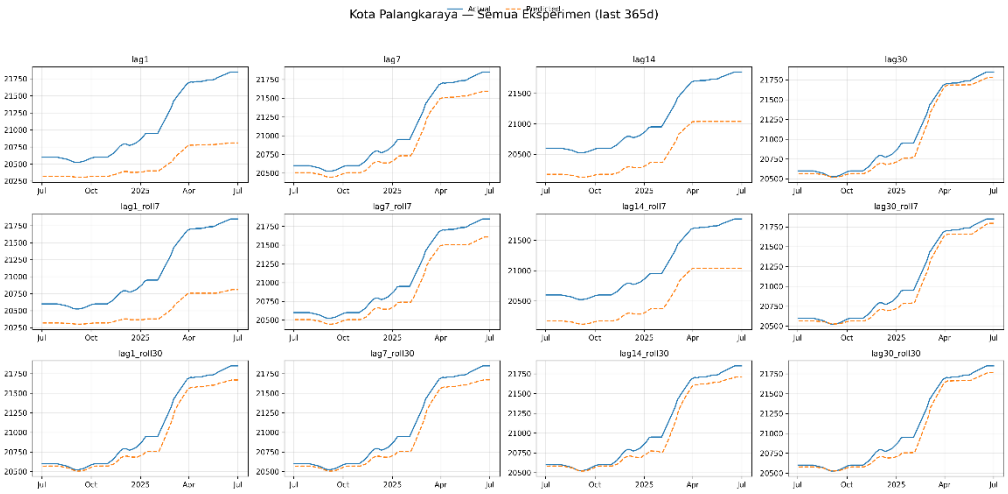

Gambar L12.71 Kota Palangkaraya

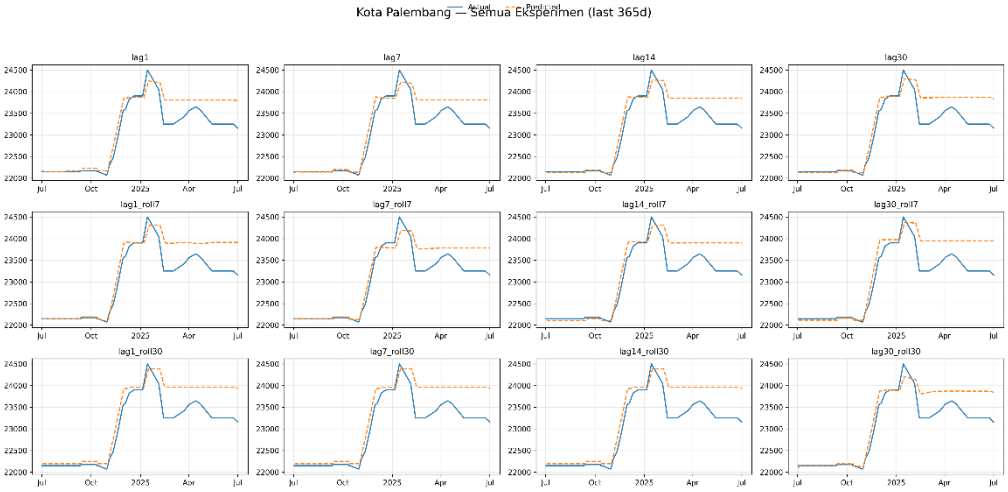

Gambar L12.72 Kota Palembang

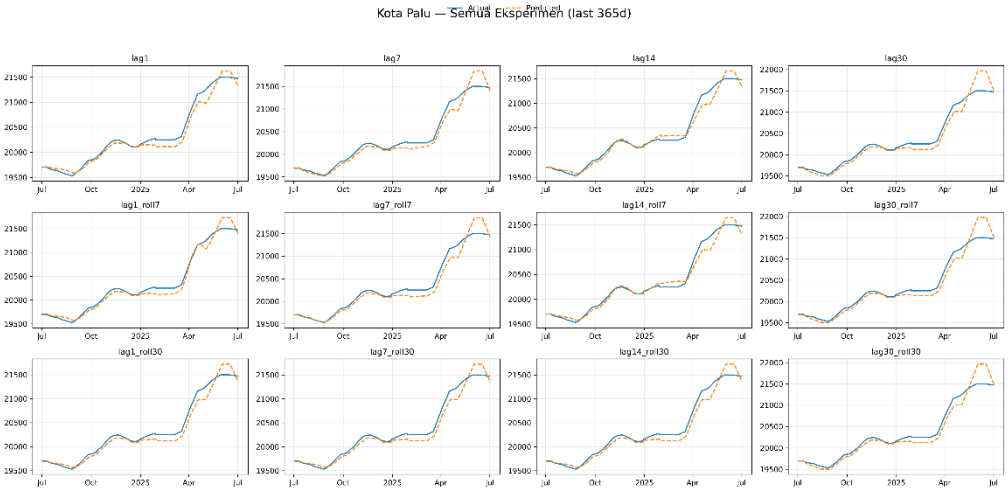

Gambar L12.73 Kota Palu

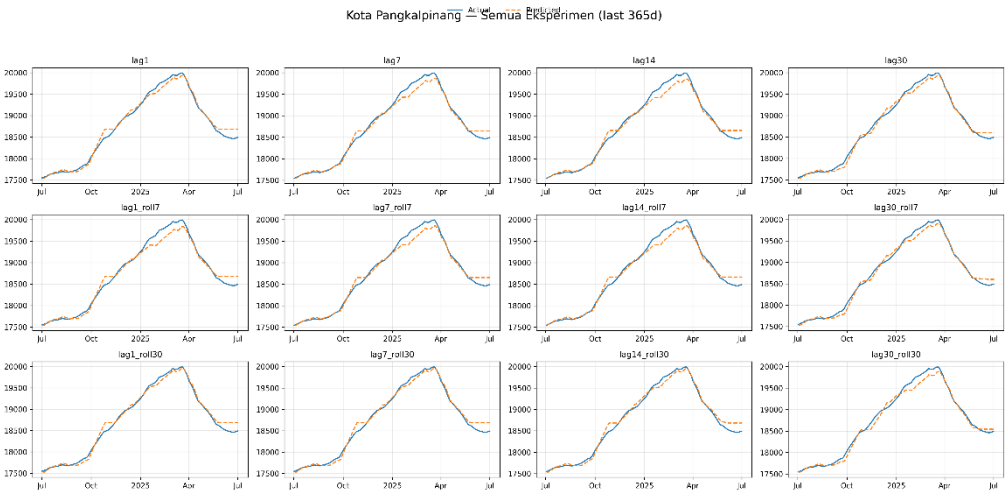

Gambar L12.74 Kota Pangkalpinang

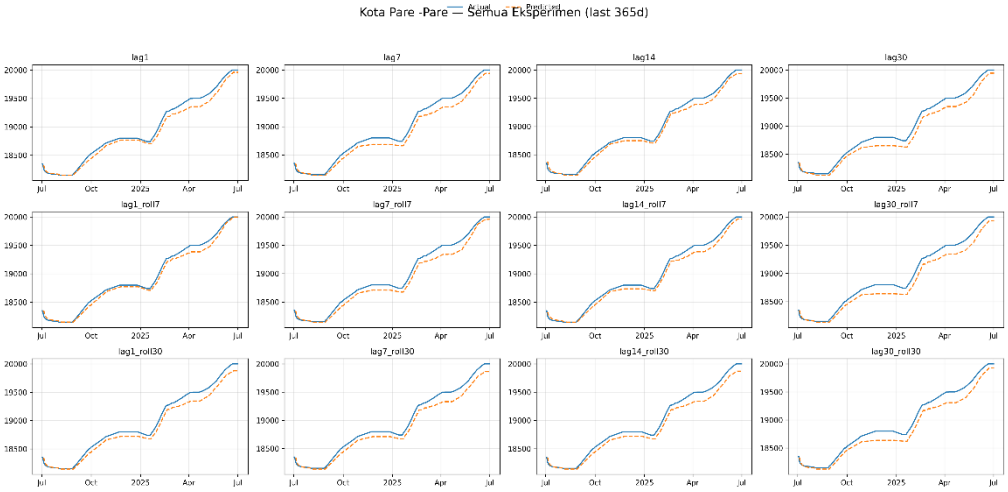

Gambar L12.75 Kota Pare – Pare

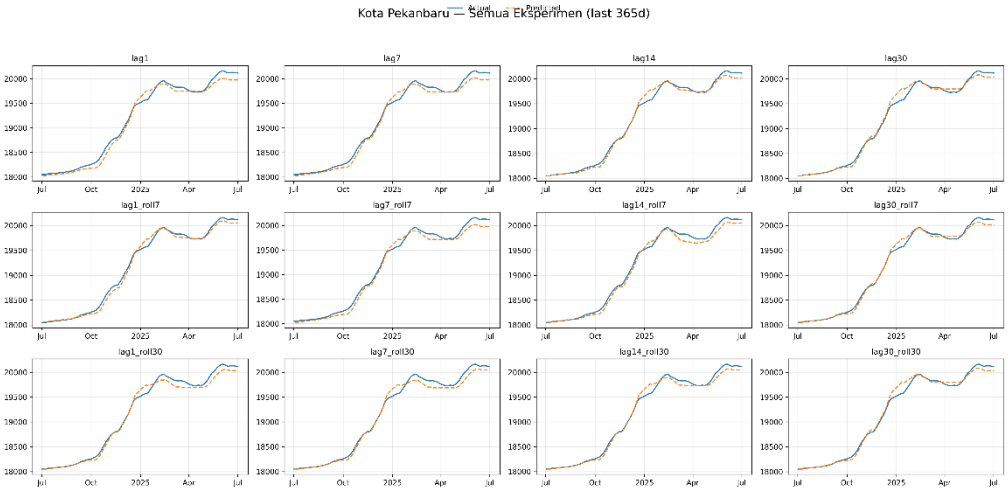

Gambar L12.76 Kota Pekanbaru

Gambar L12.77 Kota Pematang Siantar

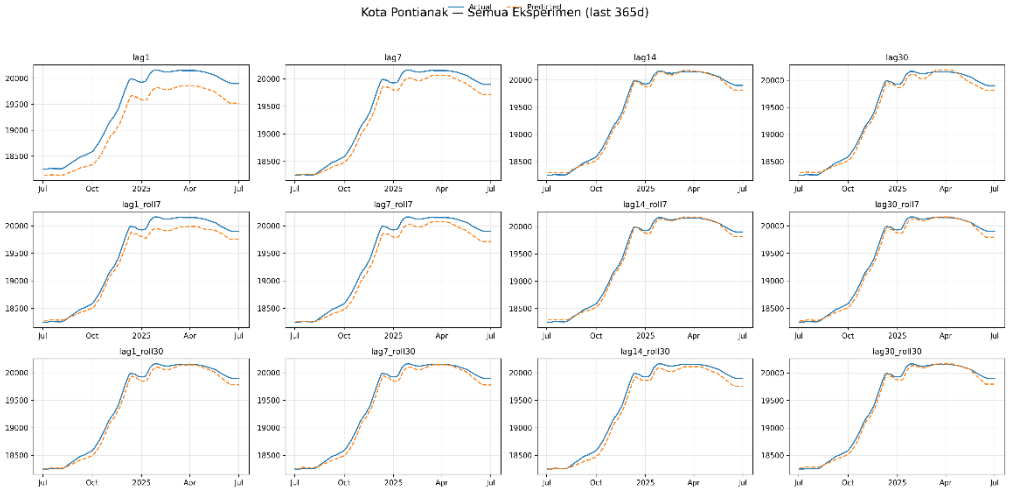

Gambar L12.78 Kota Pontianak

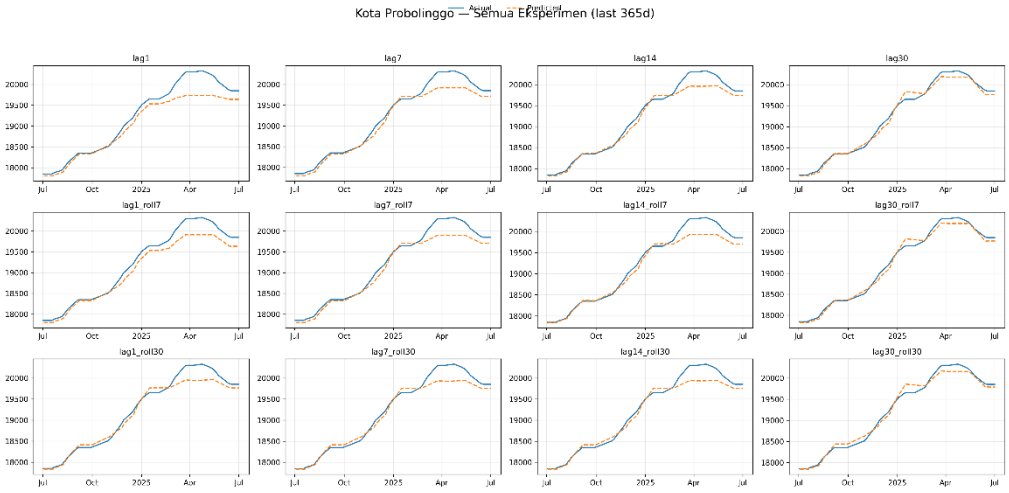

Gambar L12.79 Kota Probolinggo

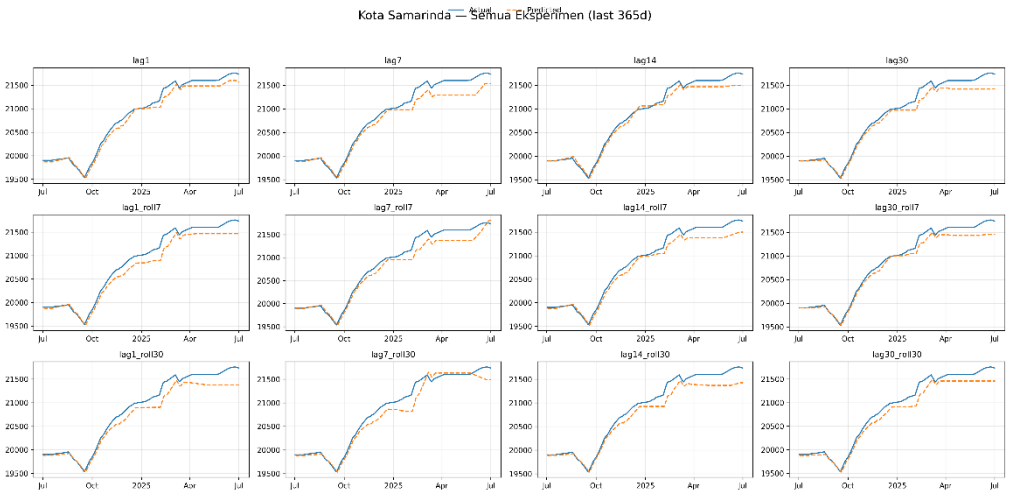

Gambar L12.80 Kota Samarinda

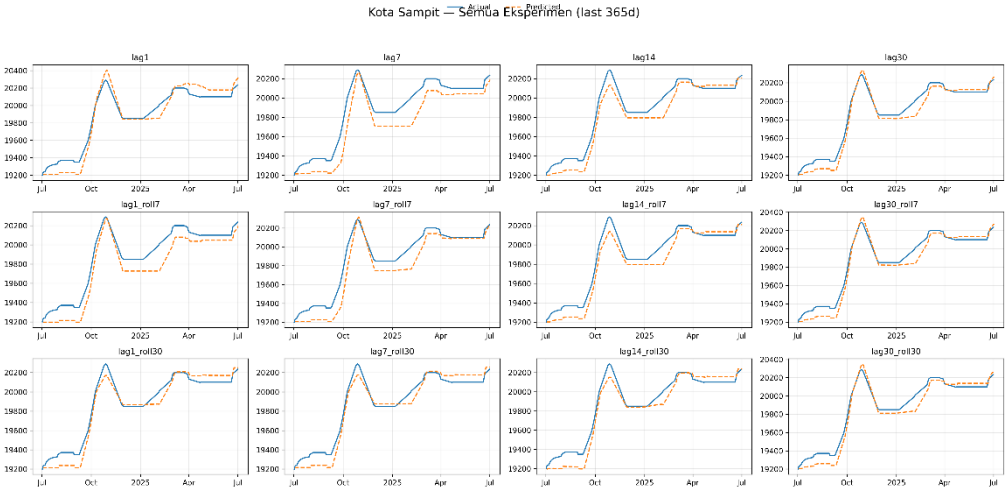

Gambar L12.81 Kota Sampit

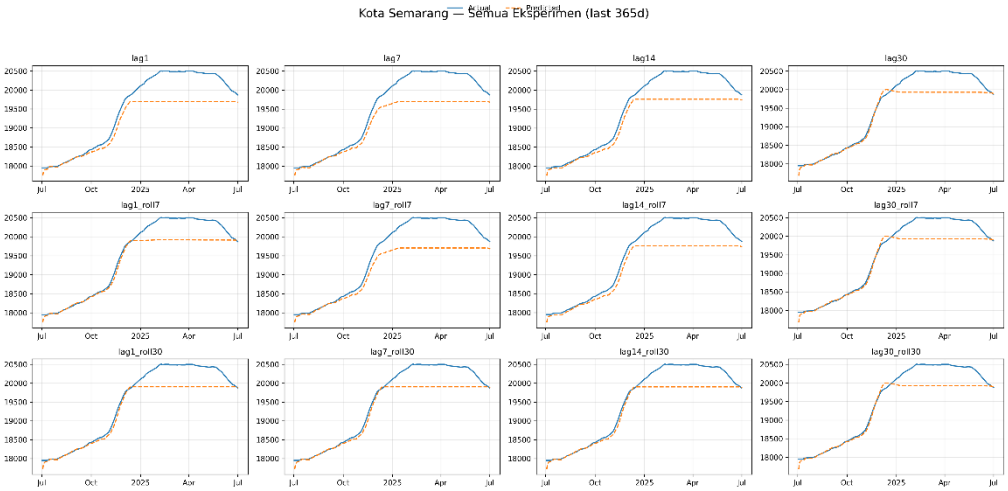

Gambar L12.82 Kota Semarang

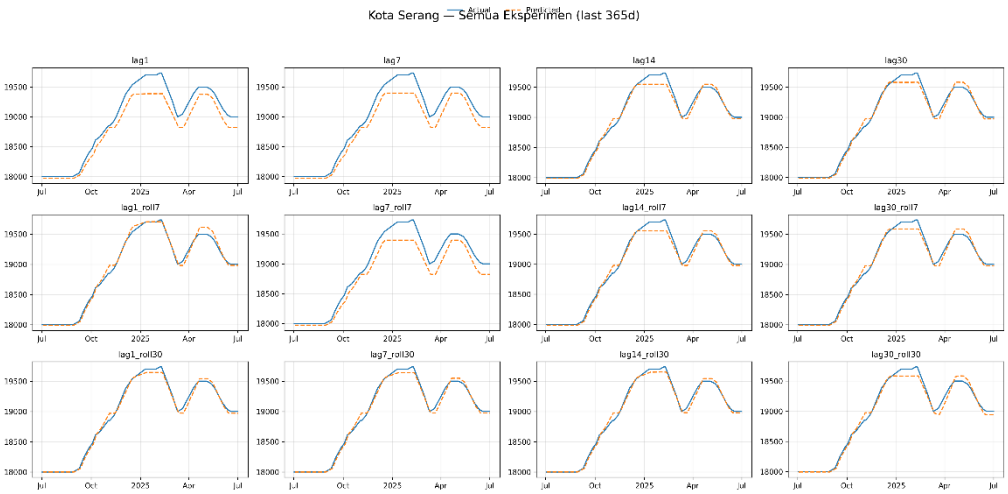

Gambar L12.83 Kota Serang

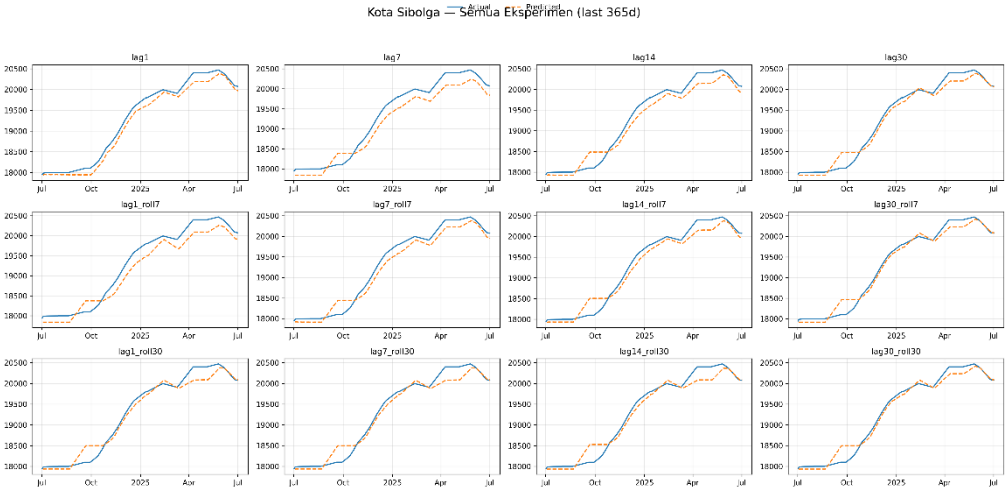

Gambar L12.84 Kota Sibolga

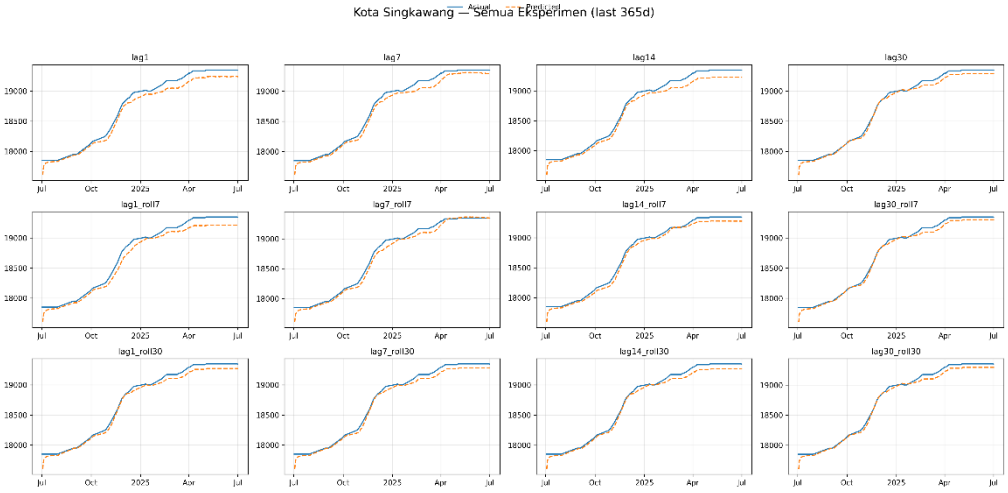

Gambar L12.85 Kota Singkawang

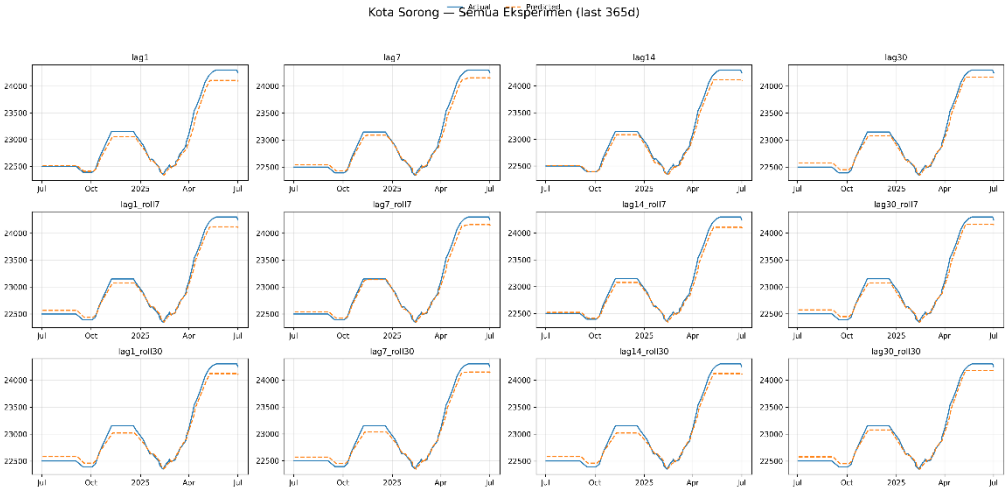

Gambar L12.86 Kota Sorong

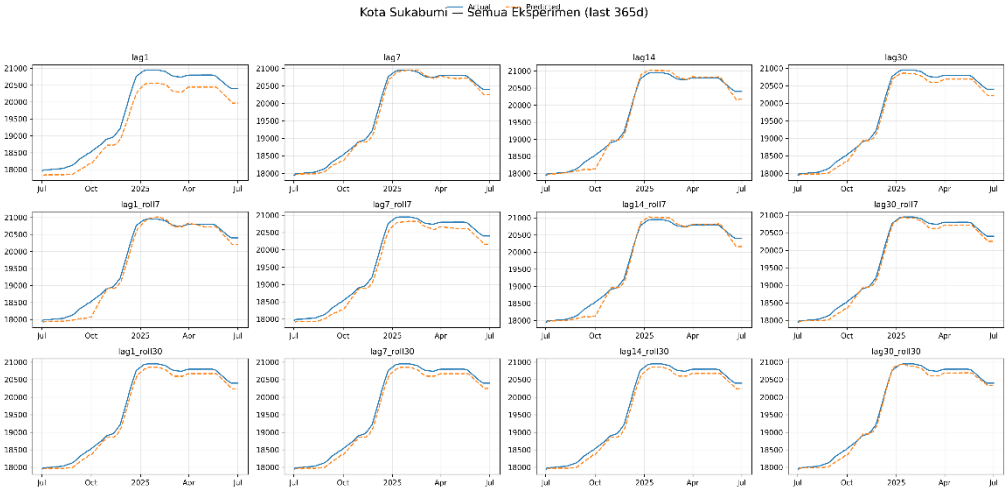

Gambar L12.87 Kota Sukabumi

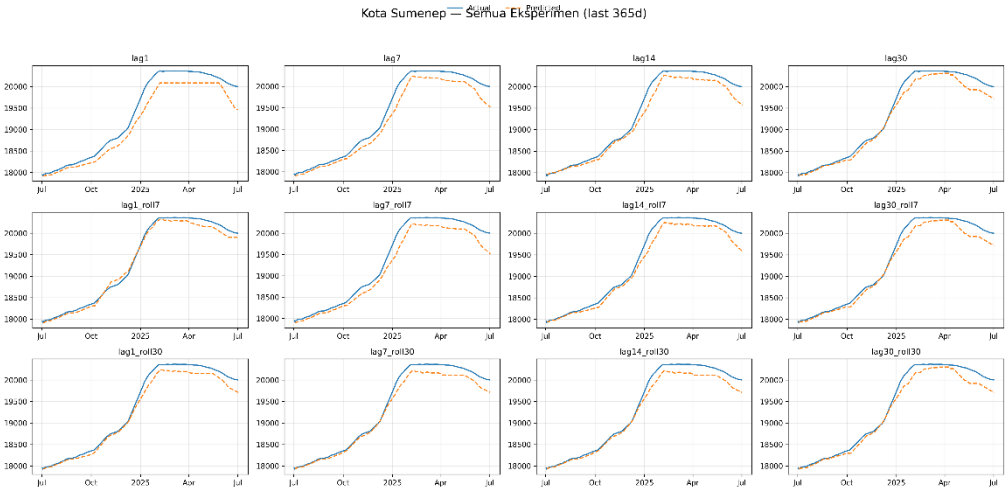

Gambar L12.88 Kota Sumenep

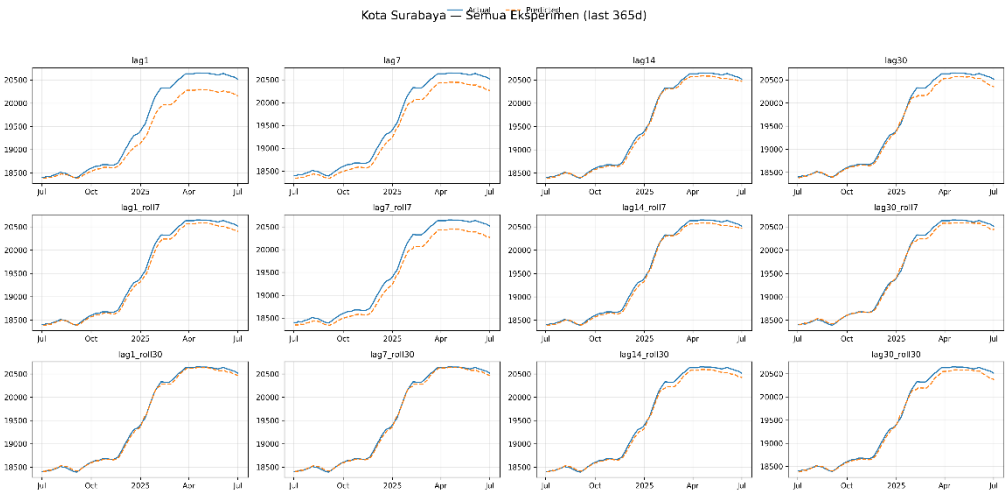

Gambar L12.89 Kota Surabaya

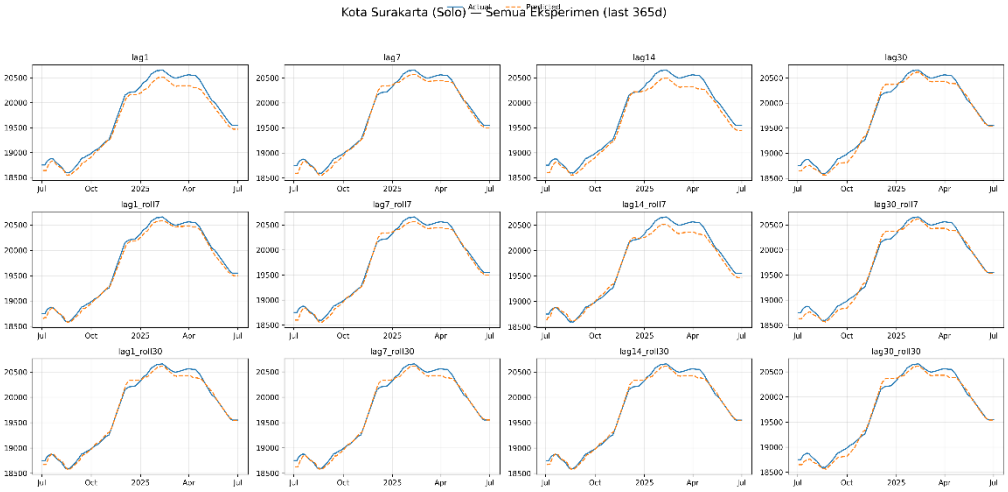

Gambar L12.90 Kota Surakarta (Solo)

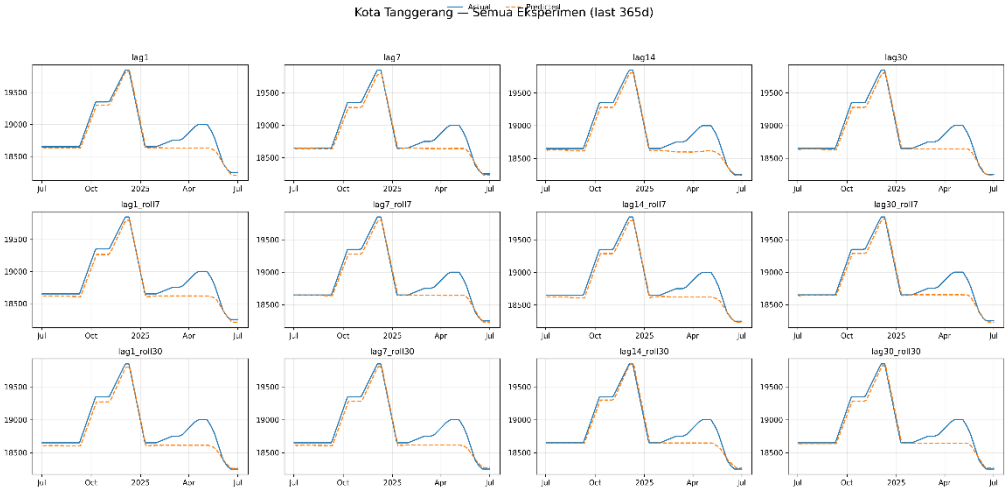

Gambar L12.91 Kota Tanggerang

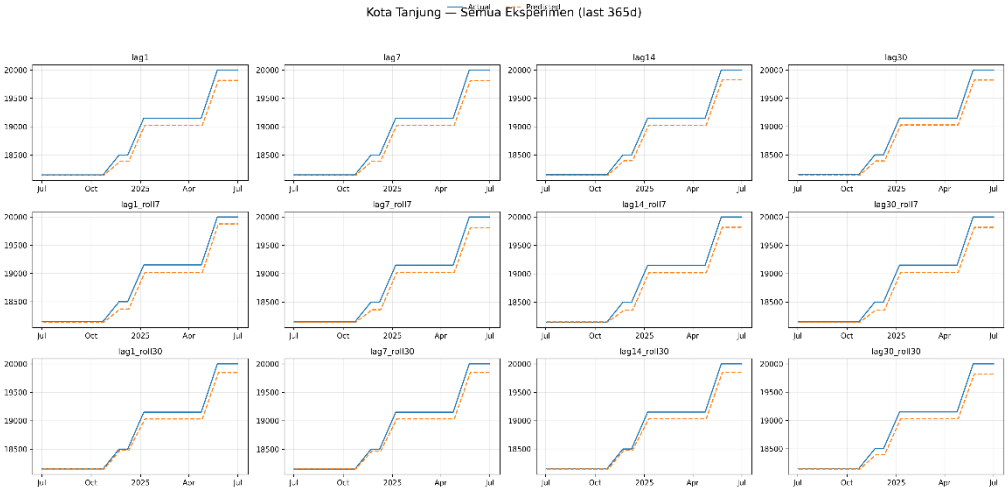

Gambar L12.92 Kota Tanjung

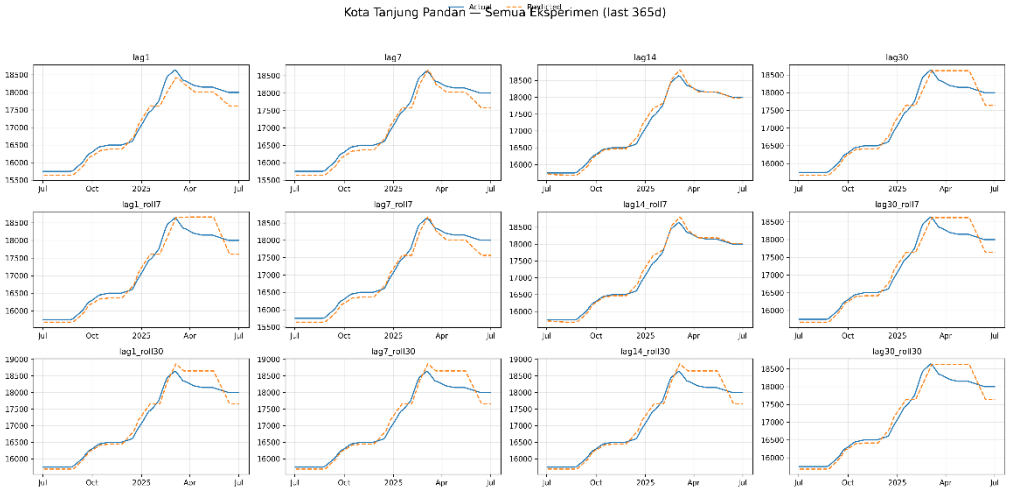

Gambar L12.93 Kota Tanjung Pandan

Gambar L12.94 Kota Tanjung Pinang

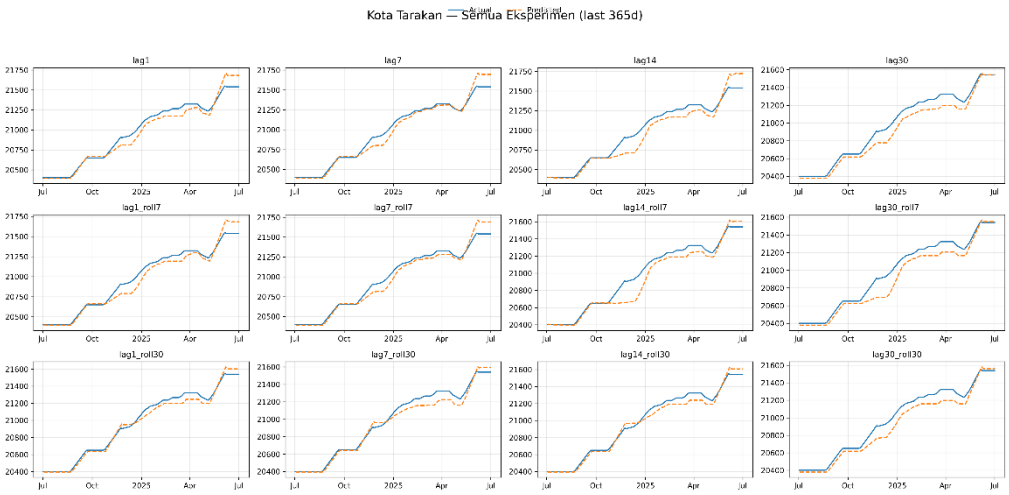

Gambar L12.95 Kota Tarakan

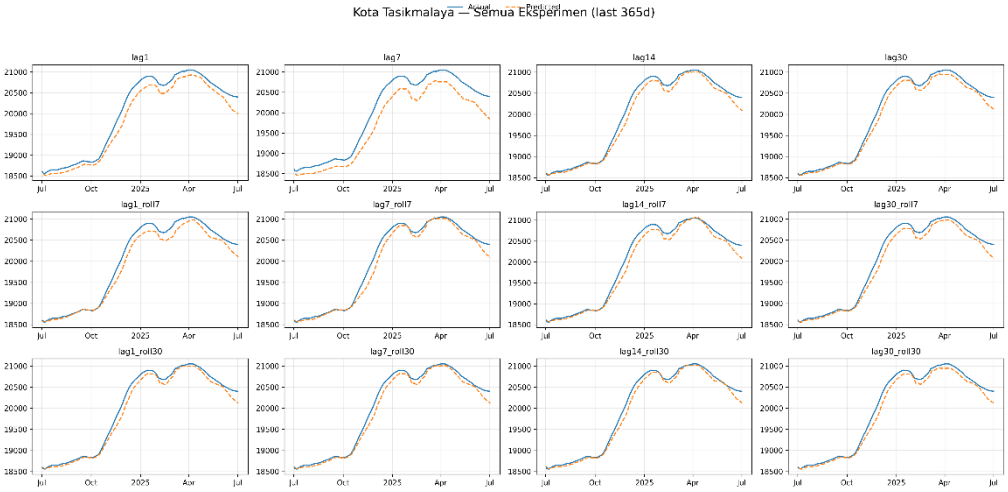

Gambar L12.96 Kotak Tasikmalaya

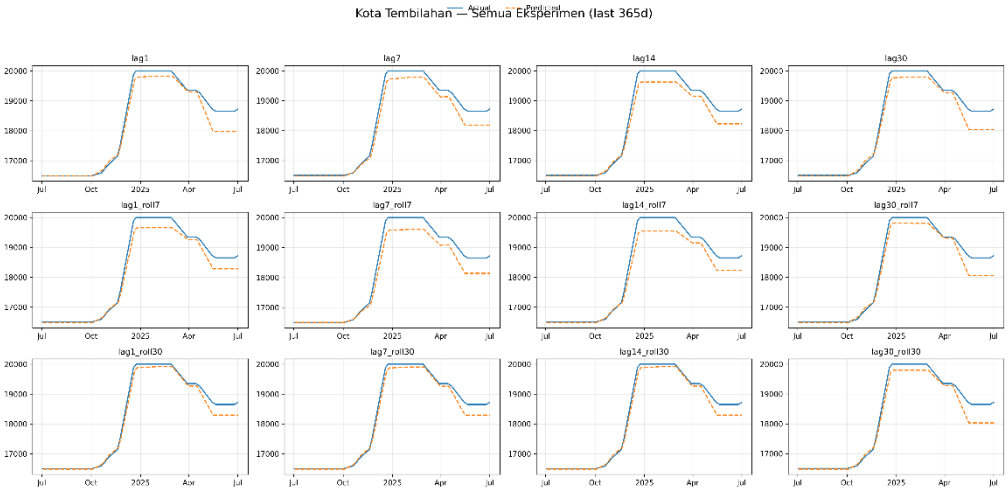

Gambar L12.97 Kota Tembilahan

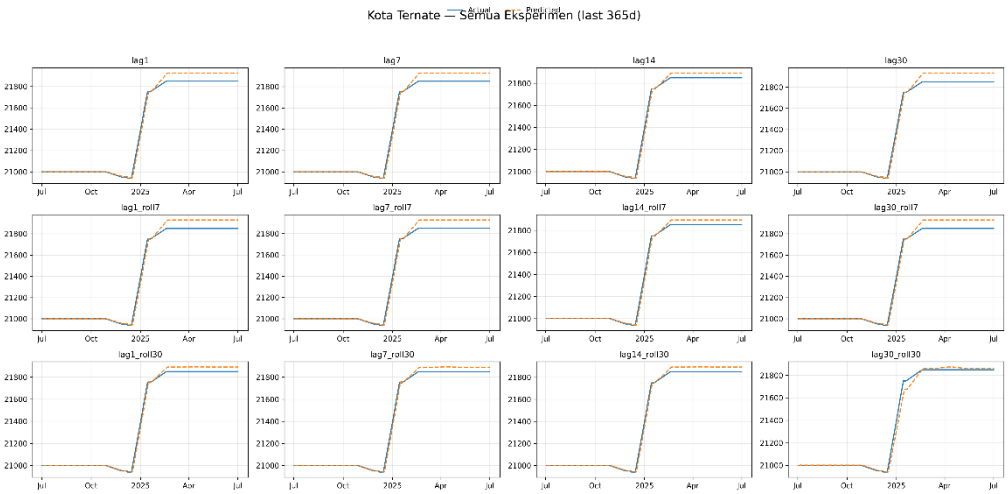

Gambar L12.98 Kota Ternate

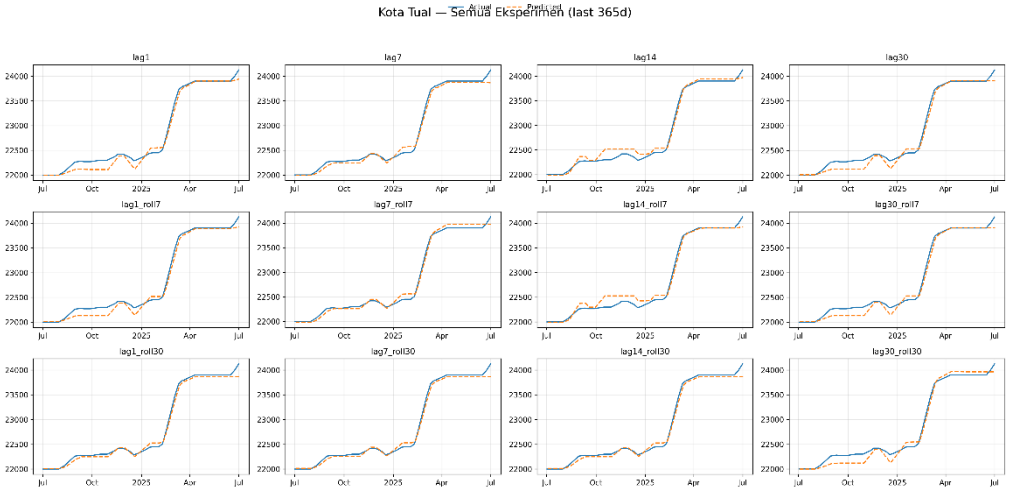

Gambar L12.99 Kota Tual

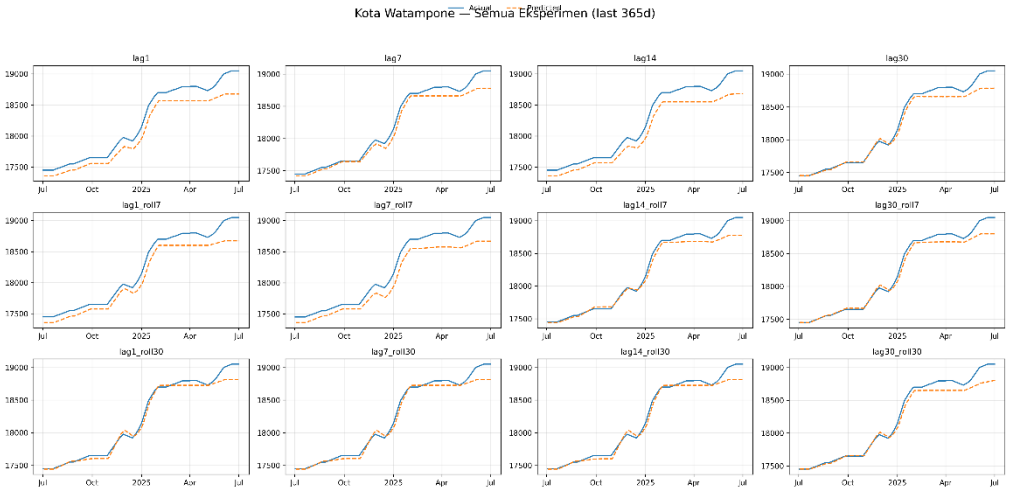

Gambar L12.100 Kota Watampone

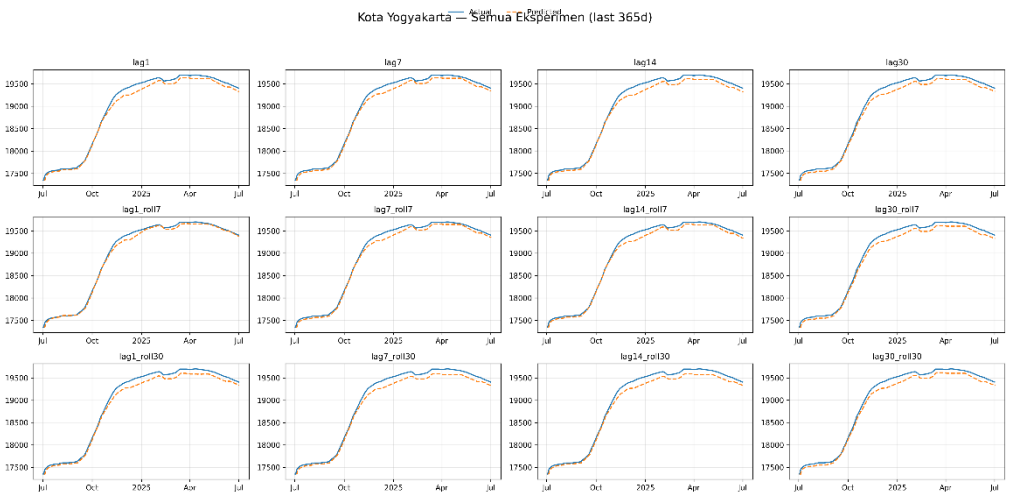

Gambar L12.101 Kota Yogyakarta

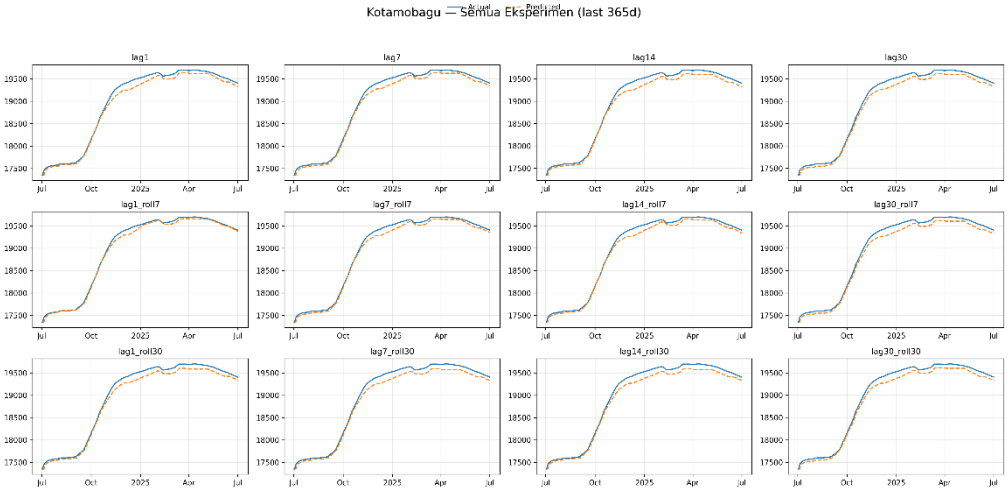

Gambar L12.102 Kotamobagu

LAMPIRAN 13

TABEL BLACK BOX TESTING (INTERNAL)

Tabel L13.1 *Black Box Testing* (Internal)

No	Fitur	Langkah	Input	Output yang diharapkan	Status
1.	Masuk ke halaman beranda	Buka aplikasi di browser, klik telusuri, maka akan terlihat tampilan pertama dari aplikasi	Tidak ada input khusus	Halaman berada ditampilan beranda	Sesuai
2	Lokasi untuk *Quick Prediction*	(Fitur lokasi harus nyala) masuk ke halaman beranda, dan *system* secara otomatis melakukan *tracking* lokasi terdekat dari daftar list *dropdown* kota yang ada	Tidak ada input khusus	Lokasi sesuai dengan harga yang inginn diprediksi	SESUAI
3	*Quick Prediction*	Masuk ke halaman beranda, kemudian memilih *dropdown* kabupaten/kota	Kabupaten/Kota (dropdown)	Sistem menampilkan harga aktual hari terakhir dan juga prediksi untuk hari esok, 7 hari kedepan dan 10 hari kedepan	Sesuai
4.	Peta Persebaran (mode aktual)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun.	Mode = Aktual, pulau = Semua Pulau, tahun = 2020,	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	Sesuai

No	Fitur	Langkah	Input	Output yang diharapkan	Status
5.	Peta Persebaran (mode aktual) – mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun	Mode = Aktual, pulau = Jawa Pulau, tahun = 2021	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	Sesuai
6.	Peta Persebaran (mode predicted)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau,	Mode = Predicted, pulau = Semua Pulau, tahun = 2020, opsional)	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	Sesuai
7.	Peta Persebaran (mode predicted) - mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun	Mode = Predicted, pulau = Jawa Pulau, tahun = 2021,	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	Sesuai
8.	Halaman Tinjauan Tren	Pilih navigasi bagian tinjauan tren		Sistem akan menampilkan halaman tinjauan tren	Sesuai
9.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Kab/Kota 1 = Banyuwangi, Kab/Kota 2 = Bulukomba, Tahun = 2021, bulan = Januari, Minggu ke = 2	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	Sesuai

No	Fitur	Langkah	Input	Output yang diharapkan	Status
10.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Kab/Kota 1 = Banyuwangi, Tahun = 2021, bulan = Januari, Minggu ke = 2	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	Sesuai
11.	Halaman Prediksi	Pilih navigasi bagian prediksi		Sistem akan menampilkan halaman prediksi	Sesuai
12.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	"Bogor"	Sistem menampilkan pilihan dropdown hanya kota bogor	Sesuai
13.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Kab/Kota = Bogor, Tanggal mulai = 1 Juli 2024, dan Tanggal akhir = 1 Juli 2025	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	Sesuai
14.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Kab/Kota = Bogor, Tanggal mulai = 2 Juli 2025, dan Tanggal akhir = 10 Juli 2025	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	Sesuai
15.	Prediksi (tidak mengisi tanggal mulai dan akhir)	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Kab/Kota = Bogor, tidak input tanggal mulai dan akhir	Sistem akan menampilkan tampilan tulisan untuk mengisi tanggal mulai dan akhir	Sesuai

No	Fitur	Langkah	Input	Output yang diharapkan	Status
16.	Download CSV template upload data	Pilih navigasi bagian upload kemudian klik button CSV	CSV button	Sistem akan melakukan pengunduhan pada file template dengan format csv	Sesuai
17.	Download XLSX template upload data	Pilih navigasi bagian upload kemudian klik button Excel	Excel button	Sistem akan melakukan pengunduhan pada file template dengan format .xlsx	Sesuai
18.	Masuk ke halaman unggah file	Pilih navigasi bagian Unggah File		Sistem akan menampilkan halaman Unggah File	Sesuai
19.	Unggah file	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis	Template.csv	Sistem akan melakukan training dan pembuatan model serta menampilkan analisa grafik dan prediksi harga, serta akan muncul button download	Sesuai
20.	Download hasil analisa	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis, kemudian muncul button download hasil analisa	Download button	Sistem akan melakukan pengunduhan file pdf hasil analisa dan prediksi harga	Sesuai
21.	Halaman tentang	Pilih navigasi bagian tentang		Sistem menampilkan halaman tentang	Sesuai

LAMPIRAN 14

PENGUJIAN (UAT) DENGAN TARGET MASYARAKAT UMUM

FORM UAT SIGN-OFF

Dengan ini kami menyatakan bahwa hasil pengujian *User Acceptance Testing* (UAT) terhadap system Program Prediksi Harga Minyak di Pasar Tradisional Indonesia dengan Menggunakan Metode Algoritma *Gradient Boosting* telah dilakukan dan hasilnya sebagai berikut:

Status:

[✓] Diterima / [ ] Ditolak

Tanggal Uji : 21 Oktober

Nama Penguji (User) : Miftah

Keterangan Tambahan :

Aplikasi bermanfaat untuk memprediksi minyak.

Tanda Tangan:

Gambar L14.1 *Form Uat Sign-Off*

Mittah.

Dokumen User Acceptance System (UAT)

Pengujian Program Prediksi Harga Minyak Goreng dengan Metode Algoritma *Gradient Boosting* di Pasar Tradisional Indonesia

No	Fitur	Langkah	Hasil yang diharapkan	Status
1.	Masuk ke halaman beranda	Buka aplikasi di browser, klik telusuri, maka akan terlihat tampilan pertama dari aplikasi	Halaman berada ditampilan beranda	
S	*Quick Prediction*	Masuk ke halaman beranda, kemudian memilih *dropdown* kabupaten/kota	Sistem menampilkan harga aktual hari terakhir dan juga prediksi untuk hari esok, 7 hari kedepan dan 10 hari kedepan	
3.	Peta Persebaran (mode aktual)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	
4.	Peta Persebaran (mode aktual) – mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	
4.	Peta Persebaran (mode predicted)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	
5.	Peta Persebaran (mode predicted) - mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil	

			(q1,q2,q3) dan tabel detail harga terprediksi	
6.	Halaman Tinjauan Tren	Pilih navigasi bagian tinjauan tren	Sistem akan menampilkan halaman tinjauan tren	
7.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	
8.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	
9.	Halaman Prediksi	Pilih navigasi bagian prediksi	Sistem akan menampilkan halaman prediksi	
10.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	Sistem menampilkan pilihan dropdown hanya kota bogor	
11.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	
12.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	
13.	Prediksi (tidak mengisi tanggal	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range	Sistem akan menampilkan tampilan tulisan untuk	

	mulai dan akhir)	waktu (tanggal mulai, dan tanggal akhir)	mengisi tanggal mulai dan akhir	
14	Download CSV template upload data	Pilih navigasi bagian upload kemudian klik button CSV	Sistem akan melakukan pengunduhan pada file template dengan format csv	
15.	Download XLSX template upload data	Pilih navigasi bagian upload kemudian klik button Excel	Sistem akan melakukan pengunduhan pada file template dengan format .xlsx	
16	Masuk ke halaman unggah file	Pilih navigasi bagian Unggah File	Sistem akan menampilkan halaman Unggah File	
17.	Unggah file	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis	Sistem akan melakukan training dan pembuatan model serta menampilkan analisa grafik dan prediksi harga, serta akan muncul button download	
18.	Download hasil analisa	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis, kemudian muncul button download hasil analisa	Sistem akan melakukan pengunduhan file pdf hasil analisa dan prediksi harga	
19.	Halaman tentang	Pilih navigasi bagian tentang	Sistem menampilkan halaman tentang	

			(q1,q2,q3) dan tabel detail harga terprediksi	
6.	Halaman Tinjauan Tren	Pilih navigasi bagian tinjauan tren	Sistem akan menampilkan halaman tinjauan tren	
7.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	
8.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	
9.	Halaman Prediksi	Pilih navigasi bagian prediksi	Sistem akan menampilkan halaman prediksi	
10.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	Sistem menampilkan pilihan dropdown hanya kota bogor	
11.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	
12.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	
13.	Prediksi (tidak mengisi tanggal	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range	Sistem akan menampilkan tampilan tulisan untuk	

FORM UAT SIGN-OFF

Dengan ini kami menyatakan bahwa hasil pengujian *User Acceptance Testing* (UAT) terhadap system Program Prediksi Harga Minyak di Pasar Tradisional Indonesia dengan Menggunakan Metode Algoritma *Gradient Boosting* telah dilakukan dan hasilnya sebagai berikut:

Status:

[✓] Diterima / [ ] Ditolak

Tanggal Uji : 23 October 2025

Nama Penguji (User) : Stephanie

Keterangan Tambahan :

cukup baik, Tidak membingungkan user flowny dan tampilan cukup rapi.

Tanda Tangan:

Gambar L14.2 *Form Uat Sign-Off*

Stephanie

Dokumen User Acceptance System (UAT)

Pengujian Program Prediksi Harga Minyak Goreng dengan Metode Algoritma *Gradient Boosting* di Pasar Tradisional Indonesia

No	Fitur	Langkah	Hasil yang diharapkan	Status
1.	Masuk ke halaman beranda	Buka aplikasi di browser, klik telusuri, maka akan terlihat tampilan pertama dari aplikasi	Halaman berada ditampilan beranda	
S	*Quick Prediction*	Masuk ke halaman beranda, kemudian memilih *dropdown* kabupaten/kota	Sistem menampilkan harga aktual hari terakhir dan juga prediksi untuk hari esok, 7 hari kedepan dan 10 hari kedepan	
3.	Peta Persebaran (mode aktual)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	
4.	Peta Persebaran (mode aktual) – mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	
4.	Peta Persebaran (mode predicted)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	
5.	Peta Persebaran (mode predicted) - mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil	

			(q1,q2,q3) dan tabel detail harga terprediksi	
6.	Halaman Tinjauan Tren	PIlih navigasi bagian tinjauan tren	Sistem akan menampilkan halaman tinjauan tren	
7.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	
8.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	
9.	Halaman Prediksi	Pilih navigasi bagian prediksi	Sistem akan menampilkan halaman prediksi	
10.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	Sistem menampilkan pilihan dropdown hanya kota bogor	
11.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	
12.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	
13.	Prediksi (tidak mengisi tanggal	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range	Sistem akan menampilkan tampilan tulisan untuk	

	mulai dan akhir)	waktu (tanggal mulai, dan tanggal akhir)	mengisi tanggal mulai dan akhir	
14	Download CSV template upload data	Pilih navigasi bagian upload kemudian klik button CSV	Sistem akan melakukan pengunduhan pada file template dengan format csv	
15.	Download XLSX template upload data	Pilih navigasi bagian upload kemudian klik button Excel	Sistem akan melakukan pengunduhan pada file template dengan format .xlsx	
16	Masuk ke halaman unggah file	Pilih navigasi bagian Unggah File	Sistem akan menampilkan halaman Unggah File	
17.	Unggah file	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis	Sistem akan melakukan training dan pembuatan model serta menampilkan analisa grafik dan prediksi harga, serta akan muncul button download	
18.	Download hasil analisa	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis, kemudian muncul button download hasil analisa	Sistem akan melakukan pengunduhan file pdf hasil analisa dan prediksi harga	
19.	Halaman tentang	Pilih navigasi bagian tentang	Sistem menampilkan halaman tentang	

RISKA

FORM UAT SIGN-OFF

Dengan ini kami menyatakan bahwa hasil pengujian *User Acceptance Testing* (UAT) terhadap system Program Prediksi Harga Minyak di Pasar Tradisional Indonesia dengan Menggunakan Metode Algoritma *Gradient Boosting* telah dilakukan dan hasilnya sebagai berikut:

Status:

[✓] Diterima / [ ] Ditolak

Tanggal Uji : 21 oktober 2025

Nama Penguji (User) : RISKA

Keterangan Tambahan :

Tampilan cukup menarik + tidak ada error serta sesuai dgn ~~pertanyaan~~ pernyataan pengujian.

Tanda Tangan: _____

Scanned with CamScanner

Gambar L14.3 *Form Uat Sign-Off*

RISKA

Dokumen User Acceptance System (UAT)

Pengujian Program Prediksi Harga Minyak Goreng dengan Metode Algoritma *Gradient Boosting* di Pasar Tradisional Indonesia

No	Fitur	Langkah	Hasil yang diharapkan	Status
1.	Masuk ke halaman beranda	Buka aplikasi di browser, klik telusuri, maka akan terlihat tampilan pertama dari aplikasi	Halaman berada ditampilan beranda	✓
S	*Quick Prediction*	Masuk ke halaman beranda, kemudian memilih *dropdown* kabupaten/kota	Sistem menampilkan harga aktual hari terakhir dan juga prediksi untuk hari esok, 7 hari kedepan dan 10 hari kedepan	✓
3.	Peta Persebaran (mode aktual)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode aktual) – mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode predicted)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	✓
5.	Peta Persebaran (mode predicted) - mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil	✓

Scanned with CamScanner

			(q1,q2,q3) dan tabel detail harga terprediksi	
6.	Halaman Tinjauan Tren	Pilih navigasi bagian tinjauan tren	Sistem akan menampilkan halaman tinjauan tren	✓
7.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	✓
8.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	✓
9.	Halaman Prediksi	Pilih navigasi bagian prediksi	Sistem akan menampilkan halaman prediksi	✓
10.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	Sistem menampilkan pilihan dropdown hanya kota bogor	✓
11.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	✓
12.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	✓
13.	Prediksi (tidak mengisi tanggal	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range	Sistem akan menampilkan tampilan tulisan untuk	✓

Scanned with CamScanner

	mulai dan akhir)	waktu (tanggal mulai, dan tanggal akhir)	mengisi tanggal mulai dan akhir	
14	Download CSV template upload data	Pilih navigasi bagian upload kemudian klik button CSV	Sistem akan melakukan pengunduhan pada file template dengan format csv	✓
15.	Download XLSX template upload data	Pilih navigasi bagian upload kemudian klik button Excel	Sistem akan melakukan pengunduhan pada file template dengan format .xlsx	✓
16	Masuk ke halaman unggah file	Pilih navigasi bagian Unggah File	Sistem akan menampilkan halaman Unggah File	✓
17.	Unggah file	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis	Sistem akan melakukan training dan pembuatan model serta menampilkan analisa grafik dan prediksi harga, serta akan muncul button download	✓
18.	Download hasil analisa	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis, kemudian muncul button download hasil analisa	Sistem akan melakukan pengunduhan file pdf hasil analisa dan prediksi harga	✓
19.	Halaman tentang	Pilih navigasi bagian tentang	Sistem menampilkan halaman tentang	✓

Scanned with CamScanner

FORM UAT SIGN-OFF

Dengan ini kami menyatakan bahwa hasil pengujian *User Acceptance Testing* (UAT) terhadap system Program Prediksi Harga Minyak di Pasar Tradisional Indonesia dengan Menggunakan Metode Algoritma *Gradient Boosting* telah dilakukan dan hasilnya sebagai berikut:

Status:

[✓] Diterima / [ ] Ditolak

Tanggal Uji : 20 - 10 - 2025

Nama Penguji (User) : ria

Keterangan Tambahan :

sudah berfungsi dgn baik

Tanda Tangan: ria

Scanned with CamScanner

Gambar L14.4 *Form Uat Sign-Off*

212

Dokumen User Acceptance System (UAT)

Pengujian Program Prediksi Harga Minyak Goreng dengan Metode Algoritma *Gradient Boosting* di Pasar Tradisional Indonesia

No	Fitur	Langkah	Hasil yang diharapkan	Status
1.	Masuk ke halaman beranda	Buka aplikasi di browser, klik telusuri, maka akan terlihat tampilan pertama dari aplikasi	Halaman berada ditampilan beranda	✓
S	*Quick Prediction*	Masuk ke halaman beranda, kemudian memilih *dropdown* kabupaten/kota	Sistem menampilkan harga aktual hari terakhir dan juga prediksi untuk hari esok, 7 hari kedepan dan 10 hari kedepan	✓
3.	Peta Persebaran (mode aktual)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode aktual) – mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode predicted)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	✓
5.	Peta Persebaran (mode predicted) - mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil	✓

Scanned with CamScanner

			(q1,q2,q3) dan tabel detail harga terprediksi	✓
6.	Halaman Tinjauan Tren	Pilih navigasi bagian tinjauan tren	Sistem akan menampilkan halaman tinjauan tren	✓
7.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	✓
8.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	✓
9.	Halaman Prediksi	Pilih navigasi bagian prediksi	Sistem akan menampilkan halaman prediksi	✓
10.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	Sistem menampilkan pilihan dropdown hanya kota bogor	✓
11.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	✓
12.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	✓
13.	Prediksi (tidak mengisi tanggal	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range	Sistem akan menampilkan tampilan tulisan untuk	

Scanned with CamScanner

	mulai dan akhir)	waktu (tanggal mulai, dan tanggal akhir)	mengisi tanggal mulai dan akhir	✓
14	Download CSV template upload data	Pilih navigasi bagian upload kemudian klik button CSV	Sistem akan melakukan pengunduhan pada file template dengan format csv	✓
15.	Download XLSX template upload data	Pilih navigasi bagian upload kemudian klik button Excel	Sistem akan melakukan pengunduhan pada file template dengan format .xlsx	✓
16	Masuk ke halaman unggah file	Pilih navigasi bagian Unggah File	Sistem akan menampilkan halaman Unggah File	✓
17.	Unggah file	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis	Sistem akan melakukan training dan pembuatan model serta menampilkan analisa grafik dan prediksi harga, serta akan muncul button download	✓
18.	Download hasil analisa	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis, kemudian muncul button download hasil analisa	Sistem akan melakukan pengunduhan file pdf hasil analisa dan prediksi harga	✓
19.	Halaman tentang	Pilih navigasi bagian tentang	Sistem menampilkan halaman tentang	✓

Scanned with CamScanner

FORM UAT SIGN-OFF

Dengan ini kami menyatakan bahwa hasil pengujian *User Acceptance Testing* (UAT) terhadap system Program Prediksi Harga Minyak di Pasar Tradisional Indonesia dengan Menggunakan Metode Algoritma *Gradient Boosting* telah dilakukan dan hasilnya sebagai berikut:

Status:

[√ Diterima / [ ] Ditolak

Tanggal Uji : 23 Oktober 2025

Nama Penguji (User) : Rachelle

Keterangan Tambahan :

Website sangat bermanfaat, tampilan menarik, dan hasil cukup detail dan terperinci.

Tanda Tangan: _____

Scanned with CamScanner

Gambar L14.5 *Form Uat Sign-Off*

Dokumen User Acceptance System (UAT)

Pengujian Program Prediksi Harga Minyak Goreng dengan Metode Algoritma *Gradient Boosting* di Pasar Tradisional Indonesia

No	Fitur	Langkah	Hasil yang diharapkan	Status
1.	Masuk ke halaman beranda	Buka aplikasi di browser, klik telusuri, maka akan terlihat tampilan pertama dari aplikasi	Halaman berada ditampilan beranda	V
S	*Quick Prediction*	Masuk ke halaman beranda, kemudian memilih *dropdown* kabupaten/kota	Sistem menampilkan harga aktual hari terakhir dan juga prediksi untuk hari esok, 7 hari kedepan dan 10 hari kedepan	V
3.	Peta Persebaran (mode aktual)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	V
4.	Peta Persebaran (mode aktual) – mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	V
4.	Peta Persebaran (mode predicted)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	V
5.	Peta Persebaran (mode predicted) - mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil	V

Scanned with CamScanner

			(q1,q2,q3) dan tabel detail harga terprediksi	
6.	Halaman Tinjauan Tren	Pilih navigasi bagian tinjauan tren	Sistem akan menampilkan halaman tinjauan tren	✓
7.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	✓
8.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	✓
9.	Halaman Prediksi	Pilih navigasi bagian prediksi	Sistem akan menampilkan halaman prediksi	✓
10.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	Sistem menampilkan pilihan dropdown hanya kota bogor	✓
11.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	✓
12.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	✓
13.	Prediksi (tidak mengisi tanggal	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range	Sistem akan menampilkan tampilan tulisan untuk	✓

Scanned with CamScanner

	mulai dan akhir)	waktu (tanggal mulai, dan tanggal akhir)	mengisi tanggal mulai dan akhir	
14	Download CSV template upload data	Pilih navigasi bagian upload kemudian klik button CSV	Sistem akan melakukan pengunduhan pada file template dengan format csv	✓
15.	Download XLSX template upload data	Pilih navigasi bagian upload kemudian klik button Excel	Sistem akan melakukan pengunduhan pada file template dengan format .xlsx	✓
16	Masuk ke halaman unggah file	Pilih navigasi bagian Unggah File	Sistem akan menampilkan halaman Unggah File	✓
17.	Unggah file	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis	Sistem akan melakukan training dan pembuatan model serta menampilkan analisa grafik dan prediksi harga, serta akan muncul button download	✓
18.	Download hasil analisa	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis, kemudian muncul button download hasil analisa	Sistem akan melakukan pengunduhan file pdf hasil analisa dan prediksi harga	✓
19.	Halaman tentang	Pilih navigasi bagian tentang	Sistem menampilkan halaman tentang	✓

Scanned with CamScanner

FORM UAT SIGN-OFF

Dengan ini kami menyatakan bahwa hasil pengujian *User Acceptance Testing* (UAT) terhadap system Program Prediksi Harga Minyak di Pasar Tradisional Indonesia dengan Menggunakan Metode Algoritma *Gradient Boosting* telah dilakukan dan hasilnya sebagai berikut:

Status:

[V] Diterima / [ ] Ditolak

Tanggal Uji : 23 Oktober 2025

Nama Penguji (User) : Najla Syifa

Keterangan Tambahan :

Webnya bermanfaat, tampilan menarik namun kurang rapih

Tanda Tangan:

Scanned with CamScanner

Gambar L14.6 *Form Uat Sign-Off*

Najla Syifa

Dokumen User Acceptance System (UAT)

Pengujian Program Prediksi Harga Minyak Goreng dengan Metode Algoritma *Gradient Boosting* di Pasar Tradisional Indonesia

No	Fitur	Langkah	Hasil yang diharapkan	Status
1.	Masuk ke halaman beranda	Buka aplikasi di browser, klik telusuri, maka akan terlihat tampilan pertama dari aplikasi	Halaman berada ditampilan beranda	✓
S	*Quick Prediction*	Masuk ke halaman beranda, kemudian memilih *dropdown* kabupaten/kota	Sistem menampilkan harga aktual hari terakhir dan juga prediksi untuk hari esok, 7 hari kedepan dan 10 hari kedepan	✓
3.	Peta Persebaran (mode aktual)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode aktual) – mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode predicted)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	✓
5.	Peta Persebaran (mode predicted) - mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil	✓

Scanned with CamScanner

			(q1,q2,q3) dan tabel detail harga terprediksi	
6.	Halaman Tinjauan Tren	Pilih navigasi bagian tinjauan tren	Sistem akan menampilkan halaman tinjauan tren	✓
7.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	✓
8.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	✓
9.	Halaman Prediksi	Pilih navigasi bagian prediksi	Sistem akan menampilkan halaman prediksi	✓
10.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	Sistem menampilkan pilihan dropdown hanya kota bogor	✓
11.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	✓
12.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	✓
13.	Prediksi (tidak mengisi tanggal	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range	Sistem akan menampilkan tampilan tulisan untuk	✓

Scanned with CamScanner

	mulai dan akhir)	waktu (tanggal mulai, dan tanggal akhir)	mengisi tanggal mulai dan akhir	
14	Download CSV template upload data	Pilih navigasi bagian upload kemudian klik button CSV	Sistem akan melakukan pengunduhan pada file template dengan format csv	✓
15.	Download XLSX template upload data	Pilih navigasi bagian upload kemudian klik button Excel	Sistem akan melakukan pengunduhan pada file template dengan format .xlsx	✓
16	Masuk ke halaman unggah file	Pilih navigasi bagian Unggah File	Sistem akan menampilkan halaman Unggah File	✓
17.	Unggah file	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis	Sistem akan melakukan training dan pembuatan model serta menampilkan analisa grafik dan prediksi harga, serta akan muncul button download	✓
18.	Download hasil analisa	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis, kemudian muncul button download hasil analisa	Sistem akan melakukan pengunduhan file pdf hasil analisa dan prediksi harga	✓
19.	Halaman tentang	Pilih navigasi bagian tentang	Sistem menampilkan halaman tentang	✓

Scanned with CamScanner

FORM UAT SIGN-OFF

Dengan ini kami menyatakan bahwa hasil pengujian *User Acceptance Testing* (UAT) terhadap system Program Prediksi Harga Minyak di Pasar Tradisional Indonesia dengan Menggunakan Metode Algoritma *Gradient Boosting* telah dilakukan dan hasilnya sebagai berikut:

Status:

[✓] Diterima / [ ] Ditolak

Tanggal Uji : 21 Okt 2025

Nama Penguji (User) : Dian

Keterangan Tambahan :

Berfungsi dgn baik u/ memprediksi harga minyak goreng

Tanda Tangan:

Scanned with CamScanner

Gambar L14.7 *Form Uat Sign-Off*

Dian

Dokumen User Acceptance System (UAT)

Pengujian Program Prediksi Harga Minyak Goreng dengan Metode Algoritma *Gradient Boosting* di Pasar Tradisional Indonesia

No	Fitur	Langkah	Hasil yang diharapkan	Status
1.	Masuk ke halaman beranda	Buka aplikasi di browser, klik telusuri, maka akan terlihat tampilan pertama dari aplikasi	Halaman berada ditampilan beranda	✓
S	*Quick Prediction*	Masuk ke halaman beranda, kemudian memilih *dropdown* kabupaten/kota	Sistem menampilkan harga aktual hari terakhir dan juga prediksi untuk hari esok, 7 hari kedepan dan 10 hari kedepan	✓
3.	Peta Persebaran (mode aktual)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode aktual) – mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode predicted)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	✓
5.	Peta Persebaran (mode predicted) - mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil	✓

Scanned with CamScanner

			(q1,q2,q3) dan tabel detail harga terprediksi	
6.	Halaman Tinjauan Tren	Pilih navigasi bagian tinjauan tren	Sistem akan menampilkan halaman tinjauan tren	✓
7.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	✓
8.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	✓
9.	Halaman Prediksi	Pilih navigasi bagian prediksi	Sistem akan menampilkan halaman prediksi	✓
10.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	Sistem menampilkan pilihan dropdown hanya kota bogor	✓
11.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	✓
12.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	✓
13.	Prediksi (tidak mengisi tanggal	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range	Sistem akan menampilkan tampilan tulisan untuk	✓

Scanned with CamScanner

	mulai dan akhir)	waktu (tanggal mulai, dan tanggal akhir)	mengisi tanggal mulai dan akhir	
14	Download CSV template upload data	Pilih navigasi bagian upload kemudian klik button CSV	Sistem akan melakukan pengunduhan pada file template dengan format csv	✓
15.	Download XLSX template upload data	Pilih navigasi bagian upload kemudian klik button Excel	Sistem akan melakukan pengunduhan pada file template dengan format .xlsx	✓
16	Masuk ke halaman unggah file	Pilih navigasi bagian Unggah File	Sistem akan menampilkan halaman Unggah File	✓
17.	Unggah file	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis	Sistem akan melakukan training dan pembuatan model serta menampilkan analisa grafik dan prediksi harga, serta akan muncul button download	✓
18.	Download hasil analisa	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis, kemudian muncul button download hasil analisa	Sistem akan melakukan pengunduhan file pdf hasil analisa dan prediksi harga	✓
19.	Halaman tentang	Pilih navigasi bagian tentang	Sistem menampilkan halaman tentang	✓

Scanned with CamScanner

FORM UAT SIGN-OFF

Dengan ini kami menyatakan bahwa hasil pengujian *User Acceptance Testing* (UAT) terhadap system Program Prediksi Harga Minyak di Pasar Tradisional Indonesia dengan Menggunakan Metode Algoritma *Gradient Boosting* telah dilakukan dan hasilnya sebagai berikut:

Status:

[✓] Diterima / [ ] Ditolak

Tanggal Uji : 22-OKT-2025

Nama Penguji (User) : SUN-HAY.S

Keterangan Tambahan :

Tanda Tangan:

Scanned with CamScanner

Gambar L14.8 *Form Uat Sign-Off*

Dokumen User Acceptance System (UAT)

Pengujian Program Prediksi Harga Minyak Goreng dengan Metode Algoritma *Gradient Boosting* di Pasar Tradisional Indonesia

No	Fitur	Langkah	Hasil yang diharapkan	Status
1.	Masuk ke halaman beranda	Buka aplikasi di browser, klik telusuri, maka akan terlihat tampilan pertama dari aplikasi	Halaman berada ditampilan beranda	✓
S	*Quick Prediction*	Masuk ke halaman beranda, kemudian memilih *dropdown* kabupaten/kota	Sistem menampilkan harga aktual hari terakhir dan juga prediksi untuk hari esok, 7 hari kedepan dan 10 hari kedepan	✓
3.	Peta Persebaran (mode aktual)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode aktual) – mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode predicted)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	✓
5.	Peta Persebaran (mode predicted) - mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil	✓

Scanned with CamScanner

			(q1,q2,q3) dan tabel detail harga terprediksi	
6.	Halaman Tinjauan Tren	Pilih navigasi bagian tinjauan tren	Sistem akan menampilkan halaman tinjauan tren	✓
7.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	✓
8.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	✓
9.	Halaman Prediksi	Pilih navigasi bagian prediksi	Sistem akan menampilkan halaman prediksi	✓
10.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	Sistem menampilkan pilihan dropdown hanya kota bogor	✓
11.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	✓
12.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	✓
13.	Prediksi (tidak mengisi tanggal	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, isi range	Sistem akan menampilkan tampilan tulisan untuk	✓

CS Scanned with CamScanner

	mulai dan akhir)	waktu (tanggal mulai, dan tanggal akhir)	mengisi tanggal mulai dan akhir	
14	Download CSV template upload data	Pilih navigasi bagian upload kemudian klik button CSV	Sistem akan melakukan pengunduhan pada file template dengan format csv	✓
15.	Download XLSX template upload data	Pilih navigasi bagian upload kemudian klik button Excel	Sistem akan melakukan pengunduhan pada file template dengan format .xlsx	✓
16	Masuk ke halaman unggah file	Pilih navigasi bagian Unggah File	Sistem akan menampilkan halaman Unggah File	✓
17.	Unggah file	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis	Sistem akan melakukan training dan pembuatan model serta menampilkan analisa grafik dan prediksi harga, serta akan muncul button download	✓
18.	Download hasil analisa	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis, kemudian muncul button download hasil analisa	Sistem akan melakukan pengunduhan file pdf hasil analisa dan prediksi harga	✓
19.	Halaman tentang	Pilih navigasi bagian tentang	Sistem menampilkan halaman tentang	✓

Scanned with CamScanner

FORM UAT SIGN-OFF

Dengan ini kami menyatakan bahwa hasil pengujian *User Acceptance Testing* (UAT) terhadap system Program Prediksi Harga Minyak di Pasar Tradisional Indonesia dengan Menggunakan Metode Algoritma *Gradient Boosting* telah dilakukan dan hasilnya sebagai berikut:

Status:

[✓] Diterima / [ ] Ditolak

Tanggal Uji : 22 - Oktober

Nama Penguji (User) : putri

Keterangan Tambahan :

Aplikasi sudah berfungsi dengan baik dan lulus semua pernyataan pengujian

Tanda Tangan:

Scanned with CamScanner

Gambar L14.9 *Form Uat Sign-Off*

putri

Dokumen User Acceptance System (UAT)

Pengujian Program Prediksi Harga Minyak Goreng dengan Metode Algoritma *Gradient Boosting* di Pasar Tradisional Indonesia

No	Fitur	Langkah	Hasil yang diharapkan	Status
1.	Masuk ke halaman beranda	Buka aplikasi di browser, klik telusuri, maka akan terlihat tampilan pertama dari aplikasi	Halaman berada ditampilan beranda	✓
S	*Quick Prediction*	Masuk ke halaman beranda, kemudian memilih *dropdown* kabupaten/kota	Sistem menampilkan harga aktual hari terakhir dan juga prediksi untuk hari esok, 7 hari kedepan dan 10 hari kedepan	✓
3.	Peta Persebaran (mode aktual)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode aktual) – mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga aktual	✓
4.	Peta Persebaran (mode predicted)	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi keseluruhan peta yang telah diwarnai berdasarkan quartil (q1,q2,q3) dan tabel detail harga terprediksi	✓
5.	Peta Persebaran (mode predicted) - mapping peta per pulau	Masuk ke halaman beranda, kemudian cari tampilan peta persebaran kemudian pilih mode, pulau, tahun, bulan, dan minggu	Sistem menampilkan peta yang berisi hanya pulau Jawa yang telah diwarnai berdasarkan quartil	✓

Scanned with CamScanner

			(q1,q2,q3) dan tabel detail harga terprediksi	
6.	Halaman Tinjauan Tren	Pilih navigasi bagian tinjauan tren	Sistem akan menampilkan halaman tinjauan tren	✓
7.	Tinjauan tren (2 kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1 dan 2, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik perbandingan Kota 1 (Banyuwangi), Kota 2 (Bulukomba) di minggu ke 2 bulan Januari 2021, dan juga grafik perbandingan harga Kota 1 dan Kota 2	✓
8.	Tinjauan Tren (1 Kota)	Pilih Navigasi bagian Tinjjauan tren, Pilih Dropdown Kab/Kota 1, piih Tahun, minggu, bulan dan minggu ke-	Sistem hanya menampilkan grafik Kota 1 (Banyuwangi) di minggu ke 2 bulan Januari 2021	✓
9.	Halaman Prediksi	Pilih navigasi bagian prediksi	Sistem akan menampilkan halaman prediksi	✓
10.	Search kota di halaman Prediksi	Pilih Navigasi bagian prediksi, ketik kota yang ingin dicari	Sistem menampilkan pilihan dropdown hanya kota bogor	✓
11.	Prediksi mode test Sesuai waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, Isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan grafik perbandingan harga aktual (Sebenarnya) dan harga terprediksi dari Kota Bogor di periode waktu 1 Juli 2024 – 1 Juli 2025	✓
12.	Prediksi mode test Lewat dari waktu data latih	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, Isi range waktu (tanggal mulai, dan tanggal akhir)	Sistem akan menampilkan popup (validasi) bahwa mode test melebihi range waktu cutoff yang seharusnya hanya sampai 1 Juli 2025	✓
13.	Prediksi (tidak mengisi tanggal	Pilih Navigasi bagian Prediksi, pilih Kabupaten/Kota, dan mode Test, Isi range	Sistem akan menampilkan tampilan tulisan untuk	✓

CS Scanned with CamScanner

	mulai dan akhir)	waktu (tanggal mulai, dan tanggal akhir)	mengisi tanggal mulai dan akhir	
14	Download CSV template upload data	Pilih navigasi bagian upload kemudian klik button CSV	Sistem akan melakukan pengunduhan pada file template dengan format csv	✓
15.	Download XLSX template upload data	Pilih navigasi bagian upload kemudian klik button Excel	Sistem akan melakukan pengunduhan pada file template dengan format .xlsx	✓
16	Masuk ke halaman unggah file	Pilih navigasi bagian Unggah File	Sistem akan menampilkan halaman Unggah File	✓
17.	Unggah file	Klik button unggah file di halaman upload kemudian *kirim file template* harga yang telah terisi, dan klik button simpan dan analisis	Sistem akan melakukan training dan pembuatan model serta menampilkan analisa grafik dan prediksi harga, serta akan muncul button download	✓
18.	Download hasil analisa	Klik button unggah file di halaman upload kemudian kirim file template harga yang telah terisi, dan klik button simpan dan analisis, kemudian muncul button download hasil analisa	Sistem akan melakukan pengunduhan file pdf hasil analisa dan prediksi harga	✓
19.	Halaman tentang	Pilih navigasi bagian tentang	Sistem menampilkan halaman tentang	✓

Scanned with CamScanner

LAMPIRAN 15

NILAI VOLATILITAS SETIAP KOTA

Nama Kota	2020	2021	2022	2023	2024	2025	Train Period	Test Period	selisih	ABS(Selisih)
Kota Bau - Bau	1.59	8.38	33.08	1.69	1.64	3.79	30.86	4.83	26.03	26.03
Kota Kendari	1.66	8.27	30.24	1.1	1.35	0.67	25.99	2.5	23.49	23.49
Kab. Polewali Mandar	1.44	6.15	10.73	0.22	1.43	0	22.07	0	22.07	22.07
Kab. Merauke	0.68	7.86	15	1.56	1.47	1.94	20.59	2.28	18.31	18.31
Kota Sorong	17.1	9.83	12.29	5.09	1.61	2.77	21.1	3.15	17.95	17.95
Kab. Manokwari	1.19	8.88	14.9	1.43	4.96	1.98	21.38	3.46	17.92	17.92
Kota Palembang	1.19	8.88	14.9	1.43	4.96	5.87	21.38	3.46	17.92	17.92
Kab. Sintang	0	11.89	10.38	2.67	1.19	0.87	18.27	0.87	17.4	17.4
Kota Ternate	3.12	3.74	9.39	2.03	0.95	1.42	18.14	1.98	16.16	16.16
Kota Gorontalo	5.52	13.75	12.67	4.06	2.99	1.17	19.39	3.44	15.95	15.95
Kota Maumere	1.73	7.33	9.38	1.06	1.5	2.47	16.7	1.69	15.01	15.01
Kota Tarakan	2.15	8.44	7.74	1.1	2.22	0.63	16.66	1.8	14.86	14.86
Kota Palangkaraya	2.02	9.51	9.75	2.1	1.18	1.53	17.03	2.43	14.6	14.6
Kota Sampit	1.91	8	8.7	3.87	1.75	0.64	16.02	1.66	14.36	14.36
Kota Tual	0.48	9.21	12.66	1.75	0.75	2.6	17.69	3.47	14.22	14.22
Kota Makassar	2.02	9.69	6.55	4.18	2.76	1.12	17.08	2.87	14.21	14.21
Kota Samarinda	5.66	6.7	16.35	2.59	2.58	0.94	17.66	3.56	14.1	14.1
Kota Madiun	2.73	13.44	12.18	1.24	1.56	0.34	17.48	3.49	13.99	13.99
Kab. Sumba Timur	0	9.34	13.37	3.56	2.86	5.28	17.87	4.13	13.74	13.74
Kab Kotabaru	0.21	8.05	13.64	1.48	1.88	1.28	16.43	2.79	13.64	13.64
Kota Padang Sidempuan	3.66	9.54	10.09	0.62	2.05	0	15.34	1.74	13.6	13.6
Kab. Mimika	0.32	6.43	14.01	4.28	1.7	2.75	16.02	2.64	13.38	13.38
Kota Pangkalpinang	5.32	11.45	8.81	1.58	3.72	3.13	17.22	4.01	13.21	13.21
Kab. Wonogiri	5.32	11.45	8.81	1.58	3.72	2.79	17.22	4.01	13.21	13.21
Kab.Klaten	4.5	6.41	12.07	3.13	2.75	1.3	16.02	2.81	13.21	13.21
Kota Mamuju	2.1	9.97	17.22	3.07	4.55	1.31	17.44	4.25	13.19	13.19
Kota Mataram	2.37	10.01	8.86	1.15	1.89	1.11	15.03	1.84	13.19	13.19
Kota Palu	1.77	10.02	14.57	1.96	2.71	2.26	16.32	3.22	13.1	13.1
Kota Denpasar	2.16	9.23	4.83	2.83	1.62	1.62	16.95	4.06	12.89	12.89
Kab Sragen	2.29	9.84	12.49	1.63	3.2	1.08	16.57	3.69	12.88	12.88
Kab. Bulungan	4.79	10.13	13.67	7.45	3.25	2.06	15.15	2.33	12.82	12.82
Kota Kupang	2.6	5.83	14.28	2.21	1.36	2.95	14.87	2.15	12.72	12.72
Kota Jambi	3.68	10.08	10.57	0.55	3.6	1.3	16.81	4.13	12.68	12.68
Kota Maluku	2.47	7.18	11.63	2.67	2.04	0.5	16.48	3.82	12.66	12.66
Kota Serang	3.9	11.17	8.22	2.42	3.14	1.61	15.51	3.07	12.44	12.44

Kota Watampone	0.3	11.06	5.48	2.51	2.26	1	15.54	3.17	12.37	12.37
Kota Banjarmasin	3.41	8.58	6.57	1.02	1.49	4.26	16.65	4.32	12.33	12.33
Kota Surakarta (Solo)	2.99	11.74	11.92	2.12	4.2	1.95	15.82	3.58	12.24	12.24
Kab. Sumbawa	3.21	6.11	11.37	1.2	2.67	0.89	14.81	2.59	12.22	12.22
Kota Pontianak	4.6	11.03	15.62	3.97	3.81	0.82	15.87	3.68	12.19	12.19
Kota Blitar	2.72	9.37	7.59	0.88	0.36	3.79	14.61	2.42	12.19	12.19
Kab. Bulukomba	1.82	10.49	11.88	2.91	3.11	1.7	15.33	3.18	12.15	12.15
Kab. Majene	3.52	11.58	19.17	1.9	4.9	1.06	16.85	4.74	12.11	12.11
Kota Medan	3.13	9.53	6.45	2.94	3.33	1.09	15.41	3.38	12.03	12.03
Kota Surabaya	3.03	10.58	10.63	1.69	1.84	0.9	16.65	4.71	11.94	11.94
Kab. Banyuwangi	5.19	10.98	12.81	0.89	1.78	1.57	15.97	4.16	11.81	11.81
Kota Singkawang	2.76	9.49	9.35	3.37	3.45	0.53	14.66	2.99	11.67	11.67
Kota Meulaboh	2.25	9.58	7.72	2.48	3.43	0.8	15.52	3.85	11.67	11.67
Kota Lubuk Linggau	3.04	13.74	10.85	0.66	3.09	1.29	15.99	4.42	11.57	11.57
Kota Bima	1.28	6.81	13.96	3.42	3.9	1.02	16.6	5.04	11.56	11.56
Kota Tanggerang	5.15	10.13	10.99	0.77	3.7	1.46	13.84	2.36	11.48	11.48
Kab. Boyolali	3.88	12.08	13.42	3.33	4.42	2.53	15.67	4.19	11.48	11.48
Kota Probolinggo	4.18	12.8	11.26	1.75	4.16	1.05	15.72	4.25	11.47	11.47
Kota Bengkulu	2.34	10.6	14.47	4.36	3.08	1.09	15.98	4.54	11.44	11.44
Kota Tasikmalaya	3.73	10.08	11.53	1.71	4.12	0.99	15.9	4.49	11.41	11.41
Kota Pekanbaru	3.92	10.71	14.6	2.34	2.88	2.52	15.41	4.01	11.4	11.4
Kab. Bungo	3.73	10.18	11.73	1.37	4.09	0.54	16.64	5.3	11.34	11.34
Kota Balikpapan	10.58	8.08	1.86	3.55	0.57	2.44	11.29	0	11.29	11.29
Kota Banda Aceh	10.58	8.08	1.86	3.55	0.57	0	11.29	0	11.29	11.29
Kota Cilegon	4.64	9.96	9.94	3.08	3.62	1.67	14.62	3.38	11.24	11.24
Kota Pare -Pare	3.8	9.31	10.55	2.14	2.35	1.9	14.29	3.08	11.21	11.21
Kota Malang	2.88	11.25	12.42	1.84	3.81	1.68	17.46	6.33	11.13	11.13
Kota Tanjung Pandan	1.99	17.32	18.92	3.34	3.64	1.37	16.83	5.75	11.08	11.08
Kota Tanjung Pinang	1.99	17.32	18.92	3.34	3.64	2.25	16.83	5.75	11.08	11.08
Kab. Sukoharjo	3.57	12.03	12.4	1.21	4.3	2.12	16.98	6.02	10.96	10.96
Kota Semarang	3.95	11.27	12.24	5.23	4.03	1.15	15.77	4.86	10.91	10.91
Kota Kediri	3.27	10.39	12.7	1.34	3.65	0.6	15.55	4.65	10.9	10.9
Kota Sumenep	3.27	10.39	12.7	1.34	3.65	0.71	15.55	4.65	10.9	10.9
Kab. Banyumas	2.56	11.1	10.36	2.41	4.76	1.05	15.34	4.45	10.89	10.89
Kota Pematang Siantar	3.73	9.91	7.15	3.28	2.93	1.52	14.28	3.47	10.81	10.81
Kota Gunung Sitoli	0	8.17	6.85	3.69	2.74	0.44	14.98	4.32	10.66	10.66
Kota Bontang	1.6	9.04	11.4	2.74	1.99	2.15	14.9	4.25	10.65	10.65
Kota Tanjung	3.03	9.24	4.04	0.73	1.63	2.08	14.1	3.52	10.58	10.58
Kota Bandung	3.81	10.58	11.9	0.81	3.19	0.62	14.9	4.33	10.57	10.57
Kab. Karanganyar	4.3	11.47	11.48	2.16	4.39	1.3	15.98	5.42	10.56	10.56
Kota Jakarta Pusat	3.55	10.08	8.37	2.39	3.23	0.76	14.32	3.77	10.55	10.55
Kota Batam	1.71	12.48	17.04	2.38	6.28	0.62	16.41	5.87	10.54	10.54

Kota Bekasi	3.69	9.85	9.78	3.67	4.05	0.93	16.29	5.78	10.51	10.51
Kab. Cilacap	3.99	10.51	12.36	2.58	4.03	1.22	15.51	5.04	10.47	10.47
Kota Cirebon	3.71	10.36	12.5	0.46	2.08	1.59	14.53	4.06	10.47	10.47
Kab. Jember	4.65	11.09	12.11	2.78	4.52	1.69	15.28	5.03	10.25	10.25
Kota Sukabumi	4.3	11.16	13.94	1.5	5.17	0.95	15.9	5.68	10.22	10.22
Kota Bogor	3.42	10.35	11.04	0.64	3.24	1.05	15.34	5.12	10.22	10.22
Kab. Cirebon	3.83	10.17	11.82	0.77	3.35	1.59	14.77	4.61	10.16	10.16
Kota Padang	3.59	10.9	13.22	3.37	4.17	0.77	14.11	4.41	9.7	9.7
Kota Dumai	3.04	9.81	9.7	1	2.21	2.21	14.59	4.91	9.68	9.68
Kab. Sumenep	4.05	9.44	13.39	3.26	2.51	0.89	15.38	5.72	9.66	9.66
Kota Manado	2.04	5.86	8	6.45	2.59	1.04	11.76	2.13	9.63	9.63
Kab. Kudus	9.63	10.28	11.35	5.12	4.64	1.5	16.34	6.75	9.59	9.59
Kota Lhokseumawe	2.51	10.19	10.93	3.33	4.37	0.56	13.82	4.39	9.43	9.43
Kota Depok	3.35	9.76	11.1	0.87	3.37	0.86	14.74	5.38	9.36	9.36
Kab. Lombok Timur	3.43	9.76	10.58	2.32	2.7	2.32	16.76	7.66	9.1	9.1
Kota Metro	4.4	10.65	9.07	2.35	6.41	2.23	16.41	7.82	8.59	8.59
Kota Sibolga	3.2	10.87	11.15	2.47	4.94	1.8	13.22	4.78	8.44	8.44
Kota Tembilahan	1.88	11.56	10.92	6.57	7.78	2.39	14.46	7.75	6.71	6.71
Kotamobagu	0	4.1	7.83	6.04	5.26	0.63	7.25	4.15	3.1	3.1
Kota Yogyakarta	0	4.1	7.83	6.04	5.26	1.73	7.25	4.15	3.1	3.1
Kota Banggai	0	0	0.55	2.28	2.51	2.62	5.11	3.67	1.44	1.44
Kab. Gorontalo	0	0	0	0	4.1	1.2	3.81	3.51	0.3	0.3
Kab. Jayawijaya	0	0	0	0	0	1.55	0.56	1.17	-0.61	0.61
Kab. Nabire	0	0	0	0	0	5.84	0.81	1.82	-1.01	1.01
Kota Bandar Lampung	0.21	0.67	0.93	0.07	0.35	15.66	9.23	17.21	-7.98	7.98

LAMPIRAN 16

TURNITIN

turnitin Page 2 of 282 - Integrity Overview Submission ID trn:oid:::12772:526408738

8% Overall Similarity

The combined total of all matches, including overlapping sources, for each database.

Filtered from the Report

- Bibliography

Top Sources

5% Internet sources
2% Publications
6% Submitted works (Student Papers)

Integrity Flags

0 Integrity Flags for Review

Our system's algorithms look deeply at a document for any inconsistencies that would set it apart from a normal submission. If we notice something strange, we flag it for you to review.

A Flag is not necessarily an indicator of a problem. However, we'd recommend you focus your attention there for further review.

turnitin Page 2 of 282 - Integrity Overview Submission ID trn:oid:::12772:526408738

LAMPIRAN 17

GITHUB

Sumber kode program mengenai perancangan aplikasi Prediksi Harga Minyak Goreng di Pasar Tradisional Indonesia Menggunakan Metode *Gradient Boosting* dapat diakses melalui tautan https://github.com/carinn123/skripsi_carin2025y/

DAFTAR RIWAYAT HIDUP

Nama	: Carin Gunawan
NPM	: 535210056
Tempat/Tanggal Lahir	: Jakarta, 26 April 2004
Alamat	: Jl. Golf Lake Residence Atlantic City 7 No 9, Jakarta Barat, DKI Jakarta, 11730.
No. Telpon/HP	: 082124057449
Alamat Email	: carin.53520056@stu.untar.ac.id

Riwayat Pendidikan

1. SD Pelita Anuerah, Jalan. Jl. Menceng Raya No.12-13 E3, RT.7/RW.6, Tegal Alur, Kec. Kalideres, Kota Jakarta Barat, Daerah Khusus Ibukota Jakarta 11820, 2010-2016
2. SMP Pelita Anugerah, Jl. Menceng Raya No.12-13 E3, RT.7/RW.6, Tegal Alur, Kec. Kalideres, Kota Jakarta Barat, Daerah Khusus Ibukota Jakarta 11820, 2016-2019
3. SMA Kasih Kemuliaan, Jalan. Perum Taman Surya V Blok RR No 1, Pegadungan, Kecamatan Kalideres, Kota Jakarta Barat, Daerah Khusus Ibukota Jakarta, 2019 – 2022.
4. Program Studi Teknik Informatika Fakultas Teknologi Informasi Universitas Tarumanagara, Jalan. Letjen S. Parman No.1, RT.6/RW.16, Tomang, Kecamatan Grogol Petamburan, Kota Jakarta Barat, Daerah Khusus Ibukota Jakarta 11440, 2022 – 2026.